Equations différentielles

UE11, Maths 2
Mines Paris - PSL

Pauline Bernard*

21 octobre 2026

*Ce document est un des produits du projet `paulinebernard/CDIS` issu de la collaboration de Pauline Bernard (CAS), Thomas Romary et Mike Perreira (GEOSCIENCES). Il est mis à disposition selon les termes de la licence Creative Commons “attribution – pas d’utilisation commerciale – partage dans les mêmes conditions” 4.0 internationale.

Table des matières

I. Etude théorique des solutions **5**

1. Un peu d'histoire **6**

2. Objectifs du cours **6**

3. Cadre de l'étude **7**
Solution d'une équation différentielle . . . 9
Problème de Cauchy (*Initial Value Problem*) . . . 9
Représentation intégrale des solutions . . . 10
Classe plus générale de solutions . . . 10

4. Etude du problème de Cauchy **11**
4.1. Existence de solutions locales . . . 11
Théorème de Peano-Arzelà . . . 11
Classe plus générale de solutions (pour la culture) . . . 11
4.2. Domaine d'existence des solutions . . . 12
Solution maximale . . . 12
Domaine maximal d'existence . . . 13
Critère d'existence globale . . . 14
4.3. Unicité des solutions maximales . . . 15
Théorème de Cauchy-Lipschitz (ou de Picard-Lindelöf) . . . 16
Relâchement à f localement lipschitzienne . . . 18
Approximations successives . . . 18

5. Régularité et stabilité des solutions **19**
5.1. Sensibilité aux conditions initiales et erreurs de modèle . . . 20
Régularité en temps fini . . . 20
Chaos déterministe et horizon de Lyapunov . . . 21
5.2. Propriétés asymptotiques . . . 23
Point d'équilibre . . . 23
Attractivité . . . 24
Stabilité, stabilité asymptotique . . . 24
Robustesse vis-à-vis des perturbations (pour la culture) . . . 25
Stabilité asymptotique d'un système linéaire stationnaire . . . 25
Critère de stabilité linéaire (pour la culture) . . . 26
Lien entre stabilité et stabilité du linéarisé tangent . . . 27
Stabilité par décroissance d'une fonction définie positive . . . 28
Fonctions et critères de Lyapunov . . . 29
Lemme de Barbalat . . . 29

6. Exercices complémentaires **30**
6.1. Ecoulement dans un réservoir (+) . . . 31
6.2. Autour du Lemme de Grönwall . . . 31
6.3. Cycle limite I (+) . . . 32
6.4. Critères de stabilité de Lyapunov . . . 32

6.5. Critères d'instabilité . . . 33
6.6. Cycle limite II (+) . . . 33
6.7. Attractivité locale implique stabilité asymptotique globale pour un système linéaire 35
6.8. Stabilisation d'une chaîne d'intégrateurs . . . 35
6.9. Problème de Kepler : collision, libération et orbites circulaires (••) . . . 35

7. Annexes **37**
7.1. Preuve du théorème de Peano-Arzelà (Hors-programme) . . . 37
7.2. Preuve du théorème du domaine maximal d'existence . . . 38

8. Références **40**

II. Simulation numérique des solutions **41**

1. Introduction **42**

2. Objectifs du cours **43**

3. Limites du schéma d'Euler **43**
3.1. Systèmes raides . . . 43
3.2. Systèmes hamiltoniens . . . 44

4. Méthodes à un pas **45**
4.1. Principe . . . 45
4.2. Exemples . . . 47
4.3. Définition implicite de Φ . . . 48

5. Analyse d'erreur **49**
5.1. Erreur de troncature locale . . . 49
Consistance . . . 49
Condition nécessaire et suffisante de consistance . . . 50
Condition nécessaire et suffisante de consistance d'ordre $\geq p$ . . . 52
5.2. Stabilité . . . 53
Stabilité . . . 53
Condition suffisante de stabilité . . . 53
5.3. Convergence . . . 54
Convergence . . . 54
Théorème de Lax . . . 54
Condition suffisante de convergence . . . 54
5.4. Erreurs d'arrondi et pas optimal . . . 55

6. Annexe – Choix du pas de temps **57**
6.1. Pas fixe . . . 57
6.2. Adaptation du pas de temps . . . 58

7. Exercices **59**
7.1. Consistance et ordre de schémas . . . 59
7.2. Convergence de schémas . . . 60
7.3. Explicite ou implicite ? . . . 60
7.4. Euler symplectique . . . 61

8. Références **62**

III. Corrections des exercices 63

1. Etude théorique des solutions **64**
1.1. Exercices essentiels 64
1.2. Ecoulement dans un réservoir 68
1.3. Autour du Lemme de Grönwall 69
1.4. Cycle limite I 71
1.5. Critères de stabilité de Lyapunov 72
1.6. Critères d'instabilité 75
1.7. Cycle limite II 77
1.8. Attractivité locale implique stabilité asymptotique globale pour un système linéaire 80
1.9. Stabilisation d'une chaîne d'intégrateurs 81
1.10. Problème de Kepler : collision, libération et orbites circulaires 82

2. Simulation numérique des solutions **85**
2.1. Consistance et ordre de schémas 85
2.2. Convergence de schémas 88
2.3. Explicite ou implicite ? 88
2.4. Euler symplectique 91

Première partie

Etude théorique des solutions

1. Un peu d'histoire

L'étude des équations différentielles remonte au XVIIe siècle lors de la découverte du calcul infinitésimal et de la modélisation du mouvement par Kepler et Newton. Avec Leibniz, leur premier réflexe est alors de chercher à résoudre ces équations de manière exacte, par exemple par des primitives de fonctions connues ou bien sous forme de série, mais ces méthodes atteignent vite leurs limites, sauf dans des cas très particuliers.

Alors que l'idée d'approximer les solutions apparaît au milieu du XVIIIe siècle avec Euler, on cherche ensuite plutôt à caractériser leurs propriétés sans les connaître explicitement. Cauchy, et parallèlement Lipschitz, démontrent les premiers, au milieu du XIXe siècle, l'existence et l'unicité des solutions sous des hypothèses de régularités de l'équation différentielle. Laplace, qui s'intéresse alors à la mécanique céleste, s'émerveille devant la capacité de l'Homme à prédire l'évolution du monde physique. C'est l'avènement du *déterminisme* c'est-à-dire la certitude que l'état du monde futur (ou passé) peut être prédit de manière unique par la connaissance de l'état initial.

Cependant, à la fin du XIXe siècle, les travaux de Poincaré et de ses contemporains mettent en évidence les limites de ce déterminisme. Le constat que le modèle physique n'est jamais exactement connu, ni sa condition initiale, amène les scientifiques à étudier la sensibilité des solutions à ces erreurs. Une sensibilité extrême chez certains systèmes rend leur simulation impossible sur des temps longs et mène à la théorie du *chaos* qui occupera les scientifiques durant une grande partie du XXe siècle.

En parallèle, l'étude de la stabilité et du comportement asymptotique des solutions intéresse dès le XIXe siècle, d'abord dans le cas des systèmes linéaires avec des mathématiciens comme Routh, Hurwitz, etc. Mais c'est finalement la thèse de Lyapunov à la fin du XIXe siècle qui lance la théorie générale de la stabilité des systèmes non linéaires qui sera ensuite étayée tout au long des XXe et XXIe siècles.

2. Objectifs du cours

Ce cours est une introduction à l'étude non linéaire des équations différentielles. Pour une étude plus complète voir par exemple (Hale 2009). En première lecture, les objectifs "opérationnels" sont les suivants :

- savoir réduire une équation différentielle à l'ordre 1.
- savoir justifier l'existence de solutions par le théorème de Peano lorsque "f est continue".
- comprendre la notion de solution maximale et savoir qu'elles sont définies tant qu'elles "n'explosent" pas et tant qu'elles n'atteignent pas la frontière du domaine où l'équation différentielle est définie. Savoir justifier qu'une solution est définie sur tout l'intervalle de temps $\mathbb{R}$ si ces éventualités ne peuvent se réaliser en temps fini et/ou en faisant appel au critère "linéairement borné".
- savoir justifier l'unicité des solutions maximales par le théorème de Cauchy-Lipschitz lorsque "f est continûment différentiable par rapport à x".
- comprendre (qualitativement) dans quelle mesure une erreur sur la condition initiale se répercute sur les solutions en temps fini.

- savoir trouver les points d'équilibre.
- savoir déterminer si un système linéaire est globalement asymptotiquement stable en regardant le signe de la partie réelle de ses valeurs propres.
- savoir déterminer si un point d'équilibre est localement asymptotiquement stable/instable par les valeurs propres de la matrice Jacobienne associée.
- savoir montrer la stabilité d'un point d'équilibre par la décroissance d'une fonction définie positive.
- savoir montrer la bornitude des solutions en temps positif lorsque cette fonction décroissante est propre.
- savoir étudier la convergence des solutions vers un point d'équilibre par l'application répétée du lemme de Barbalat.

En deuxième lecture :

- comprendre la preuve du théorème de Cauchy-Lipschitz en voyant la solution comme un point fixe de la représentation intégrale des solutions.
- savoir que l'on peut relâcher l'hypothèse du théorème de Cauchy-Lipschitz à "f lipschitzienne par rapport à x".
- comprendre ce qu'est un système chaotique et ce que représente son exposant de Lyapunov.
- comprendre ce que la notion de stabilité apporte en plus de l'attractivité dans la notion de stabilité asymptotique.
- connaître, comprendre et savoir appliquer les critères de stabilité de Lyapunov.

Notations

- $B(x, r)$: boule ouverte centrée en x et de rayon r.
- $B_f(x, r)$: boule fermée centrée en x et de rayon r.
- Pour $x : I \subset \mathbb{R} \to \mathbb{R}^n$, $\dot{x}(t) = \frac{dx}{dt}(t)$ et $\ddot{x}(t) = \frac{d^2x}{dt^2}(t)$.

3. Cadre de l'étude

Les équations différentielles apparaissent couramment en physique pour décrire l'évolution des grandeurs décrivant le système. Quelques exemples:

- La tension u_c aux bornes d'un condensateur dans un circuit RLC en série évolue selon

$$\ddot{u}_c = -\frac{R}{L}\dot{u}_c - \frac{1}{LC}u_c + u(t)$$

où R, L, C notent la résistance, inductance et capacité respectivement, et u la tension appliquée par le générateur. Cette équation différentielle implique les dérivées de u_c jusqu'à l'ordre 2, donc on parle d'équation différentielle d'ordre 2.

- En cinétique chimique, les concentrations des espèces chimiques intervenant dans une réaction
$$A + B \underset{k'}{\overset{k}{\leftrightarrows}} C$$
sont régies par une équation différentielle d'ordre 1 donnée par
$$\begin{aligned}\dot{c}_A &= -k\, c_A c_B + k' c_C \\ \dot{c}_B &= -k\, c_A c_B + k' c_C \\ \dot{c}_C &= k\, c_A c_B - k' c_C\end{aligned}$$
avec k, k' les constantes de réaction. Cette équation différentielle n'a pas de terme extérieur variant avec le temps. On dit qu'elle est *autonome*.
- La mécanique Newtonienne ou Lagrangienne amène typiquement à des équations du type
$$M\ddot{q} = \sum_k F_k(t, q, \dot{q})$$
où $q \in \mathbb{R}^n$ modélise la position du système (spatiale, angulaire, etc), $\dot{q}$ sa vitesse et $\ddot{q}$ son accélération, avec M la matrice d'inertie, et F_k les forces/couples agissant sur le système. Ici il s'agit d'une équation différentielle d'ordre 2.

Dans tous ces cas, on s'intéresse aux signaux du temps $t \mapsto y(t)$ de classe C^p qui vérifient une équation du type
$$y^{(p)}(t) = \psi\left(t, y(t), \dot{y}(t), \ldots, y^{(p-1)}(t)\right)$$
sur son ensemble de définition, où $p \in \mathbb{N}^*$ désigne l'ordre de l'équation différentielle. En fait, on se rend compte que y de classe C^p vérifie l'équation différentielle ci-dessus si et seulement si $x = (y, \dot{y}, \ldots, y^{(p-1)})$ de classe C^1 vérifie
$$\dot{x} = f(t, x)\ ,$$
où f est définie par
$$f(t, y_0, y_1, \ldots, y_{p-1}) = (y_1, y_2, \ldots, y_{p-1}, \psi(t, y_0, \ldots, y_{p-1}))\ .$$

Nous déduisons que résoudre une équation différentielle d'ordre p est en fait équivalent à résoudre une équation différentielle d'ordre 1, quitte à considérer comme inconnue la suite des dérivées $x = (y, \dot{y}, \ldots, y^{(p-1)})$ de classe C^1, au lieu de y de classe C^p. x est appelé l'*état* du système.

Exemple – Réduction à l'ordre 1.

Reprenons les exemples plus haut :

- pour un circuit RLC, on prend $x = (u_c, \dot{u}_c) \in \mathbb{R}^2$, et
$$f(t, x_1, x_2) = \begin{bmatrix} x_2 \\ -\frac{R}{L}x_2 - \frac{1}{LC}x_1 + u(t) \end{bmatrix}\ .$$
- en cinétique chimique, $x = (c_A, c_B, c_C) \in \mathbb{R}^3$ et
$$f(t, x_1, x_2, x_3) = \begin{bmatrix} -k\, x_1 x_2 + k' x_3 \\ -k\, x_1 x_2 + k' x_3 \\ k\, x_1 x_2 - k' x_3 \end{bmatrix}$$

- en mécanique, $x = (q, \dot{q})$ et

$$f(t, x_1, x_2) = \begin{bmatrix} x_2 \\ M^{-1} \sum_k F_k(t, x_1, x_2) \end{bmatrix} .$$

Ainsi, même si la physique nous donne initialement une équation différentielle d'ordre supérieur, on pourra toujours se ramener à l'ordre 1. Cette réduction est cruciale pour l'étudier mathématiquement ainsi que numériquement, et devra donc être systématique.

Commençons par définir le cadre de cette étude.

Définition – Solution d'une équation différentielle.

Soient $n \in \mathbb{N}^*$, J ouvert de $\mathbb{R}$, X ouvert de $\mathbb{R}^n$ et $f : J \times X \to \mathbb{R}^n$ une application continue. Une fonction $x : I \to \mathbb{R}^n$ définie sur un intervalle de temps $I \subset J$ non réduit[1] à un point, est dite solution[2] de l'équation différentielle

$$\dot{x} = f(t, x)$$

si x est continue sur I avec $x(t) \in X$ pour tout $t \in I$, et de classe C^1 sur $\mathring{I}$ avec $\dot{x}(t) = f(t, x(t))$ pour tout $t \in \mathring{I}$.

L'équation différentielle est dite *autonome* si l'application f ne dépend pas de t. Dans ce cas, on peut aussi définir directement $f : X \to \mathbb{R}^n$.

Lorsque l'intervalle de temps I de définition de la solution est J entier, on dira que la solution est *globale*. Mais on verra qu'il peut parfois arriver qu'une solution ne puisse être définie sur J entier, par exemple si elle explose avant, ou si elle s'apprête à quitter X.

Notons que f sera souvent définie sur $J \times X = \mathbb{R} \times \mathbb{R}^n$. Cependant, il peut arriver que cela ne soit pas le cas, comme par exemple pour deux corps de position y_a, y_b dont la force d'interaction gravitationnelle $\frac{Gm_a m_b}{\|y_a - y_b\|^2}$ n'est définie que pour $y_a \neq y_b$, où lorsque l'on veut restreindre l'étude des solutions à un domaine particulier.

La physique s'intéresse souvent aux solutions partant d'une *condition initiale* donnée. La recherche et l'étude de ces solutions particulières est due à Cauchy et porte le nom de *Problème de Cauchy* :

> Dans mes leçons données à l'École Polytechnique, comme dans la plupart des ouvrages ou mémoires que j'ai publiés sur le calcul intégral, j'ai cru devoir placer en premier lieu la recherche, non pas des intégrales générales, mais des particulières ; en sorte que la détermination des constantes ou des fonctions arbitraires ne fût plus séparée de la recherche des intégrales.

Définition – Problème de Cauchy (*Initial Value Problem*).

1. Certaines références autorisent les solutions définies sur un intervalle d'intérieur vide, c'est-à-dire réduit à un point, qui sont dites "triviales". Mais cela n'a pas grand intérêt ici et nous supposons donc que les solutions sont définies au moins "pendant un certain temps".

2. On omet de préciser l'intervalle I sur lequel x est solution lorsque I est l'ensemble de définition naturel (ou clairement défini) de x. Lorsque celui-ci est ambigu ou bien lorsque l'on veut insister sur l'intervalle de définition, on dira *solution sur* I.

Soient J ouvert de $\mathbb{R}$, X ouvert de $\mathbb{R}^n$, $(t_0, x_0) \in J \times X$ et $f : J \times X \to \mathbb{R}^n$ continue. Le *problème de Cauchy* associé fait référence au système

$$\dot{x} = f(t, x) \quad , \quad x(t_0) = x_0 \ .$$

On dira donc que $x : I \to \mathbb{R}^n$ est solution du problème de Cauchy défini par f et (t_0, x_0) si

- $t_0 \in I$ et $x(t_0) = x_0$
- x est solution de l'équation différentielle $\dot{x} = f(t, x)$ sur I.

On notera alors $x \in S_f(t_0, x_0)$.

Avant d'étudier les solutions d'un problème de Cauchy, il est crucial de remarquer la caractérisation qui suit.

Théorème – Représentation intégrale des solutions.

Soient J ouvert de $\mathbb{R}$, X ouvert de $\mathbb{R}^n$, $f : J \times X \to \mathbb{R}^n$ continue, $I \subset J$ un intervalle de $\mathbb{R}$ non réduit à un point, $t_0 \in I$, $x_0 \in X$, et $x : I \to \mathbb{R}^n$ continue telle que $x(t) \in X$ pour tout $t \in I$. Alors, x est solution du problème de Cauchy défini par f et (t_0, x_0) si et seulement si x est solution de l'équation intégrale

$$x(t) = x_0 + \int_{t_0}^{t} f(s, x(s))ds \qquad \forall t \in I \ .$$

Notons que cette caractérisation n'aurait pas été possible si l'on avait gardé une équation différentielle d'ordre $p > 1$.

Démonstration. Supposons $x \in S_f(t_0, x_0)$. Alors $x : I \to \mathbb{R}^n$ est de classe C^1 sur $\mathring{I}$, et pour tout $t \in I$,

$$x_0 + \int_{t_0}^{t} f(s, x(s))ds = x(t_0) + \int_{t_0}^{t} \dot{x}(s)ds = x(t) \ .$$

Réciproquement, si x vérifie l'équation intégrale sur $I \subset J$, $x(t_0) = x_0$, et puisque f est continue sur $I \times X$ et x continue sur I, x est de classe C^1 sur I et par dérivation, $\dot{x}(t) = f(t, x(t))$ pour tout $t \in I$. ■

Remarque – Classe plus générale de solutions.

La définition sous forme intégrale des solutions montre que la recherche de solutions C^1 et l'hypothèse de continuité de f pourraient être relâchées : il suffirait de chercher x absolument continue et pouvoir définir l'objet $\int_{t_0}^{t} f(s, x(s))ds$. Mais il est tout de même souhaitable d'assurer un minimum de propriétés telles que l'existence de solutions, comme nous allons le voir dans la section suivante.

Remarque – Portrait de phase.

En dimension 2 (ou 3), il est possible de visualiser géométriquement le comportement des solutions en traçant les courbes paramétriques $t \mapsto (x_1(t), x_2(t))$ dans le plan (ou $t \mapsto$

$(x_1(t), x_2(t), x_3(t))$ dans l'espace) pour différentes conditions initiales. C'est ce que l'on appelle un *portrait de phase*. Voir Figure 3.1 (p. 11) dans le cas d'un pendule.

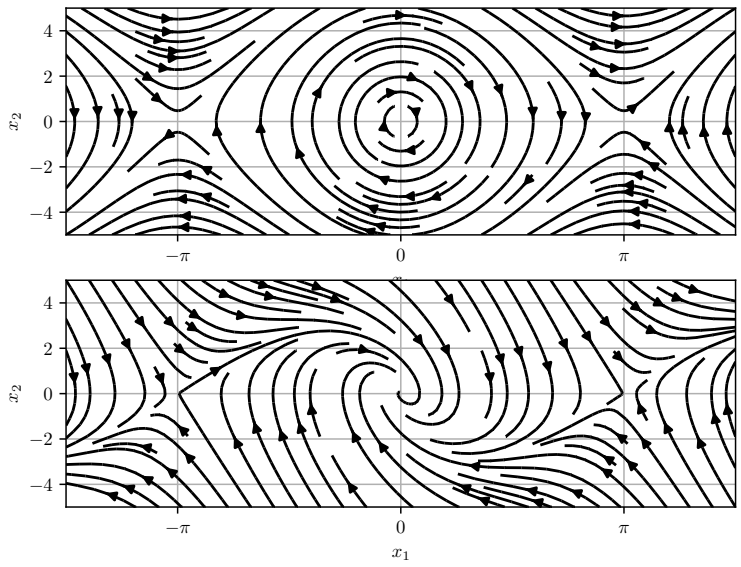


FIGURE 3.1. – Portraits de phase d'un pendule non amorti en haut et amorti en bas. x_1 représente l'angle du pendule en abscisse et x_2 sa vitesse de rotation en ordonnée. Le pendule sera décrit et étudié plus en détail dans la suite du cours.

4. Etude du problème de Cauchy

4.1. Existence de solutions locales

Notre point de départ est le théorème suivant établi à la fin du XIXe siècle, qui assure l'existence locale de solutions au problème de Cauchy (p. 9) sous une simple hypothèse de continuité de f. En d'autres termes, dans le cadre de ce cours où f est supposée continue, il existe toujours des solutions pour toute condition initiale, définies au moins pour un certain temps.

Théorème – Théorème de Peano-Arzelà.

Soient J ouvert de $\mathbb{R}$, X ouvert de $\mathbb{R}^n$, $f : J \times X \to \mathbb{R}^n$ continue. Pour tout $(t_0, x_0) \in J \times X$, il existe $\tau_m > 0$ et $x : [t_0 - \tau_m, t_0 + \tau_m] \to \mathbb{R}^n$ tels que x est solution du problème de Cauchy défini par f et (t_0, x_0).

Démonstration. La démonstration de ce résultat est hors-programme et fait appel au théorème d'Ascoli(-Arzelà). Seule la connaissance et la compréhension du résultat est exigible. Pour les curieux, la preuve est donnée en annexe (p. 37). ■

Remarque – Classe plus générale de solutions (pour la culture).

L'existence de solutions C^1 est garantie lorsque f est continue. Il s'avère que l'existence de solutions *absolument continues*, est garantie sous les hypothèses plus faibles suivantes dans un voisinage de (t_0, x_0) :

- pour tout t, $x \mapsto f(t,x)$ est continue ;
- pour tout x, $t \mapsto f(t,x)$ est mesurable ;
- il existe une fonction intégrable $t \mapsto b(t)$ telle que $|f(t,x)| \leq b(t)$ pour tout (t,x).

Ce sont les conditions de *Carathéodory*. Voir (Hale 2009). Un cadre encore plus général consiste à autoriser des discontinuités de f par rapport à x mais l'étude des solutions passe alors par celle des *inclusions différentielles* du type $\dot{x} \in F(t,x)$, ce qui nous amènerait bien trop loin de ce cours. Voir (Filippov 1988).

4.2. Domaine d'existence des solutions

Nous venons de voir que des solutions locales au problème de Cauchy existent si f est continue. Nous savons qu'elles sont définies *au moins un certain temps*, mais il est intéressant de se demander quel est l'intervalle de temps *maximal* sur lequel elles peuvent être définies. En d'autres termes, on s'intéresse aux *solutions maximales*.

Définition – Solution maximale.

Soient J ouvert de $\mathbb{R}$, X ouvert de $\mathbb{R}^n$, $f : J \times X \to \mathbb{R}^n$ continue. On dit que $x : I \to \mathbb{R}^n$ est une solution *maximale* de l'équation différentielle

$$\dot{x} = f(t,x)$$

si elle n'est pas *prolongeable* en une solution définie plus longtemps dans $J \times X$. En d'autres termes, il n'existe pas de solution $x' : I' \to \mathbb{R}^n$ avec I strictement inclus dans I' et telle que $x = x'$ sur I. On dit alors que I est l'*intervalle maximal d'existence* de la solution.

Il s'avère que l'intervalle maximal de définition I d'une solution maximale n'est pas nécessairement $\mathbb{R}$ entier même si f est définie globalement sur $\mathbb{R} \times \mathbb{R}^n$ et f est de classe C^∞.

Exemple – Explosion en temps fini.

Considérons le problème de Cauchy

$$\dot{x} = x^2 \quad , \qquad (t_0, x_0) \in \mathbb{R}^2 \ .$$

L'application $f : (t,x) \mapsto x^2$ est continue sur $\mathbb{R}^2$, donc il existe au moins une solution. On peut par exemple vérifier que, pour $x_0 > 0$, $x : I \to \mathbb{R}$ définie par

$$x(t) = \frac{x_0}{1 - x_0(t - t_0)} \quad , \quad I = \left]-\infty, t_0 + \frac{1}{x_0}\right[$$

est bien solution. Vu qu'elle diverge au temps $t_0 + \frac{1}{x_0}$, elle ne peut être prolongée au delà. Elle est donc maximale et on dit qu'elle *explose en temps fini*. Pour $x_0 < 0$, la même formule définit une solution maximale sur $I = \left]t_0 + \frac{1}{x_0}, +\infty\right[$, qui explose dans le passé, et pour $x_0 = 0$ la solution nulle est définie sur $\mathbb{R}$ (voir Figure 4.1 (p. 13)).

En fait, le théorème suivant montre que les solutions maximales sont définies sur un intervalle ouvert, et cet intervalle n'est borné que si $t \mapsto x(t)$ diverge en temps fini ou $t \mapsto (t, x(t))$ tend vers la frontière de l'ensemble de définition $J \times X$ de f en temps fini.

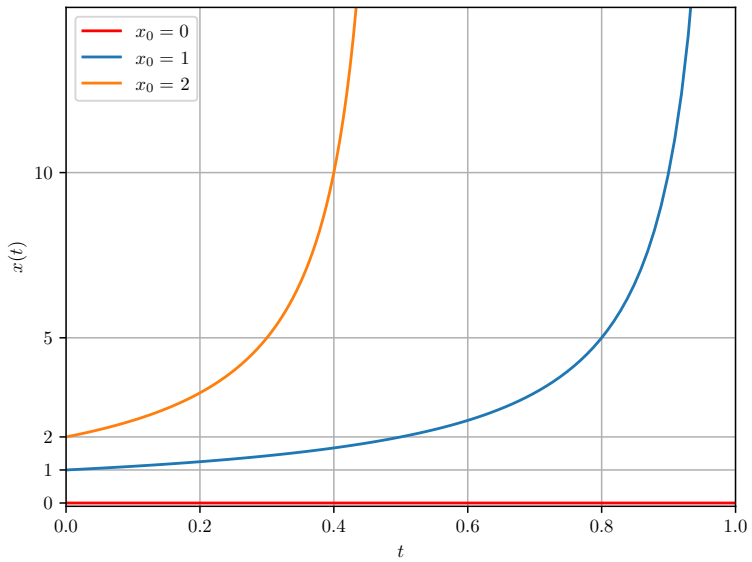


FIGURE 4.1. – Solutions à $\dot{x} = x^2$ pour $t_0 = 0$ et différentes valeurs de x_0

Théorème – Domaine maximal d'existence.

Soient J ouvert de $\mathbb{R}$, X ouvert de $\mathbb{R}^n$, $f : J \times X \to \mathbb{R}^n$ continue et $(t_0, x_0) \in J \times X$. Toute solution du problème de Cauchy défini par f et (t_0, x_0) est prolongeable en une solution maximale et toute solution maximale $x : I \to \mathbb{R}^n$ est définie sur un intervalle ouvert $]t_m^-, t_m^+[$ avec $t_m^-, t_m^+ \in \mathbb{R} \cup \{+\infty, -\infty\}$. De plus, si t_m^+ (resp. t_m^-) est fini alors

$$\lim_{t \to t_m^+} \|x(t)\| + \frac{1}{d\Big((t, x(t)), \partial(J \times X)\Big)} = +\infty \qquad \Big(\textit{resp.} \lim_{t \to t_m^-}\Big) ,$$

avec la convention $1/d = 0$ si $\partial(J \times X) = \emptyset$. Autrement dit, la solution finit par être, à chaque instant, soit très loin de l'origine, soit très proche de la frontière de $J \times X$: elle ne peut pas rester dans une région bornée et à distance positive du bord. En particulier :

- *si $X = \mathbb{R}^n$ et t_m^+ est intérieur à J, seule la première possibilité subsiste :* $\lim_{t \to t_m^+} \|x(t)\| = +\infty$, *la solution* explose en temps fini *;*
- *si X est borné, seule la seconde subsiste :* $\lim_{t \to t_m^+} d(x(t), \partial X) = 0$, *la solution* atteint le bord en temps fini.

Remarque – Diverger ou tendre vers le bord ?.

Attention, la somme tend vers $+\infty$ sans qu'aucun des deux termes n'ait forcément de limite :

rien n'empêche en général une solution d'alterner indéfiniment, en temps fini, entre des passages près de la frontière et des excursions de plus en plus lointaines. C'est pourquoi on ne peut pas écrire "ou bien $\|x(t)\| \to +\infty$, ou bien $d \to 0$" en dehors des deux cas particuliers ci-dessus.

Démonstration. La preuve complète est donnée en annexe (p. 38). On commence par observer que si l'intervalle d'existence n'était pas ouvert, la solution pourrait être prolongée au bord grâce au théorème de Peano, ce qui contredirait sa maximalité. Ensuite, la preuve consiste à montrer que si t_m^+ (resp. t_m^-) est fini, alors $(t, x(t))$ finit forcément par sortir définitivement de toute région bornée et à distance positive du bord de $J \times X$ (c'est-à-dire de tout compact de $J \times X$) lorsque t tend vers t_m^+ (resp. t_m^-), ce qui est exactement le contenu de la limite ci-dessus. ■

En pratique, pour montrer que les solutions maximales sont définies pour tout temps, i.e., sur $\mathbb{R}$, il suffit donc de montrer qu'elles ne peuvent pas aller arbitrairement loin en temps fini (par exemple si elles sont bornées sur tout intervalle de temps fini), et qu'elles ne peuvent pas s'approcher arbitrairement proche du bord de $J \times X$ en temps fini (par exemple si $J \times X = \mathbb{R} \times \mathbb{R}^n$). Un cas particulier où les solutions maximales sont forcément définies sur J entier est donné ci-dessous.

Théorème – Critère d'existence globale.

Soient J un intervalle ouvert de $\mathbb{R}$ et $f : J \times \mathbb{R}^n \to \mathbb{R}^n$ continue. Si f a une croissance au plus affine*, c'est-à-dire, s'il existe $a, b : J \to \mathbb{R}$ continues telles que*

$$\|f(t,x)\| \leq a(t)\|x\| + b(t) \quad \forall (t,x) \in J \times \mathbb{R}^n \ ,$$

alors toute solution maximale est définie sur J entier.

Démonstration. Prouvé dans l'exercice *Autour du Lemme de Grönwall* (p. 31). ■

Exemple – Solutions globales.

- Considérons une équation différentielle *linéaire*, c'est-à-dire pour laquelle il existe $A : \mathbb{R} \to \mathbb{R}^{n\times n}$ et $b : \mathbb{R} \to \mathbb{R}^n$ continues telles que
$$f(t,x) = A(t)x + b(t) \ .$$
D'après le théorème précédent, quelle que soit la condition initiale $(t_0, x_0) \in \mathbb{R} \times \mathbb{R}^n$, ses solutions maximales sont définies sur $\mathbb{R}$ entier (on verra dans la suite qu'il en existe une unique pour chaque condition initiale). Dans le cas où A est constant, on en a même une formule explicite (obtenue par la méthode de *variation de la constante*)
$$x(t) = e^{A(t-t_0)}x_0 + \int_{t_0}^{t} e^{A(t-s)}b(s)ds \ ,$$
où $e^{A(t-s)}$ est l'exponentielle de matrice définie par
$$e^{A(t-s)} = \sum_{p=0}^{+\infty} \frac{A^p(t-s)^p}{p!} \ .$$

Attention, cette formule ne fonctionne que si A est constant. Notons que si A est diagonalisable, i.e., il existe $P \in \mathbb{R}^{n\times n}$ telle que $A = P^{-1}DP$ avec $D \in \mathbb{R}^{n\times n}$ une matrice diagonale contenant les valeurs propres de A, alors

$$e^{A(t-s)} = P^{-1}e^{D(t-s)}P$$

donc les solutions avec $b = 0$ sont des combinaisons linéaires de $e^{\lambda_i t}$ où λ_i sont les valeurs propres de A. Ceci n'est plus vrai lorsque A n'est pas diagonalisable. Voir l'étude de stabilité d'un système linéaire (p. 25).

- Un autre cas important d'une croissance au plus affine est lorsque f est globalement bornée en x. Par exemple,

$$f(t,x) = c(t)\arctan(x) \qquad \text{ou} \qquad f(t,x) = \frac{c(t)}{1+x^2}$$

engendrent des problèmes de Cauchy aux solutions globales.

Exercice – Solutions globales I Justifier que pour toute condition initiale,

$$\begin{aligned} \dot{x}_1 &= \sin x_1 - \sqrt{|t|}x_2 \\ \dot{x}_2 &= \sqrt{1+x_1^2} \end{aligned}$$

admet des solutions et les solutions maximales sont définies sur $\mathbb{R}$. (Solution p. 64.)

Exercice – Solutions globales II (•) Soient $f : \mathbb{R}\times\mathbb{R}^n \to \mathbb{R}^n$ continue et $V : \mathbb{R}^n \to \mathbb{R}$ définie par $V(x) = x^\top x$ telles que

$$\langle \nabla V(x), f(t,x)\rangle \le a(t)V(x) + b(t) \qquad \forall (t,x) \in \mathbb{R}\times\mathbb{R}^n$$

avec $a, b : \mathbb{R} \to \mathbb{R}$ continues. Montrer que quelle que soit la condition initiale $(t_0, x_0) \in \mathbb{R}\times\mathbb{R}^n$, les solutions maximales de $\dot{x} = f(t,x)$ sont définies sur $[t_0, +\infty[$. On pourra pour cela étudier l'évolution de $t \mapsto V(x(t))$. (Solution p. 64.)

Exercice – Solutions globales III (•) Soient $f : \mathbb{R}\times\mathbb{R}^n \to \mathbb{R}^n$ continue et $V : \mathbb{R}^n \to \mathbb{R}$ telle que

$$\lim_{\|x\|\to+\infty} V(x) = +\infty \quad \text{et} \quad \langle \nabla V(x), f(t,x)\rangle \le 0 \qquad \forall (t,x) \in \mathbb{R}\times\mathbb{R}^n \ .$$

Montrer que quelle que soit la condition initiale $(t_0, x_0) \in \mathbb{R}\times\mathbb{R}^n$, les solutions maximales de $\dot{x} = f(t,x)$ sont définies et bornées sur $[t_0, +\infty[$. On pourra pour cela étudier l'évolution de $t \mapsto V(x(t))$. (Solution p. 65.)

4.3. Unicité des solutions maximales

Si des solutions maximales existent toujours, elles ne sont pas toujours uniques.

Exemple – Non-unicité des solutions.

Considérons le problème de Cauchy

$$\dot{x} = -\sqrt{|x|} \qquad , \qquad (t_0, x_0) = (0,0) \ .$$

Ce système permet en particulier de modéliser l'écoulement d'un fluide dans un réservoir, selon la loi de *Torricelli* (voir exercice (p. 31)). La fonction $f : (t,x) \mapsto -\sqrt{|x|}$ est continue

sur $\mathbb{R} \times \mathbb{R}$, donc ce problème de Cauchy admet au moins une solution. Mais on montrera en exercice (p. 31) qu'il existe une infinité de solutions maximales. Plus de détails sont donnés dans le notebook Equations Différentielles I.ipynb.

Le théorème suivant, dit de *Cauchy-Lipschitz*, montre que l'unicité des solutions maximales est garantie si f est de plus continûment différentiable par rapport à la variable x. On voit que ce n'est pas le cas de $x \mapsto -\sqrt{|x|}$ en 0. Le théorème et la preuve de l'époque sont disponibles en ligne dans des notes de cours (Moigno 1844).

Théorème – Théorème de Cauchy-Lipschitz (ou de Picard-Lindelöf).

Soient J ouvert de $\mathbb{R}$, X ouvert de $\mathbb{R}^n$, $f : J \times X \to \mathbb{R}^n$ continue et continûment différentiable par rapport à x, i.e. $(t, x) \mapsto \partial_x f(t, x)$ existe et est continue sur $J \times X$. Alors pour tout $(t_0, x_0) \in J \times X$, il existe une unique solution maximale $x : I \subset J \to \mathbb{R}^n$ au problème de Cauchy défini par f et (t_0, x_0).

Démonstration. Nous donnons ici le principe de la preuve qui peut être passée en première lecture, mais qu'il est intéressant de comprendre d'un point de vue scientifique. L'essentiel est en fait de montrer que sous l'hypothèse de régularité de f par rapport à x, il existe une unique solution locale au problème de Cauchy. De là on peut ensuite déduire qu'elle se prolonge en une unique solution maximale dans $J \times X$: si x et x' sont deux solutions définies sur un même intervalle $I \ni t_0$, l'ensemble $\{t \in I : x(t) = x'(t)\}$ est non vide, fermé dans I (par continuité), et ouvert (l'unicité locale appliquée en chaque point de coïncidence $(t_1, x(t_1))$ montre que x et x' coïncident sur un voisinage de t_1) ; il est donc égal à I. Deux solutions coïncident ainsi sur leur intervalle commun, et la réunion de toutes les solutions est l'unique solution maximale. La partie cruciale est donc le résultat local suivant qui constitue en fait le théorème initial de Cauchy-Lipschitz (sa généralisation aux solutions globales étant plutôt due à Picard et Lindelöf (p. 18)).

Théorème de Cauchy-Lipschitz local Soient J ouvert de $\mathbb{R}$, X ouvert de $\mathbb{R}^n$, $f : J \times X \to \mathbb{R}^n$ continue et continûment différentiable par rapport à x, et $(t_0, x_0) \in J \times X$. Soient $\tau > 0$ et $r > 0$ tels que

$$\mathcal{C} := [t_0 - \tau, t_0 + \tau] \times B_f(x_0, r) \subset J \times X \ .$$

Pour tout $\tau_m \in [0, \tau]$ tel que $\tau_m \max_{\mathcal{C}} \|f\| \leq r$, toute solution x au problème de Cauchy défini par f et (t_0, x_0) est définie de manière unique sur $[t_0 - \tau_m, t_0 + \tau_m]$.

Démonstration

La preuve consiste à voir les solutions comme des points fixes d'un certain opérateur intégral, obtenu par la représentation intégrale des solutions. Le théorème du point fixe de Banach permet ensuite de montrer l'existence et l'unicité de ce point fixe.

Tout d'abord, $\mathcal{C}$ étant compact, par continuité de f, $\max_{\mathcal{C}} \|f\|$ existe bien. Par ailleurs, l'ensemble des fonctions continues de $[t_0 - \tau_m, t_0 + \tau_m]$ dans $\mathbb{R}^n$, que nous notons E, est complet[1] pour la norme uniforme $\|\cdot\|_\infty$, et définissons

$$F = \{x \in E \ : \ x([t_0 - \tau_m, t_0 + \tau_m]) \subset B_f(x_0, r)\} \ .$$

On peut montrer que[2] F est un sous-ensemble fermé de E. F est donc complet (toujours pour la norme uniforme $\|\cdot\|_\infty$). Pour tout $x \in F$, par définition, $(s, x(s)) \in \mathcal{C} \subset J \times X$ pour tout

$s \in [t_0 - \tau_m, t_0 + \tau_m]$; on peut donc définir l'opérateur $\Gamma : F \to E$ par

$$\Gamma(x)(t) = x_0 + \int_{t_0}^{t} f(s, x(s))ds \qquad \forall t \in [t_0 - \tau_m, t_0 + \tau_m] \ .$$

Or d'après la représentation intégrale des solutions (p. 10), on sait qu'une fonction $x \in F$ est solution du problème de Cauchy sur $[t_0 - \tau_m, t_0 + \tau_m]$ si et seulement si elle vérifie

$$\Gamma(x) = x$$

c'est-à-dire x est un point fixe de Γ. Par ailleurs, on peut prouver[3] que pour tout $x \in S_f(t_0, x_0)$ définie sur $[t_0 - \tau_m, t_0 + \tau_m]$, x est dans F : c'est donc un point fixe x^* de Γ sur F. L'idée de la preuve est donc de montrer que Γ (ou une de ses itérées) est contractante pour utiliser le théorème de point fixe de Banach et en déduire l'existence et l'unicité de ce point fixe.

D'abord, pour tout $x \in F$, pour tout $t \in [t_0 - \tau_m, t_0 + \tau_m]$,

$$\|\Gamma(x)(t) - x_0\| \leq \left| \int_{t_0}^{t} \|f(s, x(s))\| ds \right| \leq \tau_m \max_{\mathcal{C}} \|f\| \leq r$$

de sorte que $\Gamma(x) \in F$, i.e. $\Gamma : F \to F$. Ensuite, pour tout $(x_a, x_b) \in F \times F$, pour tout $t \in [t_0 - \tau_m, t_0 + \tau_m]$,

$$\|\Gamma(x_a)(t) - \Gamma(x_b)(t)\| \leq \left| \int_{t_0}^{t} \|f(s, x_a(s)) - f(s, x_b(s))\| ds \right| \ .$$

Soit $k = \max_{\mathcal{C}} \|\partial_x f\|$ (bien défini car $\mathcal{C}$ est compact et $\partial_x f$ est continue par hypothèse). Alors l'application du théorème des accroissements finis nous donne

$$\|\Gamma(x_a)(t) - \Gamma(x_b)(t)\| \leq \left| \int_{t_0}^{t} k \|x_a(s) - x_b(s)\| ds \right| \leq |t - t_0| k \|x_a - x_b\|_\infty$$

et donc $\|\Gamma(x_a) - \Gamma(x_b)\|_\infty \leq \tau_m k \|x_a - x_b\|_\infty$. A ce stade, sauf si $\tau_m k < 1$, Γ n'est pas contractante. Cependant, on peut montrer par récurrence que pour tout $p \in \mathbb{N}$, et pour tout $t \in [t_0 - \tau_m, t_0 + \tau_m]$,

$$\|\Gamma^p(x_a)(t) - \Gamma^p(x_b)(t)\| \leq \frac{(|t - t_0|k)^p}{p!} \|x_a - x_b\|_\infty$$

en notant $\Gamma^p = \underbrace{\Gamma \circ \Gamma \circ \ldots \circ \Gamma}_{p \text{ fois}}$. Donc pour tout $p \in \mathbb{N}$, $\|\Gamma^p(x_a) - \Gamma^p(x_b)\|_\infty \leq \frac{(\tau_m k)^p}{p!} \|x_a - x_b\|_\infty$.
Il existe donc p suffisamment grand tel que Γ^p est contractante. D'après le théorème de point fixe de Banach, Γ^p admet un unique point fixe x^* dans F. Alors $\Gamma(x^*)$ est aussi un point fixe de Γ^p (car $\Gamma^p(\Gamma(x^*)) = \Gamma(\Gamma^p(x^*)) = \Gamma(x^*)$), donc $\Gamma(x^*) = x^*$ par unicité ; et tout point fixe de Γ est point fixe de Γ^p, donc égal à x^*. Ainsi Γ admet un unique point fixe x^* dans F. ■

Remarque – Relâchement à f localement lipschitzienne.

La première preuve d'existence et unicité locale de solutions sous l'hypothèse que f est continûment différentiable par rapport à x est due à Augustin Louis Cauchy (1820) et repose sur l'utilisation du théorème des accroissements finis[4]. Mais on remarque dans notre preuve qu'il suffirait qu'il existe $k > 0$ tel que

$$\|f(t, x_a) - f(t, x_b)\| \leq k\|x_a - x_b\| \qquad \forall t \in [t_0 - \tau_m, t_0 + \tau_m], \forall (x_a, x_b) \in B_f(x_0, r) \times B_f(x_0, r) \ ,$$

c'est-à-dire que la fonction f soit *lipschitzienne* par rapport à x au voisinage de (t_0, x_0). Cette propriété fut introduite par le mathématicien allemand Rudolf Lipschitz quelques années plus tard (1868) pour prouver le même résultat de façon indépendante : d'où le nom de *théorème de Cauchy-Lipschitz*. Notons que cette dernière hypothèse est plus faible que celle de Cauchy car elle impose seulement que $x \mapsto f(t, x)$ soit lipschitzienne au voisinage de (t_0, x_0), au lieu de différentiable. Par exemple, $x \mapsto |x|$ est lipschitzienne (mais pas différentiable) et $\dot{x} = |x|$ admet donc une unique solution maximale quelle que soit la condition initiale.

Remarque – Approximations successives.

Mise à part quelques formes particulières de f, il est très rare de savoir résoudre explicitement une équation différentielle. Cependant, la preuve (dans sa forme moderne donnée plus haut) caractérise la solution comme le point fixe de l'opérateur Γ. Or, on sait par la preuve du théorème du point fixe de Banach que ce point fixe est la limite uniforme de la suite des itérées de Γ. En pratique, on peut donc s'approcher arbitrairement proche de la solution sur l'intervalle $[t_0 - \tau_m, t_0 + \tau_m]$ (au sens de la norme uniforme), en calculant la suite $x_{p+1} = \Gamma(x_p)$ définie par

$$x_{p+1}(t) = x_0 + \int_{t_0}^{t} f(s, x_p(s))ds,$$

en notant ici de manière abusive x_0 la fonction constante égale à x_0. Cette méthode de recherche de point fixe porte le nom d'*approximations successives* et est introduite pour la

1. E est un sous-ensemble fermé de l'ensemble des fonctions $f : I \to \mathbb{R}^n$ bornées muni de la norme uniforme car toute fonction continue sur un compact est bornée et toute limite uniforme de fonctions continues est continue. Or l'ensemble des fonctions $f : I \to \mathbb{R}^n$ bornées est complet pour la norme uniforme. En effet, soit (f_p) une suite de Cauchy. Alors par définition de la norme uniforme, pour tout $t \in I$, la suite $(f_p(t))$ est de Cauchy dans $\mathbb{R}^n$ qui est complet donc converge. Notons $f_\infty(t)$ sa limite. On montre alors aisément que f_∞ est bornée sur I en la comparant à un f_p fixé et en passant à la limite dans la propriété des suites de Cauchy pour un ε fixé.

2. Pour toute suite (x_n) d'éléments de F convergeant vers x^*, pour tout $t \in [t_0 - \tau_m, t_0 + \tau_m]$,

$$\|x_n(t) - x^*(t)\| \leq \|x_n - x^*\|_\infty \underset{n\to\infty}{\longrightarrow} 0$$

donc la suite $(x_n(t))$ d'éléments du fermé $B_f(x_0, r)$ converge dans $\mathbb{R}^n$ vers $x^*(t)$ qui est donc dans $B_f(x_0, r)$. Ceci implique $x^* \in F$.

3. Il suffit de montrer que $x([t_0 - \tau_m, t_0 + \tau_m]) \subset B_f(x_0, r)$. Supposons le contraire et sans perdre en généralité supposons que $S := \{t \in [t_0, t_0 + \tau_m] \ : \ \|x(t) - x_0\| > r\}$ est non vide. Soit $t^* = \inf S$. Nécessairement $t_0 < t^* < t_0 + \tau_m$. Donc par la représentation intégrale (p. 10),

$$\|x(t^*) - x_0\| \leq (t^* - t_0) \max_{s\in[t_0,t^*]} \|f(s, x(s))\| < \tau_m \max_{\mathcal{C}} \|f\| < r \ .$$

Par continuité de x, $\|x(t) - x_0\| \leq r$ pour un temps après t^*, ce qui contredit sa définition.

4. En l'absence d'outils d'analyse fonctionnelle à cette époque, la preuve de Cauchy consistait plutôt à discrétiser en temps l'intégrale de plus en plus finement et montrer la convergence vers une solution.

première fois par le mathématicien français Emile Picard à la fin du XIXème siècle grâce aux progrès de l'analyse fonctionnelle. C'est finalement le mathématicien finlandais Ernst Lindelöf qui donne à la preuve sa forme moderne en utilisant en 1894 la théorie des espaces de Banach. Pour les anglophones, ce théorème s'appelle d'ailleurs le *théorème de Picard-Lindelöf*.

Exemple – Unicité des solutions maximales.

- Une équation différentielle *linéaire*, c'est-à-dire pour laquelle il existe $A : \mathbb{R} \to \mathbb{R}^{n\times n}$ et $b : \mathbb{R} \to \mathbb{R}^n$ continues telles que

$$f(t, x) = A(t)x + b(t) \ ,$$

  admet une unique solution maximale quelle que soit sa condition initiale $(t_0, x_0) \in \mathbb{R}\times\mathbb{R}^n$, car $\partial_x f(t, x) = A(t)$ est continue.

- Les équations décrivant l'évolution de la tension dans un circuit RLC ou la cinétique chimique données au début de ce cours admettent une unique solution maximale au voisinage de toute condition initiale (t_0, x_0). C'est aussi le cas des équations de la mécanique newtonienne ou lagrangienne si les forces/couples $F_k(t, q, \dot{q})$ sont continûment différentiables par rapport à la position et la vitesse $(q, \dot{q})$.

Exercice – Unicité de la solution maximale Justifier que pour toute condition initiale,

$$\begin{aligned} \dot{x}_1 &= \sin x_1 - \sqrt{|t|}x_2 \\ \dot{x}_2 &= \sqrt{1 + x_1^2} \end{aligned}$$

admet une unique solution maximale définie sur $\mathbb{R}$. (Solution p. 65.)

5. Régularité et stabilité des solutions

Depuis l'apparition de la mécanique Newtonienne au XVIIème siècle, l'étude des équations différentielles a toujours été motivée par l'espoir de compréhension et de prédiction du comportement futur ou passé de systèmes physiques. En particulier, une question ayant taraudé et divisé les scientifiques au cours des siècles est celle de la stabilité du système à trois corps (Terre-Lune-Soleil), ou plus généralement du système solaire. Enchanté devant les avancées de la mécanique céleste, Pierre-Simon Laplace écrit en 1814 :

> Nous devons donc envisager l'état présent de l'univers comme l'effet de son état antérieur, et comme la cause de celui qui va suivre. Une intelligence qui pour un instant donné connaîtrait toutes les forces dont la nature est animée et la situation respective des êtres qui la composent, si d'ailleurs elle était assez vaste pour soumettre ses données à l'analyse, embrasserait dans la même formule les mouvements des plus grands corps de l'univers et ceux du plus léger atome : rien ne serait incertain pour elle, et l'avenir comme le passé serait présent à ses yeux.

Cette conviction *déterministe*, c'est-à-dire que les phénomènes physiques passés ou futurs sont entièrement déterminés par leur condition initiale, fut confirmée par le théorème de Cauchy-Lipschitz quelques années plus tard. Ce dernier suggère en effet que l'on peut prévoir l'évolution

des systèmes physiques par la seule connaissance de leur condition initiale et de leur modèle physique.

Cependant, à la fin du XIXème siècle, on se rend vite compte que la réalité est en fait toute autre :

- d'une part, la condition initiale et le modèle ne sont jamais parfaitement connus : quelle est alors la qualité de notre prédiction ?
- d'autre part, ne pouvant généralement pas calculer explicitement la solution, comment anticiper son comportement sur des temps longs, voire son comportement asymptotique ?

5.1. Sensibilité aux conditions initiales et erreurs de modèle

La première question fut soulevée par Henri Poincaré à la fin du XIXème siècle alors qu'il s'attelle à la question de la stabilité du système solaire.

Le théorème suivant nous montre que pour un horizon de temps fini donné, on peut obtenir une solution arbitrairement précise si le système est initialisé suffisamment précisément et si les perturbations (ou erreurs de modèle) sont suffisamment faibles. En d'autres termes, la solution est *continue* par rapport aux perturbations en temps fini. Ceci est crucial en physique puisque l'on ne peut jamais modéliser tous les phénomènes parfaitement.

Théorème – Régularité en temps fini.

Soient J ouvert de $\mathbb{R}$, X ouvert de $\mathbb{R}^n$, $f : J \times X \to \mathbb{R}^n$ continue et continûment différentiable par rapport à x, $(t_0, x_0) \in J \times X$, et $x : I \to \mathbb{R}^n$ l'unique solution maximale au problème de Cauchy défini par f et (t_0, x_0). Pour tout $\underline{t}, \overline{t}$ tel que $t_0 \in [\underline{t}, \overline{t}] \subset I$, il existe $\delta_m > 0$ et $\lambda \in \mathbb{R}$ tels que pour tout $\delta \in \mathbb{R}^n$ vérifiant $\|\delta\| \leq \delta_m$, l'unique solution maximale x_δ au problème de Cauchy défini par f et $(t_0, x_0 + \delta)$ est définie au moins sur $[\underline{t}, \overline{t}]$ et vérifie

$$\|x(t) - x_\delta(t)\| \leq e^{\lambda|t-t_0|}\|\delta\| \qquad \forall t \in [\underline{t}, \overline{t}] \ .$$

Démonstration. Prouvé dans l'exercice *Autour du Lemme de Grönwall* (p. 31). ■

La présence du facteur exponentiel n'est pas cruciale ici, et servira dans la suite. Ce qui est important, c'est que plus l'erreur de condition initiale δ est faible, plus l'erreur sur la trajectoire à horizon de temps fini $\overline{t}$ est faible. On dit alors que la solution du problème de Cauchy est continue par rapport à la condition initiale à horizon de temps fini. Attention, l'hypothèse "continûment différentiable par rapport à x" est importante encore ici, comme illustré dans l'exercice *Ecoulement dans un réservoir (p. 31)*, mais seulement pour garantir l'unicité des solutions. Elle peut être relâchée à "f localement lipschitzienne par rapport à x" comme dans le cas du Théorème de Cauchy-Lipschitz.

Exemple – Continuité des solutions par rapport aux perturbations.

- Si $\lambda < 0$, l'erreur commise sur la condition initiale disparaît au cours du temps dans les solutions : on dit qu'elles "oublient" leurs conditions initiales et que le système est *contractant*.
- On peut aussi déduire de ce résultat la continuité des solutions par rapport à des paramètres p intervenant dans la fonction f. En effet, il suffit de considérer le système

étendu

$$\begin{aligned}\dot{y} &= f(t, y, p)\\ \dot{p} &= 0\end{aligned}$$

pour lequel l'incertitude de paramètre se ramène à une incertitude de condition initiale.

- Considérons un système linéaire à paramètre et/ou condition initiale incertains

$$\dot{x} = (a + \delta_a)x \qquad , \qquad x_0 = c + \delta_c$$

Pour $\delta_a = 0 = \delta_c$, la solution est $x(t) = ce^{at}$, et sinon

$$x_\delta(t) = (c + \delta_c)e^{(a+\delta_a)t} \ .$$

On a donc pour tout t,

$$\|x(t) - x_\delta(t)\| = \|c - (c + \delta_c)e^{\delta_a t}\|e^{at} \leq \left(|\delta_c|e^{\delta_a t} + |1 - e^{\delta_a t}||c|\right) e^{at}$$

et pour tout $\bar{t} > 0$ et $|\delta_a| \leq \frac{1}{\bar{t}}$, en utilisant $|e^u - 1| \leq e\,|u|$ pour $|u| \leq 1$,

$$\sup_{t\in[0,\bar{t}]} \|x(t) - x_\delta(t)\| \leq e\,(|\delta_c| + |\delta_a||c|\bar{t})\, e^{|a|\bar{t}}$$

qui peut être rendu aussi faible que voulu si δ_a et δ_c sont suffisamment petits. On voit bien ici que cette différence est bornée en temps fini, mais pas forcément asymptotiquement en particulier si $a > 0$.

- L'outil Fibre[1] permet d'observer en dimension 3 cette continuité des solutions par rapport aux conditions initiales, en affichant les trajectoires pour un ensemble de conditions initiales dont la taille est contrôlée à la souris: à "Integration Time" fixé, plus on réduit la *boîte* de condition initiales, plus les solutions se rapprochent les unes des autres. Par contre, lorsque l'on augmente le "Integration Time" les solutions s'écartent.

Remarque – Chaos déterministe et horizon de Lyapunov.

Même si la continuité des solutions par rapport aux paramètres/conditions initiales donne à espérer de pouvoir simuler et prédire l'évolution de systèmes physiques, elle est malheureusement parfois insuffisante. Henri Poincaré écrit :

> Si nous connaissions exactement les lois de la nature et la situation de l'univers à l'instant initial, nous pourrions prédire exactement la situation de ce même univers à un instant ultérieur. Mais, lors même que les lois naturelles n'auraient plus de secret pour nous, nous ne pourrions connaître la situation qu'approximativement. Si cela nous permet de prévoir la situation ultérieure avec la même approximation, c'est tout ce qu'il nous faut, nous disons que le phénomène a été prévu, qu'il est régi par des lois ; mais il n'en est pas toujours ainsi, il peut arriver que de petites différences dans les conditions initiales en engendrent de très grandes dans les phénomènes finaux ; une petite erreur sur les premières produirait une erreur

1. https://portsmouth.github.io/fibre/

énorme sur les derniers. La prédiction devient impossible.

En effet, le précédent théorème nous prouve seulement que des perturbations suffisamment petites donnent des solutions arbitrairement proches en temps fini. Mais, en pratique, il est rarement possible de choisir l'amplitude des perturbations (erreurs de capteurs, erreurs numériques etc.) et il se pourrait que l'ordre de grandeur des perturbations produisant des erreurs *acceptables* sur les solutions ne soit pas réalisable. Plus précisément, le théorème suggère qu'à perturbation $|\delta|$ donnée, l'écart entre les solutions pourrait croître exponentiellement vite. C'est le cas bien sûr des systèmes qui divergent exponentiellement (tels que $\dot{x} = x$), mais aussi de certains systèmes à trajectoires bornées, pour lesquels il existe $\bar{t} > 0$ tel que

$$\frac{\|x(t) - x_\delta(t)\|}{\|\delta\|} \approx e^{\lambda t} \qquad \forall 0 \leq t \leq \bar{t} \ .$$

Dans ce cas, $\frac{1}{\lambda}$ représente l'ordre de grandeur du temps maximal jusqu'auquel l'erreur sur les solutions reste du même ordre de grandeur que l'erreur initiale : on parle d'*horizon de Lyapunov*. Toute prédiction au delà de cet horizon est illusoire et le système est alors dit *chaotique*.

Il est important d'insister sur le caractère *déterministe* de ce chaos : chaque cause entraîne un effet bien déterminé mais deux causes "très proches" peuvent avoir des effets très différents.

Exemple – Systèmes chaotiques.

- Henri Poincaré met en évidence le premier un comportement chaotique des solutions du problème à 3 corps. Ses livres sont disponibles en ligne (Poincaré 1892).
- En 1963, Edward Lorenz met en évidence pour la première fois le comportement possiblement chaotique de la météorologie à travers un modèle simplifié à trois dimensions de convection donné par

$$\begin{aligned} \dot{x}_1 &= \sigma(x_2 - x_1) \\ \dot{x}_2 &= \rho\, x_1 - x_2 - x_1 x_3 \\ \dot{x}_3 &= x_1 x_2 - \beta x_3 \end{aligned}$$

  où σ, ρ et β sont des paramètres strictement positifs. Pour $\sigma = 10$, $\beta = 8/3$ et $\rho = 28$, ce système présente un attracteur en forme de papillon, où les trajectoires passent de manière *chaotique* d'une aile à l'autre, comme représenté sur la Figure 5.1 (p. 23). La croissance exponentielle de l'erreur se visualise en simulation : voir pour cela le notebook Equations Différentielles I.ipynb.
- En 1989, l'astronome français Jacques Laskar met en évidence numériquement le caractère chaotique des orbites des planètes de notre système solaire, en particulier celle de Mercure, dont les variations d'excentricité pourraient entraîner des collisions ou éjections de planètes dans certains scénarios long-termes. Ces travaux sont confirmés en 1992 par Gerald Jay Sussman et Jack Wisdom, qui démontrent que le système solaire est chaotique avec un horizon de Lyapunov de l'ordre de 4 millions d'années (Sussman and Wisdom 1992).
- Plus généralement, les systèmes chaotiques apparaissent dans des domaines très divers, comprenant l'économie, l'électricité, la mécanique, la médecine. Parfois, le comportement

chaotique apparaît seulement lorsque le système est soumis à certaines excitations, par exemple une excitation sinusoïdale du pendule ou de l'oscillateur de Van der Pol (Holmes and Rand 1978).

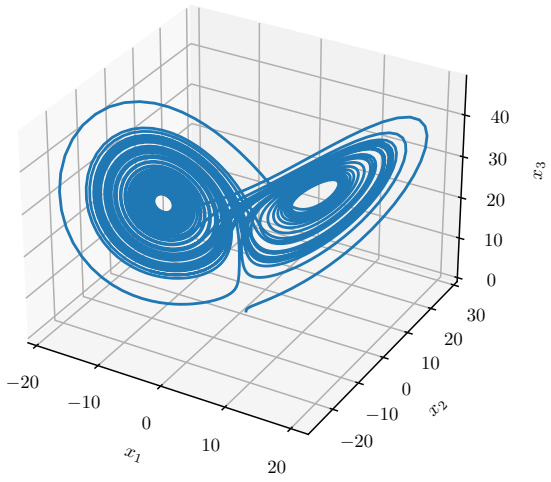


FIGURE 5.1. – Trajectoire de l'oscillateur de Lorenz

5.2. Propriétés asymptotiques

Dans la section précédente nous avons répondu à la première question qui était la sensibilité des solutions aux erreurs de condition initiale et de modèle. Mais cette étude était en temps fini et nous nous intéressons maintenant à la seconde question qui est le comportement asymptotique des solutions. L'étude théorique asymptotique des solutions prend ses origines dans la thèse de Lyapunov (Lyapunov 1892). Le but est de rechercher des critères sur la fonction f qui nous permettent de prédire ce comportement : est-ce que les solutions divergent ? est-ce qu'elles tendent vers un point en particulier ? vers un cycle limite ?

Dans la suite, pour simplifier, nous étudions les équations différentielles dites *autonomes*, c'est-à-dire dont la fonction f est indépendante du temps. On se donne donc une fonction continue $f : X \to \mathbb{R}^n$, avec X un ouvert de $\mathbb{R}^n$ et on prend par défaut $t_0 = 0$.

Définition – Point d'équilibre.

On appelle *point d'équilibre* pour f (ou pour le système $\dot{x} = f(x)$) un point $a \in X$ tel que

$$f(a) = 0 \ .$$

En d'autres termes, la fonction constante égale à a est alors solution de $\dot{x} = f(x)$.

Exemple – Pendule.

L'évolution d'un pendule de longueur ℓ et de masse m dans le champ de pesanteur g peut être décrite par une dynamique du type

$$\ddot{\theta} = -\frac{\rho}{m}\dot{\theta} - \frac{g}{\ell}\sin\theta$$

avec $\rho \geq 0$ un coefficient de frottement. En prenant $x = (\theta, \dot{\theta})$, on obtient le système

$$\begin{aligned} \dot{x}_1 &= x_2 \\ \dot{x}_2 &= -\tfrac{\rho}{m}x_2 - \tfrac{g}{\ell}\sin x_1 \end{aligned}$$

Ce système a pour points d'équilibre $(k\pi, 0)$, $k \in \mathbb{Z}$, qui correspondent soit à la position *basse* du pendule $\theta = 0$ ou la position *haute* $\theta = \pi$, toutes deux à vitesse nulle $\dot{\theta} = 0$. Si le pendule est initialisé exactement à sa position haute ou basse à vitesse nulle alors il y reste indéfiniment.

Définition – Attractivité.

Un point d'équilibre a est dit *localement attractif* si *toutes les solutions maximales initialisées suffisamment proche de a sont définies en tout temps positif et convergent vers a*, c'est-à-dire s'il existe $\eta > 0$ tel que pour tout x_0 vérifiant $\|x_0 - a\| \leq \eta$, toute solution maximale $x \in S_f(x_0)$ est définie sur $\mathbb{R}_{\geq 0}$ et vérifie

$$\lim_{t \to +\infty} x(t) = a \ .$$

De plus, a est dit *globalement attractif* si *toutes les solutions maximales sont définies en tout temps positif et convergent vers a.*

Cette notion intuitive ne dit rien sur le comportement des solutions pendant le transitoire, c'est-à-dire avant de converger vers a. Des solutions initialisées proche de a pourraient s'en éloigner arbitrairement loin avant de converger, ou mettre un temps arbitrairement long pour revenir dans un voisinage de a. Pour garantir une certaine uniformité et robustesse de cette attractivité par rapport à la condition initiale, on a recours à une notion plus forte qui est la *stabilité asymptotique.*

Définition – Stabilité, stabilité asymptotique.

Un point d'équilibre a est dit:

- *stable* si *les solutions sont définies en tout temps positif et restent arbitrairement proche de a quand elles sont initialisées suffisamment proche de a*, c'est-à-dire pour tout $\varepsilon > 0$, il existe $\eta > 0$ tel que pour tout x_0 vérifiant $\|x_0 - a\| \leq \eta$, toute solution maximale $x \in S_f(x_0)$ est définie sur $\mathbb{R}_{\geq 0}$ et vérifie

$$\|x(t) - a\| \leq \varepsilon \quad \forall t \in \mathbb{R}_{\geq 0} \ .$$

- *instable* s'il n'est pas stable.
- *localement (resp. globalement) asymptotiquement stable* s'il est à la fois stable en plus d'être localement (resp. globalement) attractif.

Exemple – Stabilité du pendule.

- Lorsqu'un pendule amorti est initialisé arbitrairement proche de sa position haute ou dans sa position haute mais à vitesse arbitrairement faible, il se met à osciller en passant par sa position basse : l'équilibre haut est donc instable, puisqu'on ne peut pas garder les trajectoires dans son voisinage. Par contre, lorsqu'il est initialisé proche de sa position basse, il oscille de façon amortie en tendant vers l'équilibre bas, qui est donc localement asymptotiquement stable. Voir le portrait de phase du pendule amorti (Figure 3.1, p. 11).
- Dans le cas d'un pendule non amorti par contre, c'est-à-dire avec $\rho = 0$, le pendule oscille indéfiniment à énergie constante : la position basse est alors toujours stable mais plus attractive, et donc plus asymptotiquement stable. Voir le portrait de phase du pendule non amorti (Figure 3.1, p. 11).

Remarque – Robustesse vis-à-vis des perturbations (pour la culture).

L'avantage de la propriété de *stabilité asymptotique* par rapport à la simple *attractivité* est qu'elle apporte de la robustesse par rapport aux perturbations. En effet, lorsque qu'un point d'équilibre est asymptotiquement stable, on peut montrer qu'en présence d'une perturbation de la dynamique, les solutions restent asymptotiquement arbitrairement proche de ce point d'équilibre si la perturbation est suffisamment petite. Il y a donc une sorte de continuité des solutions par rapport aux perturbations en temps infini (contrairement au résultat général de continuité par rapport aux conditions initiales qui n'est qu'en temps fini). Cette propriété n'est pas garantie lorsque le point d'équilibre n'est qu'attractif et c'est la raison pour laquelle en pratique, on essaye toujours d'assurer la stabilité asymptotique d'un système : on sait alors que même en présence de perturbations (inévitables en physique), le comportement du système sera proche du comportement voulu.

Théorème – Stabilité asymptotique d'un système linéaire stationnaire.

Soit $A \in \mathbb{R}^{n\times n}$. Le point d'équilibre 0 est globalement asymptotiquement stable pour le système

$$\dot{x} = Ax$$

si et seulement si les valeurs propres de A sont toutes à partie réelle strictement négative. On dit alors que la matrice est de Hurwitz*, du nom du mathématicien allemand Adolf Hurwitz.*

Démonstration. La notion de *globalement asymptotiquement stable* contient deux propriétés : la stabilité et l'attractivité globale. On montrera en exercice (p. 35) que pour un système linéaire, elles sont équivalentes à l'attractivité (locale), c'est-à-dire que la stabilité et la globalité viennent gratuitement. C'est une propriété propre aux systèmes linéaires. Il suffit donc de trouver un critère caractérisant l'attractivité de 0. On a vu que les solutions s'écrivent

$$x(t) = e^{At}x_0 \ .$$

Si A est diagonale, on a $x_i(t) = e^{\lambda_i t}x_{0,i}$, où λ_i sont les valeurs propres de A et l'on voit bien que la convergence des solutions vers 0 est équivalente à avoir $\lambda_i < 0$. Maintenant, si

A est diagonalisable, i.e., il existe $P \in \mathbb{C}^{n\times n}$ inversible telle que $P^{-1}AP$ est diagonale, on a $P^{-1}x(t) = e^{P^{-1}APt}P^{-1}x_0$, et reproduisant le même argument, $P^{-1}x$ (et donc x) converge vers 0 si et seulement si les entrées diagonales de $P^{-1}AP$, qui sont les valeurs propres de A, sont à partie réelle strictement négative. Ceci dit, toute matrice A n'est pas diagonalisable. Par contre, il existe toujours $P \in \mathbb{C}^{n\times n}$ inversible telle que

$$P^{-1}AP = D + N$$

où D est diagonale contenant les valeurs propres de A, N est nilpotente, c'est-à-dire qu'il existe $k \in \mathbb{N}$ tel que $N^k = 0$, et D et N commutent. C'est la forme dite *de Jordan*. Il s'ensuit que

$$P^{-1}e^{At}P = e^{P^{-1}APt} = e^{Dt}e^{Nt} = e^{Dt}\sum_{i=0}^{k}\frac{1}{i!}N^i t^i$$

converge vers zéro si et seulement si, encore, les valeurs propres de A sont à partie réelle strictement négative. ■

Attention ce critère n'est valable que pour A constant. Le fait que $A(t)$ soit de Hurwitz pour tout t n'implique pas que les solutions du système

$$\dot{x} = A(t)x$$

tendent vers 0 ou même restent bornées. Par exemple, la matrice

$$A(t) = \begin{pmatrix} -1 + 1.5\cos^2 t & 1 - 1.5\sin t\cos t \\ -1 - 1.5\sin t\cos t & -1 + 1.5\sin^2 t \end{pmatrix}$$

a des valeurs propres constantes égales à $-0.25 \pm 0.25\sqrt{7}j$. Pourtant, $\dot{x} = A(t)x$ admet des solutions non bornées pour $x(0)$ arbitrairement proche de 0.

Remarque – Critère de stabilité linéaire (pour la culture).

Notons aussi qu'il existe un critère de *stabilité* pour les systèmes linéaires autonomes (plus faible que stabilité asymptotique) : A est stable si et seulement si toutes ses valeurs propres sont à partie réelle négative ou nulle, et toute valeur propre à partie réelle nulle a ses multiplicités algébriques et géométriques égales. C'est-à-dire que la dimension du sous-espace propre associé est égale à sa multiplicité dans le polynôme caractéristique.

Exercice – Critère de stabilité asymptotique d'un système linéaire plan (•) Montrer que $A \in \mathbb{R}^{2\times 2}$ est de Hurwitz si et seulement si $\mathrm{tr}A < 0$ et $\det A > 0$. Attention, ce critère ne marche qu'en dimension 2 ! (Solution p. 65.)

Exercice – Oscillateurs couplés I (•) Considérons deux masses m_1, m_2 évoluant sur un support horizontal, accrochées entre elles et chacune à un mur via des ressorts de raideur k_1, k_2, k_{12}. L'évolution de leur position par rapport à leur position d'équilibre respective est décrite par

$$m_1\ddot{y}_1 = -\lambda_1\dot{y}_1 - k_1y_1 + k_{12}(y_2 - y_1)$$
$$m_2\ddot{y}_2 = -\lambda_2\dot{y}_2 - k_2y_2 - k_{12}(y_2 - y_1)$$

où λ_1, λ_2 sont des coefficients de frottement positifs ou nuls. Réduire l'équation différentielle à l'ordre 1, la résoudre et déterminer les points d'équilibre. En supposant $m_1 = m_2$, $\lambda_1 = \lambda_2$,

$k_1 = k_2 = k_{12}$, étudier leur stabilité pour $\lambda > 0$ et $\lambda = 0$. *On pourra considérer les nouvelles variables $y_1 + y_2$ et $y_1 - y_2$.* (Solution p. 65.)

Théorème – Lien entre stabilité et stabilité du linéarisé tangent.

Soit le système défini par $\dot{x} = f(x)$ avec $f : X \to \mathbb{R}^n$ continûment différentiable et $a \in X$ un point d'équilibre.

Si les valeurs propres de la matrice jacobienne $J_f(a)$ sont toutes à partie réelle strictement négative (Hurwitz) alors a est localement asymptotiquement stable.

Si $J_f(a)$ a au moins une valeur propre à partie réelle strictement positive, alors a est instable.

Démonstration. Pour le premier point, voir la question 5 de l'exercice *Critères de stabilité de Lyapunov* (p. 33), et pour le second, la question 4 de l'exercice *Critères d'instabilité* (p. 33).■

Notons cependant que rien ne peut être conclu quant à la stabilité (ou stabilité asymptotique) de a si les parties réelles de $J_f(a)$ sont négatives ou nulles : on peut avoir asymptotiquement stable, seulement stable ou instable. Par exemple, 0 est globalement asymptotiquement stable pour $\dot{x} = -x^3$ mais instable pour $\dot{x} = x^3$ alors que ces deux dynamiques ont le même linéarisé (nul) en zéro. Dans ce cas, des critères non linéaires doivent être utilisés (voir les exercices *Critères de stabilité de Lyapunov* (p. 33) et *Critères d'instabilité* (p. 33)).

Exemple – Retour au pendule.

Reprenons l'exemple du pendule amorti (p. 24). On a

$$J_f(0,0) = \begin{pmatrix} 0 & 1 \\ -\frac{g}{\ell} & -\frac{\rho}{m} \end{pmatrix} \quad , \quad J_f(\pi,0) = \begin{pmatrix} 0 & 1 \\ \frac{g}{\ell} & -\frac{\rho}{m} \end{pmatrix}$$

Dans le premier cas, $\mathrm{tr}(J_f(0,0)) < 0$ et $\det(J_f(0,0)) > 0$. Comme prouvé en exercice (p. 26), ceci implique en dimension 2 que $J_f(0,0)$ est de Hurwitz. Donc la position basse $(0,0)$ est bien un équilibre asymptotiquement stable. Dans le deuxième cas par contre, le produit des valeurs propres $\lambda_1\lambda_2 = \det(J_f(\pi,0)) < 0$. Elles ne peuvent donc pas être complexes conjuguées et sont nécessairement réelles de signes opposés. Il s'ensuit que l'une est strictement positive et la position haute $(\pi,0)$ est donc bien instable.

Notons que si $\rho = 0$, c'est-à-dire que le pendule n'est pas amorti, les valeurs propres $J_f(0,0)$ sont imaginaires pures, et l'on ne peut donc rien conclure quant à la stabilité des points d'équilibre. Une étude plus approfondie est nécessaire.

Exercice – Stabilité asymptotique I (•) Montrer que le point d'équilibre $(0,0)$ est localement asymptotiquement stable pour le système

$$\begin{aligned} \dot{x}_1 &= x_2(1 - x_2^2) \\ \dot{x}_2 &= -(x_1 + x_2)(1 - x_1^2) \end{aligned}$$

L'est-il globalement ? (Solution p. 66.)

Lorsque le linéarisé ne permet pas de conclure sur la stabilité asymptotique locale, ou que l'on veut un résultat global, on a recours à des caractérisations non linéaires, notamment celle de *Lyapunov* présentée en exercice (p. 32). Elle consiste à étudier, le long des solutions de l'équation différentielle, l'évolution d'une quantité positive, semblable à une énergie, qui s'annule

seulement au niveau du point d'équilibre. En démontrant que cette quantité est conservée, ou mieux, décroît le long des solutions, on peut typiquement déduire des propriétés de stabilité ou stabilité asymptotique (potentiellement globale) du point d'équilibre.

Théorème – Stabilité par décroissance d'une fonction définie positive.

Soient X ouvert de $\mathbb{R}^n$, $f : X \to \mathbb{R}^n$ continue, a un point d'équilibre de f dans X, W un voisinage de a dans X, et $V : W \to \mathbb{R}_{\geq 0}$ continue telle que

$$V(x) > 0 \quad \forall x \in W \setminus \{a\} \qquad , \qquad V(a) = 0 \ .$$

Si toute solution $x : I \to \mathbb{R}^n$, $0 \in I$, de $\dot{x} = f(x)$ initialisée dans W est telle que $t \mapsto V(x(t))$ est décroissante sur tout intervalle $[0, t_1] \subset I$ sur lequel $x(t) \in W$, alors a est stable.

Démonstration. Prenons $\varepsilon > 0$ suffisamment petit tel que $B_f(a, 2\varepsilon) \subset W$. Montrons qu'il existe η tel que toute solution initialisée dans $B(a, \eta)$ reste dans $B(a, \varepsilon) \subset W$. Tout d'abord, il existe $\varepsilon_V > 0$ tel que

$$\forall x \in B_f(a, 2\varepsilon) \ : \ V(x) \leq \varepsilon_V \implies x \in B(a, \varepsilon) \ .$$

En effet, sinon, il existerait une suite $(x_k)_{k\in\mathbb{N}}$ d'éléments de $B_f(a, 2\varepsilon)$ telle que pour tout $k > 0$, $V(x_k) \leq \frac{1}{k}$ et $\|x_k - a\| \geq \varepsilon$. L'ensemble $B_f(a, 2\varepsilon)$ étant compact, on peut en extraire une sous-suite convergeant vers $x^\star$ qui vérifie nécessairement $V(x^\star) = 0$ par continuité de V et $\|x^\star - a\| \geq \varepsilon$, i.e. $x^\star \neq a$. Ceci est impossible par hypothèse. On a donc l'existence de ε_V. Maintenant, par continuité de V en a et puisque $V(a) = 0$, il existe aussi $\eta > 0$ tel que

$$x \in B(a, \eta) \implies V(x) \leq \varepsilon_V \ .$$

Finalement, soit une solution maximale x de $\dot{x} = f(x)$ avec $x(0) \in B(a, \eta)$. Montrons que $x(t) \in B(a, \varepsilon)$ pour tout $t \geq 0$ où elle est définie. Supposons par l'absurde que x sorte de $B_f(a, 2\varepsilon)$, et notons

$$t_1 = \inf\{t \geq 0 \ : \ \|x(t) - a\| > 2\varepsilon\} \ ,$$

qui est strictement positif puisque $\|x(0) - a\| < \eta < \varepsilon$ et x est continue. Sur $[0, t_1]$, $x(t) \in B_f(a, 2\varepsilon) \subset W$, donc par décroissance de $t \mapsto V(x(t))$ par hypothèse, $V(x(t)) \leq V(x(0)) \leq \varepsilon_V$ et ainsi $x(t) \in B(a, \varepsilon)$. En particulier $\|x(t_1) - a\| < \varepsilon$, alors que par continuité et définition de t_1, $\|x(t_1) - a\| = 2\varepsilon$: contradiction. Donc $x(t)$ reste dans $B_f(a, 2\varepsilon)$, et le même argument montre alors que $x(t) \in B(a, \varepsilon) \subset W$ pour tout $t \geq 0$ où elle est définie. Elle reste donc dans un compact de X, et par le théorème du domaine maximal d'existence (p. 13), x est définie sur $\mathbb{R}_{\geq 0}$. On obtient la stabilité de a. ■

Exemple – Stabilité du pendule.

Reprenons le pendule (p. 24) mais cette fois-ci, non amorti, c'est-à-dire avec $\rho = 0$. Nous n'avons pas pu prouver la stabilité du point d'équilibre $(0, 0)$ par l'étude de la matrice Jacobienne car ses valeurs propres sont imaginaires pures. Inspirés par la physique, considérons $V :]-\pi, \pi[\times \mathbb{R} \to \mathbb{R}_{\geq 0}$ définie par

$$V(x_1, x_2) = \frac{1}{2} m\ell^2 x_2^2 + mg\ell(1 - \cos(x_1)) \ .$$

Le premier terme correspond à l'énergie cinétique du pendule, et le deuxième son énergie

potentielle. V est continue, à valeurs positives et s'annule seulement en $x = 0$. De plus, pour toute solution $t \mapsto x(t)$,

$$\begin{aligned}\frac{d}{dt}V(x(t)) &= m\ell^2 x_2(t)\dot{x}_2(t) + mg\ell\sin(x_1(t))\dot{x}_1(t)\\ &= m\ell^2 x_2(t)\left(-\frac{g}{\ell}\sin(x_1(t))\right) + mg\ell\sin(x_1(t))x_2(t)\\ &= 0\end{aligned}$$

ce qui traduit la conservation de l'énergie en l'absence de frottement. On en déduit donc la stabilité du point d'équilibre $(0, 0)$.

Remarque – Fonctions et critères de Lyapunov.

Une telle fonction V décroissante le long des solutions est appelée *fonction de Lyapunov*. Comme dans l'exemple précédent, on vérifie sa décroissance en étudiant le signe, de

$$\frac{d}{dt}V(x(t)) = \langle \nabla V(x(t)), \dot{x}(t)\rangle = \langle \nabla V(x(t)), f(x(t))\rangle \ .$$

Mais vu que l'on ne sait généralement pas résoudre l'équation différentielle, on ne connaît pas l'expression de $x(t)$ et on se ramène donc à étudier le signe de la quantité $\langle \nabla V(x), f(x)\rangle$ pour $x \in \mathbb{R}^n$ dans un voisinage de a, ou globalement, par un calcul algébrique sans considérer les solutions de l'équation différentielle. Ceci débouche sur les critères de *Lyapunov* présentés en exercice (p. 32). On peut se demander s'il existe toujours une telle fonction de Lyapunov, autour d'un point d'équilibre stable/asymptotiquement stable. La réponse est oui, mais c'est une question délicate étudiée en détail dans (Bacciotti and Rosier 2005).

Au delà de la stabilité donnée par le résultat précédent, les conditions de Lyapunov permettent aussi de démontrer la stabilité asymptotique locale du point d'équilibre lorsque l'on a une décroissance *stricte*, c'est-à-dire lorsque $\langle \nabla V(x), f(x)\rangle < 0$ pour $x \neq a$ dans un voisinage de a. Cette stabilité asymptotique devient *globale* lorsque cette inégalité est valide globalement et lorsque de plus la fonction V est propre, c'est-à-dire si $\lim_{\|x\|\to+\infty} V(x) = +\infty$. Attention cette dernière hypothèse est importante car elle garantit que les solutions restent bornées et sont bien définies sur $\mathbb{R}_{\geq 0}$. Sinon on pourrait avoir des solutions qui explosent en temps fini alors que V décroît strictement.

Souvent cependant, la fonction de Lyapunov V ne décroît pas *strictement* et ces derniers critères ne s'appliquent pas. On étudie alors la convergence asymptotique des solutions vers le point d'équilibre de manière ad-hoc en utilisant une variation très pratique du fameux *lemme de Barbalat*.

Théorème – Lemme de Barbalat.

Soit $v : [t_0, +\infty[\to \mathbb{R}$ *de classe* C^2 *telle que*

- $\lim_{t\to+\infty} v(t)$ *existe et est finie,*
- $\ddot{v}$ *est bornée sur* $[t_0, +\infty[$.

Alors $\lim_{t\to+\infty} \dot{v}(t) = 0$.

Démonstration. La première hypothèse dit que $\int_{t_0}^{+\infty} \dot{v}(t)dt$ est finie et la deuxième implique que $\dot{v}$ est uniformément continue sur $[t_0, +\infty[$. Le lemme de Barbalat (dans son énoncé classique) permet alors de conclure que $\dot{v}$ converge vers zéro. ■

Toujours dans le contexte d'une fonction définie positive décroissante, et en supposant que f et V sont aussi régulières que nécessaires, on a le fait que $v(t) = V(x(t))$ décroît, et donc $\dot{v}(t) \leq 0$ pour tout $t \geq 0$. Comme v est minorée par 0, elle converge asymptotiquement. Si on a par ailleurs démontré la bornitude des solutions (en temps positif), on a typiquement aussi celle de leurs dérivées puisque $\dot{x} = f(x)$, et donc aussi celle de $\ddot{v}$. Par Barbalat, on déduit que $\dot{v}(t) = \langle \nabla V(x(t)), f(x(t)) \rangle$ tend vers 0, inférant ainsi des propriétés asymptotiques sur les solutions. Par l'application répétée de Barbalat, on peut arriver à montrer l'attractivité locale ou globale du point d'équilibre, qui s'ajoute à la stabilité pour donner sa stabilité asymptotique.

Remarque – Méthode non-linéaire d'analyse de stabilité.

La méthode consiste donc à

- chercher une fonction V définie positive par rapport au point d'équilibre qui décroît le long des solutions (on considère souvent des sommes de carrés);
- en déduire la stabilité du point d'équilibre par théorème (p. 28);
- montrer que les solutions sont bornées en temps positif (par exemple en utilisant que $\lim_{\|x\|\to+\infty} V(x) = +\infty$, voir exercice (p. 15));
- en déduire par récurrence que toutes les dérivées successives nécessaires des solutions sont bornées en utilisant que $\dot{x} = f(x)$ et la régularité de f;
- utiliser le lemme de Barbalat (potentiellement un certain nombre de fois sur les dérivées successives) pour montrer que les solutions (toutes ou celles dans un voisinage) convergent vers le point d'équilibre;
- combiner avec la stabilité pour déduire la stabilité asymptotique locale ou globale.

Exercice – Oscillateurs couplés II (••) Reprendre l'exercice sur les oscillateurs couplés (p. 26) et démontrer la stabilité du point d'équilibre dans le cas général. Montrer que les solutions sont bornées en temps positif et que le point d'équilibre est globalement asymptotiquement stable si $\lambda_1 > 0$ ou $\lambda_2 > 0$. On pourra pour cela considérer l'énergie mécanique du système. (Solution p. 66.)

Exercice – Stabilité asymptotique II (••) Montrer que $(0, 0)$ est globalement asymptotiquement stable pour

$$\begin{aligned} \dot{x}_1 &= x_2 \\ \dot{x}_2 &= -x_1^3 - x_2 \end{aligned}$$

Indice : x_2^2 donne de la négativité en x_2, voir comment compléter avec des termes positifs en x_1... (Solution p. 67.)

6. Exercices complémentaires

En plus des exercices essentiels, les exercices à maîtriser sont marqués d'une croix (+).

6.1. Ecoulement dans un réservoir (+)

Considérons un réservoir cylindrique de section S qui se vide par une ouverture de section s située à sa base. On note x la hauteur de liquide dans le réservoir. D'après la *loi de Torricelli*[1], l'équation d'évolution de x est donnée par

$$\dot{x} = -k\sqrt{|x|} \qquad k = \frac{s}{S}\sqrt{2g}$$

où g est la pesanteur.

Question 1 Etant donné un temps initial t_0 et une hauteur initiale $x_0 \geq 0$, justifier sans calcul que le problème de Cauchy associé admet des solutions et que les solutions maximales sont définies sur $\mathbb{R}$. Que pouvons-nous dire a priori sur l'unicité des solutions maximales ? (Solution p. 68.)

Question 2 Pour $(t_0, x_0) \in \mathbb{R} \times \mathbb{R}_{\geq 0}$, résoudre le problème de Cauchy associé. (Solution p. 68.)

Question 3 On qualifie la solution de "physique" si elle reste dans $\mathbb{R}_{\geq 0}$. Commenter l'unicité de la solution physique en fonction de x_0. Comment pourrait s'interpréter physiquement la multitude de solutions trouvées ? (Solution p. 69.)

Question 4 Les solutions sont-elles continues par rapport aux conditions initiales au sens du théorème de régularité des solutions (p. 20) donné plus haut ? Pourquoi ? (Solution p. 69.)

6.2. Autour du Lemme de Grönwall

Question 1 (Lemme de Grönwall) Soient I un intervalle de $\mathbb{R}$, $t_0 \in I$, $u, \alpha, \beta : I \to \mathbb{R}_{\geq 0}$ continues, tels que

$$u(t) \leq \alpha(t) + \int_{t_0}^{t} \beta(s)u(s)ds \qquad \forall t \in I \ .$$

Montrer qu'alors

$$u(t) \leq \alpha(t) + \int_{t_0}^{t} \alpha(s)\beta(s) \exp\left(\int_{s}^{t} \beta(r)dr\right) ds \qquad \forall t \in I,\ t \geq t_0 \ .$$

En déduire que si α est constant,

$$u(t) \leq \alpha \exp\left(\int_{t_0}^{t} \beta(r)dr\right) \qquad \forall t \in I,\ t \geq t_0 \ .$$

1. Sous l'hypothèse d'incompressibilité du fluide, la loi de Bernoulli dit que

$$p_s + \rho g h_s + \rho\frac{v_s^2}{2} = p_o + \rho g h_o + \rho\frac{v_o^2}{2}$$

où s fait référence aux quantités à la surface et o à l'ouverture. On a $p_s = p_o$ égales à la pression atmosphérique, $h_s - h_o = x$, $v_s = \frac{s}{S}v_o$ par conservation du débit, et $\dot{x} = -v_s$. On obtient donc

$$\dot{x} = -\frac{1}{\sqrt{\left(\frac{S}{s}\right)^2 - 1}}\sqrt{2gx} \approx -\frac{s}{S}\sqrt{2gx}$$

en supposant que $s \ll S$.

Indice : poser $v(t) = \int_{t_0}^{t} \beta(s)u(s)ds$ *et étudier la dérivée de* $v(t)\exp\left(-\int_{t_0}^{t}\beta(r)dr\right)$. (Solution p. 69.)

Question 2 Utiliser le Lemme de Grönwall pour montrer le théorème d'existence globale de solutions (p. 14). (Solution p. 70.)

Question 3 Utiliser le Lemme de Grönwall pour montrer le théorème de continuité par rapport aux conditions initiales (p. 20). Expliquer pourquoi le théorème est toujours valable si f est seulement localement lipschitzienne par rapport à x sur $J \times X$. (Solution p. 70.)

6.3. Cycle limite I (+)

Considérons le système

$$\begin{aligned} \dot{x}_1 &= x_1 + x_2 - x_1(x_1^2 + x_2^2) \\ \dot{x}_2 &= -x_1 + x_2 - x_2(x_1^2 + x_2^2) \end{aligned}$$

Question 1 Montrer que ce système admet un seul point d'équilibre. Etudier sa stabilité. (Solution p. 71.)

Question 2 Montrer que quelle que soit la condition initiale, le système admet une unique solution maximale $x : I \to \mathbb{R}^2$. Soit $V : \mathbb{R}^2 \to \mathbb{R}$ définie par $V(x) = \|x\|^2 = x_1^2 + x_2^2$. En étudiant le signe de $\frac{d}{dt}V(x(t))$, montrer que $[t_0, +\infty[\subset I$. (Solution p. 71.)

Question 3 Montrer que si $\|x(t_0)\| \neq 1$ alors $\|x(t)\| \neq 1$ pour tout $t \in I$. (Solution p. 72.)

Question 4 En déduire le comportement des solutions en fonction de la condition initiale. (Solution p. 72.)

6.4. Critères de stabilité de Lyapunov

Soient X ouvert de $\mathbb{R}^n$, $f : X \to \mathbb{R}^n$ continue, a un point d'équilibre de f dans X, W un voisinage de a dans X, et $V : W \to \mathbb{R}_{\geq 0}$ continûment différentiable telle que

$$V(x) > 0 \quad \forall x \in W \setminus \{a\} \qquad , \qquad V(a) = 0 \ .$$

Question 1 Montrer que si $\langle \nabla V(x), f(x) \rangle \leq 0$ pour tout $x \in W$ alors a est stable. (Solution p. 72.)

Question 2 Montrer que si $\langle \nabla V(x), f(x) \rangle < 0$ pour tout $x \in W \setminus \{a\}$ alors a est localement asymptotiquement stable. (Solution p. 73.)

Question 3 Montrer que si $\lim_{\|x\| \to +\infty} V(x) = +\infty$, $W = \mathbb{R}^n$, et $\langle \nabla V(x), f(x) \rangle < 0$ pour tout $x \neq a$ alors a est globalement asymptotiquement stable. (Solution p. 74.)

Question 4 (Application à la stabilité des systèmes linéaires) Soit $A \in \mathbb{R}^{n \times n}$ dont les valeurs propres sont toutes à partie réelle strictement négative, et soit $Q \in \mathbb{R}^{n \times n}$ une matrice symétrique définie positive. Montrer qu'il existe une matrice symétrique définie positive $P \in \mathbb{R}^{n \times n}$ telle que

$$A^\top P + PA = -Q \ .$$

On pourra considérer $P = \int_0^{+\infty} \left(e^{As}\right)^\top Q e^{As} ds$. En déduire une fonction de Lyapunov pour le système $\dot{x} = Ax$ et retrouver que 0 est globalement asymptotiquement stable. (Solution p. 74.)

Question 5 (Application à la stabilité via linéarisé tangent) Soit $f : X \to \mathbb{R}^n$ continûment différentiable et $a \in X$ un point d'équilibre de f tel que les valeurs propres de la matrice jacobienne $J_f(a)$ sont toutes à partie réelle strictement négative. Montrer que a est localement asymptotiquement stable pour $\dot{x} = f(x)$, c'est-à-dire démontrer le premier point du théorème *Lien entre stabilité et stabilité du linéarisé tangent* (p. 27). (Solution p. 74.)

6.5. Critères d'instabilité

Soient X ouvert de $\mathbb{R}^n$, $f : X \to \mathbb{R}^n$ continue et $a \in X$ un point d'équilibre de f.

Question 1 (Théorème de Chetaev) Soient W un voisinage de a dans X et $V : W \to \mathbb{R}$ continûment différentiable telle que $V(a) = 0$ et

- V prend des valeurs strictement positives arbitrairement près de a : pour tout $\eta > 0$, il existe $x \in W$ tel que $\|x - a\| < \eta$ et $V(x) > 0$;
- $\langle \nabla V(x), f(x) \rangle > 0$ pour tout $x \in W$ tel que $V(x) > 0$.

Montrer que a est instable. On remarquera que, contrairement aux critères de stabilité, V n'est pas supposée positive. (Solution p. 75.)

Question 2 (Exemples) Montrer que 0 est instable pour $\dot{x} = x^3$ sur $\mathbb{R}$, puis pour le système

$$\dot{x}_1 = x_1 \qquad , \qquad \dot{x}_2 = -x_2$$

sur $\mathbb{R}^2$. *On pourra chercher V sous la forme d'une forme quadratique.* (Solution p. 75.)

Question 3 (Application à l'instabilité des systèmes linéaires (••)) Soit $A \in \mathbb{R}^{n \times n}$ ayant au moins une valeur propre à partie réelle strictement positive. Montrer qu'il existe $\sigma > 0$, une matrice symétrique définie positive $Q \in \mathbb{R}^{n \times n}$ et une matrice symétrique $P \in \mathbb{R}^{n \times n}$ vérifiant $\bar{x}^\top P \bar{x} > 0$ pour au moins un $\bar{x} \in \mathbb{R}^n$, telles que

$$A^\top P + PA = 2\sigma P + Q \ .$$

En déduire que 0 est instable pour $\dot{x} = Ax$. (Solution p. 76.)

Question 4 (Application à l'instabilité via linéarisé tangent) Soit $f : X \to \mathbb{R}^n$ continûment différentiable et $a \in X$ un point d'équilibre de f tel que la matrice jacobienne $J_f(a)$ a au moins une valeur propre à partie réelle strictement positive. Montrer que a est instable pour $\dot{x} = f(x)$, c'est-à-dire démontrer le second point du théorème *Lien entre stabilité et stabilité du linéarisé tangent* (p. 27). (Solution p. 77.)

6.6. Cycle limite II (+)

Les équations de Lotka-Volterra, ou "modèle proie-prédateur", sont couramment utilisées pour décrire la dynamique de systèmes biologiques dans lesquels un prédateur et sa proie interagissent dans un milieu commun. Elles ont été proposées indépendamment par A. J. Lotka en 1925 et V. Volterra en 1926 et s'écrivent de la manière suivante :

$$\begin{aligned} \dot{x}_1 &= x_1(\alpha - \beta x_2) \\ \dot{x}_2 &= -x_2(\gamma - \delta x_1) \end{aligned}$$

où x_1 et x_2 désignent le nombre (positif) de proies et de prédateurs respectivement et α, β, γ, δ sont des paramètres strictement positifs.

Question 1 Donner une interprétation physique à chaque terme de la dynamique. Montrer qu'il existe deux points d'équilibre $(0,0)$ et $\bar{x} \in \mathbb{R}_{>0} \times \mathbb{R}_{>0}$. Que peut-on dire de leur stabilité à ce stade ? (Solution p. 77.)

Question 2 Démontrer que toute solution initialisée dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$ reste dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$ sur son ensemble de définition. (Solution p. 78.)

Question 3 On considère la fonction

$$H(x_1, x_2) = \delta x_1 - \gamma \ln x_1 + \beta x_2 - \alpha \ln x_2$$

définie sur $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$. Calculer la dérivée de H le long des solutions initialisées dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$. En déduire que toute solution maximale initialisée dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$ est définie sur $\mathbb{R}$. (Solution p. 78.)

Question 4 La figure ci-dessous représente les courbes de niveau de H. Où se trouve $\bar{x}$? Qu'en conclut-on sur le comportement des solutions ? En déduire que $\bar{x}$ est stable, au sens de la définition de stabilité. (Solution p. 79.)

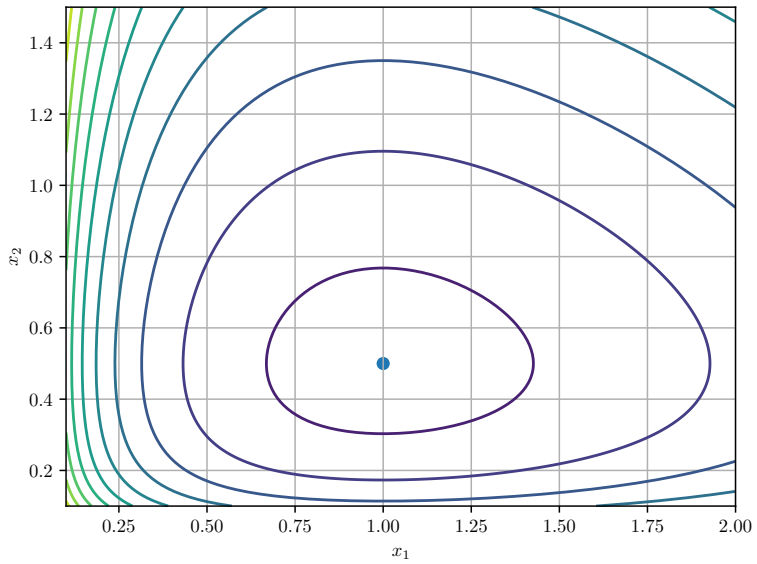


FIGURE 6.1. – Courbes de niveau de H dans l'exercice Cycle Limite II

Imaginons maintenant que l'on ait moyen de jouer sur la vitesse de reproduction des prédateurs, i.e., le système évolue selon

$$\begin{aligned} \dot{x}_1 &= x_1(\alpha - \beta x_2) \\ \dot{x}_2 &= -x_2(\gamma - \delta x_1) + u(t) \end{aligned}$$

où l'on peut choisir $t \mapsto u(t)$ librement. On souhaite stabiliser la population de proie x_1 à une valeur $x_1^* > 0$.

Question 5 Quelles doivent être les valeurs de x_2 et u à l'équilibre ? (Solution p. 79.)

Question 6 Justifier que l'on veuille faire suivre à x_2 la référence $v_r(x_1) = \frac{\alpha}{\beta} + \lambda_1(x_1 - x_1^*)$ avec $\lambda_1 > 0$. En utilisant la fonction de Lyapunov

$$V(x_1, x_2) = (x_1 - x_1^*)^2 + (x_2 - v_r(x_1))^2$$

et en supposant que x est mesuré en temps réel, proposer une loi de contrôle $t \mapsto u(t)$ qui stabilise asymptotiquement (x_1^*, x_2^*), au moins localement. (Solution p. 79.)

6.7. Attractivité locale implique stabilité asymptotique globale pour un système linéaire

Soit $A \in \mathbb{R}^{n\times n}$. Montrer que si 0 est localement attractif pour $\dot{x} = Ax$ alors il l'est globalement et 0 est stable. (Solution p. 80.)

6.8. Stabilisation d'une chaîne d'intégrateurs

Considérons un système du type

$$\begin{aligned} \dot{x}_1 &= x_2 \\ \dot{x}_2 &= x_3 \\ &\vdots \\ \dot{x}_{n-1} &= x_n \\ \dot{x}_n &= \phi(x) + u(t) \end{aligned}$$

avec $\phi : \mathbb{R}^n \to \mathbb{R}$ continue et $u : \mathbb{R} \to \mathbb{R}$ une entrée. On aimerait choisir u pour rendre un point $x^* \in \mathbb{R}^n$ globalement asymptotiquement stable.

Question 1 Que doit vérifier x^* pour qu'il puisse être un point d'équilibre ? Quelle est la commande u^* associée ? (Solution p. 81.)

Question 2 Si on mesure $t \mapsto x(t)$, montrer que l'on peut alors toujours choisir $t \mapsto u(t)$ pour rendre x^* globalement asymptotiquement stable. (Solution p. 81.)

Question 3 Comment faire si l'on veut maintenant faire suivre au système une trajectoire de référence $t \mapsto x_r(t)$? (Solution p. 82.)

6.9. Problème de Kepler : collision, libération et orbites circulaires (••)

On s'intéresse au mouvement d'un satellite (ou d'une planète) de masse négligeable attiré par un corps ponctuel de masse M placé à l'origine. En notant $q \in \mathbb{R}^3$ la position du satellite et $\mu = GM > 0$, avec G la constante de gravitation, la loi de la gravitation universelle donne

$$\ddot{q} = -\mu \frac{q}{\|q\|^3} \ .$$

Résoudre cette équation (le *problème de Kepler*) permet d'établir les lois de Kepler. On se propose ici d'obtenir, *sans la résoudre*, des propriétés qualitatives fortes de ses solutions à l'aide des outils du cours. On écrit l'équation sous la forme d'un système du premier ordre en posant $v = \dot{q}$ et $x = (q, v)$, défini sur l'ouvert $X = (\mathbb{R}^3 \setminus \{0\}) \times \mathbb{R}^3$. Pour une solution $t \mapsto (q(t), v(t))$, on note

$$E = \frac{1}{2}\|v\|^2 - \frac{\mu}{\|q\|} \qquad , \qquad L = q \times v$$

respectivement l'*énergie* (par unité de masse) et le *moment cinétique* (par unité de masse), où $\times$ désigne le produit vectoriel.

Question 1 (Cadre) Montrer que pour toute condition initiale $(q_0, v_0) \in X$, le problème de Cauchy admet une unique solution maximale $(q, v) :]t_m^-, t_m^+[\to X$. Montrer que E et L sont constants le long des solutions. Que dit le théorème du domaine maximal d'existence (p. 13) si $t_m^+ < +\infty$? Interpréter physiquement les deux alternatives. (Solution p. 82.)

Question 2 (Confinement et vitesse de libération) Montrer l'*identité de Lagrange-Jacobi*

$$\frac{d^2}{dt^2}\left(\frac{\|q(t)\|^2}{2}\right) = 2E + \frac{\mu}{\|q(t)\|} \ .$$

En déduire que

- si $E < 0$, alors $\|q(t)\| \leq \frac{\mu}{|E|}$ pour tout $t \in]t_m^-, t_m^+[$ (le satellite reste confiné) ;
- si $E > 0$ et $t_m^+ = +\infty$, alors $\lim_{t\to+\infty} \|q(t)\| = +\infty$ (le satellite s'échappe).

Quelle condition sur la vitesse initiale $\|v_0\|$ garantit $E > 0$? Cette vitesse est appelée *vitesse de libération*. (Solution p. 83.)

Question 3 (Pas de collision si $L \neq 0$) Montrer que $\|L\| \leq \|q\|\,\|v\|$ et en déduire que pour tout $t \in]t_m^-, t_m^+[$,

$$\|L\|^2 \leq 2E\|q(t)\|^2 + 2\mu\|q(t)\| \ .$$

On suppose $L \neq 0$. Montrer qu'il existe $r_{\min} > 0$ tel que $\|q(t)\| \geq r_{\min}$ pour tout t. En déduire que v est bornée, puis que la solution est globale, i.e. $t_m^- = -\infty$ et $t_m^+ = +\infty$. (Solution p. 83.)

Question 4 (Collision en temps fini si $L = 0$) On suppose maintenant $L = 0$ et on note $u = q_0/\|q_0\|$.

a) Montrer que $t \mapsto \frac{q(t)}{\|q(t)\|}$ est constante, et donc que $q(t) = r(t)\,u$ avec $r(t) = \|q(t)\| > 0$. Montrer que r vérifie

$$\ddot{r} = -\frac{\mu}{r^2} \ .$$

b) On suppose de plus $E < 0$. Montrer que $t_m^+ < +\infty$ et que $\lim_{t\to t_m^+} \|q(t)\| = 0$: le satellite percute le corps central en temps fini. *Indice : raisonner par l'absurde en supposant $t_m^+ = +\infty$, distinguer selon le signe de $\dot{r}$, et utiliser le Lemme de Barbalat (p. 29).*

(Solution p. 83.)

Question 5 (Stabilité des orbites circulaires) On suppose à nouveau $L \neq 0$ et on note $\ell = \|L\|$ et $r(t) = \|q(t)\|$.

a) Montrer l'identité $\|q \times v\|^2 = \|q\|^2\|v\|^2 - (q \cdot v)^2$ et en déduire que r est solution de l'équation différentielle *autonome*

$$\ddot{r} = \frac{\ell^2}{r^3} - \frac{\mu}{r^2}$$

sur $\mathbb{R}_{>0}$.

b) Montrer que le système d'état $(r, \dot{r})$ associé admet un unique point d'équilibre $(r^*, 0)$, que l'on exprimera en fonction de ℓ et μ. A quel mouvement du satellite correspond-il ?

c) Montrer que le théorème du linéarisé tangent ne permet pas de conclure quant à la stabilité de cet équilibre.

d) Exprimer E en fonction de r et $\dot{r}$ et en déduire une fonction définie positive permettant de montrer que $(r^*, 0)$ est stable. Est-il asymptotiquement stable ? Interpréter.

e) Pourquoi ne peut-on pas parler de stabilité de l'orbite circulaire pour le système complet d'état (q, v) avec les définitions du cours ?

(Solution p. 84.)

7. Annexes

7.1. Preuve du théorème de Peano-Arzelà (Hors-programme)

Cette preuve repose sur le théorème d'Ascoli :

> Soient K un espace métrique compact, Y un espace métrique complet, et $S \subset C(K,Y)$, où $C(K,Y)$ est l'ensemble des fonctions continues de K dans Y. Les deux propriétés suivantes sont équivalentes :
>
> 1. S est *relativement compact* dans $C(K,Y)$
> 2. S est *équicontinu* et pour tout $z \in K$, $\{g(z)\ ,\ g \in S\}$ est *relativement compacte* dans Y.

On dit qu'un ensemble est *relativement compact* si son adhérence est compacte. En dimension finie, vu que "compact" est équivalent à "fermé-borné" et que l'adhérence est fermée par définition, "relativement compact" est équivalent à "borné". Mais ce n'est pas le cas en dimension infinie (en particulier $C(K,Y)$) où "relativement compact" est alors équivalent au fait de pouvoir extraire des suites convergentes dans l'adhérence de l'ensemble.

Ici, puisque K est compact et Y complet, on peut montrer que $C(K,Y)$ muni de la norme uniforme $\|\cdot\|_\infty$ est complet, donc fermé. Il s'ensuit que "S est relativement compact dans $C(K,Y)$" implique pouvoir extraire de toute suite de S une sous-suite convergente dans $C(K,Y)$ (au sens de $\|\cdot\|_\infty$). C'est ce que nous allons utiliser pour prouver l'existence d'une solution au problème de Cauchy.

Maintenant, le deuxième terme nécessitant des explications est l'*équicontinuité* de S. Cette notion veut simplement dire que les fonctions dans S sont toutes continues *au même rythme*, i.e., plus précisément,

$$\forall \varepsilon > 0\ \exists \delta\ , \quad d_K(z_a, z_b) \leq \delta \implies \forall g \in S\ ,\ d_Y(g(z_a), g(z_b)) \leq \varepsilon\ ,$$

où d_K et d_Y sont les distances sur K et Y respectivement.

Revenons maintenant à nos moutons. On suppose donc f continue sur $J \times X$ et on veut montrer que $S_f(t_0, x_0) \neq \emptyset$. Soient d'abord $\tau > 0$ et $r > 0$, tels que $\mathcal{C} := [t_0 - \tau, t_0 + \tau] \times B_f(x_0, r) \subset J \times X$. Soit $\tau_m \in]0, \tau]$ tel que $\tau_m \max_{\mathcal{C}} \|f\| \leq r$. On va montrer l'existence d'une solution définie par sa forme intégrale

$$x(t) = x_0 + \int_{t_0}^{t} f(s, x(s))ds$$

sur $[t_0, t_0 + \tau_m]$ et la preuve sur $[t_0 - \tau_m, t_0]$ se fait de la même façon.

L'idée est d'approximer de plus en plus finement la forme intégrale et montrer que ce procédé converge. On définit donc pour $\epsilon \in]0, 1[$ la fonction

$$\begin{aligned} x_\epsilon(t) &= x_0 && \forall t \in [t_0 - 1, t_0] \\ &= x_0 + \int_{t_0}^{t} f(s, x_\epsilon(s - \epsilon))ds && \forall t \in [t_0, t_0 + \tau_m] \end{aligned}$$

Ces fonctions sont définies et continues sur $[t_0 - 1, t_0]$. Puis sur $[t_0, t_0 + \epsilon] \cap [t_0, t_0 + \tau_m]$, on voit que l'intégrale ne dépend que de x_ϵ sur $[t_0 - 1, t_0]$, donc elle est toujours bien définie et continue. De proche en proche, x_ϵ est donc bien définie et continue sur $[t_0 - 1, t_0 + \tau_m]$. En fait, ϵ représente un petit retard introduit dans l'intégrale pour la rendre explicite. Si l'on arrive à montrer que ces

fonctions convergent vers une fonction continue lorsque ϵ tend vers 0, cette limite sera solution de l'équation intégrale sur $[t_0, t_0 + \tau_m]$ et sera donc solution.

La première étape est de montrer de proche en proche, grâce au retard, que $x_\epsilon(t) \in B_f(x_0, r)$ pour tout $t \in [t_0 - 1, t_0 + \tau_m]$ puisque $\tau_m \max_{\mathcal{C}} \|f\| \leq r$. Donc

$$\forall \epsilon \in]0,1[\ , \ x_\epsilon \in E := C([t_0 - 1, t_0 + \tau_m], B_f(x_0, r)) \ .$$

De plus, pour tout $\epsilon \in]0,1[$ et pour tout $(t, t') \in [t_0 - 1, t_0 + \tau_m]^2$,

$$\|x_\epsilon(t) - x_\epsilon(t')\| \leq \max_{\mathcal{C}} \|f\| \, |t - t'|$$

donc la famille $S := \{x_\epsilon, \ \epsilon \in]0,1[\}$ est équicontinue. De plus, vu que leur image est bornée dans $B_f(x_0, r)$ de dimension finie, elle est bien relativement compacte. Le théorème d'Ascoli nous dit alors que S est relativement compacte dans E. Il existe donc une sous suite x_{ϵ_k} telle que $\lim_{k \to +\infty} \epsilon_k = 0$ et $\lim_{k \to +\infty} x_{\epsilon_k} = x^\star \in E$ au sens de la norme uniforme $\| \cdot \|$. Par uniforme continuité de f sur le compact $\mathcal{C}$, on en déduit alors que pour tout $s \in [t_0, t_0 + \tau_m]$, $\lim_{k \to +\infty} f(s, x_{\epsilon_k}(s - \epsilon_k)) = f(s, x^\star(s))$ et donc que $x^\star$ est bien solution de l'équation intégrale, ce qui donne le résultat.

7.2. Preuve du théorème du domaine maximal d'existence

Soit $x : I \to \mathbb{R}^n$ une solution dans $S_f(t_0, x_0)$. Si x n'est pas une solution maximale, elle peut être prolongée sur un intervalle I' contenant strictement I par définition, donc on peut supposer sans perte de généralité que I est fermé d'un côté, disons à droite, et nous allons montrer qu'elle peut être prolongée sur un intervalle maximal d'existence à droite. Si elle peut être prolongée sur $[t_0, +\infty)$, c'est directement un intervalle maximal à droite et donc on suppose que x est définie sur $[t_0, t_1]$ et ne peut être prolongée sur $[t_0, +\infty)$. La preuve de ce qu'il se passe à gauche de t_0 est similaire.

Soit K un compact de $J \times X$ contenant $x(t)$ pour $t \in [t_0, t_1]$ (qui existe par continuité de x sur le compact $[t_0, t_1]$). Comme $J \times X$ est ouvert, il existe τ, r strictement positifs tels que

$$\mathcal{C} := \bigcup_{(t_{\text{init}}, x_{\text{init}}) \in K} [t_{\text{init}} - \tau, t_{\text{init}} + \tau] \times B_f(x_{\text{init}}, r) \subset J \times X \ .$$

$\mathcal{C}$ est compact et f continue sur $\mathcal{C}$ donc il existe $0 < \tau_m < \tau$ tel que $\tau_m \max_{\mathcal{C}} \|f\| \leq r$. En reproduisant la preuve du théorème de Peano-Arzelà, on voit que pour toute condition initiale $(t_{\text{init}}, x_{\text{init}})$ dans K, il existe une solution au problème de Cauchy définie au moins sur $[t_{\text{init}} - \tau_m, t_{\text{init}} + \tau_m]$.

Revenons donc à notre solution x définie sur $[t_0, t_1]$ dans K. Dénotant $x_1 := x(t_1)$, on a $(t_1, x_1) \in K$ donc il existe $x' : [t_1 - \tau_m, t_1 + \tau_m] \to \mathbb{R}^n$ dans $S_f(t_1, x_1)$. Alors on peut construire $\tilde{x} : [t_0, t_1 + \tau_m] \to \mathbb{R}^n$ telle que

$$\tilde{x}(t) = \begin{cases} x(t) & \text{si } t \in [t_0, t_1] \\ x'(t) & \text{si } t > t_1 \end{cases}$$

$\tilde{x}$ est bien continue et à valeurs dans $J \times X$ sur $[t_0, t_1 + \tau_m]$. De plus, elle est de classe C^1 sur $]t_0, t_1 + \tau_m[\backslash\{t_1\}$ telle que $\dot{\tilde{x}}(t) = f(t, \tilde{x}(t))$ pour tout $t \in]t_0, t_1 + \tau_m[\backslash\{t_1\}$. Par continuité de $\tilde{x}$ en t_1 et de f en (t_1, x_1), on en déduit que $\tilde{x}$ est bien C^1 sur $]t_0, t_1 + \tau_m[$. Donc $\tilde{x} \in S_f(t_0, x_0)$. On a donc trouvé une prolongation $\tilde{x}$ de la solution x sur l'intervalle $[t_0, t_1 + \tau_m]$. Si $(t_1 + \tau_m, \tilde{x}(t_1 + \tau_m))$ est toujours dans K, on peut itérer le processus. Parce que τ_m est uniforme sur K et K est compact, on construit ainsi en un nombre fini d'itérations une extension $\tilde{x}$ de x qui va finir par sortir de K, c'est-à-dire, définie sur $[t_0, t_K]$ avec $t_K > t_1$ tel que $(t_K, \tilde{x}(t_K)) \notin K$.

Considérons maintenant une suite strictement croissante de compacts (K_n) de $J \times X$, avec $K_0 = K$, telle que pour tout n, $K_n \subset \mathring{K}_{n+1}$ et $\cup_n \mathring{K}_n = J \times X$. Pour chaque n, on construit récursivement une extension $\tilde{x}$ de x sur des intervalles de plus en plus grand $[t_0, t_{K_n}]$ tels que $(t_{K_n}, \tilde{x}(t_{K_n})) \notin K_n$. Puisqu'on a supposé que x n'était pas prolongeable sur $[t_0, +\infty[$, la suite des (t_{K_n}) est strictement croissante, bornée, et on peut donc en extraire une sous-suite qui converge. On note t_m^+ cette limite. On a donc construit une prolongation $\tilde{x}$ de x définie sur $[t_0, t_m^+)$. De plus, par croissance des K_n, la suite des $(t_{K_n}, \tilde{x}(t_{K_n})) \notin K_n$ sort définitivement de chacun des K_n et donc devient "de plus en plus grand' '. Ou bien $(\tilde{x}(t_{K_n}))$ est non-bornée, ou bien $(\tilde{x}(t_{K_n}))$ est bornée, et on peut en extraire une sous-suite qui converge disons vers x^*, qui est dans la frontière de $J \times X$. Donc dans les deux cas, x ne peut pas être prolongée à droite au delà de t_m^+. On a donc bien prolongé x en une solution maximale à droite. On fait de même à gauche.

Maintenant, considérons une solution maximale $x : I \to \mathbb{R}^n$ dans $S_f(t_0, x_0)$. Alors I est ouvert, de la forme $]t_m^-, t_m^+[$ avec t_m^-, t_m^+ dans $\mathbb{R} \cup \{+\infty, -\infty\}$, car sinon, on pourrait prolonger x de la même manière que plus haut sur un intervalle strictement plus grand.

Supposons t_m^+ fini. Montrons qu'alors $\|x(t)\| + 1/d\big((t, x(t)), \partial(J \times X)\big)$ tend vers $+\infty$ lorsque t tend vers t_m^+. La propriété se montre de manière similaire en t_m^-. Pour cela, nous allons montrer que lorsque t se rapproche de t_m^+, $(t, x(t))$ finit par sortir définitivement de tout sous-ensemble K compact de $J \times X$. Cela suffit : pour $M > 0$, l'ensemble

$$K_M = \Big\{(t, x) \in J \times X \ : \ t \leq t_m^+ \ , \ \|x\| \leq M \ , \ d\big((t, x), \partial(J \times X)\big) \geq \frac{1}{M}\Big\}$$

est borné, et fermé dans $\mathbb{R} \times \mathbb{R}^n$ (un point limite de $J \times X$ à distance au moins $1/M$ de la frontière est dans $J \times X$), donc compact ; si $(t, x(t))$ en sort définitivement, alors $\|x(t)\| + 1/d > M$ pour t proche de t_m^+, et ce pour tout M. Soit donc K compact de $J \times X$.

Supposons d'abord qu'il existe τ tel que $(t, x(t)) \in K$ pour tout $t \in [\tau, t_m^+[$. Puisque f est continue, $\|f(t, x)\|$ est borné disons par M sur K. Donc pour toute suite (t_k) d'éléments de $[\tau, t_m^+[$ tendant vers t_m^+, par la représentation intégrale des solutions,

$$\|x(t_{k+p}) - x(t_k)\| \leq \int_{t_k}^{t_{k+p}} \|f(s, x(s))\| ds \leq M(t_{k+p} - t_k) \ .$$

Donc la suite $(x(t_k))$ est de Cauchy et donc aussi la suite $(t_k, x(t_k))$ dans K. Puisque K est un sous-ensemble fermé de $\mathbb{R} \times \mathbb{R}^n$ complet, il est complet. Donc $(t_k, x(t_k))$ converge vers $(t_m^+, \bar{x}) \in K \subset J \times X$. Donc x peut-être prolongée par continuité en une solution sur $]t_m^-, t_m^+]$, ce qui est impossible par maximalité. Donc $(t, x(t))$ sort de manière persistante de K.

Supposons maintenant que $(t, x(t))$ entre aussi de manière persistante dans K, i.e.,

$$\forall t_K \in \Big[t_0, t_m^+\Big[\ , \ \exists t \in \Big[t_K, t_m^+\Big[\ : \ (t, x(t)) \in K$$

Alors il existe une suite $(t_p)_{p \in \mathbb{N}}$ telle que

$$t_m^+ - \frac{1}{p} \leq t_p < t_m^+ \quad \text{et} \quad (t_p, x(t_p)) \in K \quad \forall p \in \mathbb{N}$$

On a donc $\lim_{p \to +\infty} t_p = t_m^+$, et par compacité de K, on peut extraire de $(t_p, x(t_p))_{p \in \mathbb{N}}$ une sous-suite qui converge vers $(t_m^+, \overline{x}) \in K$. Pour simplifier les notations, on suppose donc directement $\lim_{p \to +\infty} x(t_p) = \overline{x}$.

Notons $\xi = (t_m^+, \overline{x})$. Soit $\varepsilon > 0$ tel que $B_f(\xi, 2\varepsilon) \subset J \times X$. Il existe p^* tel que pour tout $p \geq p^*$, $(t_p, x(t_p)) \in B_f(\xi, \varepsilon)$. Mais puisque $B_f(\xi, 2\varepsilon)$ est un sous-ensemble compact de $J \times X$, on sait que $(t, x(t))$ en sort de manière persistante. Donc sans perte de généralité, on peut supposer que pour tout p, il existe $t_p < t'_p < t_{p+1}$ tel que

$$\|(t'_p, x(t'_p)) - \xi\| = 2\varepsilon \qquad , \qquad (t, x(t)) \in B_f(\xi, 2\varepsilon) \quad \forall t \in [t_p, t'_p] \ .$$

Soit alors M le maximum de $\|f\|$ sur le compact $B_f(\xi, 2\varepsilon)$. Par la représentation intégrale, et pour p suffisamment grand, on a donc

$$\frac{\varepsilon}{2} \leq \|x(t'_p) - x(t_p)\| \leq \int_{t_p}^{t'_p} \|f(s, x(s))\| ds \leq M(t'_p - t_p) \leq M(t_{p+1} - t_p) \ .$$

Il s'ensuit que pour p suffisamment grand, $t_{p+1} - t_p \geq \frac{\varepsilon}{2M}$, ce qui est impossible puisque (t_p) tend vers t_m^+. On peut donc conclure que $(t, x(t))$ sort de manière définitive de tout compact K lorsque t s'approche de t_m^+.

8. Références

Bacciotti, A., and L. Rosier. 2005. *Lyapunov Functions and Stability in Control Theory*. 2nd ed. Communications and Control Engineering Series. Springer-Verlag, Berlin.

Filippov, A. F. 1988. *Differential Equations with Discontinuous Right-Hand Sides*. Mathematics and its Applications Kluwer Academic Publishers Group.

Hale, J. K. 2009. *Ordinary Differential Equations*. Dover Publication Inc.

Holmes, P., and D. Rand. 1978. "Bifurcations of the Forced van Der Pol Oscillator." *Quarterly of Applied Mathematics* 35: 495–509.

Lyapunov, A. 1892. "The general problem of the stability of motion." Kharkov Mathematical Society.

Moigno. 1844. "26ème Leçon." In *Leçons de Calcul Différentiel et Intégral, Rédigées Principalement d'après Les Méthodes de M. A.-L. Cauchy, et étendues Aux Travaux Les Plus Récents Des Géomètres*, pages 385–96. Bachelier, Imprimeur-Libraire de l'Ecole Polytechnique. `https://books.google.fr/books?id=booAAAAAMAAJ&pg=PA385#v=onepage&q&f=false`.

Poincaré, H. 1892. *Les Méthodes Nouvelles de La Mécanique Céleste*. Gauthier-Villars, Imprimeur-Libraire de l'Ecole Polytechnique. `https://iris.univ-lille.fr/handle/1908/3851`.

Sussman, G. J., and J. Wisdom. 1992. "Chaotic Evolution of the Solar System." *Science*, 1992.

Deuxième partie

Simulation numérique des solutions

1. Introduction

Ce chapitre est consacré à la résolution numérique d'équations différentielles

$$\dot{x} = f(t, x) \qquad , \qquad x(t_0) = x_0 \ .$$

La nécessité de développer des méthodes d'intégration numériques vient du constat que seule une infime partie des équations différentielles sont résolubles exactement. Or, on a parfois besoin de connaître le plus précisément possible le comportement futur d'un système dynamique :

- soit en temps fini, par exemple pour déterminer la trajectoire d'une fusée pour la mise en orbite d'un satellite;
- soit en temps *long*, par exemple pour déterminer un cycle limite asymptotique (dynamique de population) ou bien se prononcer sur la stabilité de notre système solaire.

La méthode la plus connue est la *méthode d'Euler* datant de 1768, qui consiste à implémenter

$$x^{j+1} = x^j + \Delta t \, f(t_j, x^j) \qquad x^0 = x_0$$

pour un pas de temps Δt suffisamment petit. Cette méthode appartient à la famille des méthodes *explicites*, c'est-à-dire que x^{j+1} est directement et explicitement défini en fonction de x^j. En 1824, Cauchy montre la convergence de cette méthode lorsque le pas de temps Δt tend vers 0, et prouve ainsi l'existence et l'unicité des solutions (en fait, il utilise plutôt la version *implicite* de la méthode d'Euler).

Même si la méthode d'Euler suffit dans les cas simples, elle exige parfois de recourir à des pas très faibles pour obtenir une précision acceptable sur des temps longs (voir Systèmes raides (p. 43)). Parfois, le compromis entre précision à chaque itération et accumulation des erreurs d'arrondis devient même impossible. De plus, cette méthode n'est pas adaptée à la simulation de certains systèmes dont certaines propriétés cruciales (comme la conservation de l'énergie) ne sont pas préservées (voir Systèmes Hamiltoniens (p. 44)). Au cours des derniers siècles, les scientifiques ont donc progressivement développé des méthodes de plus en plus complexes et performantes : schémas multi-pas d'ordre supérieur, méthodes implicites, variation du pas, schémas symplectiques etc.

En fait, dans l'histoire des équations différentielles, c'est souvent la mécanique céleste qui a été motrice des plus grandes avancées. Au milieu du XIXe siècle, les astronomes Adams et Le Verrier prédisent mathématiquement l'existence et la position de la planète Neptune et l'on entend parler pour la première fois de méthodes multi-pas. Ensuite, les progrès se sont enchaînés au rythme des modèles physiques. La première tendance a été de rechercher des schémas permettant toujours plus de précision à pas plus grand. Parmi les dates clés, on peut citer la publication en 1895 de la première méthode de Runge-Kutta par Runge, puis en 1901, de la populaire méthode de Runge-Kutta d'ordre 4 par Kutta, et ensuite en 1910, de l'*extrapolation de Richardson* permettant la montée en ordre et donc le recours à des pas plus grand pour une même précision. Mais au milieu du XXe siècle, on découvre des systèmes, dits *raides* (Hirschfelder, 1952), pour lesquels cette montée en ordre ne suffit pas et pour lesquels il faut repenser de nouveaux schémas (Dalquist, 1968). Enfin, à partir des années 80, les scientifiques développent l'intégration numérique *géométrique*, c'est-à-dire qui préservent les propriétés structurelles du système (symétrie, conservation d'énergie etc.), utile en particulier pour la simulation des systèmes hamiltoniens.

2. Objectifs du cours

Ce cours a pour but de sensibiliser aux problèmes apparaissant lors de la simulation numérique des solutions d'équations différentielles, et de donner les bases d'analyse d'erreur numérique. Pour un exposé plus approfondi, on pourra par exemple se référer à (Demailly 2006).

En première lecture :

- comprendre les limites d'un schéma d'Euler.
- comprendre qu'un schéma numérique à un pas consiste à discrétiser une intégrale, en connaître quelques-uns autres que le schéma d'Euler.
- comprendre les notions de consistance/convergence d'un schéma et leur ordre. Savoir montrer que le schéma d'Euler explicite est convergent d'ordre 1.

En deuxième lecture :

- comprendre comment fonctionne un schéma implicite, comment l'implémenter, et quand il est pertinent de l'utiliser (systèmes raides ou non-lisses par exemple).
- savoir calculer l'ordre de consistance et montrer la convergence de schémas de base.
- comprendre l'apport de schémas symplectiques pour les systèmes hamiltoniens.
- comprendre que la convergence est la combinaison de deux concepts : la consistance et la stabilité ; savoir utiliser ces notions pour évaluer l'impact des erreurs d'arrondi.

3. Limites du schéma d'Euler

La première limite du schéma d'Euler est qu'il est d'ordre 1, c'est-à-dire qu'il produit une erreur en Δt^2 à chaque pas. Nous verrons dans la suite des algorithmes d'ordre supérieur qui permettent d'utiliser un pas plus grand pour une précision donnée. Mais au delà de cette problématique, il existe des systèmes pour lesquels de telles méthodes (même d'ordre supérieur) échouent. En voici deux exemples célèbres.

3.1. Systèmes raides

La dénomination *systèmes raides* a été introduite en 1952 par Hirschfelder pour désigner des systèmes comprenant des dynamiques aux constantes de temps très différentes. Dans ce cas, le pas nécessaire pour simuler avec précision les dynamiques très rapides est si petit, qu'il est alors impossible de simuler assez longtemps pour observer les parties lentes. La particularité de ces systèmes est que cette décroissance du pas apparaît alors que la solution est parfaitement régulière, et non pas proche de singularités. C'est le cas des systèmes linéaires

$$\dot{x} = Ax + b$$

avec A de Hurwitz quand le rapport entre les parties réelles maximales et minimales des valeurs propres devient très grand. Ce phénomène peut notamment apparaître dans un simple système masse/ressort

$$m\ddot{y} = -\rho\dot{y} - ky$$

qui se met sous la forme précédente avec $x = (y, \dot{y}) \in \mathbb{R}^2$ et $A = \begin{pmatrix} 0 & 1 \\ -\frac{k}{m} & -\frac{\rho}{m} \end{pmatrix}$. Lorsque les valeurs propres sont réelles (i.e. $\rho > 2\sqrt{mk}$), leur rapport est donné par

$$\frac{1 + \sqrt{1 - 4\frac{mk}{\rho^2}}}{1 - \sqrt{1 - 4\frac{mk}{\rho^2}}}$$

qui explose lorsque $\frac{mk}{\rho^2}$ tend vers 0. Par exemple, lorsque les frottements sont très grands par rapport à la raideur du ressort, ou bien lorsque ρ et k sont du même ordre de grandeur et très grands.

Plus généralement, la coexistence de dynamiques très lentes à très rapides apparaît en cinétique chimique ou en biologie. La réaction de Robertson (1966)

$$\begin{aligned} A &\xrightarrow{0.04} B \quad \text{(lente)} \\ B + B &\xrightarrow{3\times10^7} B + C \quad \text{(très rapide)} \\ B + C &\xrightarrow{10^4} A + C \quad \text{(rapide)} \end{aligned}$$

modélisée par

$$\begin{aligned} \dot{x}_a &= -0.04x_a + 10^4 x_b x_c \\ \dot{x}_b &= 0.04x_a - 10^4 x_b x_c - 3 \times 10^7 x_b^2 \\ \dot{x}_c &= 3 \times 10^7 x_b^2 \end{aligned}$$

en est un exemple classique, souvent utilisée pour tester les schémas numériques. Il s'avère que pour ces systèmes, des schémas dits *implicites* performent beaucoup mieux car ils autorisent l'utilisation de pas plus grands pour une même précision et plus de stabilité (voir l'exercice *Explicite ou Implicite?* (p. 60)). Pour plus de détails voir (Hairer and Wanner 1996). L'impossibilité de trouver un pas approprié avec un schéma d'Euler explicite pour ce système, et la résolution du problème par Euler implicite, sont aussi illustrés dans le notebook Equations Differentielles II.ipynb. A noter que l'utilisation des schémas implicites est aussi cruciale dans la simulation des sytèmes non-lisses (f discontinue), qui apparaissent en mécanique par exemple (frottement sec), voir l'exercice ci-dessus.

3.2. Systèmes hamiltoniens

La mécanique hamiltonienne permet typiquement de modéliser le comportement de systèmes dont une certaine énergie est conservée au cours du temps. Il peut s'agir par exemple de planètes en interaction gravitationnelle, de particules en interaction électromagnétique, etc.

Par exemple, dans un problème à N corps en interaction gravitationnelle, l'hamiltonien s'écrit [1]

$$H(q,p) = \sum_{i=1}^{N} \frac{1}{2m_i} p_i^\top p_i - \sum_{1 \le i < k \le N} G \frac{m_i m_j}{\|q_i - q_k\|}$$

1. Pour obtenir l'hamiltonien, on commence par définir le lagrangien $L(t, q, \dot{q})$, puis la quantité de mouvement $p = \nabla_{\dot{q}} L(t, q, \dot{q})$, et enfin l'hamiltonien $H(t, q, p)$ est obtenu par transformée de Legendre. Notons que dans ce cas général où H peut dépendre explicitement du temps (par exemple si de l'énergie est injectée ou prélevée par une action extérieure au système), on a $\frac{d}{dt} H(t, q(t), p(t)) = \nabla_t H(t, q(t), p(t))$, donc l'hamiltonien varie selon cet effet extérieur, et n'est plus constant.

où $q_i \in \mathbb{R}^3$ désigne la position de chaque corps, m_i sa masse, et $p_i = m_i \dot{q}_i \in \mathbb{R}^3$ sa quantité de mouvement. Le comportement de chaque corps est alors régi par la dynamique hamiltonienne [2]

$$\dot{q}_i = \nabla_{p_i} H(q,p) = \frac{1}{m_i} p_i$$
$$\dot{p}_i = -\nabla_{q_i} H(q,p) = -G \sum_{k \neq i} \frac{m_i m_j}{\|q_i - q_k\|^3} (q_i - q_k)$$

On a alors le long des trajectoires

$$\frac{d}{dt} H(q(t),p(t)) = \langle \nabla_q H(t,q(t),p(t)), \dot{q} \rangle + \langle \nabla_p H(t,q(t),p(t)), \dot{p} \rangle = 0$$

et l'énergie $H(q,p)$ est donc conservée.

Or, lorsqu'on essaye de simuler le système solaire avec un schéma d'Euler (explicite), l'énergie augmente peu à peu à chaque révolution et les trajectoires sont des spirales divergentes. Avec un schéma d'Euler implicite, Jupiter et Saturne s'effondre vers le soleil en quelques années (voir Figure 3.1 (p. 46)). Même des schémas d'ordre supérieur ne permettent pas de simuler correctement ce système sur des temps "courts" sur l'échelle de temps astronomique (à moins de prendre des pas déraisonnablement petits). En fait, le problème c'est que ces méthodes d'intégration ne préservent pas les propriétés structurelles des solutions telles que la conservation de l'énergie. Il faut donc développer des schémas particuliers, appelés *symplectiques*, comme illustré sur un simple oscillateur dans l'exercice *Schéma symplectique* (p. 61). Pour aller plus loin sur ces méthodes, voir (Hairer, Lubich, and Wanner 2010). Un exemple simple de système à deux corps est aussi donné dans le notebook Equations Differentielles II.ipynb.

4. Méthodes à un pas

4.1. Principe

Pour approximer les solutions d'une équation différentielle sur un intervalle $[0,T]$, les méthodes numériques à un pas se basent sur la représentation intégrale

$$x(t) = x_0 + \int_{t_0}^{t} f(s,x(s))ds = x_0 + \sum_{j=0}^{J-1} \int_{t_j}^{t_{j+1}} f(s,x(s))ds$$

où $t_0 < t_1 < \ldots < t_J$ avec $t_J = T$. L'idée est d'approximer les intégrales $\int_{t_j}^{t_{j+1}} f(s,x(s))$ sur des intervalles $[t_j, t_{j+1}]$ suffisamment petits.

Dans la suite, on note x^j l'approximation au temps t_j de la valeur exacte $x(t_j)$ et $\Delta t_j = t_{j+1} - t_j$ le $j$ème pas de temps. L'idée est de calculer récursivement

$$x^{j+1} = x^j + \Delta t_j \Phi(t_j, x^j, \Delta t_j)$$

où $\Phi(t_j, x^j, \Delta t_j)$ doit donc approximer

$$\frac{1}{t_{j+1} - t_j} \int_{t_j}^{t_{j+1}} f(s,x(s))ds \ .$$

2. L'application des lois de Newton donnerait directement

$$m_i a_i = m_i \ddot{q}_i = \sum_{k \neq i} F_k = -G \sum_{k \neq i} \frac{m_i m_j}{\|q_i - q_k\|^2} \frac{(q_i - q_k)}{\|q_i - q_k\|}$$

où F_k sont les forces de gravitation exercées par chaque corps k sur le corps i.

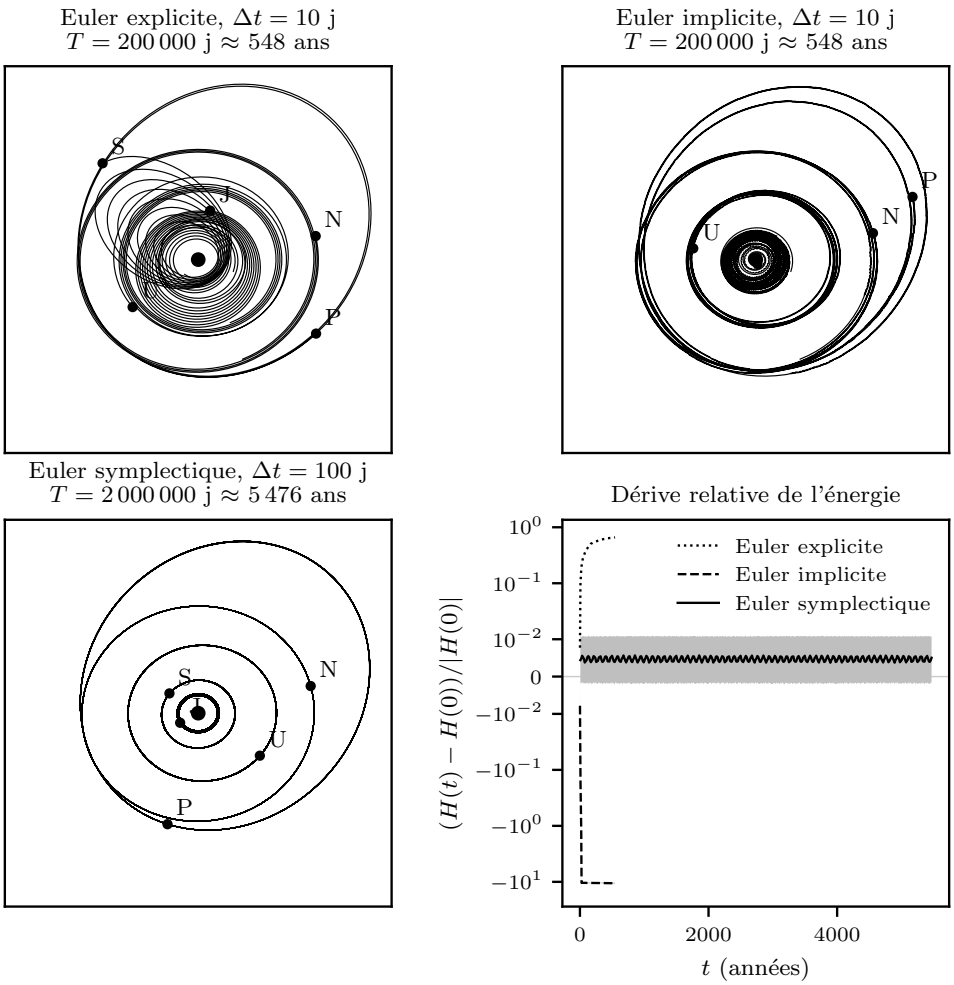


FIGURE 3.1. – Simulation du système solaire externe (Soleil, Jupiter, Saturne, Uranus, Neptune, Pluton, données de (Hairer, Lubich, and Wanner 2010)) par les schémas d'Euler explicite, implicite et symplectique, dans le référentiel du Soleil et projetée dans le plan de l'écliptique. Avec Euler explicite, l'énergie augmente et les orbites de Jupiter et Saturne s'ouvrent en spirale ; avec Euler implicite, elle diminue et les deux planètes tombent sur le Soleil en quelques dizaines d'années. Le schéma symplectique, avec un pas dix fois plus grand et un horizon dix fois plus long, conserve les orbites : l'erreur sur l'énergie oscille à chaque révolution mais ne dérive pas. En bas à droite, dérive relative de l'hamiltonien H (échelle logarithmique de part et d'autre de $\pm 10^{-2}$) : Euler explicite gagne de l'énergie, Euler implicite en perd, massivement, jusqu'à la chute de Jupiter ; au-delà, le pas est bien trop grand pour résoudre l'orbite numérique résiduelle et la simulation implicite n'a plus de sens.

Les différentes méthodes de quadrature, i.e. d'approximation de l'intégrale, peuvent donc être mises à profit. La difficulté ici est que seule la valeur initiale $f(t_j, x(t_j))$ de f est connue (ou du moins estimée) à l'itération j, par $f(t_j, x^j)$. On distingue donc les méthodes *explicites* où $\Phi(t_j, x^j, \Delta t_j)$ est écrite directement explicitement en fonction de la valeur initiale x^j, et les méthodes *implicites* où cette expression n'est connue qu'implicitement et des étapes intermédiaires de calcul sont nécessaires.

4.2. Exemples

1. Méthodes explicites:

- Euler explicite: l'intégrale est approximée par l'aire d'un rectangle déterminé par la valeur initiale de f à *gauche de l'intervalle*, i.e.

$$x^{j+1} = x^j + \Delta t_j \, f(t_j, x^j) \ .$$

- méthode de Heun : l'intégrale est approximée par l'aire d'un trapèze déterminé par la valeur initiale de f et une approximation de sa valeur finale, i.e.,

$$x^{j+1} = x^j + \frac{\Delta t_j}{2}\Big(f(t_j, x^j) + f\big(t_{j+1}, x^j + \Delta t_j f(t_j, x^j)\big)\Big) \ .$$

- schéma de Runge–Kutta d'ordre 4:

$$\begin{cases} F_1 = f(t_j, x^j) \\ F_2 = f\left(t_j + \dfrac{\Delta t_j}{2}, x^j + \dfrac{\Delta t_j}{2} F_1\right) \\ F_3 = f\left(t_j + \dfrac{\Delta t_j}{2}, x^j + \dfrac{\Delta t_j}{2} F_2\right) \\ F_4 = f(t_j + \Delta t_j, x^j + \Delta t_j F_3), \end{cases}$$

et on pose

$$x^{j+1} = x^j + \Delta t \, \frac{F_1 + 2F_2 + 2F_3 + F_4}{6} \ .$$

2. Méthodes implicites:

- Euler implicite : l'intégrale est approximée par l'aire d'un rectangle déterminé par la valeur finale de f à *droite de l'intervalle*, i.e.

$$x^{j+1} = x^j + \Delta t_j \, f(t_{j+1}, x^{j+1}) \ .$$

- méthode des trapèzes (ou Crank–Nicolson) : l'intégrale est approximée par l'aire du trapèze déterminé par les valeurs initiales et finales de f, i.e.

$$x^{j+1} = x^j + \frac{\Delta t_j}{2}\Big(f(t_j, x^j) + f(t_{j+1}, x^{j+1})\Big) \ .$$

- méthode du point milieu : l'intégrale est approximée par l'aire d'un rectangle déterminé par une approximation de la valeur de f au milieu de l'intervale, i.e.

$$x^{j+1} = x^j + \Delta t_j f\left(\frac{t_j + t_{j+1}}{2}, \frac{x^j + x^{j+1}}{2}\right) \ .$$

On peut bien sûr construire des méthodes plus compliquées et plus précises pour des méthodes de Runge–Kutta d'ordre supérieur (explicites ou implicites).

4.3. Définition implicite de Φ

Dans les schémas implicites, l'application Φ est définie de manière implicite. Par exemple, pour le schéma d'Euler, on a :

$$\Phi(t_j, x^j, \Delta t_j) = f\Big(t_j + \Delta t_j, x^j + \Delta t_j \Phi(t_j, x^j, \Delta t_j)\Big).$$

Il faut donc s'assurer que Φ est bien définie, c'est-à-dire qu'il existe bien x^{j+1} tel que

$$x^{j+1} = x^j + \Delta t_j \, f(t_{j+1}, x^{j+1}) \ .$$

Pour cela, nous pouvons voir x^{j+1} comme le point fixe de l'application F_j définie par

$$F_j(x) = x^j + \Delta t_j \, f(t_{j+1}, x) \ .$$

à x^j, Δt_j, t_{j+1} fixés. L'existence (et l'unicité) de ce point fixe peut alors être démontrée par le théorème de point fixe de Banach. Si $x \mapsto f(t_{j+1}, x)$ est Lipschitzienne, c'est-à-dire s'il existe L_j tel que

$$\|f(t_{j+1}, x_a) - f(t_{j+1}, x_b)\| \leq L_j \|x_a - x_b\| \qquad \forall (x_a, x_b) \in \mathbb{R}^n \times \mathbb{R}^n \ ,$$

alors $F_j : \mathbb{R}^n \to \mathbb{R}^n$ est contractante pour un pas de temps Δt_j suffisamment petit puisque

$$\|F_j(x_a) - F_j(x_b)\| \leq \Delta t_j L_j \|x_a - x_b\| \ .$$

Puisque $\mathbb{R}^n$ est complet, on déduit par le théorème du point fixe que x^{j+1} existe bien.

En pratique, on peut utiliser la méthode itérative de construction de ce point fixe donnée par la preuve du théorème pour approcher x^{j+1}. Une stratégie est de partir de la valeur donnée par le schéma d'Euler explicite

$$x^{j,0} = x^j + \Delta t_j f(t_j, x^j)$$

et affiner ensuite par l'algorithme du point fixe en itérant

$$x^{j,k+1} = F(x^{j,k})$$

jusqu'à ce que l'évolution relative

$$\frac{x^{j,k+1} - x^{j,k}}{x^{j,0}}$$

devienne inférieure à un seuil choisi par l'utilisateur. Puisque la suite $(x^{j,k})_{k \in \mathbb{N}}$ est de Cauchy, on sait que cette algorithme s'arrête en un nombre fini d'itérations.

Notons que l'algorithme du point fixe n'est pas la seule façon de résoudre l'équation $x^{j+1} = F_j(x^{j+1})$: c'est un système de n équations non linéaires à n inconnues, $G_j(x) = x - F_j(x) = 0$, que l'on peut confier à n'importe quel solveur d'équations non linéaires, typiquement la *méthode de Newton*

$$x^{j,k+1} = x^{j,k} - \big(J_{G_j}(x^{j,k})\big)^{-1} G_j(x^{j,k}) \ ,$$

que l'on initialise là encore avec la prédiction du schéma explicite. C'est ce que fait la fonction `scipy.optimize.fsolve` en Python, et c'est la solution "systématique" : elle converge en quelques itérations même lorsque $\Delta t_j L_j \geq 1$ et que F_j n'est plus contractante, alors que l'algorithme du point fixe diverge. C'est précisément dans ce régime, celui des pas de temps grands devant les constantes de temps du système, que les schémas implicites sont intéressants, et c'est pourquoi les solveurs implicites utilisent en pratique une méthode de type Newton. Cette solution a ses limites :

- chaque itération demande la jacobienne $J_{G_j} = I - \Delta t_j J_f$ (calculée analytiquement, ou approchée par différences finies au prix de n évaluations supplémentaires de f) et la résolution d'un système linéaire de taille n : le coût par pas de temps croît vite avec la dimension ;
- Newton ne converge que depuis une initialisation suffisamment proche de la solution, et il n'y a aucune garantie si Δt_j est trop grand ; le théorème de point fixe de Banach n'assure plus l'unicité de la solution, et le solveur peut converger vers une racine *parasite* de G_j, sans rien signaler. On l'observe par exemple sur le système raide de Robertson de la section précédente (p. 43), où un schéma d'Euler implicite résolu par `fsolve` converge pour $\Delta t = 0{,}1$ vers une solution à concentrations négatives (voir le notebook Equations Differentielles II.ipynb) ;
- à l'inverse, si l'on choisit un pas de temps assez petit pour que F_j soit contractante, le point fixe est unique, l'algorithme de point fixe converge et n'exige aucune jacobienne : c'est la méthode la plus simple, et elle suffit tant que l'on n'exploite pas la stabilité du schéma implicite pour prendre de grands pas.

Un tel schéma est plus lourd en terme de calculs qu'un algorithme explicite mais il apporte en général plus de stabilité et permet souvent d'utiliser un pas plus grand. C'est en particulier utile pour les systèmes raides ou non-lisses, comme illustré dans l'exercice *Explicite ou Implicite?* (p. 60).

5. Analyse d'erreur

L'objectif de l'analyse d'erreur *a priori* est de donner une estimation de l'erreur commise par la méthode numérique en fonction des paramètres du problème (temps d'intégration, pas de temps, propriétés de f). L'idée générale est de remarquer qu'à chaque pas de temps, on commet une erreur d'intégration locale (erreur de troncature dans la discrétisation de l'intégrale, à laquelle s'ajoutent souvent des erreurs d'arrondi), et que ces erreurs locales s'accumulent au fil des pas. Le contrôle de cette accumulation demande l'introduction d'une notion de stabilité adéquate, alors que les erreurs locales sont liées à une notion de consistance. L'alliance de stabilité et de consistante donne une propriété de convergence qui est souhaitée lors de l'implémentation de méthodes numériques.

5.1. Erreur de troncature locale

L'erreur de troncature locale à l'itération j est l'erreur que l'on commet en une seule itération lors de l'approximation de l'intégrale pour passer de x^j à x^{j+1}. C'est donc l'erreur théorique que l'on obtiendrait si l'on appliquait le schéma numérique à la solution exacte $x(t_j)$. Elle est ainsi définie comme

$$\eta^{j+1} := \frac{x(t_{j+1}) - x(t_j) - \Delta t_j \Phi(t_j, x(t_j), \Delta t_j)}{\Delta t_j}.$$

Définition – Consistance.

On note $\Delta t = \max_{0 \leq j \leq J-1} \Delta t_j$ le pas de temps maximal. On dit qu'une méthode numérique est *consistante* si

$$\lim_{\Delta t \to 0} \left(\max_{1 \leq j \leq J} \|\eta^j\| \right) = 0 \ ,$$

et qu'elle est *consistante d'ordre* $\geq p$ s'il existe une constante c_s telle que, pour tout $0 \leq j \leq J-1$,

$$\|\eta^{j+1}\| \leq c_s \, (\Delta t_j)^p \ .$$

Une méthode est donc *consistante d'ordre* p si elle est consistante d'ordre $\geq p$, mais pas $\geq p+1$.

Théorème – Condition nécessaire et suffisante de consistance.

Si Φ *est continue, alors le schéma est consistant si et seulement si*

$$\Phi(t,x,0) = f(t,x) \qquad \forall (t,x) \in [0,T] \times \mathbb{R}^n \ .$$

Démonstration. Soit C un ensemble fermé et borné tel que $x(t) \in C$ pour tout $t \in [0,T]$. On note toujours $\Delta t = \max_{0 \leq j \leq J-1} \Delta t_j$. Par la représentation intégrale des solutions,

$$x(t_{j+1}) = x(t_j) + \int_{t_j}^{t_{j+1}} f(x(s),s) ds$$

l'erreur de troncature locale s'écrit

$$\eta^{j+1} = \frac{1}{\Delta t_j} \int_{t_j}^{t_{j+1}} \Big(f(s,x(s)) - \Phi(t_j, x(t_j), \Delta t_j) \Big) ds \ .$$

Si le schéma est consistant alors cette erreur tend vers 0 lorsque Δt tend vers 0 (pour n'importe quel système et n'importe quelle trajectoire). Or,

$$\lim_{\Delta t \to 0} \frac{1}{\Delta t_j} \int_{t_j}^{t_j + \Delta t} \Big(f(s,x(s)) - \Phi(t_j, x(t_j), \Delta t_j) \Big) ds = f(t_j, x(t_j)) - \Phi(t_j, x(t_j), 0)$$

qui doit donc être nul.

Réciproquement, supposons $\Phi(\cdot,\cdot,0) = f$. On doit montrer que l'erreur de consistance tend vers 0 lorsque Δt tend vers 0 (uniformément en $j = 1, \ldots, N$). Soit $\varepsilon > 0$. Par la continuité de Φ et f et puisque $\Phi(\cdot,\cdot,0) = f$, il existe $\Delta_1 > 0$ tel que si $\Delta t \leq \Delta_1$, alors

$$\|\Phi(t,x,\Delta t_j) - f(t,x)\| \leq \varepsilon \qquad \forall (t,x) \in [0,T] \times C \quad \forall j = 1, \ldots, N \ .$$

Donc

$$\|\eta^{j+1}\| \leq \varepsilon + \frac{1}{\Delta t_j} \int_{t_j}^{t_{j+1}} \|f(s,x(s)) - f(t_j, x(t_j))\| ds \ .$$

Puisque $s \mapsto f(s,x(s))$ est continue sur l'intervalle fermé et borné $[0,T]$, elle y est uniformément continue, donc il existe $\Delta_2 > 0$ tel que si $\Delta t \leq \Delta_2$,

$$\big\| f(s,x(s)) - f(t_j, x(t_j)) \big\| \leq \varepsilon \qquad \forall s \in [t_j, t_{j+1}] \quad \forall j = 1, \ldots, N$$

et donc $\|\eta^{j+1}\| \leq 2\varepsilon$ pour tout j. Le schéma est donc bien consistant. ■

Exemple – Schémas consistants.

Reprenons les exemples donnés plus haut.

- Euler explicite : $\Phi(t,x,\Delta t) = f(t,x)$ indépendamment de Δt donc la condition est trivialement satisfaite.
- Méthode de Heun : $\Phi(t,x,\Delta t) = \frac{f(t,x)+f(t+\Delta t,x+\Delta t f(t,x))}{2}$ donne bien $f(t,x)$ si $\Delta t = 0$.
- Runge Kutta d'ordre 4 : lorsque $\Delta t = 0$, $F_1 = F_2 = F_3 = F_4 = f(t,x)$ donc $\Phi(t,x,0) = \frac{F_1+2F_2+2F_3+F_4}{6} = f(t,x)$.

De même, la consistance des méthodes implicites s'obtiennent en remarquant que $x^{j+1} = x^j$ lorsque $\Delta t = 0$.

Cette condition suffisante permet donc de prouver facilement le caractère consistant d'un schéma. Cependant, en pratique, on s'intéresse surtout à son ordre de consistance. Pour cela, l'erreur de consistance se calcule souvent par des développements de Taylor des solutions lorsque celles-ci sont suffisamment régulières, et la constante c_s s'exprime alors comme une borne sur les dérivées des solutions. En fait, on remarque que lorsque f est continue, la solution est C^1 (par définition de nos solutions). Mais puisque $\dot{x}(t) = f(t,x(t))$, $\dot{x}$ hérite de la régularité de f: si f est C^k alors les solutions x sont C^{k+1}. Le calcul de l'ordre de consistance dans le cas dus schéma d'Euler explicite est donné ci-dessous. Pour les autres schémas, voir l'exercice *Consistance de schémas* (p. 59)

Exemple – Ordre de consistance du schéma d'Euler explicite.

L'erreur de troncature s'écrit

$$\eta^{j+1} = \frac{x(t_j+\Delta t_j) - \Big(x(t_j) + \Delta t_j\, f(t_j, x(t_j))\Big)}{\Delta t_j}.$$

Or, si f est C^1, alors x est C^2 et par application la formule de Taylor avec reste intégral, on a

$$x(t_j+\Delta t_j) = x(t_j) + \Delta t f(t_j,x(t_j)) + \Delta t_j^2 \int_0^1 \ddot{x}(t_j+s\Delta t_j)(1-s)ds,$$

en utilisant $\dot{x}(t_j) = f(t_j,x(t_j))$. Ceci donne donc

$$\|\eta^{j+1}\| \leq \Delta t_j \int_0^1 \ddot{x}(t_j+s\Delta t_j)(1-s)ds \leq \frac{\Delta t_j}{2} \max_{t\in[t_j,t_{j+1}]} \|\ddot{x}(t)\| \leq \frac{\Delta t_j}{2} \max_{t\in[0,T]} \|\ddot{x}(t)\| .$$

Le schéma d'Euler explicite est donc consistant d'ordre ≥ 1 avec

$$c_s = \frac{\max_{t\in[0,T]} \|\ddot{x}(t)\|}{2} .$$

Notons qu'en utilisant $\dot{x}(t) = f(t,x(t))$,

$$\ddot{x}(t) = \partial_t f(t,x(t)) + \partial_x f(t,x(t)) \cdot f(t,x(t)),$$

et on peut exprimer c_s en fonction de bornes sur x et sur les dérivées de f. Plus généralement, en dérivant successivement lorsque f est C^k, notons $f^{[k]} : \mathbb{R}\times\mathbb{R}^n \to \mathbb{R}^n$ la fonction dépendant des dérivées successives de f telle que

$$x^{(k+1)}(t) = f^{[k]}(t,x(t)) .$$

On a alors le théorème suivant, généralisant les calculs précédents.

Théorème – Condition nécessaire et suffisante de consistance d'ordre $\geq p$.

Si Φ et f sont C^p alors le schéma est consistant d'ordre $\geq p$ si et seulement si

$$\frac{\partial^k \Phi}{\partial \Delta t^k}(t,x,0) = \frac{1}{k+1} f^{[k]}(t,x) \qquad \forall 0 \leq k \leq p-1 \ , \quad \forall (t,x) \in [0,T] \times \mathbb{R}^n \ .$$

Démonstration. L'erreur de troncature s'écrit

$$\eta^{j+1} = \frac{x(t_j + \Delta t_j) - \Big(x(t_j) + \Delta t_j \, \Phi(t_j, x(t_j), \Delta t_j)\Big)}{\Delta t_j}.$$

Or, si f est C^p, alors x est C^{p+1} et par application la formule de Taylor avec reste intégral, on a

$$\begin{aligned} x(t_j + \Delta t_j) &= x(t_j) + \sum_{k=1}^{p} \frac{\Delta t_j^k}{k!} x^{(k)}(t_j) + \frac{\Delta t_j^{p+1}}{p!} \int_0^1 x^{(p+1)}(t_j + s\Delta t_j)(1-s)^p ds \\ &= x(t_j) + \sum_{k=0}^{p-1} \frac{\Delta t_j^{k+1}}{(k+1)!} f^{[k]}(t_j, x(t_j)) + \frac{\Delta t_j^{p+1}}{p!} \int_0^1 x^{(p+1)}(t_j + s\Delta t_j)(1-s)^p ds \end{aligned}$$

Par ailleurs, puisque Φ est C^p,

$$\Phi(t,x,\Delta t) = \sum_{k=0}^{p-1} \frac{\Delta t^k}{k!} \frac{\partial^k \Phi}{\partial \Delta t^k}(t,x,0) + \frac{\Delta t^p}{(p-1)!} \int_0^1 \frac{\partial^p \Phi}{\partial \Delta t^p}(t,x,t_j + s\Delta t_j)(1-s)^{p-1} ds$$

Il s'ensuit que

$$\eta^{j+1} = \sum_{k=0}^{p-1} \frac{\Delta t_j^k}{k!} \left[\frac{1}{k+1} f^{[k]}(t_j, x(t_j)) - \frac{\partial^k \Phi}{\partial \Delta t^k}(t_j, x(t_j), 0) \right] + \Delta t_j^p R_j$$

où R_j est borné (uniformément en Δt_j) par continuité de $\frac{\partial^p \Phi}{\partial \Delta t^p}$ et $x^{(p+1)}$.

Maintenant, si le schéma est d'ordre $\geq p$, alors $\frac{\eta^{j+1}}{\Delta t_j^p}$ doit rester borné lorsque Δt_j tend vers 0 et on obtient bien la condition du théorème. Réciproquement, si la condition du théorème est vérifiée, on obtient directement que η^{j+1} est borné en Δt_j^p. ■

Exemple – Ordre de consistance de schémas.

On a vu que si f est C^1, le schéma d'Euler explicite est consistant d'ordre ≥ 1. On peut le retrouver ici en appliquant le critère précédent pour $p = 1$ puisque $\Phi(\cdot,\cdot,0) = f$. Ensuite, si f est C^2, on constate que

$$\frac{\partial \Phi}{\partial \Delta t}(t,x,0) = 0 \neq f^{[1]}(t,x) = \partial_t f(t,x) + \partial_x f(t,x) \cdot f(t,x)$$

donc le schéma d'Euler explicite est consistant d'ordre exactement 1.

Par contre, toujours si f est C^2, on constate que l'on a bien pour le schéma de Heun

$$\frac{\partial \Phi}{\partial \Delta t}(t,x,0) = f^{[1]}(t,x) = \partial_t f(t,x) + \partial_x f(t,x) \cdot f(t,x)$$

donc ce schéma est d'ordre ≥ 2. On peut vérifier que si f est C^3, le critère n'est pas vérifié à l'ordre supérieur donc il est consistant d'ordre égal à 2.

5.2. Stabilité

Une fois que l'on a étudié l'erreur locale commise en une itération, on s'intéresse à la manière dont elle va se propager au fur et à mesure des itérations. Pour cela, la notion de stabilité quantifie la robustesse de l'approximation numérique par rapport à l'accumulation des erreurs locales et perturbations.

Définition – Stabilité.

On dit qu'une méthode numérique est *stable* s'il existe une constante $S(T) > 0$ (indépendente des Δt_j) telle que, pour toutes suites $x = \{x^j\}_{1\leq j\leq J}$ et $z = \{z^j\}_{1\leq j\leq J}$ vérifiant

$$\begin{cases} x^{j+1} = x^j + \Delta t_j \Phi(t_j, x^j, \Delta t_j), \\ z^{j+1} = z^j + \Delta t_j \Phi(t_j, z^j, \Delta t_j) + \delta^{j+1}, \end{cases}$$

on ait

$$\max_{1\leq j\leq J} \|x^j - z^j\| \leq S(T) \left(\|x^0 - z^0\| + \sum_{j=1}^{J} \|\delta^j\| \right).$$

Théorème – Condition suffisante de stabilité.

Si Φ sont Lipschitziennes en x, c'est-à-dire il existe $L > 0$ tel que pour tout $0 \leq j \leq J$,

$$\|\Phi(t_j, x_a, \Delta t_j) - \Phi(t_j, x_b, \Delta t_j)\| \leq L\|x_a - x_b\| \qquad \forall (x_a, x_b) \in \mathbb{R}^n \times \mathbb{R}^n$$

alors le schéma est stable avec $S(T) = e^{LT}$.

Démonstration. On a alors

$$\|x^{j+1} - z^{j+1}\| \leq \|\delta^{j+1}\| + (1 + \Delta t_j L)\|x^j - z^j\| \leq \|\delta^{j+1}\| + e^{\Delta t_j L}\|x^j - z^j\|$$

puisque $1 + x \leq e^x$ pour tout $x \in \mathbb{R}$. Par récurrence, on montre alors que pour tout $1 \leq j \leq J$,

$$\|x^j - z^j\| \leq e^{(t_j - t_0)L}\|x^0 - z^0\| + \sum_{k=1}^{j} e^{(t_j - t_k)L}\|\delta^k\| \ .$$

Il s'ensuit que

$$\|x^j - z^j\| \leq e^{TL} \left(\|x^0 - z^0\| + \sum_{k=1}^{j} \|\delta^k\| \right) \ ,$$

ce qui donne le résultat. ■

Théorème – Théorème de Lax.

Une méthode stable et consistante (à l'ordre p) est convergente (à l'ordre p).

Démonstration. Notons $z^j = x(t_j)$. On remarque que

$$z^{j+1} = z^j + \Delta t_j \Phi(t_j, z^j, \Delta t_j) + \Delta t_j \, \eta^{j+1},$$

où η est l'erreur de consistance. D'après la propriété de stabilité, on a donc

$$\|x^j - x(t_j)\| \leq S(T) \sum_{j=1}^{J} \Delta t_{j-1} \|\eta^j\| \ ,$$

et par consistance

$$\|x^j - x(t_j)\| \leq S(T)\, c_s \sum_{j=1}^{J} \Delta t_{j-1} \, (\Delta t_{j-1})^p \leq c_s \, S(T) \, T \, (\Delta t)^p \ .$$

■

Théorème – Condition suffisante de convergence.

L'inconvénient du théorème de Lax est qu'il faut prouver la stabilité pour obtenir la convergence. Or la seule condition suffisante dont nous disposions à cet effet, est le caractère globalement Lipschitzien de $x \mapsto \Phi(t, x, \Delta t)$. Mais il s'agit d'une condition très forte. En fait, il est possible de prouver la convergence sous la condition plus faible que $x \mapsto \Phi(t, x, \Delta t)$ est "localement Lipschitzienne" :

Si

1. *le schéma est consistant d'ordre p,*
2. *pour tout boule fermée B de $\mathbb{R}^n$, il existe $L > 0$, $\Delta t_m > 0$ tels que pour tout $t \in [0, T]$ et pour tout $\Delta t \in [0, \Delta t_m]$,*

$$\|\Phi(t_j, x_a, \Delta t_j) - \Phi(t_j, x_b, \Delta t_j)\| \leq L\|x_a - x_b\| \qquad \forall (x_a, x_b) \in B \times B$$

Alors il existe un pas de temps maximal $\Delta t_{\max} > 0$ tel que le schéma est convergent d'ordre p.

L'hypothèse 2. est en particulier vérifiée si $x \mapsto \Phi(t, x, \Delta t)$ est C^1 d'après une version un peu plus générale du théorème des accroissement finis.

Exemple – Convergence du schéma d'Euler explicite.

On a déjà montré que le schéma d'Euler explicite est consistant d'ordre 1. Par ailleurs, si f est C^1 par rapport à x, alors $x \mapsto \Phi(t, x) = f(t, x, \Delta t)$ est C^1. Donc d'après le théorème précédent, le schéma est convergent d'ordre 1.

Numériquement, l'ordre de convergence des schémas peut être visualisé en simulant une équation différentielle dont la solution analytique est connue, afin de tracer, en échelle log-log, l'erreur numérique de simulation en fonction du pas de temps : la pente de la courbe obtenue est l'ordre de convergence. C'est ce qui est fait sur la Figure 5.1 (p. 56) pour les schémas à un pas vus dans l'exercice *Consistance et ordre de schémas* (p. 59), sur le problème test $\dot{x} = -x$, $x(0) = 1$, de solution $x(t) = e^{-t}$. On retrouve les pentes 1, 2 et 4 démontrées analytiquement. Deux observations méritent d'être soulignées. D'une part, un schéma implicite n'est pas plus précis qu'un schéma explicite : Euler implicite est d'ordre 1 comme Euler explicite, et ce que l'implicite apporte n'est pas de la précision mais de la stabilité (voir la section sur les systèmes raides (p. 43)). D'autre part, pour le schéma de Runge-Kutta 4, la courbe cesse de décroître en dessous de $\Delta t \approx 10^{-3}$ et la pente "casse" : l'erreur de troncature en $(\Delta t)^4$ est alors devenue plus petite que la précision de la machine, et ce sont les erreurs d'arrondi, accumulées à chaque itération, qui dominent. C'est l'objet de la section suivante.

5.4. Erreurs d'arrondi et pas optimal

A chaque itération, lorsque la machine calcule x^{j+1}, elle commet en plus de l'erreur de troncature de l'intégrale des erreurs d'arrondi de l'ordre de la précision machine. La solution obtenue est donc en fait donnée par

$$\hat{x}^{j+1} = \hat{x}^j + \Delta t_j \left(\Phi(t_j, \hat{x}^j, \Delta t_j) + \rho^{j+1}\right) + \varepsilon^{j+1}$$

au lieu de

$$x^{j+1} = x^j + \Delta t_j \Phi(t_j, x^j, \Delta t_j) \ ,$$

où ρ modélise l'erreur commise sur le calcul de Φ et ϵ l'erreur sur l'addition finale. La stabilité nous donne alors l'écart

$$\max_{0 \leq j \leq J} \|x^j - \hat{x}^j\| \leq S(T) \sum_{j=1}^{J} \Delta t_{j-1} \|\rho^j\| + \|\varepsilon^j\| \ .$$

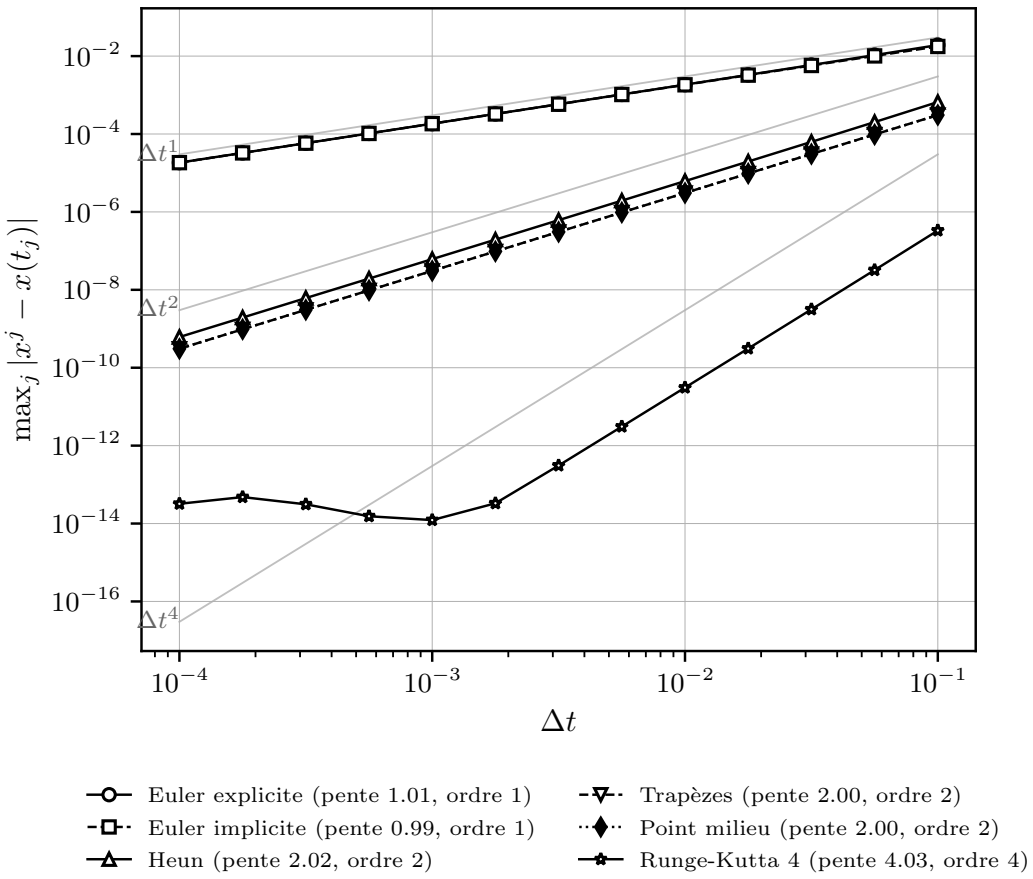


FIGURE 5.1. – Ordre de convergence expérimental des schémas à un pas du cours sur le problème test $\dot{x} = -x$, $x(0) = 1$, $t \in [0, 2]$: erreur globale $\max_j |x^j - x(t_j)|$ en fonction du pas Δt (échelle log-log), et pente estimée sur les six plus grands pas. Les droites grises sont les références $(\Delta t)^p$.

En considérant une borne ε des ε^j et ρ des ρ^j, on obtient

$$\max_{0\leq j\leq J} \|x^j - \hat{x}^j\| \leq S(T)(T\rho + J\varepsilon) \leq S(T)T\left(\rho + \frac{\varepsilon}{\min \Delta t_j}\right) ,$$

et donc finalement, en supposant l'algorithme convergent d'ordre p,

$$\begin{aligned}\max_{0\leq j\leq J} \|x(t_j) - \hat{x}^j\| &\leq \max_{0\leq j\leq J} \|x(t_j) - x^j\| + \|x^j - \hat{x}^j\| \\ &\leq c_v(\max_j \Delta t_j)^p + S(T)T\left(\rho + \frac{\varepsilon}{\min_j \Delta t_j}\right) .\end{aligned}$$

Les paramètres ε et ρ sont typiquement petits de l'ordre d'un facteur de la précision machine. Cependant, on voit que plus le pas de temps décroit, plus il y a d'itérations et plus les erreurs d'arrondi se propagent. D'un autre côté, plus il augmente, plus les erreurs de quadrature augmentent. En supposant le pas constant, il y a donc un pas "optimal' ' donné par

$$\Delta t_{opt} = \left(\frac{S(T)T\varepsilon}{c_v p}\right)^{\frac{1}{p+1}} .$$

Ce phénomène est illustré sur la Figure 5.2 (p. 57) avec le schéma de Runge-Kutta 4 sur le problème test $\dot{x} = -x$: en diminuant le pas sur cinq ordres de grandeur, on voit l'erreur décroître

en $(\Delta t)^4$, passer par un minimum autour de 10^{-14}, puis remonter. Plus l'ordre p est élevé, plus Δt_{opt} est grand : un schéma d'ordre élevé atteint la précision machine avec un pas raisonnable, là où un schéma d'ordre 1 demanderait un pas (et un nombre d'itérations) déraisonnable. Il est donc illusoire de chercher à améliorer la précision en diminuant indéfiniment le pas : en pratique, on travaille toujours avec $\Delta t \gg \Delta t_{opt}$, et c'est le choix du schéma et l'adaptation du pas (voir l'annexe (p. 57)) qui permettent de contrôler l'erreur.

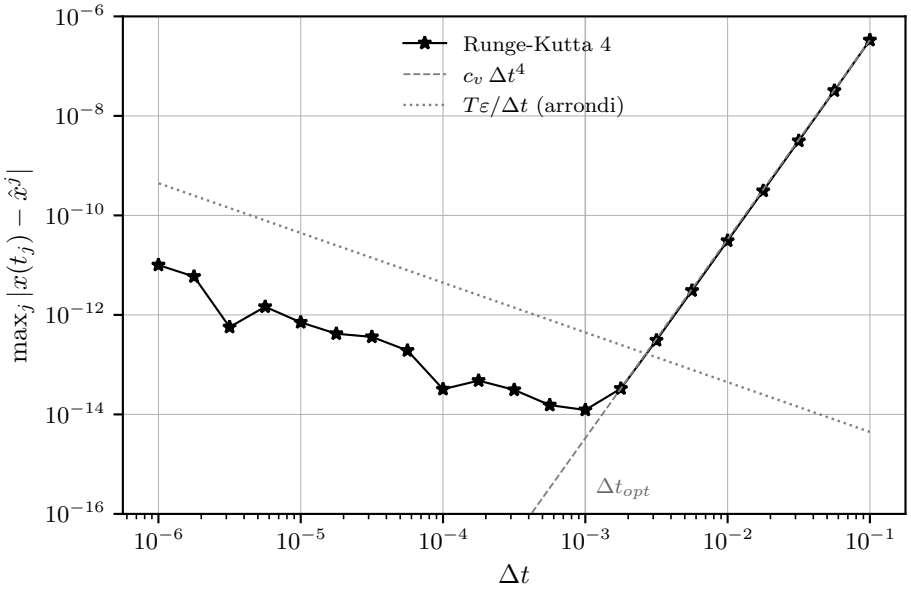


FIGURE 5.2. – Erreur globale du schéma de Runge-Kutta 4 sur $\dot{x} = -x$, $x(0) = 1$, $t \in [0, 2]$ en fonction du pas, en double précision ($\varepsilon \approx 2 \cdot 10^{-16}$). Pour les grands pas, l'erreur de troncature $c_v(\Delta t)^4$ domine ; pour les petits pas, les erreurs d'arrondi accumulées sur les $T/\Delta t$ itérations dominent et l'erreur remonte lorsque le pas diminue. La borne $T\varepsilon/\Delta t$ du cours est un pire cas : en pratique les erreurs d'arrondi se compensent partiellement et la remontée observée est en dessous de cette borne.

6. Annexe – Choix du pas de temps

Jusqu'à présent, on a présenté des schémas dépendant de pas de temps Δt_j, sans jamais dire comment les choisir. Le plus simple est de choisir un pas Δt fixe mais il est difficile de savoir à l'avance quel pas est nécessaire. En particulier, comment savoir si la solution obtenue est suffisamment précise, sans connaître la vraie ?

6.1. Pas fixe

Une voie empirique est de fixer un pas, lancer la simulation, puis fixer un pas plus petit, relancer la simulation, jusqu'à ce que les résultats *ne semble plus changer* (au sens de ce qui nous intéresse d'observer). Notons que la connaissance des constantes de temps présentes dans le système peut aider à fixer un premier ordre de grandeur du pas. On pourrait aussi directement choisir le pas Δt_{opt} obtenu plus haut en prenant en compte les erreurs d'arrondis. Mais les constantes c_v et $S(T)$ sont souvent mal connues et conservatives.

6.2. Adaptation du pas de temps

Les méthodes à pas fixe exploitent la convergence des schémas, mais

- on ne peut pas prendre un pas de temps arbitrairement petit car on est contraint par le temps de simulation.
- on n'a aucune idée de l'erreur commise et on n'est jamais sûr d'avoir la bonne solution.
- l'utilisation d'un pas très petit peut n'être nécessaire qu'autour de certains points *sensibles* (proches de singularités par exemple) et consomme des ressources inutiles ailleurs.

L'idée serait donc plutôt d'adapter la valeur du pas Δt_j à chaque itération. En d'autres termes, on se fixe une tolérance d'erreur que l'on juge acceptable et on modifie le pas de temps en ligne, selon si l'on estime être au-dessus ou en-dessous du seuil d'erreur. Mais cela suppose d'avoir une idée de l'erreur commise... Il existe justement des moyens de l'estimer.

Tout d'abord, de quelle erreur parle-t-on ?

- erreur *globale* ? L'idéal serait de contrôler $\max_{0\leq j\leq N} \|x^j - x(t_j)\|$. Or la stabilité nous dit que

$$\max_{0\leq j\leq N} \|x^j - x(t_j)\| \leq S(T) \sum_{j=1}^{J} \Delta t_{j-1} \|\eta^j\|$$

  avec η^j les erreurs de consistances locales. Donc si on se fixe une tolérance sur l'erreur globale $\texttt{Tol}_g$, on a

$$\|\eta^j\| \leq \frac{\texttt{Tol}_g}{TS(T)} \qquad \Longrightarrow \qquad \max_{0\leq j\leq N} \|x^j - x(t_j)\| \leq \texttt{Tol}_g \ .$$

  En d'autre termes, $\texttt{Tol}_g$ nous fixe une erreur maximale *locale* sur η^j, à chaque itération. Notons cependant que cette borne ne prend pas en compte la propagation des erreurs d'arrondis : plus Δt diminue, plus l'erreur globale risque d'augmenter. Ce phénomène devrait donc en toute rigueur aussi nous donner un pas de temps minimal $\Delta t_{\min}$. Notons que tous ces calculs dépendent des constantes c_v et $S(T)$ qui sont souvent mal connues ou très conservatives.

- erreur (absolue) *locale* ? A chaque itération, une erreur locale est commise dûe à l'approximation de l'intégrale. Cette erreur est donnée par

$$e^{j+1} = \tilde{x}(t_{j+1}) - x^{j+1} = \left(x^j + \int_{t_j}^{t_{j+1}} f(s, \tilde{x}(s)) ds \right)$$

  où $\tilde{x}$ est la solution de $\dot{x} = f(t, x)$ qui serait initialisée à x^j au temps t_j. Notons que si on avait $x^j = x(t_j)$, on aurait exactement $e^{j+1} = \Delta t_j \eta^{j+1}$, où η^{j+1} est l'erreur de consistance. On se donne donc une tolérance d'erreur locale

$$\|e^{j+1}\| \leq \texttt{Tol}_{abs} \ .$$

- erreur *relative* ? Fixer une erreur absolue est parfois trop contraignant et n'a de sens que si les solutions gardent un certain ordre de grandeur. En effet, l'erreur acceptable quand la solution vaut 1000 n'est peut-être pas la même que lorsqu'elle vaut 1. On peut donc plutôt exiger une certaine erreur relative $\texttt{Tol}_{rel}$, i.e.,

$$\frac{\|e^{j+1}\|}{\|x^j\|} \leq \texttt{Tol}_{rel} \ .$$

En général, les solvers assurent (approxivement)

$$\|e^{j+1}\| \leq \texttt{Tol}_{abs} + \texttt{Tol}_{rel}\|x^j\| \ .$$

Par défaut, dans les solvers de Numpy, $\texttt{Tol}_{abs} = 10^{-6}$ et $\texttt{Tol}_{rel} = 10^{-3}$.

Mais pour cela nous devons trouver un moyen d'estimer l'erreur locale. C'est souvent fait en utilisant une même méthode à deux pas différents (par exemple Δt_j et $\Delta t_j/2$), ou bien en imbriquant des schémas de Runge-Kutta d'ordres différents.

En fait, il est possible de montrer (exercice) que si f est C^1, on a pour un schéma d'Euler explicite

$$\|e^{j+1}\| = \Delta t_j \, \frac{\|f(t_{j+1}, x^{j+1}) - f(t_j, x^j)\|}{2} + o(\Delta t_j^2)$$

On peut donc estimer à chaque itération l'erreur commise e^{j+1} et adapter le pas selon si celle-ci est inférieure ou supérieure au seuil de tolérance. En effet, puisque l'on sait par ailleurs que $e^{j+1} = O(\Delta t_j^2)$, une possible stratégie d'adaptation est de prendre

$$\Delta t_{new} = \Delta t_j \sqrt{\frac{\texttt{Tol}_{abs}}{\|e^{j+1}\|}}$$

(éventuellement avec une marge de sécurité)

La fonction correspondante

```
def solve_euler_explicit_variable_step(f, x0, t0, tf, dtmin, dtmax, atol):
  ...
  return t, x
```

est fournie dans le notebook Equations Differentielles II.ipynb. La Figure 6.1 (p. 60) montre cette stratégie à l'œuvre sur l'oscillateur de Van der Pol

$$\dot{y}_1 = y_2 \quad , \qquad \dot{y}_2 = \mu(1 - y_1^2)\, y_2 - y_1$$

avec $\mu = 10$ et $y(0) = (2, 0)$. Pour μ grand, ce système présente des *oscillations de relaxation* : la solution alterne entre des phases lentes, où elle suit de près une courbe en S dans le plan de phase, et des sauts rapides quasi verticaux d'une branche de cette courbe à l'autre. Le système est autonome : ce n'est pas le temps qui rend f grande, c'est la trajectoire elle-même qui revient périodiquement dans les régions de l'espace d'état (au voisinage de $y_1 = \pm 1$) où f et sa dérivée $f^{[1]}$, donc l'erreur de consistance, explosent. Le pas se resserre d'un facteur mille pendant chaque saut puis se relâche jusqu'à $\Delta t_{\max}$ sur les phases lentes, indéfiniment et en phase avec le cycle limite. Un pas fixe devrait être choisi à la plus petite de ces valeurs partout. Notons enfin que cette stratégie ne contrôle que l'erreur *locale* : rien ne garantit l'erreur globale, qui dépend de la constante de stabilité $S(T)$; et que pour μ plus grand encore, le système devient franchement raide (voir la section sur les systèmes raides (p. 43)) et le pas d'un schéma explicite s'effondrerait pendant les sauts : il faudrait alors passer à un schéma implicite.

7. Exercices

7.1. Consistance et ordre de schémas

Supposons f de classe C^2. Montrer que :

Question 1 le schéma de Heun est consistant d'ordre ≥ 2 et égal à 2 si f est C^3. (Solution p. 86.)

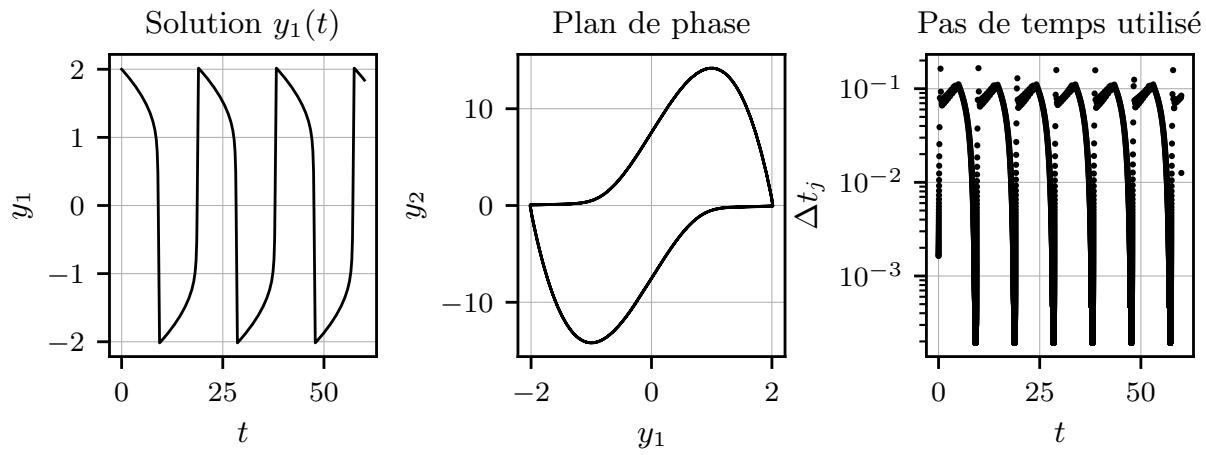


FIGURE 6.1. – Euler explicite à pas adaptatif sur l'oscillateur de Van der Pol ($\mu = 10$, $y(0) = (2, 0)$, $\texttt{Tol}_{abs} = 10^{-4}$, $\Delta t \in [10^{-6}, 0{,}2]$). De gauche à droite : la solution $y_1(t)$, le plan de phase, et le pas Δt_j retenu à chaque itération (échelle logarithmique), qui se resserre à chaque saut du cycle limite.

Question 2 le schéma d'Euler implicite est consistant d'ordre ≥ 1 (Solution p. 86.)

Question 3 la méthode des trapèzes est consistante d'ordre ≥ 2. (Solution p. 87.)

Question 4 le schéma du point milieu est consistant d'ordre ≥ 2. (Solution p. 87.)

Question 5 le schéma de Runge-Kutta d'ordre 4 est bien consistant d'ordre 4 si f est C^5. (Solution p. 88.)

On supposera le pas suffisamment petit pour que les schémas implicites soient définis.

7.2. Convergence de schémas

Sous l'hypothèse que f est C^1, montrer que les schémas de Heun et d'Euler implicite sont convergents. (Solution p. 88.)

7.3. Explicite ou implicite ?

Commençons par considérer le cas des systèmes raides.

Question 1 Comparer les performances des schémas d'Euler implicites et explicites à pas fixe dans le cas de $\dot{x} = -\lambda x$, $x(0) = 1$, et $\dot{x} = \lambda x$, $x(0) = 1$, sur un horizon de temps T donné. (Solution p. 88.)

Question 2 Lorsqu'on modélise des systèmes chimiques ou biologiques, on obtient souvent des réactions aux constantes de temps très différentes. Vaut-il mieux utiliser un schéma d'Euler implicite ou explicite pour simuler

$$\dot{x} = \begin{pmatrix} -1 & 0 \\ 0 & -\mu \end{pmatrix} x$$

avec $\mu >> 1$? (Solution p. 89.)

Considérons maintenant le cas des systèmes non-lisses. Un solide freiné par un frottement sec (de Coulomb) subit une force de module constant, toujours opposée à sa vitesse. En notant x la vitesse, le modèle le plus simple est

$$\dot{x} = -\text{sign}(x) \qquad , \qquad x(0) = x_0 \ ,$$

avec la convention $\text{sign}(0) = 0$. La fonction sign n'étant pas continue en 0, les théorèmes du chapitre I ne s'appliquent pas tels quels : on cherche ici une solution continue, dérivable sauf en un nombre fini d'instants, qui vérifie l'équation partout ailleurs.

Question 3

a) Déterminer la solution pour $x_0 > 0$, puis pour x_0 quelconque. Qu'a-t-elle de remarquable par rapport à celle de $\dot{x} = -\lambda x$? Un tel comportement serait-il possible pour une équation $\dot{x} = f(x)$ avec f continûment différentiable ?

b) Ecrire le schéma d'Euler explicite de pas Δt et décrire précisément le comportement de la suite (x^j) à partir de $x_0 > 0$, en particulier lorsqu'elle arrive au voisinage de 0. Diminuer le pas résout-il le problème ?

c) Ecrire le schéma d'Euler implicite et montrer que, pour $0 < |x^j| \leq \Delta t$, l'équation définissant x^{j+1} n'a pas de solution avec la convention $\text{sign}(0) = 0$. Montrer qu'en autorisant sign(0) à prendre n'importe quelle valeur dans $[-1, 1]$ (c'est la régularisation naturelle de la discontinuité), l'équation admet au contraire une unique solution pour tout x^j, que l'on explicitera.

d) En déduire la suite (x^j) produite par le schéma implicite et justifier qu'il résout le problème observé en b).

(Solution p. 89.)

7.4. Euler symplectique

Pour $\omega > 0$ donné, considérons le système

$$\dot{x}_1 \ = \ x_2 \quad , \qquad \dot{x}_2(t) \ = \ -\omega^2 x_1$$

de condition initiale $x(0) \ = \ (1, 0)$. On rappelle que pour une suite de la forme $x^{j+1} = Ax^j$ converge vers 0 si les valeurs propres de A sont à l'intérieur du cercle unité et diverge si au moins une valeur propre est à l'extérieur.

Question 1 Montrer que pour n'importe quel pas Δt fixé, un schéma d'Euler explicite donne une solution divergente, et un schéma d'Euler implicite donne une solution qui converge vers 0. Lequel a raison ? (Solution p. 91.)

On définit maintenant le schéma suivant qui "mélange'' les schémas d'Euler implicites et explicites :

$$\begin{aligned} x_1^{j+1} &= x_1^j + \Delta t\, x_2^j \\ x_2^{j+1} &= x_2^j - \Delta t\, \omega^2 x_1^{j+1} \end{aligned}$$

Question 2 Montrer que la quantité $\omega^2 x_1^2 + x_2^2 + \Delta t\, \omega^2 x_1 x_2$ est conservée. Quelle est alors la forme des solutions obtenues dans le plan de phase si $\omega \Delta t < 2$? En déduire la pertinence de ce schéma. On parle de schéma *symplectique*, car il conserve les volumes. (Solution p. 91.)

Question 3 En écrivant le schéma sous la forme $x^{j+1} = Ax^j$, montrer qu'il diverge par contre si $\Delta t\, \omega > 2$. (Solution p. 92.)

Question 4 Plus généralement, proposer un schéma pour simuler un système Hamiltonien du type

$$\dot{q} = \nabla_p H(q,p)$$
$$\dot{p} = -\nabla_q H(q,p)$$

où $(q,p) \in \mathbb{R}^N \times \mathbb{R}^N$ sont les positions généralisées et quantités de mouvement, H est le Hamiltonien que l'on pourra vérifier être conservé le long des trajectoires. (Solution p. 92.)

A noter que les conclusions de cet exercice sont les mêmes si l'on utilise un schéma d'Euler implicite sur la première composante et un schéma d'Euler explicite sur la deuxième. Ces deux schémas s'appellent respectivement Euler symplectique A et B.

8. Références

Demailly, J.-P. 2006. *Analyse Numérique et équations Différentielles*. EDP Sciences. Grenoble Sciences.

Hairer, E., C. Lubich, and G. Wanner. 2010. *Geometric Numerical Integration : Structure-Preserving Algorithms for Ordinary Differential Equations*. Edited by Springer Series in Computational Mathematics. 2nd ed. Springer-Verlag, Berlin.

Hairer, E., and G. Wanner. 1996. *Solving Ordinary Differential Equations II. Stiff and Differential-Algebraic Problems*. Edited by Springer Series in Computational Mathematics. 2nd ed. Springer-Verlag, Berlin.

Troisième partie

Corrections des exercices

1. Etude théorique des solutions

1.1. Exercices essentiels

Solutions globales I Fixons une condition initiale dans $\mathbb{R} \times \mathbb{R}^2$. La fonction $f : (t, x_1, x_2) \mapsto (\sin x_1 - \sqrt{|t|}x_2, \sqrt{1+x_1^2})$ est continue sur $\mathbb{R} \times \mathbb{R}^2$. Donc d'après le théorème de Peano des solutions existent. D'après le théorème du domaine maximal d'existence, les solutions maximales sont définies sur un intervalle de temps I ouvert.

Par ailleurs, on peut vérifier que pour tout $y \in \mathbb{R}$, $\sqrt{1+y^2} \leq 1 + |y|$, donc

$$|f_1(x)| \leq 1 + \sqrt{|t|}|x_2| \quad , \quad |f_2(x)| \leq 1 + |x_1|$$

et f est bornée par une fonction affine en $\|x\|$. Toutes les solutions maximales sont donc globales, i.e. $I = \mathbb{R}$.

Solutions globales II Considérons une condition initiale dans $\mathbb{R} \times \mathbb{R}^n$ et une solution maximale $t \mapsto x(t)$ définie sur un intervalle I (qui existe d'après le théorème de Peano car f est continue sur $\mathbb{R} \times \mathbb{R}^n$). Alors

$$\frac{d}{dt}V(x(t)) = \langle \nabla V(x(t)), f(t, x(t)) \rangle \leq a(t)V(x(t)) + b(t) \quad \forall t \in I \ ,$$

et donc

$$\frac{d}{dt}\left[e^{-\int_{t_0}^t a(\tau)d\tau} V(x(t)) \right] \leq e^{-\int_{t_0}^t a(\tau)d\tau} b(t) \quad \forall t \in I \ .$$

En intégrant entre t_0 et $t \geq t_0$,

$$e^{-\int_{t_0}^t a(\tau)d\tau} V(x(t)) - V(x(t_0)) \leq \int_{t_0}^t e^{-\int_{t_0}^s a(\tau)d\tau} b(s)ds \quad \forall t \in I \cap [t_0, +\infty[$$

et donc

$$V(x(t)) \leq e^{\int_{t_0}^t a(\tau)d\tau} V(x(t_0)) + \int_{t_0}^t e^{\int_s^t a(\tau)d\tau} b(s)ds \quad \forall t \in I \cap [t_0, +\infty[\ .$$

Une autre manière de faire est de montrer que $V(x(t)) \leq v(t)$ où v est solution maximale de

$$\dot{v} = a(t)v + b(t)$$

pour la condition initiale $v(t_0) = V(x(t_0))$, qui est définie et continue sur $\mathbb{R}$ car la dynamique de v est affine.

Or si $t_m^+ = \sup I$ est fini, d'après le théorème du domaine maximal, $(t, x(t))$ tend soit vers la frontière du domaine de définition de f, soit diverge. Comme f est définie et continue sur $\mathbb{R} \times \mathbb{R}^n$, nécessairement $\lim_{t \to t_m^+} \|x(t)\| = +\infty$ et donc $\lim_{t \to t_m^+} V(x(t)) = +\infty$. Or par continuité de a, b sur $\mathbb{R}$,

$$\lim_{t \to t_m^+} V(x(t)) \leq e^{\int_{t_0}^{t_m^+} a(\tau)d\tau} V(x(t_0)) + \int_{t_0}^{t_m^+} e^{\int_s^{t_m^+} a(\tau)d\tau} b(s)ds \ .$$

C'est donc impossible et $t_m^+ = +\infty$.

Solutions globales III Considérons une condition initiale dans $\mathbb{R} \times \mathbb{R}^n$ et une solution maximale $t \mapsto x(t)$ définie sur un intervalle I. Alors

$$\frac{d}{dt}V(x(t)) = \langle \nabla V(x(t)), f(t, x(t)) \rangle \leq 0 \quad \forall t \in I \ ,$$

donc $t \mapsto V(x(t))$ décroît et est donc bornée en temps positif par $V(x(t_0))$. D'après le théorème du domaine maximal, puisque $\mathbb{R} \times \mathbb{R}^n$ n'a pas de frontière, la seule raison pour laquelle $[t_0, +\infty)$ ne serait pas inclus dans I serait que la solution diverge en temps fini. Or c'est impossible car par hypothèse, on aurait alors $t \mapsto V(x(t))$ qui diverge. Donc x est définie sur $[t_0, +\infty[$. Supposons maintenant qu'elle est non bornée sur $[t_0, +\infty[$. Alors il existe une suite de temps (t_n) avec $\lim_{n\to+\infty} t_n = +\infty$ et $\lim_{n\to+\infty} \|x(t_n)\| = +\infty$, et on a $\lim_{n\to+\infty} V(x(t_n)) = +\infty$, ce qui est impossible. Donc x est bien définie et bornée sur $[t_0, +\infty[$.

Unicité de la solution maximale Nous avons vu dans l'exercice Solutions globales I que les solutions maximales de ce système sont définies sur $\mathbb{R}$. Par ailleurs, la fonction $f : (t, x_1, x_2) \mapsto (\sin x_1 - \sqrt{|t|}x_2, \sqrt{1 + x_1^2})$ est continûment différentiable par rapport à x sur $\mathbb{R} \times \mathbb{R}^2$. Donc pour chaque condition initiale dans $\mathbb{R} \times \mathbb{R}^2$, il existe une unique solution maximale.

Critère de stabilité asymptotique d'un système linéaire plan Soient λ_1 et λ_2 les valeurs propres d'une matrice A de dimension 2. Son polynôme caractéristique est donné par

$$s^2 - \mathrm{tr}A s + \det A = (s - \lambda_1)(s - \lambda_2) = s^2 - (\lambda_1 + \lambda_2)s + \lambda_1\lambda_2 \ .$$

Donc $\mathrm{tr}A = \lambda_1 + \lambda_2$ et $\det A = \lambda_1\lambda_2$. Il y a deux cas: soit les valeurs propres sont complexes conjuguées, soit elles sont réelles.

Si $\lambda_i = \lambda_0 \pm j\omega$, alors $\lambda_1\lambda_2 = \lambda_0^2 + \omega^2$ et $\lambda_1 + \lambda_2 = 2\lambda_0$. Donc $\lambda_0 < 0$ si et seulement si $\mathrm{tr}A < 0$ (et on a alors toujours $\det A > 0$).

Si les valeurs propres sont réelles, les avoir toutes deux strictement négatives implique que $\lambda_1\lambda_2 > 0$ et $\lambda_1 + \lambda_2 < 0$. Réciproquement, si $\lambda_1\lambda_2 > 0$, elles sont non nulles et du même signe, et si de plus $\lambda_1 + \lambda_2 < 0$, ce signe est nécessairement négatif.

Donc dans tous les cas, λ_i à parties réelles strictement négatives équivaut à $\mathrm{tr}A < 0$ et $\det A > 0$.

Oscillateurs couplés I Prenons $x = (y_1, \dot{y}_1, y_2, \dot{y}_2)$ qui vérifie

$$\dot{x} = \begin{pmatrix} x_2 \\ -\frac{k_1}{m_1}x_1 - \frac{\lambda_1}{m_1}x_2 + \frac{k_{12}}{m_1}(x_3 - x_1) \\ x_4 \\ -\frac{k_2}{m_2}x_3 - \frac{\lambda_2}{m_2}x_4 - \frac{k_{12}}{m_2}(x_3 - x_1) \end{pmatrix} = Ax$$

avec $A = \begin{pmatrix} 0 & 1 & 0 & 0 \\ -\frac{k_1+k_{12}}{m_1} & -\frac{\lambda_1}{m_1} & \frac{k_{12}}{m_1} & 0 \\ 0 & 0 & 0 & 1 \\ \frac{k_{12}}{m_2} & 0 & -\frac{k_2+k_{12}}{m_2} & -\frac{\lambda_2}{m_2} \end{pmatrix}$. Pour avoir un point d'équilibre, il faut $x_2 = x_4 = 0$ et

$$\begin{pmatrix} -\frac{k_1+k_{12}}{m_1} & \frac{k_{12}}{m_1} \\ \frac{k_{12}}{m_2} & -\frac{k_2+k_{12}}{m_2} \end{pmatrix} \begin{pmatrix} x_1 \\ x_3 \end{pmatrix} = 0$$

dont la seule solution est $x_1 = x_3 = 0$ (matrice inversible). Donc le seul point d'équilibre est $x = (0, 0, 0, 0)$. Vu que l'on a un système linéaire, les solutions sont uniques, définies sur $\mathbb{R}$ et s'écrivent $x(t) = \exp(At)x(0)$.

Si l'on savait calculer les valeurs propres de A en fonction des paramètres, on pourrait en déduire le comportement des solutions et la stabilité des points d'équilibre.

Lorsque les paramètres des deux masses sont identiques, c'est possible. En effet, le changement de variable linéaire inversible $z = (x_1 + x_3, x_2 + x_4, x_1 - x_3, x_2 - x_4) = Px$ donne des dynamiques découplées de deux oscillateurs indépendants. En effet, $\dot{z} = \Sigma z = PAP^{-1}z$ avec $\Sigma = \begin{pmatrix} 0 & 1 & 0 & 0 \\ -\frac{k}{m} & -\frac{\lambda}{m} & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & -\frac{3k}{m} & -\frac{\lambda}{m} \end{pmatrix}$ qui est diagonale par bloc. On peut donc facilement étudier les valeurs propres de chacun des deux sous-systèmes 2×2.

Si $\lambda > 0$, on a les traces égales à $-\frac{\lambda}{m} < 0$ et les déterminants égaux respectivement à $\frac{k}{m} > 0$ et $\frac{3k}{m} > 0$. Donc d'après l'exercice Critère de stabilité asymptotique d'un système linéaire plan (p. 65), chacune des sous-matrices est de Hurwitz, donc Σ l'est aussi, et donc A aussi car elles sont semblables. Il s'ensuit que 0 est globalement asymptotiquement stable. On peut aussi calculer explicitement les valeurs propres et vérifier qu'elles sont à partie réelle strictement négative.

Lorsque $\lambda = 0$, les frottements sont absents et les valeurs propres sont $\pm i\sqrt{\frac{k}{m}}$ et $\pm i\sqrt{\frac{3k}{m}}$. Comme le système est linéaire, on peut dire que 0 n'est pas attractif donc pas asymptotiquement stable. Mais par contre, il est bien stable. En effet, vu l'expression des solutions, elles s'expriment comme des combinaisons linéaires de sin et cos aux pulsations $\sqrt{\frac{k}{m}}$ et $\sqrt{\frac{3k}{m}}$. En d'autres termes, le système oscille avec une superposition de ces fréquences suivant la condition initiale. Il existe donc M tel que

$$\|x(t)\| \leq M\|x(0)\| \quad \forall t \in \mathbb{R} \ ,$$

et le point d'équilibre est *stable* au sens de la définition.

NB : On aurait pu retrouver ce résultat de stabilité en appliquant un critère de stabilité linéaire sur la matrice Σ (voir Remarque (p. 26)) en disant qu'il y a 4 valeurs propres (complexes) distinctes donc les sous-espaces propres des valeurs propres à partie réelle nulle sont tous de dimension 1, égale à leur multiplicité algébrique.

Stabilité asymptotique I La jacobienne de la dynamique est donnée par

$$J_f(x_1, x_2) = \begin{pmatrix} 0 & 1 - 3x_2^2 \\ -1 + 3x_1^2 + 2x_1x_2 & -(1 - x_1^2) \end{pmatrix}$$

soit

$$J_f(0, 0) = \begin{pmatrix} 0 & 1 \\ -1 & -1 \end{pmatrix}$$

qui est de Hurwitz (valeurs propres $\frac{-1 \pm i\sqrt{3}}{2}$). Donc $(0, 0)$ est bien localement asymptotiquement stable. Cependant, il ne l'est pas globalement car $(1, 1)$ est aussi un point d'équilibre : la fonction constante égale à $(1, 1)$ est solution (et ne tend pas vers 0).

Oscillateurs couplés II L'énergie mécanique du système s'écrit

$$V(x) = \frac{1}{2}k_1x_1^2 + \frac{1}{2}k_2x_3^2 + \frac{1}{2}k_{12}(x_1 - x_3)^2 + \frac{1}{2}m_1x_2^2 + \frac{1}{2}m_2x_4^2 \ .$$

Il s'agit d'une fonction à valeurs positives, et telle que $V(x) = 0$ équivaut à $x = 0$. Si on considère une solution x, on calcule

$$\frac{d}{dt}V(x(t)) = -\lambda_1x_2(t)^2 - \lambda_2x_4(t)^2 \leq 0 \ .$$

D'après le théorème de stabilité par décroissance d'une fonction définie positive (p. 28), la position d'équilibre 0 est donc stable.

Par ailleurs, on voit que V étant décroissante le long des solutions, elle est bornée le long des solutions. Vu que $\lim_{\|x\|\to\infty} V(x) = +\infty$, on en déduit que les solutions maximales sont bornées sur $[0, +\infty[$. En effet, s'il existait une suite de temps (t_n) avec $\lim_{n\to+\infty} t_n = +\infty$ et $\lim_{n\to+\infty} \|x(t_n)\| = +\infty$, on aurait $\lim_{n\to+\infty} V(x(t_n)) = +\infty$, ce qui est impossible.

De plus, vu que $\dot{x} = Ax$, les dérivées successives des solutions s'écrivent comme des combinaisons linéaires des solutions et sont donc elles aussi toutes bornées sur $[0, +\infty[$.

Soit $v : [0, +\infty[\to \mathbb{R}$ définie par $v(t) = V(x(t))$ pour une solution $x : [0, +\infty) \to \mathbb{R}^4$. v est minorée par 0 et décroissante car

$$\dot{v}(t) = -\lambda_1 x_2(t)^2 - \lambda_2 x_4(t)^2 \leq 0$$

donc elle converge lorsque t tend vers l'infini. Par ailleurs,

$$\ddot{v}(t) = -2\lambda_1 x_2(t)\dot{x}_2(t) - 2\lambda_2 x_4(t)\dot{x}_4(t)$$

est bornée vu qu'on a montré que les dérivées successives des solutions sont bornées. En appliquant le lemme de Barbalat, on en déduit que $\dot{v}$ tend vers 0 lorsque t tend vers l'infini.

Supposons que λ_1 est strictement positif. Alors $0 \leq x_2(t)^2 \leq -\frac{\dot{v}(t)}{\lambda_1}$ et la vitesse x_2 de la première masse tend vers 0. Mais vu que $\ddot{x}_2$ est bornée, on a de nouveau par Barbalat que $\dot{x}_2$ tend vers zéro, soit $-k_1 x_1 - k_{12}(x_1 - x_3)$ tend vers 0. En redérivant et en réappliquant Barbalat, on obtient alors que $-k_1 x_2 - k_{12}(x_2 - x_4)$ tend vers zéro, et vu que x_2 tend vers 0, x_4 tend vers 0. En redérivant et en réappliquant Barbalat sur x_4, on obtient que $-k_2 x_3 + k_{12}(x_1 - x_3)$ tend vers 0, et donc enfin, en combinant avec $-k_1 x_1 - k_{12}(x_1 - x_3)$, les positions (x_1, x_3) tendent vers 0. On conclut donc finalement que $\lim_{t\to\infty} x(t) = 0$ et 0 est globalement attractif. Vu que par ailleurs, il est stable, on démontre ainsi qu'il est asymptotiquement stable.

On obtient de manière similaire le résultat si λ_2 est strictement positif.

Stabilité asymptotique II La jacobienne de la dynamique est donnée par

$$J_f(0,0) = \begin{pmatrix} 0 & 1 \\ 0 & -1 \end{pmatrix}$$

qui admet 0 et -1 comme valeurs propres. Nous ne pouvons donc rien conclure sur la stabilité de 0 par le linéarisé.

Considérons $V : \mathbb{R}^2 \to \mathbb{R}_{\geq 0}$ définie par

$$V(x_1, x_2) = x_1^4 + 2x_2^2$$

qui est positive et ne s'annule qu'en $x = 0$. De plus, elle vérifie le long des solutions

$$\frac{d}{dt}V(x(t)) = -4x_2(t)^2 \leq 0$$

donc V décroît le long des solutions et 0 est stable.

La décroissance de $t \mapsto V(x(t))$ implique aussi que $t \mapsto V(x(t))$ est bornée, ce qui empêche les solutions de diverger, car $\lim_{\|x\|\to+\infty} V(x) = +\infty$. Donc les solutions ne peuvent pas diverger en temps fini positif, et les solutions maximales sont définies sur $[0, \infty[$. Elles sont même bornées (en temps positif), car sinon il existerait une suite de temps (t_n) avec $\lim_{n\to+\infty} t_n = +\infty$ et $\lim_{n\to+\infty} \|x(t_n)\| = +\infty$, et on aurait $\lim_{n\to+\infty} V(x(t_n)) = +\infty$, ce qui est impossible. Le long de n'importe quelle solution maximale $t \mapsto x(t)$, on a donc (i) $v(t) = V(x(t))$ qui décroît et est minoré, donc converge lorsque t tend vers l'infini, (ii) $\dot{v}(t) = -4x_2^2(t)$, et (iii) $\ddot{v}(t) = -8x_2(t)\dot{x}_2(t) =$

$-8x_2(t)(-x_1(t)^3 - x_2(t))$ bornée. Donc, par le lemme de Barbalat, $t \mapsto x_2(t)$ converge vers 0 lorsque t tend vers l'infini. Par ailleurs, de manière similaire, $\ddot{x}_2(t) = -3x_1^2 x_2 - (-x_1(t)^3 - x_2(t))$ est bornée, et donc en appliquant Barbalat de nouveau à x_2, on en déduit que $\dot{x}_2$ tend vers 0 et donc x_1 tend vers 0. Ainsi, $(0,0)$ est globalement attractif, et on a vu qu'il est stable, donc il est bien globalement asymptotiquement stable.

Notons qu'avec l'habitude, on aurait pu considérer la fonction $V : \mathbb{R}^2 \to \mathbb{R}_{\geq 0}$ définie par

$$V(x_1, x_2) = x_1^4 + x_2^2 + (x_1 + x_2)^2$$

qui est aussi positive et ne s'annule qu'en $x = 0$. En effet, celle-ci a le bon goût de vérifier

$$\begin{aligned}\frac{d}{dt}V(x(t)) &= 4x_1^3 x_2 - 2x_1^3 x_2 - 2x_2^2 + 2(x_1 + x_2)(x_2 - x_1^3 - x_2) \\ &= -2x_2(t)^2 - 2x_1(t)^4\end{aligned}$$

qui est strictement négatif tant que la solution n'est pas au point d'équilibre. L'application du Lemme de Barbalat donne alors directement la convergence de la solution vers 0 sans avoir à l'appliquer plusieurs fois. En fait dans ce cas, le troisième *critère de Lyapunov* (p. 32) ($\langle \nabla V(x), f(x) \rangle < 0$ pour tout $x \neq 0$ et $\lim_{\|x\| \to +\infty} V(x) = +\infty$) permet de déduire directement la stabilité asymptotique globale.

1.2. Ecoulement dans un réservoir

Question 1 $f : (t, x) \mapsto -k\sqrt{|x|}$ est continue sur $\mathbb{R} \times \mathbb{R}$ donc le théorème de Peano nous garantit l'existence de solutions au problème de Cauchy dans $\mathbb{R}$ pour toute condition initiale.

De plus, $\sqrt{|x|} \leq 1 + |x|$ pour tout $x \in \mathbb{R}$ donc f est bornée de manière affine et toute solution maximale (dans $\mathbb{R}$) est définie sur $\mathbb{R}$.

Enfin, f est continûment différentiable sur $\mathbb{R} \times (\mathbb{R} \setminus \{0\})$ donc lorsque $x_0 \neq 0$, il existe une unique solution maximale dans $\mathbb{R} \setminus \{0\}$ d'après le théorème de Cauchy-Lipschitz (appliqué ici sur l'ouvert $X = \mathbb{R} \setminus \{0\}$). Autrement dit, la solution est unique tant qu'elle reste dans $\mathbb{R} \setminus \{0\}$. Par contre, f n'est pas différentiable en 0 (ni même lipschitzienne) donc le théorème de Cauchy-Lipschitz ne s'applique pas sur $X = \mathbb{R}$: on ne peut plus garantir l'unicité à partir du moment où la solution maximale passe par 0.

Question 2 Soit d'abord $x_0 > 0$. Tant que $x(t) > 0$, on a

$$\dot{x} = -k\sqrt{|x|} \quad \Leftrightarrow \quad \frac{\dot{x}}{\sqrt{x}} = -k \quad \Leftrightarrow \quad x(t) = \left(\sqrt{x_0} - \frac{k}{2}(t - t_0)\right)^2$$

Donc tant que $x(t) > 0$, la solution est unique (comme prévu dans la question précédente) et par continuité, elle atteint 0 en $t_1 = t_0 + 2\sqrt{x_0}/k$. A partir de là, une solution est de rester constamment égale à 0. Sinon, considérons t_2 l'infimum des temps supérieurs à t_1 tels que $x(t)$ est non nul. Alors vu que $\dot{x} \leq 0$, on a $x(t) < 0$ pour tout $t \in]t_2, +\infty[$. Sur cet intervalle,

$$\dot{x} = -k\sqrt{|x|} \quad \Leftrightarrow \quad \frac{\dot{x}}{\sqrt{-x}} = -k \quad \Leftrightarrow \quad x(t) = -\left(\frac{k}{2}(t - t_2)\right)^2$$

On voit alors que toutes les fonctions de ce type avec $t_2 \geq t_1$ arbitraire sont solutions. Pour $x_0 > 0$, l'ensemble des solutions est donc l'ensemble des fonctions définies par

$$x(t) = \begin{cases} \left(\sqrt{x_0} - \frac{k}{2}(t - t_0)\right)^2 & \forall t \in]-\infty, t_0 + 2\sqrt{x_0}/k] \\ 0 & \forall t \in [t_0 + 2\sqrt{x_0}/k, t_2] \\ -\left(\frac{k}{2}(t - t_2)\right)^2 & \forall t \in [t_2, +\infty) \end{cases}$$

pour n'importe quel $t_2 \in [t_0 + 2\sqrt{x_0}/k, +\infty]$. Il y a donc une infinité de solutions (unicité du passé et non unicité du futur).

Maintenant si $x_0 = 0$. Pour $t \geq t_0$, on reproduit le même raisonnement. De même, pour $t \leq t_0$, soit x reste à 0 soit il existe $t_1 < t_0$ tel que $x(t_1) > 0$, et on obtient que les solutions maximales s'écrivent

$$x(t) = \begin{cases} \frac{k^2}{4}(t-t_1)^2 & \forall t \in]-\infty, t_1] \\ 0 & \forall t \in [t_1, t_2] \\ -\frac{k^2}{4}(t-t_2)^2 & \forall t \in [t_2, +\infty] \end{cases}$$

pour n'importe quels $t_1 \in [-\infty, t_0]$ et $t_2 \in [t_0, +\infty]$. Il y a donc une infinité de solutions (à la fois dans le passé et le futur).

Question 3 Lorsque $x_0 > 0$, il y a une seule solution physique, celle qui va à zéro et y reste à jamais. Par contre, lorsque $x_0 = 0$, il y a une infinité de passés possibles car lorsqu'on voit le réservoir vide à t_0 on ne sait pas depuis quand il est vide...

Question 4 Lorsque $x_0 > 0$, les solutions sont continues par rapport à la condition initiale tant qu'elles restent strictement positives (théorème appliqué sur le domaine $X = \mathbb{R} \setminus \{0\}$ où f est C^1). Par contre, si $x_0 = 0$, une solution possible est $x \equiv 0$ alors que pour tout $\delta > 0$, la solution partant de $x_0 + \delta$ est donnée par $x_\delta(t) = \left(\sqrt{x_0 + \delta} - \frac{k}{2}(t - t_0)\right)^2$ pour $t \leq t_0$. Donc sur un horizon de temps fixé (rétrograde) $[\underline{t}, t_0]$, la différence $\|x - x_\delta\|$ ne peut être rendue arbitrairement petite en faisant tendre δ vers 0. Le même phénomène apparaît en temps positif lorsque l'on considère les solutions négatives. En ce sens, on n'a pas la continuité des solutions par rapport à la condition initiale. Cela ne contredit pas le théorème car $f(x) = -\sqrt{|x|}$ n'est pas C^1, ni lipschitzienne en 0.

1.3. Autour du Lemme de Grönwall

Question 1 (Lemme de Grönwall) Soit v l'application définie par $v(t) = \int_{t_0}^t \beta(s)u(s)ds$ sur I. Elle vérifie

$$\dot{v}(t) = \beta(t)u(t) \quad , \quad u(t) \leq \alpha(t) + v(t) \ ,$$

et donc puisque β est à valeurs positives,

$$\dot{v}(t) \leq \alpha(t)\beta(t) + \beta(t)v(t) \ .$$

Soit maintenant w l'application définie par $w(t) = v(t) \exp\left(-\int_{t_0}^t \beta(r)dr\right)$. w est dérivable sur I et pour tout $t \in I$,

$$\begin{aligned} \dot{w}(t) &= (\dot{v}(t) - \beta(t)v(t)) \exp\left(-\int_{t_0}^t \beta(r)dr\right) \\ &\leq \alpha(t)\beta(t) \exp\left(-\int_{t_0}^t \beta(r)dr\right) \end{aligned}$$

En intégrant des deux côtés entre t_0 et $t \geq t_0$, on obtient

$$w(t) - w(t_0) \leq \int_{t_0}^t \alpha(s)\beta(s) \exp\left(-\int_{t_0}^s \beta(r)dr\right) ds$$

et en remplaçant w par son expression,

$$v(t) \leq \int_{t_0}^t \alpha(s)\beta(s) \exp\left(\int_s^t \beta(r)dr\right) ds \ ,$$

ce qui donne le résultat. Finalement, si α est constant alors

$$\begin{aligned} u(t) &\leq \alpha + \alpha \left[-\exp\left(\int_s^t \beta(r)dr \right) \right]_{t_0}^t \\ &\leq \alpha - \alpha + \alpha \exp\left(\int_{t_0}^t \beta(r)dr \right) \end{aligned}$$

ce qui donne le résultat.

Question 2 Soit $x : I \subset J \to \mathbb{R}^n$ une solution maximale au problème de Cauchy. Par le théorème de représentation intégrale des solutions (p. 10), pour tout $t \in I$,

$$x(t) = x_0 + \int_{t_0}^t f(s, x(s))ds \ ,$$

et donc, utilisant l'hypothèse de borne au plus affine de f,

$$\|x(t)\| \leq \|x_0\| + \int_{t_0}^t |b(s)| + |a(s)|\|x(s)\|ds$$

pour tout $t \in I$ avec $t \geq t_0$. Le Lemme de Grönwall donne alors

$$\|x(t)\| \leq \alpha(t) + \int_{t_0}^t \alpha(s)\beta(s) \exp\left(\int_s^t \beta(r)dr \right) ds$$

avec $\alpha(t) = \|x_0\| + \int_{t_0}^t |b(s)|ds$ et $\beta(t) = |a(t)|$ qui sont continues sur J. Donc x ne peut pas exploser en temps fini supérieurs à t_0 dans J (le membre de droite restant borné). En reprenant le raisonnement en temps inférieurs à t_0 en renversant le temps et considérant $-f$ au lieu de f, on obtient que x ne peut pas non plus exploser en temps fini inférieurs à t_0 dans J. Donc nécessairement $I = J$ d'après le théoreme du domaine maximal d'existence (p. 13), vu que f est définie sur $J \times \mathbb{R}^n$.

Question 3 Soient $(t_0, x_0) \in J \times X$ et $\delta \in \mathbb{R}^n$ tel que $(t_0, x_0 + \delta) \in J \times X$. Soient $x : I \to \mathbb{R}^n$ et $x_\delta : I' \to \mathbb{R}^n$ les solutions maximales aux problèmes de Cauchy associés (uniques par le théorème de Cauchy Lipschitz), et $\underline{t}, \overline{t}$ tels que $[\underline{t}, \overline{t}] \subset I$. On sait que

$$\begin{aligned} x(t) &= x_0 + \int_{t_0}^t f(s, x(s))ds && \forall t \in I \\ x_\delta(t) &= x_0 + \delta + \int_{t_0}^t f(s, x_\delta(s))ds && \forall t \in I' \end{aligned}$$

Puisque x est continue, l'ensemble $x([\underline{t}, \overline{t}])$ est un sous-ensemble compact de l'ouvert X. Donc il existe $\varepsilon > 0$ tel que le "tube"

$$\mathcal{C} = \{(t, x_\delta) \in [\underline{t}, \overline{t}] \times \mathbb{R}^n \mid \|x_\delta - x(t)\| \leq \varepsilon\}$$

est inclus dans $J \times X$. On va montrer que $(t, x_\delta(t))$ est définie et reste dans ce tube sur $[\underline{t}, \overline{t}]$ si δ est suffisamment petit. Soit $\underline{t}'$ et $\overline{t}'$ les temps minimaux et maximaux sur $[\underline{t}, \overline{t}]$ tel que

$$(t, x_\delta(t)) \in \mathcal{C} \qquad \forall t \in [\underline{t}', \overline{t}']$$

Puisque $\mathcal{C}$ est compact, et $\partial_x f$ est continue sur $\mathcal{C}$, $M = \max_{\mathcal{C}} \|\partial_x f\|$ est bien défini. Commençons par étudier le comportement des solutions pour $t \geq t_0$. On a

$$\|x(t) - x_\delta(t)\| \leq \|\delta\| + \int_{t_0}^t \|f(s, x(s)) - f(s, x_\delta(s))\|ds \qquad \forall t \in I \cap I' \ , \ t \geq t_0 \ .$$

Donc d'après le théorème des accroissements finis appliqué sur le segment $[(s, x(s)), (s, x_\delta(s))]$ inclus dans $\mathcal{C}$,

$$\|x(t) - x_\delta(t)\| \leq \|\delta\| + \int_{t_0}^{t} M\|x(s) - x_\delta(s)\|ds \qquad \forall t \in [t_0, \bar{t}'] \ .$$

Donc par le Lemme de Grönwall,

$$\|x(t) - x_\delta(t)\| \leq \|\delta\| e^{M(t-t_0)} \qquad \forall t \in [t_0, \bar{t}'] \ .$$

Pour δ suffisamment petit, $\|\delta\| e^{M(t-t_0)} \leq \varepsilon$ sur $[t_0, \bar{t}]$. On a alors nécessairement $\bar{t}' = \bar{t}$. Par un changement de temps dans les solutions pour les parcourir en rétrograde avec la dynamique $-f$ au lieu de f, on montre de la même manière que $\underline{t}' = \underline{t}$ et le résultat est montré. Notons que la preuve est bien toujours valable pour f localement lipschitzienne par rapport à x sur $J \times X$, puisqu'il suffit alors de prendre pour M la constante de Lipschitz de f par rapport à x sur $\mathcal{C}$ qui est compact.

1.4. Cycle limite I

On étudie le comportement des solutions de $\dot{x} = f(x)$ pour

$$f(x) = \begin{pmatrix} x_1 + x_2 - x_1(x_1^2 + x_2^2) \\ -x_1 + x_2 - x_2(x_1^2 + x_2^2) \end{pmatrix}$$

Question 1 Chercher les points d'équilibre du système revient à résoudre

$$\begin{aligned} 0 &= x_1 + x_2 - x_1(x_1^2 + x_2^2) \\ 0 &= -x_1 + x_2 - x_2(x_1^2 + x_2^2) \end{aligned}$$

Multiplier la première ligne par x_2, la deuxième par x_1 et soustraire, donne $x_1^2 + x_2^2 = 0$, soit $x_1 = x_2 = 0$. Il n'y a donc qu'un point d'équilibre $(0, 0)$. La jacobienne de la dynamique est donnée par

$$J_f(x_1, x_2) = \begin{pmatrix} 1 - (x_1^2 + x_2^2) - 2x_1^2 & 1 - 2x_1x_2 \\ -1 - 2x_1x_2 & 1 - (x_1^2 + x_2^2) - 2x_2^2 \end{pmatrix}$$

soit

$$J_f(0, 0) = \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}$$

qui a pour valeurs propres $1 \pm i$. La partie réelle étant positive, le point d'équilibre est instable.

Question 2 $f : \mathbb{R}^2 \to \mathbb{R}^2$ définie par $f(x) = (x_1 + x_2 - x_1(x_1^2 + x_2^2), -x_1 + x_2 - x_2(x_1^2 + x_2^2))$ est continûment différentiable sur $\mathbb{R}^2$. Donc d'après le théorème de Cauchy-Lipschitz, le système admet une unique solution maximale pour toute condition initiale. De plus,

$$\begin{aligned} \frac{d}{dt}V(x(t)) &= \langle \nabla V(x), f(x) \rangle \\ &= 2(x_1^2 + x_1x_2 - x_1^2(x_1^2 + x_2^2) - x_1x_2 + x_2^2 - x_2^2(x_1^2 + x_2^2)) \\ &= -2(x_1^2 + x_2^2 - 1)(x_1^2 + x_2^2) = -2(V(x) - 1)V(x) \end{aligned}$$

Donc $\frac{d}{dt}V(x(t))$ est négatif lorsque $V(x) > 1$, i.e., à l'extérieur du disque de centre 0 et de rayon 1, zéro lorsque $V(x) = 1$, i.e., sur le cercle, et positif lorsque $0 < V(x) < 1$, i.e., à l'intérieur du disque, et zéro à l'équilibre. Il s'ensuit en particulier que $V(x) = \|x\|^2$ décroît lorsque $\|x\| > 1$, donc les solutions restent bornées en temps positif. Or, vu que f est continue sur $\mathbb{R}^2$, on sait du Théorème du domaine maximal d'existence (p. 13) que la seule raison pour laquelle une solution maximale ne serait pas définie pour tout $t \geq t_0$ serait qu'elle explose en temps fini. C'est impossible ici.

Question 3 Supposons que $x_0 := x(t_0)$ vérifie $\|x_0\| \neq 1$ et qu'il existe t_1 tel que $\|x(t_1)\| = 1$. Considérons le problème de Cauchy de condition initiale $x^* := x(t_1)$ à $t = t_1$. Il admet donc une solution qui au temps t_0 vaut x_0. Mais il existe une autre solution

$$\begin{pmatrix} \cos(t-t_1) & \sin(t-t_1) \\ -\sin(t-t_1) & \cos(t-t_1) \end{pmatrix} x^*$$

qui reste sur le cercle en tout temps et qui vaut aussi x^* à $t = t_1$, ce qui est impossible par le théorème de Cauchy-Lipschitz (car f est continûment différentiable).

Question 4 Si $V(x(t_0)) = \|x(t_0)\|^2 = 1$, alors V est constant donc les trajectoires initialisées sur le cercle de rayon 1 y restent. Sur le cercle, la dynamique suit celle d'un oscillateur

$$\begin{aligned} \dot{x}_1 &= x_2 \\ \dot{x}_2 &= -x_1 \end{aligned}$$

donc les trajectoires "tournent" sur le cercle.

Si $V(x(t_0)) = x_1(t_0)^2 + x_2(t_0)^2 > 1$ alors V décroît strictement tant qu'il reste plus grand que 1, et il reste plus grand que 1 pour tout temps d'après la question précédente. Donc $t \mapsto V(x(t))$ est décroissante et minorée par 1, et converge vers une limite $\ell \geq 1$. Si l'on avait $\ell > 1$, alors pour tout $t \geq t_0$,

$$\frac{d}{dt}V(x(t)) = -2\big(V(x(t)) - 1\big)V(x(t)) \leq -2(\ell - 1)\ell < 0 \ ,$$

et $V(x(t))$ tendrait vers $-\infty$: contradiction. Donc $\ell = 1$ et $\|x(t)\| \to 1$: les trajectoires initialisées à l'extérieur du cercle s'en approchent asymptotiquement sans jamais le rencontrer.

Si $0 < V(x(t_0)) = x_1(t_0)^2 + x_2(t_0)^2 < 1$ alors V croît strictement tant qu'il reste plus petit que 1, et le même argument (V croissante, majorée par 1, de limite $\ell \leq 1$ avec $\frac{d}{dt}V \geq 2(1-\ell)V(x(t_0)) > 0$ si $\ell < 1$) donne $\|x(t)\| \to 1$.

Enfin, la trajectoire initialisée à zéro reste à zéro. En résumé, le cercle unité est un *cycle limite attractif* : toute solution non nulle s'enroule asymptotiquement sur lui, de l'intérieur ou de l'extérieur.

Le portrait de phase est donné Figure 1.1 (p. 73).

1.5. Critères de stabilité de Lyapunov

Question 1 Supposons d'abord que $\langle \nabla V(x), f(x) \rangle \leq 0$ pour tout $x \in W$. On a donc pour toute solution $t \mapsto x(t)$ initialisée dans W, $V(x(t)) \leq V(x(0))$ tant que $x(t) \in W$. Prenons $\varepsilon > 0$ suffisamment petit tel que $B_f(a, 2\varepsilon) \subset W$. On veut montrer qu'il existe η tel que toute trajectoire initialisée dans $B(a, \eta)$ reste dans $B(a, \varepsilon) \subset W$. Tout d'abord, il existe $\varepsilon_V > 0$ tel que

$$\forall x \in B_f(a, 2\varepsilon) \ : \ V(x) \leq \varepsilon_V \implies x \in B(a, \varepsilon) \ .$$

En effet, sinon, il existerait une suite $(x_k)_{k\in\mathbb{N}}$ d'éléments de $B_f(a, 2\varepsilon)$ telle que pour tout $k > 0$, $V(x_k) \leq \frac{1}{k}$ et $\|x_k - a\| \geq \varepsilon$. L'ensemble $B_f(a, 2\varepsilon)$ étant compact, on peut en extraire une sous-suite convergeant vers $x^\star$ qui vérifie nécessairement $V(x^\star) = 0$ par continuité de V et $\|x^\star - a\| \geq \varepsilon$, i.e. $x^\star \neq a$. Ceci est impossible par hypothèse. On a donc l'existence de ε_V. Maintenant, par continuité de V en a et puisque $V(a) = 0$, il existe aussi $\eta > 0$ tel que

$$x \in B(a, \eta) \implies V(x) \leq \varepsilon_V \ .$$

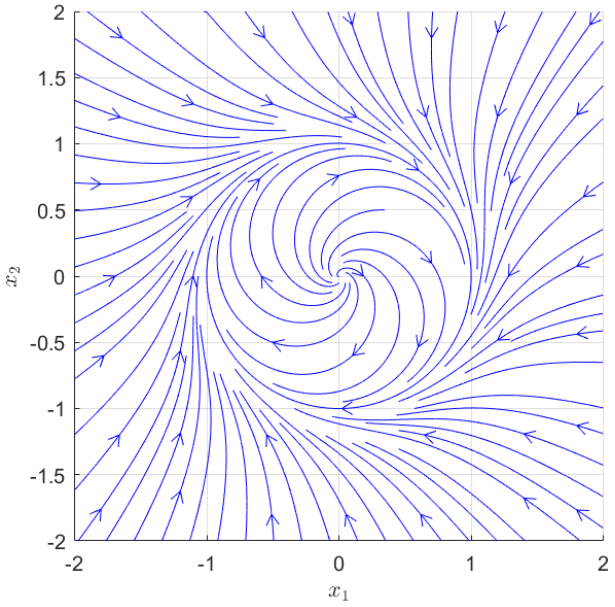


FIGURE 1.1. – Portrait de phase de l'exercice Cycle Limite I

Soit alors une solution maximale x avec $x(0) \in B(a,\eta)$. Attention, la décroissance de $V(x(t))$ n'est acquise que tant que $x(t) \in W$: il faut donc s'assurer que la solution ne quitte pas W. Supposons par l'absurde que x sorte de $B_f(a,2\varepsilon)$, et notons

$$t_1 = \inf\{t \geq 0 \ : \ \|x(t)-a\| > 2\varepsilon\} > 0 \ .$$

Sur $[0,t_1]$, $x(t) \in B_f(a,2\varepsilon) \subset W$, donc $V(x(t)) \leq V(x(0)) \leq \varepsilon_V$ et ainsi $x(t) \in B(a,\varepsilon)$; en particulier $\|x(t_1)-a\| < \varepsilon$, alors que par continuité et définition de t_1, $\|x(t_1)-a\| = 2\varepsilon$: contradiction. Donc $x(t)$ reste dans $B_f(a,2\varepsilon) \subset W$, et le même argument donne $x(t) \in B(a,\varepsilon)$ pour tout $t \geq 0$ tant qu'elle est définie. Elle reste ainsi dans un compact de X, donc par le théorème du domaine maximal d'existence (p. 13), x est définie sur $\mathbb{R}_{\geq 0}$. Ceci prouve la stabilité de a.

Question 2 Supposons maintenant $\langle \nabla V(x), f(x)\rangle < 0$ pour tout $x \in W \setminus \{a\}$. Alors par le point précédent a est stable. Il suffit de montrer l'attractivité locale. Par stabilité, si $x(0) \in B(a,\eta)$, $x(t) \in B(a,\varepsilon) \subset W$ pour tout t et $t \to V(x(t))$ est donc strictement décroissante. Comme elle est aussi bornée inférieurement par 0, elle converge vers $\ell \geq 0$. Supposons $\ell > 0$. Alors, par continuité de V, il existe $0 < \nu < \varepsilon$ et $\bar{t} > 0$ tel que pour tout $t \geq \bar{t}$, $\|x(t)-a\| \geq \nu$. Soit

$$\gamma = \max_{\nu \leq \|x-a\| \leq \varepsilon} \langle \nabla V(x), f(x)\rangle$$

qui existe par continuité de ∇V et f sur un compact. Puisque $\langle \nabla V(x), f(x)\rangle < 0$ sur $W \setminus \{a\}$, $\gamma < 0$. Alors, pour tout $t \geq \bar{t}$,

$$V(x(t)) = V(x(\bar{t})) + \int_{\bar{t}}^{t} \langle \nabla V(x(s)), f(x(s))\rangle ds \leq V(x(\bar{t})) + \gamma(t-\bar{t}) \ .$$

Mais comme $\gamma < 0$ cette quantité devient strictement négative au bout d'un certain temps, ce qui est impossible. Donc $\lim_{t\to+\infty} V(x(t)) = 0$. Finalement, reproduisant le même raisonnement que pour l'existence de ε_V, on peut garantir que $\|x-a\|$ est arbitrairement petit en prenant $V(x)$ suffisamment petit. Donc on en déduit que $\lim_{t\to+\infty} \|x(t)-a\| = 0$.

Question 3 Supposons enfin que $\lim_{\|x\|\to+\infty} V(x) = +\infty$ et $W = \mathbb{R}^n$. Alors $V(x(t)) \leq V(x(0))$ pour tout $t \in I$, $t \geq 0$, donc $x(t) \in V^{-1}([0, V(x(0))])$ pour tout $t \geq 0$. Le fait que $\lim_{\|x\|\to+\infty} V(x) = +\infty$ est équivalent au fait que l'image réciproque de toute compact est compact (on dit que V est propre). Donc $V^{-1}([0, V(x(0))])$ est compact et par le théorème du domaine maximal d'existence nécessairement (p. 13) $x(t)$ est défini pour tout $t \geq 0$, et reste dans ce compact. Alors on peut reproduire le même raisonnement que plus haut et obtenir la convergence de x vers a.

Question 4 (Application à la stabilité des systèmes linéaires) Puisque les valeurs propres de A sont à partie réelle strictement négative, il existe $C \geq 1$ et $\mu > 0$ tels que $\|e^{As}\| \leq Ce^{-\mu s}$ pour tout $s \geq 0$. L'intégrale

$$P = \int_0^{+\infty} \left(e^{As}\right)^\top Q e^{As} ds$$

est donc bien définie (absolument convergente). La matrice P est symétrique car l'intégrande l'est. Pour tout $x \in \mathbb{R}^n$,

$$x^\top P x = \int_0^{+\infty} \left(e^{As}x\right)^\top Q \left(e^{As}x\right) ds \geq \lambda_{\min}(Q) \int_0^{+\infty} \|e^{As}x\|^2 ds \ ,$$

qui est strictement positif si $x \neq 0$ car e^{As} est inversible et $s \mapsto \|e^{As}x\|^2$ est continue. Donc P est définie positive. Enfin, puisque A commute avec e^{As},

$$A^\top P + PA = \int_0^{+\infty} \left(A^\top e^{A^\top s} Q e^{As} + e^{A^\top s} Q e^{As} A\right) ds = \int_0^{+\infty} \frac{d}{ds}\left(e^{A^\top s} Q e^{As}\right) ds = \lim_{S\to+\infty} e^{A^\top S} Q e^{AS} - Q = -Q \ ,$$

car $\|e^{AS}\| \to 0$ lorsque $S \to +\infty$.

Posons alors $V(x) = x^\top P x$. Cette fonction est C^1, $V(0) = 0$, $V(x) > 0$ pour $x \neq 0$, et $V(x) \geq \lambda_{\min}(P)\|x\|^2 \to +\infty$ lorsque $\|x\| \to +\infty$. De plus, pour tout x,

$$\langle \nabla V(x), Ax\rangle = 2x^\top P A x = x^\top \left(A^\top P + PA\right) x = -x^\top Q x < 0 \qquad \forall x \neq 0 \ .$$

Par la question 3 (avec $f(x) = Ax$, $a = 0$, $W = \mathbb{R}^n$), 0 est globalement asymptotiquement stable pour $\dot{x} = Ax$.

Question 5 (Application à la stabilité via linéarisé tangent) Posons $J = J_f(a)$ et

$$\Delta(x) = f(x) - f(a) - J(x-a) = f(x) - J(x-a) \ ,$$

puisque $f(a) = 0$. Par différentiabilité de f en a, la fonction δ définie par $\delta(x) = \Delta(x)/\|x-a\|$ pour $x \neq a$ et $\delta(a) = 0$ vérifie $\lim_{x\to a} \delta(x) = 0$, et $\Delta(x) = \delta(x)\|x-a\|$ pour tout x.

Par la question 4 avec $A = J$ et $Q = I$, il existe $P = P^\top > 0$ telle que

$$J^\top P + PJ = -I \ .$$

Considérons $V(x) = (x-a)^\top P(x-a)$, qui est C^1, positive et nulle seulement en $x = a$. Pour tout $x \in X$,

$$\begin{aligned}
\langle \nabla V(x), f(x)\rangle &= 2(x-a)^\top P f(x) \\
&= (x-a)^\top \left(J^\top P + PJ\right)(x-a) + 2(x-a)^\top P \Delta(x) \\
&\leq -\|x-a\|^2 + 2\|x-a\|\|P\|\|\Delta(x)\| \\
&\leq -\|x-a\|^2 \left(1 - 2\|P\|\|\delta(x)\|\right) \ .
\end{aligned}$$

Comme X est ouvert et $\delta(x) \to 0$ lorsque $x \to a$, il existe $r > 0$ tel que $B(a,r) \subset X$ et

$$\|\delta(x)\| \leq \frac{1}{4\|P\|} \qquad \forall x \in B(a,r) \ .$$

Alors $\langle \nabla V(x), f(x)\rangle \leq -\frac{1}{2}\|x-a\|^2 < 0$ pour tout $x \in B(a,r) \setminus \{a\}$. Par la question 2 (avec $W = B(a,r)$), a est localement asymptotiquement stable.

1.6. Critères d'instabilité

Question 1 (Théorème de Chetaev) Supposons par l'absurde que a soit stable. Prenons $\varepsilon > 0$ tel que $B_f(a,\varepsilon) \subset W$. Par stabilité, il existe $\eta > 0$ tel que toute solution maximale initialisée dans $B_f(a,\eta)$ est définie sur $\mathbb{R}_{\geq 0}$ et reste dans $B_f(a,\varepsilon)$. Par hypothèse, il existe $x_0 \in B(a,\eta)$ tel que $V(x_0) > 0$. Soit x une solution maximale initialisée en x_0 et $v(t) = V(x(t))$, qui est C^1 sur $\mathbb{R}_{\geq 0}$ avec

$$\dot{v}(t) = \langle \nabla V(x(t)), f(x(t))\rangle \ .$$

Montrons d'abord que $v(t) \geq v(0)$ pour tout $t \geq 0$. Sinon, $t_1 = \inf\{t \geq 0 \ : \ v(t) < v(0)\}$ vérifie $v(t_1) = v(0) > 0$ par continuité, donc $\dot{v}(t_1) > 0$ par hypothèse, et $v > v(0)$ sur un intervalle $]t_1, t_1 + h]$, ce qui contredit la définition de t_1. Ainsi, pour tout $t \geq 0$, $x(t)$ appartient à

$$K = \{x \in B_f(a,\varepsilon) \ : \ V(x) \geq V(x_0)\} \ ,$$

qui est compact (fermé dans le compact $B_f(a,\varepsilon)$ par continuité de V) et ne contient pas a puisque $V(a) = 0 < V(x_0)$. Soit

$$\gamma = \min_{x \in K} \langle \nabla V(x), f(x)\rangle$$

qui existe par continuité de ∇V et f sur le compact K. Puisque $V > 0$ sur K, $\gamma > 0$ par hypothèse. Alors, pour tout $t \geq 0$,

$$V(x(t)) = V(x_0) + \int_0^t \langle \nabla V(x(s)), f(x(s))\rangle ds \geq V(x_0) + \gamma t \ ,$$

qui tend vers $+\infty$. C'est impossible puisque V est continue donc bornée sur le compact $B_f(a,\varepsilon)$. Donc a est instable.

Question 2 (Exemples) Pour $\dot{x} = x^3$, prenons $V(x) = x^2$, qui est C^1, nulle en 0 et strictement positive ailleurs. On a $\langle \nabla V(x), x^3\rangle = 2x^4 > 0$ pour tout $x \neq 0$, donc 0 est instable par la question 1 avec $W = \mathbb{R}$. Notons que le théorème du linéarisé tangent (p. 27) ne permet pas de conclure ici puisque le linéarisé en 0 est nul. On peut d'ailleurs vérifier que la solution initialisée en $x_0 \neq 0$ est $x(t) = \frac{x_0}{\sqrt{1-2x_0^2 t}}$, qui explose en temps fini $t = \frac{1}{2x_0^2}$, aussi proche de 0 que soit x_0.

Pour le second système, prenons $V(x) = x_1^2 - x_2^2$, qui n'est pas de signe constant. On a $V(0) = 0$, $V(\eta, 0) = \eta^2 > 0$ pour tout $\eta > 0$, et

$$\langle \nabla V(x), f(x)\rangle = 2x_1 \cdot x_1 - 2x_2 \cdot (-x_2) = 2\|x\|^2 > 0 \qquad \forall x \neq 0 \ ,$$

en particulier lorsque $V(x) > 0$. Par la question 1 avec $W = \mathbb{R}^2$, 0 est instable. Les trajectoires s'éloignent en effet de 0 selon la direction x_1 : c'est un *point selle*.

Question 3 (Application à l'instabilité des systèmes linéaires) Notons $\lambda_1, \dots, \lambda_p$ les valeurs propres (complexes, distinctes) de A, de multiplicités $m_1, \dots, m_p$, et $\mu = \max_i \mathrm{Re}(\lambda_i) > 0$. Choisissons $\sigma \in]0, \mu[$ différent de tous les $\mathrm{Re}(\lambda_i)$, ce qui est possible puisqu'ils sont en nombre fini. Ce décalage permet de traiter les éventuelles valeurs propres de partie réelle nulle, qui ne sont ni « stables » ni « instables » : elles sont ici rangées du côté stable.

Écrivons le polynôme caractéristique $\chi_A = \chi_+\chi_-$, où χ_+ (resp. χ_-) est le produit des facteurs $(X-\lambda_i)^{m_i}$ tels que $\mathrm{Re}(\lambda_i) > \sigma$ (resp. $\mathrm{Re}(\lambda_i) < \sigma$). Les valeurs propres non réelles de A étant deux à deux conjuguées avec la même multiplicité, χ_+ et χ_- sont à coefficients réels, et ils sont premiers entre eux. Par le théorème de Cayley-Hamilton et le lemme des noyaux,

$$\mathbb{R}^n = E_+ \oplus E_- \qquad , \qquad E_\pm = \ker \chi_\pm(A) \ ,$$

où E_+ et E_- (éventuellement réduit à $\{0\}$) sont stables par A. Il existe donc $T \in \mathbb{R}^{n\times n}$ inversible (dont les colonnes sont une base de E_+ suivie d'une base de E_-) telle que

$$T^{-1}AT = \begin{pmatrix} A_+ & 0 \\ 0 & A_- \end{pmatrix} \ ,$$

où $\chi_\pm(A_\pm) = 0$. Les valeurs propres de A_+ sont donc des racines de χ_+, c'est-à-dire de partie réelle $> \sigma$, et celles de A_- sont de partie réelle $< \sigma$. Par ailleurs, $E_+ \neq \{0\}$: si $v \in \mathbb{C}^n$ est un vecteur propre associé à une valeur propre λ de partie réelle μ, alors $\chi_+(A)v = \chi_+(\lambda)v = 0$, donc $\mathrm{Re}(v)$ et $\mathrm{Im}(v)$, qui ne sont pas tous deux nuls, sont dans E_+ puisque $\chi_+(A)$ est réelle.

Les valeurs propres de $\sigma I - A_+$ et de $A_- - \sigma I$ sont donc toutes à partie réelle strictement négative. Par la question 4 de l'exercice *Critères de stabilité de Lyapunov* (p. 32) appliquée avec $Q = I$, il existe P_+ et P_- symétriques définies positives telles que

$$(\sigma I - A_+)^\top P_+ + P_+(\sigma I - A_+) = -I \qquad , \qquad (A_- - \sigma I)^\top P_- + P_-(A_- - \sigma I) = -I \ ,$$

c'est-à-dire

$$A_+^\top P_+ + P_+ A_+ = 2\sigma P_+ + I \qquad , \qquad A_-^\top P_- + P_- A_- = 2\sigma P_- - I \ .$$

Posons alors, avec $T^{-\top} = (T^{-1})^\top$,

$$D = \begin{pmatrix} P_+ & 0 \\ 0 & -P_- \end{pmatrix} \qquad , \qquad P = T^{-\top} D\, T^{-1} \qquad , \qquad Q = T^{-\top}T^{-1} \ .$$

Les matrices P et Q sont symétriques, Q est définie positive, et en notant $M = T^{-1}AT$,

$$\begin{aligned} A^\top P + PA &= T^{-\top}\left(M^\top D + DM\right) T^{-1} \\ &= T^{-\top} \begin{pmatrix} A_+^\top P_+ + P_+ A_+ & 0 \\ 0 & -(A_-^\top P_- + P_- A_-) \end{pmatrix} T^{-1} \\ &= T^{-\top}\left(2\sigma D + I\right) T^{-1} = 2\sigma P + Q \ . \end{aligned}$$

Enfin, pour $z_+ \in \mathbb{R}^{\dim E_+}$ non nul et $\bar{x} = T(z_+, 0)$, on a $\bar{x}^\top P \bar{x} = z_+^\top P_+ z_+ > 0$.

Considérons maintenant $V(x) = x^\top P x$. On a $V(0) = 0$ et, pour tout $t > 0$, $V(t\bar{x}) = t^2\, \bar{x}^\top P \bar{x} > 0$, donc V prend des valeurs strictement positives arbitrairement près de 0. De plus, pour tout $x \in \mathbb{R}^n$,

$$\langle \nabla V(x), Ax \rangle = 2x^\top PAx = x^\top \left(A^\top P + PA\right) x = 2\sigma V(x) + x^\top Q x \ ,$$

qui est strictement positif dès que $V(x) > 0$ (et donc $x \neq 0$). Par la question 1 avec $W = \mathbb{R}^n$, 0 est instable pour $\dot{x} = Ax$.

Notons que pour un système linéaire, on pouvait conclure plus directement : si v est un vecteur propre associé à une valeur propre λ de partie réelle strictement positive, la solution initialisée en $\eta\,\mathrm{Re}(v)$ s'écrit $x(t) = \eta\,\mathrm{Re}(e^{\lambda t}v)$ et n'est pas bornée, aussi petit que soit $\eta > 0$. L'intérêt de la fonction V construite ici est qu'elle reste une fonction de Chetaev pour des perturbations non linéaires de $\dot{x} = Ax$, comme on va le voir à la question suivante.

Question 4 (Application à l'instabilité via linéarisé tangent) Comme dans la question 5 de l'exercice *Critères de stabilité de Lyapunov* (p. 74), posons $J = J_f(a)$ et $\Delta(x) = f(x) - J(x-a)$, de sorte que $\Delta(x) = \delta(x)\|x-a\|$ avec $\lim_{x\to a}\delta(x) = 0$. Par la question 3 appliquée à $A = J$, il existe $\sigma > 0$, Q symétrique définie positive et P symétrique telles que

$$J^\top P + PJ = 2\sigma P + Q \ ,$$

et $\bar{x} \in \mathbb{R}^n$ tel que $\bar{x}^\top P \bar{x} > 0$ (en particulier $P \neq 0$). Considérons $V(x) = (x-a)^\top P(x-a)$. Pour tout $x \in X$,

$$\begin{aligned}
\langle \nabla V(x), f(x)\rangle &= 2(x-a)^\top P f(x) \\
&= (x-a)^\top \left(J^\top P + PJ\right)(x-a) + 2(x-a)^\top P\Delta(x) \\
&= 2\sigma V(x) + (x-a)^\top Q(x-a) + 2(x-a)^\top P\Delta(x) \\
&\geq 2\sigma V(x) + \lambda_{\min}(Q)\|x-a\|^2 - 2\|P\|\|\delta(x)\|\|x-a\|^2 \ .
\end{aligned}$$

Comme X est ouvert et $\delta(x) \to 0$ lorsque $x \to a$, il existe $r > 0$ tel que $B(a,r) \subset X$ et

$$\|\delta(x)\| \leq \frac{\lambda_{\min}(Q)}{4\|P\|} \qquad \forall x \in B(a,r) \ .$$

Alors, pour tout $x \in B(a,r)$,

$$\langle \nabla V(x), f(x)\rangle \geq 2\sigma V(x) + \frac{\lambda_{\min}(Q)}{2}\|x-a\|^2 \ ,$$

qui est strictement positif dès que $V(x) > 0$ (et donc $x \neq a$). Par ailleurs $V(a) = 0$ et $V(a+t\bar{x}) = t^2\,\bar{x}^\top P\bar{x} > 0$ pour tout $t > 0$, avec $a + t\bar{x} \in B(a,r)$ pour t assez petit. Par la question 1 avec $W = B(a,r)$, a est instable.

1.7. Cycle limite II

On étudie le comportement des solutions de $\dot{x} = f(x)$ pour

$$f(x) = \begin{pmatrix} x_1(\alpha - \beta x_2) \\ -x_2(\gamma - \delta x_1) \end{pmatrix}$$

Question 1 On résout $f(x) = 0$, ce qui donne les points d'équilibre $(0,0)$ et $\bar{x} = \left(\frac{\gamma}{\delta}, \frac{\alpha}{\beta}\right)$.

La jacobienne de la dynamique est donnée par

$$J_f(x) = \begin{pmatrix} \alpha - \beta x_2 & -\beta x_1 \\ \delta x_2 & -(\gamma - \delta x_1) \end{pmatrix}$$

En $(0,0)$,

$$J_f(0,0) = \begin{pmatrix} \alpha & 0 \\ 0 & -\gamma \end{pmatrix}$$

a pour valeur propre $\alpha > 0$, donc $(0,0)$ est instable. Par contre, en $\bar{x}$,

$$J_f(\bar{x}) = \begin{pmatrix} 0 & -\beta\frac{\gamma}{\delta} \\ \delta\frac{\alpha}{\beta} & 0 \end{pmatrix}$$

a des valeurs propres imaginaires pures $\pm i\sqrt{\alpha\gamma}$, donc a priori on ne peut rien dire sur la stabilité de $\bar{x}$ pour le système non linéaire.

Question 2 Soit $x_0 = (0, x_{2,0}) \in \{0\} \times \mathbb{R}_{\geq 0}$ sur l'axe des ordonnées. Puisque f est C^1 sur $\mathbb{R}^2$, par le théorème de Cauchy-Lipschitz, le problème de Cauchy associé à la condition initiale (t_0, x_0) pour un t_0 quelconque, admet une unique solution

$$x(t) = (0, x_2(t))$$

définie sur $\mathbb{R}$ avec x_2 solution de

$$\dot{x}_2 = -\gamma x_2 \ .$$

De même, pour $x_0 = (x_{1,0}, 0) \in \mathbb{R}_{\geq 0} \times \{0\}$, le problème de Cauchy associé pour un t_0 quelconque, admet une unique solution du type

$$x(t) = (x_1(t), 0)$$

définie sur $\mathbb{R}$ avec x_1 solution de

$$\dot{x}_1 = \alpha x_1 \ .$$

Si une solution initialisée dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$ croisait l'axe des abscisses ou des ordonnées, il existerait une autre solution au problème de Cauchy associé à $x_0 = (0, x_{2,0})$ ou $x_0 = (x_{1,0}, 0)$ qui ne resterait pas sur l'axe en temps négatif, ce qui est impossible. Elle reste donc dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$.

Question 3 f est continue sur $\mathbb{R}^2$ donc d'après le théorème du domaine maximal d'existence, si une solution maximale initialisée dans $\mathbb{R}^2$ n'est pas définie sur $\mathbb{R}$, c'est que nécessairement $\|x\|$ diverge en temps fini (car la frontière de $\mathbb{R}^2$ est vide).

Maintenant considérons une solution maximale $x : I \subset \mathbb{R} \to \mathbb{R}^2$ initialisée dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$. Par la question précédente, elle reste dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$ donc $H(x(t))$ est bien définie pour tout $t \in I$, et on a

$$\frac{d}{dt} H(x(t)) = \langle \nabla H(x(t)), \dot{x}(t) \rangle = \langle \nabla H(x(t)), f(x(t)) \rangle = 0$$

Donc H est constante et il est impossible que $\|x\|$ diverge en temps fini car on aurait $\lim H(x(t)) = +\infty$. Donc $I = \mathbb{R}$.

Remarque : On aurait pu aussi directement se placer sur $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$ et considérer les solutions maximales $x : I \subset \mathbb{R} \to \mathbb{R}_{>0} \times \mathbb{R}_{>0}$ de $\dot{x} = f(x)$ dans cet ensemble (où f est bien sûr continue). Si x n'était pas définie sur $\mathbb{R}$, alors nécessairement d'après le théorème du domaine maximal d'existence, $x(t)$ finirait, en temps fini, par être à chaque instant soit arbitrairement loin de l'origine, soit arbitrairement proche de la frontière de $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$, c'est-à-dire avec x_1 ou x_2 arbitrairement petit. Mais ceci est impossible car $H(x) = u_{\delta,\gamma}(x_1) + u_{\beta,\alpha}(x_2)$, où $u_{c,d}(z) = cz - d\ln z$ est minorée et tend vers $+\infty$ en 0^+ comme en $+\infty$: dans chacun des cas on aurait

$$\lim H(x(t)) = +\infty \ ,$$

contredisant la conservation de H. On prouve alors en même temps que les solutions initialisées dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$ sont définies sur $\mathbb{R}$ dans $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$ (et donc restent dans cet ensemble)

Bonus : Ici, en calculant le gradient et la hessienne de H (voir Calcul Différentiel III), on voit que H atteint un minimum local (et en fait global) en $\bar{x}$ (gradient nul et matrice hessienne

définie positive, mais on peut aussi le montrer en étudiant la fonction réelle $u(z) = z - c\ln z$ pour une constante $c > 0$). Donc

$$V(x) = H(x) - H(\bar{x})$$

est une fonction C^1 sur $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$, positive, qui ne s'annule localement qu'en $\bar{x}$. Vu que H est conservée le long des trajectoires, on peut déduire que $\bar{x}$ est stable par le théorème de décroissance (p. 28).

Question 4 L'équilibre $\bar{x}$ se trouve au milieu des courbes de niveau (car c'est en fait le minimum de H). Donc si on se donne $\varepsilon > 0$, on peut trouver $\eta_H > 0$ tel que $H(x) - H(\bar{x}) < \eta_H$ implique $\|x - \bar{x}\| < \varepsilon$. On en déduit que pour toute condition initiale telle que $H(x_0) - H(\bar{x}) < \eta_H$, la trajectoire reste à une distance inférieure à ε de $\bar{x}$. Par ailleurs, l'ensemble des courbes de niveau de $H - H(\bar{x})$ inférieures à η_H constituent bien un voisinage de $\bar{x}$ donc $\bar{x}$ est stable par définition.

Le portrait de phase est donné Figure 1.2 (p. 79).

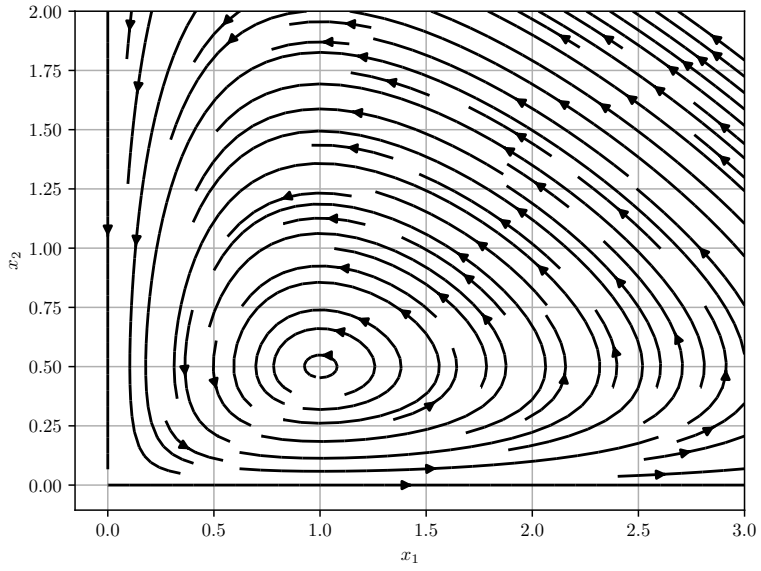


FIGURE 1.2. – Portrait de phase de l'exercice Cycle Limite II

Question 5 Pour que x_1 vale x_1^* à l'équilibre, il faut que x_2 vale $x_2^* = \frac{\alpha}{\beta}$ et $u^* = x_2^*(\gamma - \delta x_1^*)$.

Question 6 Commençons par justifier le choix de la référence v_r. Si l'on parvenait à imposer $x_2 = v_r(x_1)$, la première équation deviendrait

$$\dot{x}_1 = x_1(\alpha - \beta v_r(x_1)) = -\beta\lambda_1\, x_1(x_1 - x_1^*)\ ,$$

équation scalaire pour laquelle x_1^* est asymptotiquement stable sur $\mathbb{R}_{>0}$ ($\dot{x}_1 < 0$ si $x_1 > x_1^*$, $\dot{x}_1 > 0$ si $0 < x_1 < x_1^*$). La référence $v_r(x_1) = \frac{\alpha}{\beta} + \lambda_1(x_1 - x_1^*)$ corrige donc la valeur d'équilibre $\frac{\alpha}{\beta}$ des prédateurs proportionnellement à l'écart des proies à leur cible : plus de prédateurs s'il y a trop de proies, moins s'il n'y en a pas assez. Il reste à faire converger x_2 vers $v_r(x_1)$ à l'aide de u, ce que mesure le second terme de V.

On utilise ici pour simplifier le deuxième critère de Lyapunov (p. 32). La fonction V est C^1, à valeurs positives et s'annule si et seulement si $x_1 = x_1^*$ et $x_2 = v_r(x_1^*) = x_2^*$. C'est donc une

fonction de Lyapunov associée à (x_1^*, x_2^*). Calculons sa dérivée le long des trajectoires.

$$\langle \nabla V(x), f(x) \rangle = -2\beta\lambda_1 x_1 (x_1 - x_1^*)^2 - 2\beta x_1 (x_1 - x_1^*)(x_2 - v_r(x_1)) \\ + 2(x_2 - v_r(x_1)) \left(-x_2(\gamma - \delta x_1) + u - \lambda_1 f_1(x)\right)$$

en utilisant $\alpha - \beta x_2 = -\beta\lambda_1(x_1 - x_1^*) - \beta(x_2 - v_r(x_1))$ et $\frac{d}{dt}\left(x_2 - v_r(x_1)\right) = \dot{x}_2 - v_r'(x_1)\dot{x}_1 = \dot{x}_2 - \lambda_1 f_1(x)$. L'idée est alors de choisir u afin d'assurer que $\langle \nabla V(x), f(x) \rangle < 0$ au moins dans un voisinage de l'équilibre. On prend donc par exemple

$$u = -\lambda_2(x_2 - v_r(x_1)) + x_2(\gamma - \delta x_1) + \lambda_1 f_1(x) + \beta x_1 (x_1 - x_1^*)$$

avec $\lambda_2 > 0$. Ceci donne

$$\langle \nabla V(x), f(x) \rangle = -2\beta\lambda_1 x_1 (x_1 - x_1^*)^2 - 2\lambda_2 (x_2 - v_r(x_1))^2$$

qui est bien strictement négatif pour $x \neq (x_1^*, x_2^*)$ dans un voisinage où $x_1 > 0$. On en déduit que (x_1^*, x_2^*) est localement asymptotiquement stable. Il ne l'est pas globalement car $(0, v_r(0)) = (0, \frac{\alpha}{\beta} - \lambda_1 x_1^*)$ est aussi point d'équilibre du système bouclé (en $x_1 = 0$, on a $\dot{x}_2 = -\lambda_2(x_2 - v_r(0))$). Mais ce dernier est instable ($\frac{\partial f_1}{\partial x_1}(0, v_r(0)) = \beta\lambda_1 x_1^* > 0$) et une étude plus fine pourrait montrer que le bassin d'attraction inclut $\mathbb{R}_{>0} \times \mathbb{R}_{>0}$.

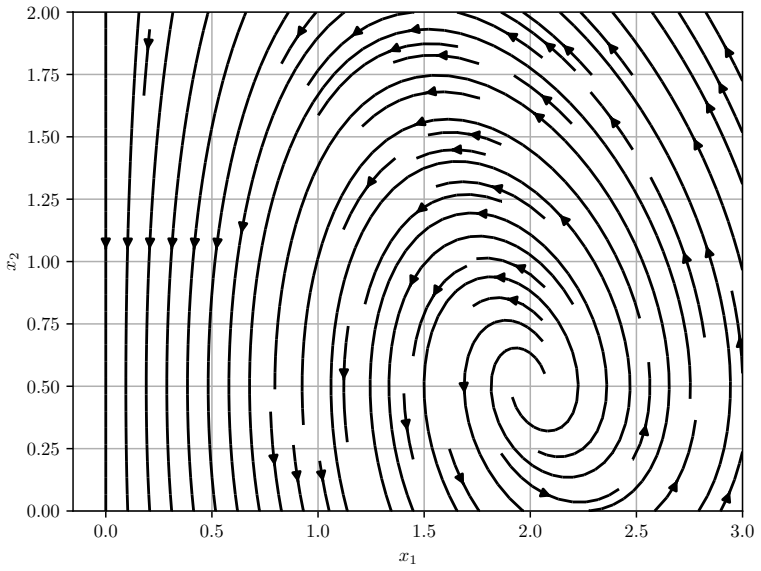


FIGURE 1.3. – Portrait de phase de l'exercice Cycle Limite II avec l'entrée u choisie pour $x_1^* = 2$ avec $\lambda_1 = \lambda_2 = 1$.

1.8. Attractivité locale implique stabilité asymptotique globale pour un système linéaire

Tout d'abord, montrons que l'attractivité locale de 0 implique l'attractivité globale. Ceci est dû à la propriété d'*homogénéité* des systèmes linéaires: si x est une solution initialisée à $x_0 \in \mathbb{R}$, alors λx est solution initialisée à λx_0 puisque

$$\lambda x(t) = \lambda e^{At} x_0 = e^{At}(\lambda x_0) \ .$$

Donc soit $\eta > 0$ tel que toute solution initialisée dans $B(0,\eta)$ converge vers 0. Soit x une solution initialisée à $x_0 \in \mathbb{R}$. Alors λx avec $\lambda < \eta/\|x_0\|$ est solution initialisée dans $B(0,\eta)$ et converge vers 0. Donc x converge vers 0.

Maintenant, montrons la stabilité. Soit $\varepsilon > 0$. Notons $(x_i)_{i=1\ldots n}$ une base orthonormale de $\mathbb{R}^n$. Soit alors $M > 0$ tel que

$$\|e^{At}x_i\| \leq M \quad \forall t \in \mathbb{R}_{\geq 0} \quad \forall i \in \{1, ..., n\}$$

qui existe bien puisque toutes les solutions convergent vers 0 et n est fini. Soit maintenant $\eta > 0$. Pour tout $x_0 \in B(0,\eta)$ dont la décomposition dans la base s'écrit

$$x_0 = \sum_{i=1}^{n} \alpha_i x_i$$

on a $|\alpha_i| \leq \eta$ et donc pour tout $t \in \mathbb{R}_{\geq 0}$,

$$\left\|e^{At}x_0\right\| \leq \left\|\sum_{i=1}^{n} e^{At}\alpha_i x_i\right\| \leq n\eta M$$

On conclut que pour des conditions initiales suffisamment petites ($\eta < \frac{\varepsilon}{nM}$), les solutions restent inférieures à ε en norme. Donc le système est stable.

1.9. Stabilisation d'une chaîne d'intégrateurs

La dynamique du système est de la forme $\dot{x} = f(x,u)$.

Question 1 Pour que x^* soit point d'équilibre avec la commande u^*, il faut $f(x^*,u^*) = 0$, soit $x_2^* = x_3^* = \ldots = x_n^* = 0$ et $u^* = -\phi(x_1^*, 0, \ldots, 0)$.

Question 2 L'idée est de se placer autour de x^* et donc considérer l'erreur $e = x - x^*$ que l'on souhaite stabiliser à 0. On constate alors que

$$\begin{array}{rcl} \dot{e}_1 & = & e_2 \\ \dot{e}_2 & = & e_3 \\ & \vdots & \\ \dot{e}_{n-1} & = & e_n \\ \dot{e}_n & = & \phi(x) + u(t) \end{array}$$

Si l'on mesure $x(t)$, on peut prendre

$$u(t) = -\phi(x(t)) - k_1 e_1(t) - k_2 e_2(t) - \ldots - k_n e_n(t)$$

ce qui donne

$$\dot{e} = Ae$$

avec A de la forme

$$A = \begin{pmatrix} 0 & 1 & 0 & \ldots & 0 \\ \vdots & \ddots & \ddots & & \vdots \\ \vdots & & \ddots & 1 & 0 \\ 0 & & & 0 & 1 \\ -k_1 & -k_2 & \ldots & \ldots & -k_n \end{pmatrix}$$

qui admet pour polynôme caractéristique

$$s^n + k_n s^{n-1} + \ldots + k_2 s + k_1 \ .$$

Il suffit donc de choisir les coefficients k_i tels que ce polynôme ait ses racines à partie réelle strictement négative pour que $e = 0$ soit globalement asymptotiquement stable. En d'autres termes, on prend

$$u(t) = -\phi(x(t)) - k_1(x_1(t) - x_1^*) - k_2 x_2(t) - \ldots - k_n x_n(t)$$

c'est-à-dire on corrige le système en fonction de la distance à x^*. Il s'agit d'un feedback, ou retour d'état en français.

Question 3 Si l'on voulait stabiliser une trajectoire $t \mapsto x_r(t)$, il faudrait d'abord que cette trajectoire soit admissible, c'est-à-dire, qu'elle soit solution de $\dot{x}_r = f(x_r, u_r)$ pour une certaine commande de référence u_r. Dans ce cas, on remarque que $e = x - x_r$ vérifie

$$\begin{aligned} \dot{e}_1 &= e_2 \\ \dot{e}_2 &= e_3 \\ &\vdots \\ \dot{e}_{n-1} &= e_n \\ \dot{e}_n &= \phi(x) + u(t) - \dot{x}_{r,n} \end{aligned}$$

et donc similairement, on prendrait

$$u(t) = \dot{x}_{r,n} - \phi(x(t)) - k_1(x_1(t) - x_{r,1}(t)) - k_2(x_2(t) - x_{r,2}(t)) - \ldots - k_n(x_n(t) - x_{r,n}(t)) \ .$$

1.10. Problème de Kepler : collision, libération et orbites circulaires

Question 1 (Cadre) Le système s'écrit $\dot{x} = f(x)$ avec

$$f(q, v) = \left(v \, , \, -\mu \frac{q}{\|q\|^3} \right)$$

qui est de classe C^∞ (donc continûment différentiable, donc localement lipschitzienne) sur l'ouvert X puisque $q \neq 0$ sur X. Le théorème de Cauchy-Lipschitz (p. 16) dans sa version localement lipschitzienne donne l'existence et l'unicité d'une solution maximale pour toute condition initiale dans X, définie sur un intervalle ouvert $]t_m^-, t_m^+[$.

Le long d'une solution,

$$\dot{E} = v \cdot \dot{v} + \mu \frac{q \cdot \dot{q}}{\|q\|^3} = -\mu \frac{v \cdot q}{\|q\|^3} + \mu \frac{q \cdot v}{\|q\|^3} = 0$$

en utilisant $\frac{d}{dt}\|q\| = \frac{q \cdot \dot{q}}{\|q\|}$, et

$$\dot{L} = \dot{q} \times v + q \times \dot{v} = v \times v - \frac{\mu}{\|q\|^3} \, q \times q = 0 \ .$$

E et L sont donc des *intégrales premières* : ce sont les lois de conservation de l'énergie et du moment cinétique.

Ici $J = \mathbb{R}$ n'a pas de bord et le bord de X est $\partial X = \{0\} \times \mathbb{R}^3$, de sorte que $d\big((t, x(t)), \partial(J \times X)\big) = \|q(t)\|$. Le théorème du domaine maximal dit donc que si $t_m^+ < +\infty$, alors

$$\lim_{t \to t_m^+} \|(q(t), v(t))\| + \frac{1}{\|q(t)\|} = +\infty \ ,$$

c'est-à-dire qu'à chaque instant proche de t_m^+, ou bien $\|q(t)\|$ est très petit, le satellite *s'approche du corps central* (collision), ou bien $\|(q(t), v(t))\|$ est très grand, la position ou la vitesse *explosent*. L'existence de solutions sur $\mathbb{R}$ entier n'a donc rien d'évident a priori : le critère de croissance affine ne s'applique pas, et f n'est même pas définie sur $\mathbb{R}^6$ entier.

Question 2 (Confinement et vitesse de libération) Posons $\rho(t) = \frac{1}{2}\|q(t)\|^2$. On a $\dot\rho = q \cdot v$ et

$$\ddot\rho = \|v\|^2 + q \cdot \dot v = \|v\|^2 - \mu\frac{\|q\|^2}{\|q\|^3} = \|v\|^2 - \frac{\mu}{\|q\|} = 2E + \frac{\mu}{\|q\|}$$

puisque $\|v\|^2 = 2E + \frac{2\mu}{\|q\|}$.

- Si $E < 0$: comme $\|v\|^2 \geq 0$, la définition de E donne $E \geq -\frac{\mu}{\|q(t)\|}$, soit $\|q(t)\| \leq \frac{\mu}{|E|}$ pour tout t. Le satellite reste dans une boule fixée : en particulier, *il ne peut pas y avoir d'explosion de la position* et une solution d'énergie négative définie sur $\mathbb{R}$ est bornée en position.
- Si $E > 0$ et $t_m^+ = +\infty$: $\ddot\rho(t) \geq 2E > 0$ pour tout $t \geq t_0$ et donc, en intégrant deux fois,

  $$\rho(t) \geq \rho(t_0) + \dot\rho(t_0)(t - t_0) + E(t - t_0)^2 \xrightarrow[t\to+\infty]{} +\infty \ .$$

  Le satellite part à l'infini quelle que soit la direction de sa vitesse initiale.

Enfin $E > 0$ équivaut à $\|v_0\|^2 > \frac{2\mu}{\|q_0\|}$, soit $\|v_0\| > v_{lib} := \sqrt{\frac{2\mu}{\|q_0\|}}$. Au niveau du sol terrestre, $v_{lib} \approx 11{,}2$ km/s. Remarquons que ce résultat d'échappement ne demande aucune hypothèse sur la direction de la vitesse : toute l'information est dans l'énergie.

Question 3 (Pas de collision si $L \neq 0$) L'inégalité $\|q \times v\| \leq \|q\|\,\|v\|$ découle de la définition du produit vectoriel ($\|q \times v\| = \|q\|\,\|v\|\,|\sin\theta|$) ou de l'identité de la question 5a. En élevant au carré et en utilisant la conservation de E et de L,

$$\|L\|^2 \leq \|q(t)\|^2\|v(t)\|^2 = \|q(t)\|^2\left(2E + \frac{2\mu}{\|q(t)\|}\right) = 2E\|q(t)\|^2 + 2\mu\|q(t)\| \qquad \forall t \in \left]t_m^-, t_m^+\right[.$$

Supposons $L \neq 0$. La fonction $g(r) = 2Er^2 + 2\mu r$ est continue et tend vers 0 lorsque $r \to 0^+$: il existe donc $r_{\min} > 0$ tel que $g(r) < \|L\|^2$ pour tout $r \in]0, r_{\min}[$. Comme $g(\|q(t)\|) \geq \|L\|^2$ pour tout t, on a nécessairement $\|q(t)\| \geq r_{\min}$ pour tout t : *le satellite ne s'approche jamais du corps central*, et ce uniformément en temps. Physiquement, c'est la *barrière centrifuge* : à moment cinétique fixé, se rapprocher du centre demanderait une vitesse (donc une énergie cinétique) infinie.

On en déduit que

$$\|v(t)\|^2 = 2E + \frac{2\mu}{\|q(t)\|} \leq 2E + \frac{2\mu}{r_{\min}} =: v_{\max}^2 \qquad \forall t \in \left]t_m^-, t_m^+\right[$$

donc v est bornée, puis par intégration $\|q(t)\| \leq \|q_0\| + v_{\max}|t - t_0|$, donc q est bornée sur tout intervalle de temps borné. Supposons $t_m^+ < +\infty$. Par la question 1, $\|(q(t), v(t))\| + 1/\|q(t)\|$ devrait tendre vers $+\infty$; or cette quantité est majorée sur $[t_0, t_m^+[$ par $\|q_0\| + v_{\max}(t_m^+ - t_0) + v_{\max} + 1/r_{\min}$: contradiction. Donc $t_m^+ = +\infty$, et de même $t_m^- = -\infty$: la solution est globale.

Remarquons qu'on a prouvé l'existence globale sans connaître la forme des trajectoires (coniques), uniquement grâce aux deux intégrales premières.

Question 4 (Collision en temps fini si $L = 0$)

a) Puisque $L = q \times v = 0$ pour tout t, $v(t)$ est colinéaire à $q(t)$ à tout instant, c'est-à-dire $v = \frac{(q\cdot v)}{\|q\|^2}\, q$. Or

$$\frac{d}{dt}\left(\frac{q}{\|q\|}\right) = \frac{v}{\|q\|} - \frac{(q \cdot v)}{\|q\|^3}\, q = \frac{1}{\|q\|}\left(v - \frac{(q \cdot v)}{\|q\|^2}\, q\right) = 0 \ .$$

Donc $\frac{q(t)}{\|q(t)\|} = u$ pour tout t et $q(t) = r(t)u$ avec $r = \|q\| = q \cdot u > 0$. En projetant l'équation sur u,

$$\ddot{r} = \ddot{q} \cdot u = -\mu \frac{q \cdot u}{\|q\|^3} = -\frac{\mu r}{r^3} = -\frac{\mu}{r^2} \ .$$

Le mouvement est rectiligne : c'est une chute libre (ou un lancer vertical) vers le corps central. Notons que $v = \dot{r}u$, donc $\|v\| = |\dot{r}|$ et $E = \frac{1}{2}\dot{r}^2 - \frac{\mu}{r}$.

b) Supposons $E < 0$ et, par l'absurde, $t_m^+ = +\infty$. Comme $\ddot{r} = -\mu/r^2 < 0$, $\dot{r}$ est strictement décroissante sur $[t_0, +\infty[$. Deux cas :

- S'il existe $t_1 \geq t_0$ tel que $\dot{r}(t_1) < 0$, alors $\dot{r}(t) \leq \dot{r}(t_1) < 0$ pour tout $t \geq t_1$ et donc $r(t) \leq r(t_1) + \dot{r}(t_1)(t - t_1)$, qui devient négatif pour t assez grand : contradiction avec $r > 0$.
- Sinon, $\dot{r}(t) \geq 0$ pour tout $t \geq t_0$: r est croissante et majorée par $\mu/|E|$ (question 2), donc converge vers une limite finie $r_\infty \geq r(t_0) > 0$. Par ailleurs $|\ddot{r}| = \mu/r^2 \leq \mu/r(t_0)^2$ est bornée. Le Lemme de Barbalat appliqué à r donne $\lim \dot{r} = 0$. Appliquons-le une seconde fois à $\dot{r}$: $\dot{r}$ a une limite finie et $\dddot{r} = 2\mu\dot{r}/r^3$ est bornée ($\dot{r}$ l'est, puisque décroissante et positive), donc $\lim \ddot{r} = 0$. Mais $\ddot{r} = -\mu/r^2 \to -\mu/r_\infty^2 \neq 0$: contradiction.

Donc $t_m^+ < +\infty$. Par la question 1, $\sqrt{r^2 + \dot{r}^2} + 1/r \to +\infty$; mais $r \leq \mu/|E|$ est bornée et $\dot{r}^2 = 2E + 2\mu/r$, donc $\sqrt{r^2 + \dot{r}^2} + 1/r \leq \mu/|E| + \sqrt{2E + 2\mu/r} + 1/r$ ne peut tendre vers $+\infty$ que si $r \to 0$. Ainsi $\lim_{t \to t_m^+} \|q(t)\| = 0$: la solution maximale n'est pas définie pour tout temps parce qu'elle *atteint le bord du domaine* (collision), et non parce qu'elle explose. Le même raisonnement en temps rétrograde montre $t_m^- > -\infty$: le satellite « vient » aussi du corps central.

Avec la question 3, on a donc montré qu'une solution du problème de Kepler est globale *si et seulement si* $L \neq 0$ (au moins dans le cas $E < 0$; si $E \geq 0$ et $L = 0$, on montre de même qu'il y a collision dès que $\dot{r}(t_0) \leq 0$, et échappement sinon).

Question 5 (Stabilité des orbites circulaires)

a) Avec $q \cdot v = \|q\| \, \|v\| \cos\theta$ et $\|q \times v\| = \|q\| \, \|v\| \, |\sin\theta|$, on obtient $\|q \times v\|^2 + (q \cdot v)^2 = \|q\|^2 \|v\|^2$ (identité de Lagrange). Posons $r = \|q\|$. On a $\dot{r} = \frac{q \cdot v}{r}$ puis

$$\ddot{r} = \frac{\|v\|^2 + q \cdot \dot{v}}{r} - \frac{(q \cdot v)\,\dot{r}}{r^2} = \frac{\|v\|^2}{r} - \frac{\mu}{r^2} - \frac{(q \cdot v)^2}{r^3} = \frac{r^2\|v\|^2 - (q \cdot v)^2}{r^3} - \frac{\mu}{r^2} = \frac{\ell^2}{r^3} - \frac{\mu}{r^2}$$

en utilisant $q \cdot \dot{v} = -\mu/r$ et l'identité de Lagrange avec $\|q \times v\| = \ell$ constant. Comme ℓ est une constante, r est bien solution d'une équation autonome du second ordre sur $\mathbb{R}_{>0}$, ce qui définit un système $\frac{d}{dt}(r, \dot{r}) = \left(\dot{r}, \frac{\ell^2}{r^3} - \frac{\mu}{r^2}\right)$ sur l'ouvert $\mathbb{R}_{>0} \times \mathbb{R}$.

b) Les points d'équilibre vérifient $\dot{r} = 0$ et $\frac{\ell^2}{r^3} = \frac{\mu}{r^2}$, soit $r^* = \frac{\ell^2}{\mu}$. Un rayon constant et un moment cinétique $\ell = r^*\|v\| \neq 0$ correspondent à une *orbite circulaire* de rayon r^*, parcourue à la vitesse constante $\|v\| = \ell/r^* = \sqrt{\mu/r^*}$.

c) La jacobienne du champ en $(r^*, 0)$ est

$$J = \begin{pmatrix} 0 & 1 \\ -\frac{3\ell^2}{r^{*4}} + \frac{2\mu}{r^{*3}} & 0 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ -\frac{\mu}{r^{*3}} & 0 \end{pmatrix}$$

en utilisant $\ell^2 = \mu r^*$. Ses valeurs propres sont $\pm i\sqrt{\mu/r^{*3}}$, imaginaires pures : le théorème du linéarisé tangent (p. 27) ne permet pas de conclure. (On reconnaît dans $\omega = \sqrt{\mu/r^{*3}}$

la vitesse angulaire de l'orbite circulaire, c'est la troisième loi de Kepler : une petite perturbation du rayon oscille à la fréquence orbitale.)

d) Par l'identité de Lagrange, $\|v\|^2 = \dot r^2 + \frac{\ell^2}{r^2}$ et donc

$$E = \frac{1}{2}\dot r^2 + U(r) \qquad \text{avec} \qquad U(r) = \frac{\ell^2}{2r^2} - \frac{\mu}{r}$$

le *potentiel effectif*. On a $U'(r) = -\frac{\ell^2}{r^3} + \frac{\mu}{r^2} = \frac{\mu}{r^3}(r - r^*)$, négatif sur $]0, r^*[$ et positif sur $]r^*, +\infty[$: U atteint son minimum strict sur $\mathbb{R}_{>0}$ en r^* (et on vérifie $U''(r^*) = \mu/r^{*3} > 0$). Posons

$$V(r, \dot r) = \frac{1}{2}\dot r^2 + U(r) - U(r^*) \ .$$

V est continue, $V(r^*, 0) = 0$ et $V > 0$ partout ailleurs sur $\mathbb{R}_{>0} \times \mathbb{R}$. De plus $V = E - U(r^*)$ est constante, donc décroissante, le long des solutions. Le théorème de stabilité par décroissance d'une fonction définie positive (p. 28) donne la stabilité de $(r^*, 0)$.

Il n'est pas asymptotiquement stable : une solution initialisée en $(r_0, \dot r_0) \neq (r^*, 0)$ vérifie $V(r(t), \dot r(t)) = c := V(r_0, \dot r_0) > 0$ pour tout t ; si elle convergeait vers $(r^*, 0)$, la continuité de V donnerait $c = V(r^*, 0) = 0$. Interprétation : une orbite circulaire légèrement perturbée devient une orbite dont le rayon oscille indéfiniment entre deux valeurs proches de r^* (une ellipse peu excentrique), sans jamais redevenir circulaire. C'est le propre des systèmes conservatifs : l'énergie est une fonction de Lyapunov, mais elle ne décroît pas strictement.

e) Le champ complet $f(q, v) = (v, -\mu q/\|q\|^3)$ ne s'annule jamais sur X : le système complet n'a *aucun point d'équilibre*. L'orbite circulaire n'est pas un point mais une trajectoire périodique, et les définitions de stabilité du cours portent sur des points d'équilibre. Pour parler de stabilité d'une orbite, il faut une notion de *stabilité orbitale* (les solutions voisines restent proches de l'ensemble décrit par l'orbite), qui n'est pas au programme ; le passage à la variable réduite r permet de contourner cette difficulté en se ramenant à un point d'équilibre.

2. Simulation numérique des solutions

2.1. Consistance et ordre de schémas

Vu que f est C^2, la dérivée seconde (en temps) des solutions s'écrit

$$\begin{aligned}\ddot x(t) &= \frac{d}{dt}\Big(f(t, x(t))\Big) = \partial_t f(t, x(t)) + \partial_x f(t, x(t))\dot x(t) \\ &= \partial_t f(t, x(t)) + \partial_x f(t, x(t)) f(t, x(t)).\end{aligned}$$

On a donc

$$f^{[1]}(t, x) = \partial_t f(t, x) + \partial_x f(t, x) f(t, x)$$

et la formule de Taylor le long des solutions donne

$$\begin{aligned}x(t_{j+1}) = x(t_j) &+ \Delta t f(t_j, x(t_j)) \\ &+ \frac{\Delta t^2}{2}\Big(\partial_t f(t_j, x(t_j)) + \partial_x f(t_j, x(t_j)) f(t_j, x(t_j))\Big) + \mathrm{O}(\Delta t^3).\end{aligned} \tag{2.1}$$

Pour les calculs de consistance, deux options possibles:

- soit on compare à la main (2.1) aux développements en puissances de Δt de la solution numérique x^{j+1}, partant de $x(t_j)$.
- soit on utilise la condition nécessaire et suffisante de consistance (p. 52).

Question 1 A la main, pour la méthode de Heun,

$$\eta^{j+1} = \frac{1}{\Delta t}\left(x(t_{j+1}) - x(t_j) - \frac{\Delta t}{2}\left[f(t_j, x(t_j)) + f\Big(t_{j+1}, x(t_j) + \Delta t f(t_j, x(t_j))\Big)\right]\right).$$

Or,

$$\begin{aligned} f\Big(t_{j+1}&, x(t_j) + \Delta t f(t_j, x(t_j))\Big) \\ &= f(t_j, x(t_j)) + \partial_t f(t_j, x(t_j))(t_{j+1} - t_j) + \partial_x f(t_j, x(t_j))\Delta t f(t_j, x(t_j)) + \mathrm{O}(\Delta t^2) \\ &= f(t_j, x(t_j)) + \Delta t\Big(\partial_t f(t_j, x(t_j)) + \partial_x f(t_j, x(t_j)) f(t_j, x(t_j))\Big) + \mathrm{O}(\Delta t^2). \end{aligned}$$

On en déduit que $\eta^{j+1} = \mathrm{O}(\Delta t^2)$ en utilisant (2.1). Donc on a une consistance d'ordre ≥ 2.

Sinon il suffit de constater que

$$\Phi(t, x, 0) = f(t, x) \quad , \quad \frac{\partial \Phi}{\partial \Delta t}(t, x, 0) = \frac{1}{2} f^{[1]}(t, x) \ .$$

Par contre, si f est C^3, $\frac{\partial^2 \Phi}{\partial \Delta t^2}(t, x, 0) \neq \frac{1}{3} f^{[2]}(t, x)$ donc le schéma n'est pas d'ordre 3 et donc il est d'ordre égal exactement à 2.

Question 2 Pour le schéma d'Euler implicite

$$\eta^{j+1} = \frac{x(t_{j+1}) - x(t_j) - \Delta t f(t_{j+1}, x^{j+1})}{\Delta t},$$

où x^{j+1} est solution de

$$x^{j+1} = x(t_j) + \Delta t f\left(t_{j+1}, x^{j+1}\right).$$

Comme vu dans la section Définition implicite de Φ (p. 48), cette définition implicite de x^{j+1} admet une unique solution pour Δt suffisamment petit si f est Lipschitzienne par rapport à x. On aimerait dire ici que $x^{j+1} = x(t_j) + \mathrm{O}(\Delta t)$ pour Δt suffisamment petit. Pour faire ça proprement, fixons $(t_j, x(t_j))$ et posons

$$F(x, \Delta t) = x - \left(x(t_j) + \Delta t f\left(t_j + \Delta t, x\right)\right)$$

qui est de classe C^1. On a alors

$$F(x(t_j), 0) = 0 \quad , \quad F(x^{j+1}, \Delta t) = 0 \ .$$

Puisque $\partial_x F(x(t_j), 0) = \mathrm{Id}$ est inversible, le théorème des fonctions implicites nous dit que pour Δt suffisamment petit, il existe une fonction ψ de classe C^1 telle que

$$F(x^{j+1}, \Delta t) = 0 \qquad , \qquad x^{j+1} = \psi(\Delta t)$$

au voisinage de $(x(t_j), 0)$. Puisque ψ est continue, il s'ensuit donc bien que $x^{j+1} = x(t_j) + \mathrm{O}(\Delta t)$. On a donc

$$\begin{aligned} f(t_{j+1}, x^{j+1}) &= f(t_j, x(t_j)) + \partial_t f(t_j, x(t_j))(t_{j+1} - t_j) + \partial_x f(t_j, x(t_j))(x^{j+1} - x(t_j)) + \mathrm{O}(\|h\|^2) \\ &= f(t_j, x(t_j)) + \mathrm{O}(\Delta t) \end{aligned}$$

avec l'incrément $h = (t_{j+1} - t_j, x^{j+1} - x(t_j))$ qui vérifie $\|h\| = \mathrm{O}(\Delta t)$.

Ainsi, toujours au vu de (2.1),

$$\eta^{j+1} = \frac{1}{\Delta t}\Big[x(t_{j+1}) - \Big(x(t_j) + \Delta t f(t_j, x(t_j)) + \mathrm{O}(\Delta t^2)\Big)\Big] = \mathrm{O}(\Delta t).$$

Question 3 Pour la méthode des trapèzes, on a l'erreur

$$\eta^{j+1} = \frac{x(t_{j+1}) - x(t_j) - \frac{\Delta t}{2}\left(f(t_j, x(t_j)) + f(t_{j+1}, x^{j+1})\right)}{\Delta t},$$

où x^{j+1} est solution de

$$x^{j+1} = x(t_j) + \frac{\Delta t}{2}\left(f(t_j, x(t_j)) + f(t_{j+1}, x^{j+1})\right).$$

Cette fois-ci on voudrait montrer que $x^{j+1} = x(t_j) + \Delta t f(t_j, x(t_j)) + \mathrm{O}(\Delta t^2)$. Pour cela, on redéfinit

$$F(x, \Delta t) = x - \left(x(t_j) + \frac{\Delta t}{2}\left(f(t_j, x(t_j)) + f(t_j + \Delta t, x^{j+1})\right)\right)$$

qui est de classe C^1. On a alors

$$F(x(t_j), 0) = 0 \quad , \quad F(x^{j+1}, \Delta t) = 0 \ .$$

Puisque $\partial_x F(x(t_j), 0) = \mathrm{Id}$ est inversible, le théorème des fonctions implicites nous dit que pour Δt suffisamment petit, il existe une fonction ψ de classe C^1 telle que

$$F(x^{j+1}, \Delta t) = 0 \qquad , \qquad x^{j+1} = \psi(\Delta t)$$

au voisinage de $(x(t_j), 0)$ et de plus,

$$\psi'(0) = \mathrm{Id}^{-1} \cdot \partial_{\Delta t} F(x(t_j), 0) = f(t_j, x(t_j)) \ .$$

Puisque ψ est de classe C^1, on a donc bien

$$x^{j+1} = x(t_j) + \Delta t f(t_j, x(t_j)) + \mathrm{O}(\Delta t^2) \ .$$

Il s'ensuit que

$$f(t_{j+1}, x^{j+1}) = f(t_j, x(t_j)) + \Delta t \left(\partial_t f(t_j, x(t_j)) + \partial_x f(t_j, x(t_j)) f(t_j, x(t_j))\right) + \mathrm{O}(\Delta t^2)$$

soit

$$x^{j+1} = x(t_j) + \Delta t f(t_j, x(t_j) + \frac{\Delta t^2}{2}\left(\partial_t f(t_j, x(t_j)) + \partial_x f(t_j, x(t_j)) f(t_j, x(t_j))\right) + \mathrm{O}(\Delta t^3)$$

On en déduit donc $\eta^{j+1} = \mathrm{O}(\Delta t^2)$.

Question 4 Enfin, pour la méthode du point milieu, on a l'erreur

$$\eta^{j+1} = \frac{x(t_{j+1}) - x(t_j) - \Delta t f\left(t_j + \frac{\Delta t}{2}, \frac{x(t_j) + x^{j+1}}{2}\right)}{\Delta t},$$

où x^{j+1} est solution de

$$x^{j+1} = x(t_j) + \Delta t f\left(t_j + \frac{\Delta t}{2}, \frac{x(t_j) + x^{j+1}}{2}\right).$$

On montre de la même façon qu'à la question précédente que pour Δt suffisamment petit, $x^{j+1} = x(t_j) + \Delta t f(t_j, x(t_j)) + \mathrm{O}(\Delta t^2)$ et donc

$$\begin{aligned}
&f\left(t_j + \frac{\Delta t}{2}, \frac{x(t_j) + x^{j+1}}{2}\right) \\
&= f(t_j, x(t_j)) + \partial_t f(t_j, x(t_j)) \frac{\Delta t}{2} + \partial_x f(t_j, x(t_j)) \left(\frac{x(t_j) + x^{j+1}}{2} - x(t_j)\right) + \mathrm{O}(\|h\|^2) \\
&= f(t_j, x(t_j)) + \frac{\Delta t}{2}(\partial_t f(t_j, x(t_j)) + \partial_x f(t_j, x(t_j)) f(t_j, x(t_j))) + \mathrm{O}(\Delta t^2)
\end{aligned}$$

avec l'incrément $h = \Big(\frac{\Delta t}{2}, \frac{x(t_j)+x^{j+1}}{2} - x(t_j)\Big)$, soit

$$x^{j+1} = x(t_j) + \Delta t f(t_j, x(t_j) + \frac{\Delta t^2}{2}(\partial_t f(t_j, x(t_j)) + \partial_x f(t_j, x(t_j)) f(t_j, x(t_j))) + \mathrm{O}(\Delta t^3)$$

On en déduit donc $\eta^{j+1} = \mathrm{O}(\Delta t^2)$.

Question 5 On vérifie que le critère est vérifié pour $0 \leq k \leq 3$ mais pas pour $k = 4$!

2.2. Convergence de schémas

Tout d'abord, dans l'exercice précédent, nous avons montré que les schémas de Heun et d'Euler implicite étaient consistants d'ordre 2 et 1 respectivement. Il ne nous reste donc plus qu'à montrer que Φ est localement lipschitzienne (ou C^1) par rapport à x pour Δt suffisamment petit, pour en déduire la convergence à l'ordre 2 et 1 respectivement.

Pour le schéma de Heun,

$$\Phi(t, x, \Delta t) = \frac{1}{2}\Big(f(t, x) + f\big(t + \Delta t, x + \Delta t f(t, x)\big)\Big)$$

donc Φ est C^1 par rapport à x si f l'est.

Prenons maintenant le schéma d'Euler implicite. Pour $\Delta t \leq \Delta t_m$, Φ est définie par

$$\Phi(t, x, \Delta t) = f\Big(t + \Delta t, x + \Delta t \Phi(t, x, \Delta t)\Big).$$

Soit B un compact de $\mathbb{R}^n$. Soit B' un compact tel que $x + \Delta t \Phi(t, x, \Delta t) \in B'$ pour tout $x \in B$, tout $t \in [0, T]$ et tout $\Delta t \in [0, \Delta t_m]$. Puisque f est continue, et C^1 par rapport à x, il existe $L_f > 0$ tel que

$$\|f(t, x_a) - f(t, x_b)\| \leq L_f \|x_a - x_b\| \qquad \forall (x_a, x_b, t) \in B' \times B' \times [0, T + \Delta t_m] \ .$$

Ceci est vrai par le théorème des accroissements finis appliqué à $x \mapsto f(t, x)$ et pour t dans un intervalle fermé et borné. Prenons maintenant $(x_a, x_b) \in B \times B$, $t \in [0, T]$ et $\Delta t \in [0, \Delta t_m]$, alors

$$\begin{aligned}
&\|\Phi(t, x_a, \Delta t) - \Phi(t, x_b, \Delta t)\| \\
&\quad = \|f\Big(t + \Delta t, x_a + \Delta t \Phi(t, x_a, \Delta t)\Big) - f\Big(t + \Delta t, x_b + \Delta t \Phi(t, x_b, \Delta t)\Big)\| \\
&\quad \leq L_f \left(\|x_a - x_b\| + \Delta t \|\Phi(t, x_a, \Delta t) - \Phi(t, x_b \Delta t)\|\right)
\end{aligned}$$

soit

$$\|\Phi(t, x_a, \Delta t) - \Phi(t, x_b, \Delta t)\| \leq \frac{L_f}{1 - L_f \Delta t} \|x_a - x_b\|$$

si $\Delta t < 1/L_f$. Donc Φ est bien localement lipschitzienne par rapport à x.

2.3. Explicite ou implicite ?

Question 1 Prenons d'abord $\dot{x} = -\lambda x$, $x(0) = 1$, dont la solution exacte est $x(t) = e^{-\lambda t}$.

Le schéma d'Euler explicite donne

$$x^{j+1} = x^j - \lambda \Delta t x^j = (1 - \lambda \Delta t)^j$$

soit

$$x^J = (1 - \lambda \Delta t)^J = (1 - \lambda \Delta t)^{\frac{T}{\Delta t}} = \Big((1 - \lambda \Delta t)^{\frac{T}{\lambda \Delta t}}\Big)^{\lambda} \ .$$

On a bien

$$\lim_{\Delta t \to 0} x^J = e^{-\lambda T} .$$

Cependant, il faut $|1 - \lambda\Delta t| < 1$ pour que la solution converge au moins vers 0. Sinon, pour $\lambda\Delta t = 2$, $x^J = (-1)^J$, qui n'a rien à voir avec la solution. Pire, pour $\lambda\Delta t = 2$, l'algorithme diverge. Il faut donc adapter Δt à la constante de temps λ du système. Ceci peut poser problème lorsque l'on simule des systèmes sur des temps longs (par rapport à λ)

De l'autre côté, le schéma d'Euler implicite donne

$$x^{j+1} = x^j - \lambda\Delta t x^{j+1}$$

soit

$$x^J = \frac{1}{(1+\lambda\Delta t)^J} = \frac{1}{(1+\lambda\Delta t)^{\frac{T}{\Delta t}}}$$

qui tend vers 0 quelque soit le pas Δt ! On parle de stabilité inconditionnelle. Ceci est très pratique pour des simulations sur temps longs, où la condition $\lambda\Delta t < 1$ est trop contraignante.

Prenons maintenant $\dot{x} = \lambda x$, $x(0) = 1$, dont la solution exacte est $x(t) = e^{\lambda t}$. Cette fois-ci, Euler explicite donne

$$x^J = (1+\lambda\Delta t)^{\frac{T}{\Delta t}}$$

qui fait maintenant sens même pour des pas grands. Par contre, Euler implicite donne

$$x^J = \frac{1}{(1-\lambda\Delta t)^{\frac{T}{\Delta t}}}$$

qui n'est pas défini pour $\lambda\Delta t = 1$ et qui explose pour des valeurs proche de 1.

Question 2 Lorsque l'on a deux dynamiques asymptotiquement stables aux constantes de temps très différentes la condition de stabilité de Euler explicite exige de choisir un pas câlé sur la plus petite constante de temps, i.e. il faut $\Delta t < \frac{1}{\mu}$. Ceci est très exigeant car il faut attendre un nombre d'itérations de l'ordre de μ pour voir l'évolution du système lent. Par contre, une méthode implicite permet de choisir librement le pas de temps en fonction des performances souhaitées.

Question 3 (Frottement sec)

a) Tant que $x(t) > 0$, l'équation s'écrit $\dot{x} = -1$, donc $x(t) = x_0 - t$: ceci est valable jusqu'à l'instant $t^* = x_0$ où x s'annule. Ensuite, $x \equiv 0$ est solution puisque $\text{sign}(0) = 0$, et c'est la seule continuation qui reste continue et vérifie l'équation : si x redevenait strictement positive (resp. négative) sur un intervalle, on y aurait $\dot{x} = -1$ (resp. $+1$), ce qui ramène vers 0. Par symétrie, pour tout x_0,

$$x(t) = \begin{cases} x_0 - \text{sign}(x_0)\, t & \text{si } t \le t^* := |x_0| \\ 0 & \text{si } t \ge t^* \end{cases}$$

qui est continue, dérivable sauf en t^*, et vérifie l'équation partout ailleurs. Contrairement à $e^{-\lambda t}$, qui ne s'annule jamais, la solution *atteint exactement l'équilibre en temps fini* et y reste : un solide freiné par frottement sec s'arrête, alors qu'un solide freiné par frottement visqueux ralentit indéfiniment.

Ceci est impossible pour f continûment différentiable (ou seulement localement Lipschitzienne) : le théorème de Cauchy-Lipschitz garantit alors l'unicité des solutions, y compris en temps rétrograde. Si une solution atteignait l'équilibre x^* en un temps t^*, elle coïnciderait, par unicité de la solution passant par (t^*, x^*), avec la solution stationnaire $x \equiv x^*$, donc on aurait $x(0) = x^*$. La convergence en temps fini est un phénomène propre aux dynamiques non Lipschitziennes.

b) Le schéma d'Euler explicite s'écrit

$$x^{j+1} = x^j - \Delta t \operatorname{sign}(x^j) \ .$$

Partant de $x_0 > 0$, la suite décroît de Δt à chaque pas, $x^j = x_0 - j\Delta t$, tant que $x^j > 0$. Soit J le premier indice tel que $x^J \leq 0$, c'est-à-dire $x^{J-1} \in]0, \Delta t]$ et $x^J = x^{J-1} - \Delta t \in]-\Delta t, 0]$. Si par chance $x^J = 0$ (i.e. x_0 est un multiple de Δt), la suite y reste. Sinon $x^J < 0$ et $x^{J+1} = x^J + \Delta t = x^{J-1} > 0$, puis $x^{J+2} = x^J < 0$, etc. : la suite est 2-périodique et *oscille indéfiniment* entre $x^{J-1} > 0$ et $x^J < 0$, avec une amplitude Δt, à la fréquence maximale que permet le pas. Ce phénomène est appelé *chattering*. Diminuer Δt réduit l'amplitude des oscillations mais ne les supprime pas : la solution numérique ne s'arrête jamais, et sa "vitesse" $(x^{j+1} - x^j)/\Delta t$ vaut ± 1 alors que la vraie vaut 0. Le comportement est qualitativement faux pour tout $\Delta t > 0$ (et en pratique catastrophique si $\operatorname{sign}(x)$ pilote une force : celle-ci change de sens à chaque pas).

c) Le schéma d'Euler implicite s'écrit

$$x^{j+1} = x^j - \Delta t \operatorname{sign}(x^{j+1}) \ .$$

Raisonnons par disjonction des cas sur le signe de x^{j+1} :

- si $x^{j+1} > 0$, alors $x^{j+1} = x^j - \Delta t$, ce qui exige $x^j > \Delta t$;
- si $x^{j+1} < 0$, alors $x^{j+1} = x^j + \Delta t$, ce qui exige $x^j < -\Delta t$;
- si $x^{j+1} = 0$, alors $0 = x^j - \Delta t \operatorname{sign}(0)$, soit $x^j = 0$ avec la convention $\operatorname{sign}(0) = 0$.

Pour $0 < |x^j| \leq \Delta t$, aucun des trois cas n'est possible : l'équation n'a pas de solution, et le schéma implicite n'est pas défini. La convention $\operatorname{sign}(0) = 0$ est trop restrictive : si l'on autorise $\operatorname{sign}(0)$ à prendre n'importe quelle valeur $s \in [-1, 1]$, le troisième cas devient $x^j = \Delta t\, s$, possible exactement lorsque $|x^j| \leq \Delta t$, avec $s = x^j/\Delta t$. Les trois cas sont alors mutuellement exclusifs et recouvrent toutes les valeurs de x^j : pour tout x^j, l'équation implicite a une unique solution

$$x^{j+1} = \begin{cases} x^j - \Delta t & \text{si } x^j > \Delta t \\ 0 & \text{si } |x^j| \leq \Delta t \\ x^j + \Delta t & \text{si } x^j < -\Delta t \end{cases} \qquad \text{i.e.} \qquad x^{j+1} = \operatorname{sign}(x^j) \max\left(|x^j| - \Delta t,\, 0\right) \ .$$

Autoriser $\operatorname{sign}(0) \in [-1, 1]$ n'est pas un artifice : physiquement, le frottement sec à l'arrêt prend exactement la valeur nécessaire pour compenser les autres forces, dans la limite de son module maximal ; mathématiquement, c'est la définition des solutions au sens de Filippov des équations à second membre discontinu (voir la remarque *Classe plus générale de solutions* du chapitre I).

d) Partant de $x_0 > 0$, la suite implicite est $x^j = \max(x_0 - j\Delta t, 0)$: elle décroît de Δt par pas, atteint *exactement* 0 au premier indice J tel que $J\Delta t \geq x_0$, et y reste. Elle coïncide avec la solution exacte aux instants t_j pour $t_j \leq t^*$, et ensuite à une erreur près d'au plus Δt sur l'instant d'arrêt : il n'y a plus de chattering, et ce quel que soit le pas Δt (même très grand). Le schéma implicite reproduit le comportement qualitatif de la solution, l'arrêt en temps fini, que le schéma explicite est incapable de produire. Les deux comportements sont comparés sur la Figure 2.1 (p. 91).

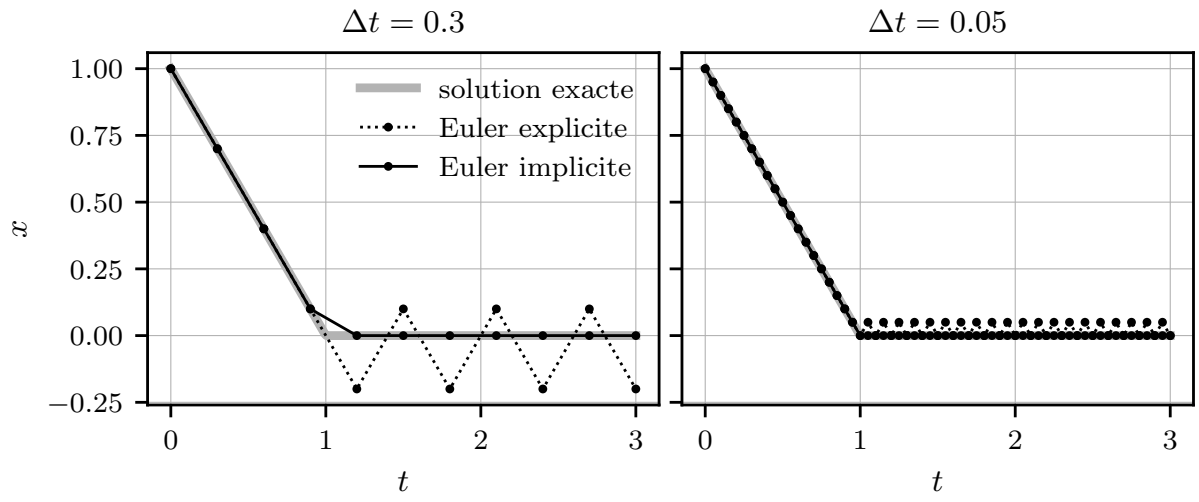


FIGURE 2.1. – Simulation de $\dot{x} = -\text{sign}(x)$, $x(0) = 1$, par les schémas d'Euler explicite et implicite avec $\Delta t = 0{,}3$ (à gauche) et $\Delta t = 0{,}05$ (à droite). Le schéma explicite oscille indéfiniment autour de 0 avec une amplitude Δt (chattering) ; le schéma implicite s'arrête exactement en 0.

2.4. Euler symplectique

Question 1 Dans le cas d'Euler explicite, $x^{j+1} = Ax^j$ avec

$$A = \begin{pmatrix} 1 & \Delta t \\ -\Delta t\,\omega^2 & 1 \end{pmatrix}$$

dont les valeur propres sont $1 \pm i\omega\Delta t$ de norme $\sqrt{1+\Delta t^2\,\omega^2} > 1$. Donc les solutions divergent.

Dans le cas d'Euler implicite, $x^{j+1} = Ax^j$ avec

$$A = \frac{1}{1+\Delta t^2\,\omega^2}\begin{pmatrix} 1 & \Delta t \\ -\Delta t\,\omega^2 & 1 \end{pmatrix}$$

dont les valeurs propres sont $1/(1 \pm i\omega\Delta t)$ de norme $1/\sqrt{1+\Delta t^2\,\omega^2} < 1$. Donc les solutions convergent vers 0.

Or on peut vérifier que le long des vraies solutions, l'énergie $\omega^2 x_1^2 + x_2^2$ est constante donc les trajectoires sont bornées et ne peuvent pas converger vers zéro. Aucun des deux schémas n'approxime les solutions correctement sur le long-terme.

Question 2 Le schéma symplectique donne

$$\begin{pmatrix} \omega^2 & 0 \\ \Delta t\,w^2 & 1 \end{pmatrix}\begin{pmatrix} x_1^{j+1} \\ x_2^{j+1} \end{pmatrix} = \begin{pmatrix} \omega^2 & \Delta t\,w^2 \\ 0 & 1 \end{pmatrix}\begin{pmatrix} x_1^{j} \\ x_2^{j} \end{pmatrix}$$

En multipliant à gauche alternativement par $\begin{pmatrix} x_1^{j+1} & x_2^{j+1} \end{pmatrix}$ et $\begin{pmatrix} x_1^{j} & x_2^{j} \end{pmatrix}$, on obtient

$$\begin{aligned} \omega^2(x_1^{j+1})^2 + (x_2^{j+1})^2 + \Delta t\,\omega^2 x_1^{j+1}x_2^{j+1} &= \omega^2 x_1^{j+1}x_1^j + x_2^{j+1}x_2^j + \Delta t\,\omega^2 x_1^{j+1}x_2^j \\ &= \omega^2(x_1^j)^2 + (x_2^j)^2 + \Delta t\,\omega^2 x_1^j x_2^j \end{aligned}$$

et donc la quantité $\omega^2 x_1^2 + x_2^2 + \Delta t\,\omega^2 x_1 x_2$ est bien constante. Pour $\omega^2 - \frac{\Delta t^2\omega^4}{4} > 0$, soit $\omega\Delta t < 2$, cette matrice est définie positive, donc les solutions restent sur une ellipse. Cette ellipse se

rapproche de la vraie solution lorsque Δt tend vers 0. Ce schéma est donc approprié pour simuler les trajectoires sur un temps long. Les trois schémas sont comparés sur la Figure 2.2 (p. 92) : en quelques périodes, Euler explicite spirale vers l'extérieur et Euler implicite vers l'origine, tandis qu'Euler symplectique reste sur une ellipse proche du cercle exact. Son énergie $\omega^2 x_1^2 + x_2^2$ n'est pas exactement constante, mais oscille sans dériver ; c'est la quantité modifiée $\omega^2 x_1^2 + x_2^2 + \Delta t\, \omega^2 x_1 x_2$ qui est conservée.

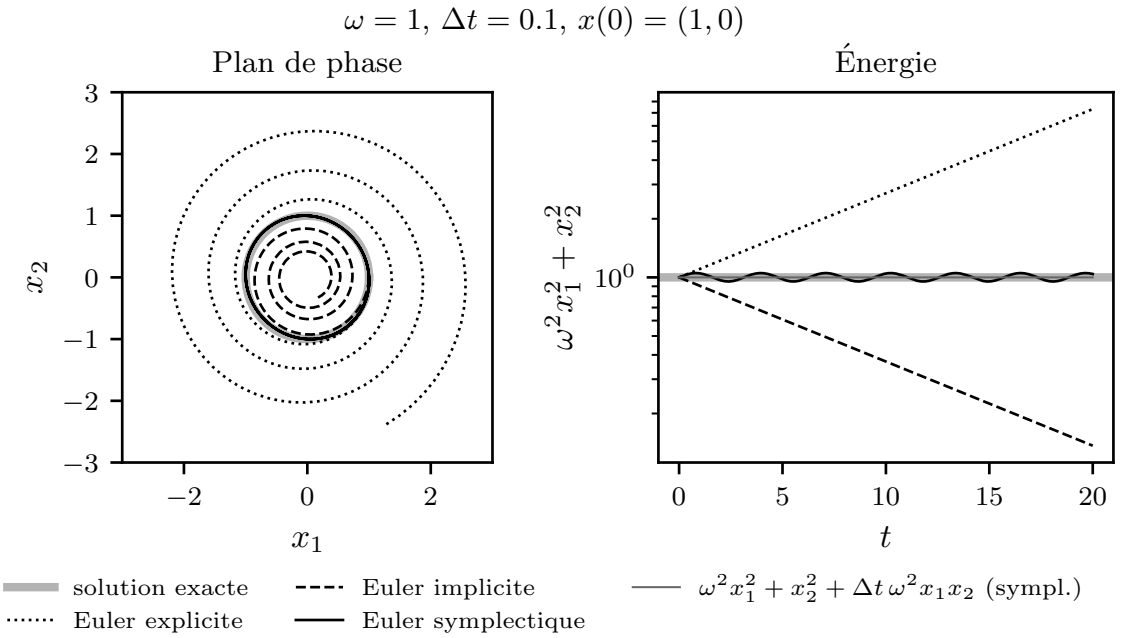


FIGURE 2.2. – Simulation de l'oscillateur $\dot{x}_1 = x_2$, $\dot{x}_2 = -\omega^2 x_1$ par les schémas d'Euler explicite, implicite et symplectique ($\omega = 1$, $\Delta t = 0{,}1$, trois périodes).

Question 3 L'algorithme symplectique est décrit par $x^{j+1} = Ax^j$ avec

$$A = \begin{pmatrix} 1 & \Delta t \\ -\Delta t\, \omega^2 & 1 - \Delta t^2\, \omega^2 \end{pmatrix}$$

dont le polynôme caractéristique s'écrit

$$s^2 - (2 - \Delta t^2\, \omega^2)s + 1$$

On a les cas suivants :

- si $(2 - \Delta t^2\, \omega^2)^2 - 4 < 0$, i.e., si $\omega \Delta t < 2$, les valeurs propres sont imaginaires conjuguées et de module 1.
- si $\omega \Delta t > 2$, les valeurs propres sont réelles de produit 1, donc l'une est supérieure à 1 est le schéma diverge.
- dans le cas extrême où $\omega \Delta t = 2$, il y a une valeur propre double en -1.

Question 4 Pour un système hamiltonien, on peut donc proposer

$$q^{j+1} = q^j + \Delta t\, \nabla_p H(q^j, p^j)$$
$$p^{j+1} = p^j - \Delta t\, \nabla_q H(q^{j+1}, p^{j+1})$$

ou bien

$$q^{j+1} = q^j + \Delta t \, \nabla_p H(q^{j+1}, p^{j+1})$$
$$p^{j+1} = p^j - \Delta t \, \nabla_q H(q^j, p^j)$$

pour Δt suffisamment petit. C'est cet algorithme qui est utilisé dans la Figure 3.1 (p. 46)