Probabilités

UE11, Maths 2
Mines Paris - PSL

Thomas Romary et Mike Perreira*

23 octobre 2026

*Ce document est un des produits du projet paulinebernard/CDIS issu de la collaboration de Pauline Bernard (CAS), Thomas Romary et Mike Perreira (STIM). Il est mis à disposition selon les termes de la licence Creative Commons “attribution – pas d’utilisation commerciale – partage dans les mêmes conditions” 4.0 internationale.

Table des matières

I. Probabilités I : Probabilités et variables aléatoires 9

1. Introduction 10
1.1. Exemple de la modélisation du climat . . . 10
1.2. Plan du cours . . . 11
1.3. Historique . . . 11

2. Objectifs d'apprentissage 12

3. Probabilités des événements 13
3.1. Phénomènes aléatoires et événements . . . 13
L'espace fondamental . . . 13
Evénement . . . 14
3.1.1. Correspondance entre opérations logiques et ensemblistes . . . 14
Tribu . . . 14
3.2. Probabilité . . . 15
Probabilité . . . 15
Propriété presque-sûre . . . 15
Propriétés élémentaires . . . 15
Théorème de la continuité monotone . . . 16
Suite décroissante . . . 16
Une majoration bien utile . . . 16
3.3. Probabilité conditionnelle . . . 17
Information a priori . . . 17
Probabilité conditionnelle . . . 17
Conséquences . . . 17
Formule des probabilités totales . . . 17
Formule de Bayes . . . 18
3.4. Indépendance des événements . . . 18
Indépendance de deux événements . . . 19
Indépendance de n événements . . . 20
3.5. Remarque : réflexion sur le concept de probabilité . . . 20

4. Variables aléatoires 20
Variable aléatoire . . . 21
Vocabulaire . . . 21
Notation . . . 21
4.1. Variables aléatoires réelles . . . 22
Tribu engendrée . . . 22
Tribus engendrées . . . 22
Tribu borélienne sur $\mathbb{R}$ . . . 22
Définition alternative . . . 22
Variable aléatoire réelle . . . 23
Loi d'une variable aléatoire réelle . . . 23
Composition . . . 23

4.1.1. Démonstration . . . 23
Conséquences . . . 23
4.2. Loi des variables aléatoires réelles . . . 24
Fonction de répartition . . . 24
La fonction de répartition caractérise la probabilité . . . 24
Caractérisation de la fonction de répartition . . . 24
Quelques propriétés . . . 25
Nécessité des tribus . . . 25
Probabilités discrètes . . . 25
4.3. Variables aléatoires réelles à densité . . . 27
Densité de probabilité . . . 27
Variable aléatoire réelle à densité . . . 28
Fonction de répartition d'une variable aléatoire à densité . . . 28
Quelques lois à densités . . . 29

5. Exercices complémentaires **33**
5.1. Indépendance et conditionnement . . . 33
5.2. Problème de Monty Hall . . . 33
5.3. Mesure de Probabilité . . . 34
5.4. Queues de distributions . . . 34
5.5. Densité et fonction de répartition d'une loi Normale . . . 35
Ratio de Mills . . . 36
5.6. Loi de vie et de mort . . . 36

6. Références **37**

II. Probabilités II : Moments, vecteurs aléatoires, modélisation statistique **38**

1. Objectifs d'apprentissage **39**

2. Moments d'une variable aléatoire **40**
Espérance d'une variable aléatoire réelle . . . 40
Interprétation . . . 40
Propriétés de base . . . 40
Rappel : cas discret . . . 41
Variance . . . 41
Propriétés . . . 41
La variance est positive . . . 42
Variable centrée réduite . . . 42
Covariance . . . 42
Inégalité de Cauchy-Schwarz . . . 43
Espérance de $g(X)$ . . . 43
Cas particulier . . . 44
Inégalité de Jensen . . . 44
2.1. Exemples de loi à densité . . . 45
2.1.1. *Loi uniforme* . . . 45
2.1.2. *Loi exponentielle* . . . 45
2.1.3. *Loi gamma* . . . 46
2.1.4. *Loi normale* . . . 46

Estimation statistique 46

3. Rappels sur les intégrales multiples **47**
Théorème de Fubini (pour les probabilités) 47
Changement de variables 47

4. Vecteurs aléatoires **48**
4.1. Définitions 49
Vecteur aléatoire à densité 49
Fonction d'un vecteur aléatoire 49
Densités marginales 49
Réciproque ? 50
4.2. Moments d'un vecteur aléatoire 50
Vecteur espérance et covariance 50
Matrice de covariance 50
Vecteur Gaussien n-dimensionel 51

5. Variables aléatoires indépendantes **51**
Vecteurs aléatoires indépendants 52
Caractérisation de l'indépendance – cas à densité 52
Fonctions de vecteurs aléatoires indépendants 52
Cas général 53
Covariance de variables aléatoires indépendantes 53
5.0.1. Remarque 53

6. Identification de densité **53**
Méthode de la fonction muette 54
Coordonnées polaires 55
Somme de deux variables aléatoires indépendantes 56

7. Modélisation statistique **56**
Divergence de Kullback-Leibler 56
Positivité de la divergence de Kullback-Leibler 57

8. Exercices complémentaires **58**
8.1. Durée de vie 58
8.2. Crues centennales de la Seine 58
8.3. Indépendance et vecteurs gaussiens 59
8.4. Symétrie de la gaussienne 59
8.5. Loi du χ^2 59
8.6. Combinaisons linéaires de variables Gaussiennes indépendantes 60
8.7. Loi de Maxwell 60
8.7.1. Partie 1 60
8.7.2. Partie 2 61

III. Probabilités III : Conditionnement **62**

1. Objectifs d'apprentissage **63**

2. Lois conditionnelles **63**
2.1. Introduction . . . 63
2.2. Lois conditionnelles dans un couple . . . 64
2.3. Cas où X est discrète . . . 64
Image de la probabilité conditionnelle . . . 64
Pour fixer les idées (1) . . . 65
2.4. Densités conditionnelles . . . 66
Densité conditionnelle . . . 66
2.5. Cas général . . . 67
Fubini conditionnel . . . 67
A noter . . . 68
2.6. Conséquences . . . 68
Formule de balayage conditionnel . . . 68
Pour fixer les idées (2) . . . 69
Critère d'indépendance . . . 69

3. Espérance conditionnelle **70**
Espérance conditionnelle . . . 70
Conséquences . . . 70
Espérance conditionelle d'une fonction de variables aléatoires . . . 71
Espérance totale . . . 71
Transfert conditionnel . . . 72
3.1. Exemple : vecteurs Gaussiens à densité . . . 72

4. Régression et espérance conditionnelle des variables de carré intégrable **73**
4.1. Rappels sur les espaces de Hilbert et application en probabilités . . . 74
Prédicteur optimal sur un convexe fermé . . . 74
4.2. Cas particulier: la régression linéaire . . . 75
Limites de la régression linéaire . . . 76
4.3. Cas général . . . 76

5. Exercices **78**
5.1. Couple de variables . . . 78
5.2. Mélanges de lois . . . 78
5.3. Lois conjuguées . . . 78
5.4. Randomisation . . . 79
5.5. Etats cachés — indépendance conditionnelle . . . 79
5.6. Covariance totale . . . 79
5.7. Débruitage (formule de Tweedie) . . . 80
5.8. Non-réponse . . . 80

6. Références **81**

IV. Probabilités IV : Convergences **82**

1. Objectifs d'apprentissage **83**

2. Préambule **83**
Espace $\mathcal{L}^p$ . . . 84
Inclusion . . . 84

Inégalité de Markov . . . 84
Inégalité de Bienaymé-Chebyshev . . . 85
Interprétation . . . 85

3. Suites de variables indépendantes **85**
Mesure produit sur un espace de dimension infinie . . . 85
Suites de variables aléatoires indépendantes . . . 86
Conséquences . . . 86
Développement dyadique . . . 86
Borel-Cantelli . . . 87

4. Convergences et loi des grands nombres **87**
4.1. Convergences des variables aléatoires . . . 87
Pile ou face infini (bis) . . . 87
Modes de convergences . . . 88
Convergence $\mathcal{L}^p$ . . . 88
p.s. / $\mathcal{L}^1 \Rightarrow$ en proba . . . 89
Cas borné . . . 90
Existence d'une sous-suite convergente . . . 90
Continuité . . . 91
4.2. La loi des grands nombres . . . 92
Loi des grands nombres cas $\mathcal{L}^2$ . . . 92
4.2.1. Démonstration . . . 92
Loi des grands nombres cas $\mathcal{L}^1$ . . . 94

5. Convergence en loi et théorème central limite **94**
5.1. Convergence en loi . . . 94
Convergence en loi . . . 94
Cas fini . . . 94
Univers de définition . . . 95
En proba $\Rightarrow$ en loi . . . 95
Convergence en loi et fonction de répartition . . . 96
Cas où X admet une densité . . . 97
5.2. Théorème central limite . . . 97
central limite (TCL) . . . 98
Conséquence . . . 99
5.2.1. Exemple : convergence des lois binomiales . . . 99
central limite multi-dimensionnel . . . 100
Vitesse de convergence . . . 100

6. Annexe **100**
6.1. Fonctions caractéristiques . . . 100
Fonction caractéristique . . . 100
Interprétation . . . 100
Propriétés de la fonction caractéristique . . . 101
Transformation linéaire . . . 101
6.1.1. Fonction caractéristique d'une variable gaussienne . . . 102
Caractérisation . . . 102
Somme . . . 104
6.1.2. Exemples : . . . 104

Fonction caractéristique et moments . . . 104
Vecteur Gaussien (cas général) . . . 105
Cas gaussien . . . 105
de Lévy . . . 106

7. Exercices **106**
7.1. Inégalités de concentration . . . 106
7.2. Lemme de Borel-Cantelli . . . 107
7.3. Convergence vers une constante . . . 107
7.4. Fonction de répartition empirique . . . 108
7.5. Théorème de Weierstrass sur $[0, 1]$ . . . 108
7.6. Théorème de Slutsky . . . 109

8. Références **109**

V. Probabilités V : Simulation **110**

1. Objectifs d'apprentissage **111**

2. Intégrale de Monte-Carlo **111**

3. Génération de nombres pseudo-aléatoires **112**
Générateur de nombres uniformes pseudo-aléatoires . . . 113
la méthode des congruences . . . 113

4. Méthodes de simulation de variables aléatoires réelles **114**
4.1. Méthode d'inversion . . . 114
Cas où F_X est bijective . . . 114
Réciproque généralisée . . . 115
Conséquences . . . 115
Méthode d'inversion . . . 115
4.1.1. Limitations . . . 116
4.2. Méthode de rejet . . . 116
Loi uniforme sur un borélien . . . 116
Stabilité par conditionnement . . . 116
Loi uniforme sur le sous-graphe d'une densité . . . 116
4.2.1. Méthode de rejet . . . 117
4.2.2. Limitations . . . 117
4.3. Simulation de variables aléatoires gaussiennes : Box-Muller . . . 118

5. Simulation d'un vecteur gaussien à densité **119**

6. Echantillonnage d'importance **120**
Loi de Cauchy conditionnelle . . . 120
Echantillonnage d'importance . . . 121
Densité optimale . . . 122

7. Exercices **122**
7.1. Loi uniforme dans un domaine . . . 122
7.2. Simulation selon la loi géométrique . . . 123

7.3. Simulation de la loi gaussienne par la méthode de rejet 123
7.4. Simulation selon la loi de Wigner 123
7.5. Loi des grands nombres et théorème central limite 123
7.6. Simulation d'un mélange de gaussiennes 124
7.7. Echantillonnage d'importance 124

8. Annexe **124**
8.1. Preuve de la méthode d'inversion 124

9. Références **126**

Première partie

Probabilités I : Probabilités et variables aléatoires

1. Introduction

Le but de ce cours est de consolider et compléter les connaissances en théorie des probabilités acquises en CPGE mais surtout de permettre d'acquérir le raisonnement probabiliste. En effet, les probabilités peuvent être vues comme un outil de modélisation de phénomènes qui ont la caractéristique d'être aléatoires. L'aléatoire peut intervenir de différentes manières dans ces phénomènes.

- Dans les cas d'école que sont les jeux de pile ou face ou de lancés de dés, la différence entre les résultats, si l'on réitère l'expérience, peut être liée à l'impulsion initiale communiquée au dé et à d'autres facteurs environnementaux comme le vent, la rugosité de la table, etc. Le hasard intervient du fait de la méconnaissance des conditions initiales, car la pièce ou le dé ont des trajectoires parfaitement définies par la mécanique classique.
- Dans beaucoup de cas de figure, on fait intervenir l'aléatoire dans la modélisation du fait d'une connaissance incomplète des phénomènes. On parle alors de modélisation de l'incertitude. C'est le cas par exemple en sciences du climat, dont nous discutons ci-dessous.
- Dans certains domaines, tels la physique quantique, l'aléatoire fait intrinsèquement partie de la théorie.

Les probabilités sont aussi un préalable indispensable pour aborder l'analyse statistique des données et les méthodes d'apprentissage automatique.

En CPGE, les probabilités ont été vues dans le cadre de phénomènes aléatoires qui admettent un nombre au plus dénombrable de résultats possibles. Ce cadre restreint est supposé connu. On pourra se reporter au chapitre 3 du cours de Garnier (2018) ou aux deux premiers chapitres du cours de Jourdain (2016) pour une éventuelle mise à niveau.

1.1. Exemple de la modélisation du climat

Les prédictions de la météo et les projections du climat proviennent généralement de modèle numériques qui simulent les différents processus physiques à l'oeuvre. Les incertitudes dans la construction et l'application de ces modèles sont variées et peuvent être réparties en quatre groupes : les conditions initiales (on ne connaît jamais parfaitement l'ensemble des variables climatiques en tout point du globe), les conditions aux limites (par exemple lorsqu'on travaille à l'échelle d'un continent ou d'un pays), les valeurs des paramètres intervenant dans les modèles (constantes issues d'observations diverses), les incertitudes structurelles enfin qui relèvent des choix de modélisation. Pour tenir compte de ces incertitudes, les climatologues effectuent des ensembles de simulations, où les différentes quantités incertaines sont échantillonnées selon des modèles probabilistes (voir en particulier Tebaldi and Knutti (2007)).

L'incertitude sur les conditions initiales est particulièrement influente aux faibles échelles de temps. La météo est un système chaotique, les prévisions sont extrêmement sensibles aux variations des conditions initiales utilisées pour initialiser les modèles. Ces dernières sont en revanche connues de manière imparfaite. Il est ainsi nécessaire de tenir compte de cette incertitude. Ceci est rendu possible par la modélisation probabiliste. Les conditions aux limites font intervenir des **variables continues** (température, pression, vitesse du vent, etc.), ce qui représente la principale nouveauté par rapport au programme de CPGE, et il est nécessaire de caractériser leurs relations de **dépendance**. Il convient par ailleurs de tenir compte des observations (satellites, station de mesure, ...) en incluant cette information dans la modélisation probabiliste. On parle de **conditionnement** aux données. Il s'agit enfin d'en générer les valeurs via des algorithmes de

simulation stochastique. La validité de l'approche est assurée par les **théorèmes limites**, qui garantissent la représentativité des ensembles générés.

1.2. Plan du cours

Le cours est organisé en 5 amphis et abordera consécutivement les notions évoquées ci-dessus, à savoir les probabilités définies sur $\mathbb{R}$, les variables et vecteurs aléatoires réels, l'indépendance et le conditionnement de variables aléatoires, l'étude des suites de variables aléatoires et, enfin, les méthodes de simulation stochastique.

1.3. Historique

Avant que l'étude des probabilités soit considérée comme une science, l'observation du hasard dans les événements naturels a amené les philosophes et les scientifiques à réfléchir sur la notion de liens entre événements, causes et conséquences, et lois de la nature. Les jeux de hasard, les situations météorologiques ou les trajectoires des astres ont fait partie des domaines étudiés. Les explications données sont alors liées au destin, à une colère céleste ou à une présence divine.

Il est communément admis que le début de la science des probabilités se situe au XVIe siècle avec l'analyse de jeux de hasard par Jérôme Cardan et au XVIIe siècle avec les discussions entre Pierre de Fermat et Blaise Pascal au sujet de paradoxes issus de ces jeux, notamment posés par Antoine Gombaud, chevalier de Méré. Cette nouvelle théorie est nommée géométrie aléatoire par le chevalier de Méré en 1654, elle est appelée par la suite calcul conjectural, arithmétique politique et plus communément aujourd'hui théorie des probabilités. Cette théorie, dite des probabilités modernes, est alors étudiée par de nombreux penseurs jusqu'au XIXe siècle : Kepler, Galilée, Leibniz, Huygens, Halley, Buffon, les frères Bernoulli, Moivre, Euler, D'Alembert, Condorcet, Laplace, Fourier. Elle est principalement basée sur les événements discrets et la combinatoire.

Des considérations analytiques ont forcé l'introduction de variables aléatoires continues dans la théorie. Cette idée prend tout son essor dans la théorie moderne des probabilités, dont les fondations ont été posées par Andreï Nikolaevich Kolmogorov. Kolmogorov combina la notion d'univers, introduite par Richard von Mises et la théorie de la mesure pour présenter son système d'axiomes pour la théorie des probabilités en 1933. Très vite, son approche devint la base incontestée des probabilités modernes.

Le XXe siècle voit également le développement de l'application de la théorie des probabilités dans plusieurs sciences.

Avec la mécanique newtonienne, la théorie du champ électromagnétique ou la thermodynamique, la physique classique est la théorie utilisée jusqu'à la fin du XIXe siècle. En 1925, Erwin Schrödinger étudie l'équation qui détermine l'évolution d'une onde au cours du temps : l'équation de Schrödinger. Max Born utilise cette équation pour décrire une collision entre des particules telles que des électrons ou des atomes. Les observations de ces expériences l'amènent à supposer que le module de la fonction d'onde est la probabilité que la particule soit détectée en un point de l'espace. C'est le début d'une nouvelle approche de la physique quantique.

En 1900, Louis Bachelier fut un des premiers mathématiciens à modéliser les variations de prix boursiers grâce à des variables aléatoires. « le marché n'obéit qu'à une seule loi : la loi du hasard ». Bachelier utilise alors le calcul stochastique pour étudier les variations boursières au cours du temps. En 1970, Fischer Black et Myron Scholes reprennent les idées de Bachelier pour modéliser les rendements d'une action.

L'utilisation des probabilités en biologie a pris un essor dans les années 1970, notamment dans l'étude de l'évolution des espèces. La reproduction des individus est modélisée par un choix aléatoire des gènes transmis ainsi que des mutations apparaissant de manière aléatoire

sur les individus. L'extinction des espèces ou des gènes est alors étudiée en fonction des effets stochastiques.

De nos jours, l'Ecole française de Probabilités est très active. La première Médaille Fields décernée à un probabiliste a été attribuée à Wendelin Werner en 2006. Les probabilités se développent de plus en plus, alimentées en particulier de manière essentielle par la physique, le développement des réseaux de télécommunications, la finance, la biologie, la médecine... Elles permettent de construire des modèles mathématiques, qui peuvent être validés par les données suivant la théorie statistique, et fournissent également des possibilités d'expérimentations fictives dans de multiples domaines d'applications.

2. Objectifs d'apprentissage

Probabilités des événements

- connaître les définitions de base des probabilités :
  - ∘ espace fondamental Ω
  - ∘ événement $A \subset \Omega$
  - ∘ tribu (de parties)
  - • probabilité
  - • propriété presque sûre
- connaître, savoir démontrer et exploiter les résultats suivants :
  - • les propriétés élémentaires d'une probabilité
  - • le théorème de continuité monotone
- indépendance et conditionnement
  - • connaître la définition de la probabilité conditionnelle
  - • connaître et savoir exploiter la formule des probabilités totales
  - • connaître et savoir exploiter la formule de Bayes
  - • connaître la définition de l'indépendance d'événements

Variables aléatoires

- variables aléatoires réelles
  - •• connaître la définition de la tribu borélienne
  - •• savoir manipuler la notion de tribu engendrée
  - •• savoir que la tribu borélienne est engendrée par les intervalles de la forme $]-\infty, x],\ x \in \mathbb{R}$
  - • connaître la définition d'une variable aléatoire réelle et de sa loi de probabilité
- loi des variables aléatoires réelles
  - • savoir que la fonction de répartition caractérise la loi d'une variable aléatoire réelle
  - •• connaître les propriétes de base de la fonction de répartition
  - •• savoir calculer la fonction de répartition d'une variable aléatoire
- densité de probabilité

– •• connaître la définition d'une densité de probabilité
– •• connaître la définition d'une variable aléatoire réelle à densité
– •• savoir identifier si une variable aléatoire admet une densité

3. Probabilités des événements

3.1. Phénomènes aléatoires et événements

L'objet de la théorie des probabilités est l'analyse mathématique de phénomènes dans lesquels le hasard intervient. Les phénomènes aléatoires résultent d'expériences dont le résultat ne peut être prédit à l'avance et qui **peut** varier si on répète l'expérience dans des conditions identiques.

Il est aisé de trouver des exemples de tels phénomènes.

Exemple.

1. Jeu de Pile ou Face
2. Lancé de dés
3. Durée de vie d'une ampoule électrique
4. Température demain à 12h au sommet de la tour Eiffel
5. Évolution de la vitesse d'une molécule dans un gaz raréfié sur un intervalle de temps $[t_1, t_2]$

La théorie des probabilités vise à fournir un modèle mathématique pour décrire ces phénomènes. Elle repose sur trois ingrédients essentiels dont on donne ici les définitions.

Définition – L'espace fondamental.

Noté habituellement Ω, l'*espace fondamental* (ou encore l'*espace d'état* ou *univers*) contient l'ensemble de tous les résultats possibles d'un phénomène aléatoire. Un résultat possible d'une expérience sera noté $\omega \in \Omega$.

Si on reprend les exemples précédents, on peut facilement définir les univers associés.

Exemple.

1. Jeu de Pile ou Face, $\Omega = \{\text{pile}, \text{face}\}$
2. Lancé de dés, $\Omega = \{1, 2, 3, 4, 5, 6\}$
3. Durée de vie d'une ampoule électrique, $\Omega = [0, +\infty[$
4. Température demain à 12h au sommet de la tour Eiffel (en degrés Kelvin), $\Omega = [0, +\infty[$
5. Évolution de la vitesse d'une molécule dans un gaz raréfié sur un intervalle de temps $[t_1, t_2]$, Ω : ensemble des application continues sur $[t_1, t_2]$ à valeurs dans $\mathbb{R}^3$

Cette liste d'exemples montre que l'espace Ω peut varier énormément dans sa structure, d'une expérience à l'autre. Cela permet de réaliser la richesse de la théorie qu'il faut mettre en place, pour créer un modèle qui englobe tous ces cas. Nous verrons également ultérieurement que le modèle abstrait que nous allons construire permettra de s'affranchir du fait que Ω décrit précisément tous les résultats possibles de l'expérience.

Définition – Evénement.

Un *événement* est une propriété qui est vérifiée ou non une fois l'expérience réalisée. On identifie un événement A à un sous-ensemble ou *partie* de Ω, i.e. $A = \{\omega \in \Omega : A \text{ est vérifiée pour } \omega\}$.

Exemple.

1. Jeu de Pile ou Face : $A = \{\text{pile}\}$.
2. Lancé de dés : $A = \{1, 3, 5\}$.
3. Durée de vie d'une ampoule électrique : $A = [t_1, t_2] \subset \mathbb{R}_+$.
4. Température demain à 12h au sommet de la tour Eiffel (en degrés Kelvin) : $A = [T_1, T_2] \cup [T_3, T_4] \subset \mathbb{R}_+$.
5. Évolution de la vitesse d'une molécule dans un gaz raréfié sur un intervalle de temps $[t_1, t_2] \subset \mathbb{R}_+$: $A = \{f \in C([t_1, t_2], \mathbb{R}^3) : \|f - g\|_\infty \leq a\}$, où $g \in C([t_1, t_2], \mathbb{R}^3)$ et $a \in \mathbb{R}_+$.

Les événements étant des ensembles, les opérations ensemblistes classiques admettent une interprétation probabiliste.

3.1.1. Correspondance entre opérations logiques et ensemblistes

Terminologie probabiliste	Terminologie ensembliste	Notation
événement certain	ensemble entier	Ω
événement impossible	ensemble vide	$\varnothing$
événement contraire	complémentaire	A^c
événement atomique	singleton	$\{\omega\}$
implication	inclusion	$\subset$
et	intersection	$\cap$
ou	réunion	$\cup$
événements incompatibles	ensembles disjoints	$A_1 \cap A_2 = \varnothing$

On doit maintenant répondre à la question de savoir quels sont les événements dont on va vouloir évaluer la probabilité d'occurence. On va ainsi regrouper les événements en un ensemble $\mathcal{A}$ qui constitue une collection de sous-ensembles de Ω. On va souhaiter en particulier pouvoir combiner des événements au sein de $\mathcal{A}$ par les opérations ensemblistes courantes.

Ceci conduit à la notion de *tribu de parties* de Ω.

Définition – Tribu.

Une *tribu* (ou *σ-algèbre*) $\mathcal{A}$ est une collection de sous-ensembles de Ω tels que :

1. $\Omega \in \mathcal{A}$,
2. $A \in \mathcal{A} \Rightarrow A^c \in \mathcal{A}$,
3. $\forall\, n \in \mathbb{N}, A_n \in \mathcal{A} \Rightarrow \bigcup_n A_n \in \mathcal{A}$.

Le couple $(\Omega, \mathcal{A})$ est appelé *espace probabilisable*. On notera qu'il s'agit d'un espace mesurable dans la terminologie du cours d'intégration;

Exemple.

1. $\mathcal{A} = \{\varnothing, \Omega\}$ est la tribu *grossière* ou *triviale* : c'est la plus petite tribu de Ω.
2. Dans le cas où Ω est au plus dénombrable, on choisit systématiquement l'ensemble $\mathcal{P}(\Omega)$ des parties de Ω dont on vérifie aisément qu'il s'agit d'une tribu ; c'est le cadre étudié en CPGE. On verra plus loin que cette tribu est trop grande dans le cas où Ω est infini non dénombrable.
3. Si $\Omega = \mathbb{R}$, on peut le munir de la tribu formée des ensembles mesurables de $\mathbb{R}$, dite *tribu de Lebesgue*.
4. On verra plus loin qu'il est aisé de définir une tribu sur tout espace topologique.

3.2. Probabilité

Définition – Probabilité.

Une *probabilité* sur l'espace $(\Omega, \mathcal{A})$ est une application $\mathbb{P} : \mathcal{A} \to [0,1]$, telle que :

1. $\mathbb{P}(\Omega) = 1$,
2. pour toute suite (dénombrable) $(A_n)_{n\in\mathbb{N}^\star}$ d'éléments de $\mathcal{A}$ **deux à deux disjoints**, on a
$$\mathbb{P}\left(\bigcup_{n\in\mathbb{N}^\star} A_n\right) = \sum_{n\in\mathbb{N}^\star} \mathbb{P}(A_n).$$

Le triplet $(\Omega, \mathcal{A}, \mathbb{P})$ est appelé *espace probabilisé*. La modélisation probabiliste consiste ainsi à décrire une expérience aléatoire par la donnée d'un espace probabilisé.

On notera que dans la terminologie du cours d'intégration, $(\Omega, \mathcal{A}, \mathbb{P})$ est un espace mesuré. On vérifie aisément que $\mathbb{P}$ est une mesure qui a la particularité d'être finie, c'est-à-dire telle que $\mathbb{P}(\Omega) = 1$. On parle aussi de *mesure de probabilité*.

La définition suivante est fondamentale en théorie des probabilités. Elle introduit une notion de "vrai ou faux" qui dépend de la probabilité choisie sur l'espace fondamental.

Définition – Propriété presque-sûre.

Soit $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé. On dit qu'un événement $A \in \mathcal{A}$ se réalise $\mathbb{P}$-*presque sûrement* (en abrégé $\mathbb{P}$-p.s.) si $\mathbb{P}(A) = 1$.

Proposition – Propriétés élémentaires.

1. $\forall\, A \in \mathcal{A}$, $\mathbb{P}(A) \in [0,1]$ *et* $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$.
2. $\forall\, A, B \in \mathcal{A}$, $A \subset B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$.
3. $\forall\, A, B \in \mathcal{A}$, $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$.
4. Inégalité de Boole : $\forall\, n \in \mathbb{N}^*$, $\forall\, (A_i)_{1\leq i\leq n} \in \mathcal{A}$,
$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) \leq \sum_{i=1}^{n} \mathbb{P}(A_i).$$

5. Formule de Poincaré : $\forall\, n \in \mathbb{N}^*,\ \forall\, (A_i)_{1\leq i\leq n} \in \mathcal{A}$

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \sum_{i=1}^{n} \mathbb{P}(A_i) - \sum_{1\leq i<j\leq n} \mathbb{P}(A_i \cap A_j) + \ldots + (-1)^n \mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right).$$

Exercice – Démonstration (•)

Théorème – Théorème de la continuité monotone.

Dans le cas d'une suite $(A_n)_{n\in\mathbb{N}^*}$ *d'éléments de* $\mathcal{A}$ *croissante, on a*

$$\mathbb{P}\left(\bigcup_{n\in\mathbb{N}^*} A_n\right) = \lim_{n\to\infty} \mathbb{P}(A_n).$$

Exercice – Démonstration (•)

Exercice – Une définition alternative de la probabilité (•) Soit $(\Omega, \mathcal{A})$ un espace probabilisable. Supposons que $\mathbb{P} : \mathcal{A} \to [0,1]$ vérifie :

1. $\mathbb{P}(\Omega) = 1$,
2. Pour $A, B \in \mathcal{A}$, tels que $A \cap B = \varnothing$, $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$ (additivité),
3. Pour toute suite $(A_n)_{n\in\mathbb{N}^*}$ d'éléments de $\mathcal{A}$ croissante

$$\mathbb{P}\left(\bigcup_{n\in\mathbb{N}^*} A_n\right) = \lim_{n\to\infty} \mathbb{P}(A_n).$$

Montrer que $\mathbb{P}$ vérifie la propriété de σ-additivité (p. 15).

Remarque – Suite décroissante.

Dans le cas d'une suite décroissante, on a

$$\mathbb{P}\left(\bigcap_{n\in\mathbb{N}^*} A_n\right) = \lim_{n\to\infty} \mathbb{P}(A_n).$$

Le second point de la définition de la probabilité (p. 15) donne la probabilité de la réunion $\cup_n A_n$ en fonction des $\mathbb{P}(A_n)$ lorsque les événements sont deux à deux disjoints. Si ce n'est pas le cas, on a tout de même la majoration suivante :

Proposition – Une majoration bien utile.

Soit $\mathbb{P}$ *une probabilité et soit* $(A_n)_{n\in\mathbb{N}^*}$ *une famille dénombrable d'événements. On a alors*

$$\mathbb{P}(\cup_n A_n) \leq \sum_{n\in\mathbb{N}^*} \mathbb{P}(A_n)$$

Exercice – Démonstration (•)

3.3. Probabilité conditionnelle

La construction d'un modèle probabiliste repose sur l'information connue **a priori** sur l'expérience aléatoire. Ce modèle permet de quantifier les probabilités de réalisation de certains résultats de l'expérience. Il est fondamental de remarquer que si l'information change, les probabilités de réalisation changent.

Exemple – Information a priori.

On cherche pour un lancer de deux dés, la probabilité de l'événement "la somme est supérieure ou égale à 10". Elle vaut 1/6 sans information supplémentaire, 1/2 si l'on sait que le résultat d'un des dés est 6, 0 si l'on sait a priori que le résultat d'un des dés est 2. Pour obtenir ces résultats, on a calculé dans chaque cas le rapport du nombre de résultats favorables sur le nombre de cas possibles. Il est ainsi indispensable de bien définir l'espace de probabilité lié à l'expérience munie de l'information a priori. On remarque également que l'information a priori a changé la valeur de la probabilité de l'événement.

L'outil qui va nous permettre d'introduire de l'information est la probabilité conditionnelle dont nous donnons ici la définition.

Définition – Probabilité conditionnelle.

Soient $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé, $A, B \in \mathcal{A}$ tels que $\mathbb{P}(B) > 0$. La *probabilité conditionnelle* de A sachant B est le nombre

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Cela définit une probabilité comme le montre la proposition suivante.

Proposition – Conséquences.

1. *Soient $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé et $B \in \mathcal{A}$ tel que $\mathbb{P}(B) > 0$. Alors l'application de $\mathcal{A}$ dans $[0, 1]$ qui à A associe $\mathbb{P}(A|B)$ définit une nouvelle probabilité sur Ω, appelée probabilité conditionnelle sachant B.*
2. *Si $\mathbb{P}(A) > 0$ et $\mathbb{P}(B) > 0$, nous avons*

$$\mathbb{P}(A|B)\,\mathbb{P}(B) = \mathbb{P}(A \cap B) = \mathbb{P}(B|A)\,\mathbb{P}(A).$$

Démonstration. Il est clair que $0 \leq \mathbb{P}(A|B) \leq 1$. Par ailleurs, les deux propriétés de la définition de la probabilité (p. 15) pour $\mathbb{P}(\cdot|B)$ proviennent des mêmes propriétés pour $\mathbb{P}$ et des remarques suivantes : $\Omega \cap B = B$, et $(\bigcup_{n\in\mathbb{N}^*} A_n) \cap B = \bigcup_{n\in\mathbb{N}^*}(A_n \cap B)$. De plus, si A et C sont disjoints, il en est de même de $A \cap B$ et $C \cap B$. L'assertion 2 est évidente, d'après la définition de la Probabilité conditionnelle (p. 17). ■

Proposition – Formule des probabilités totales.

Soit $(B_n)_{n\in\mathbb{N}^*}$ une partition finie ou dénombrable d'événements de Ω (i.e. telle que $\bigcup_{n\in\mathbb{N}^*} B_n = \Omega$ et les B_n sont deux-à-deux disjoints), telle que $\mathbb{P}(B_n) > 0$ pour tout $n \in \mathbb{N}^*$. Pour tout $A \in \mathcal{A}$, on a alors

$$P(A) = \sum_{n\in\mathbb{N}^*} P(A \cap B_n) = \sum_{n\in\mathbb{N}^*} P(A|B_n)\, P(B_n).$$

Démonstration. Nous avons $A = \bigcup_{n\in\mathbb{N}^*}(A \cap B_n)$. Par hypothèse, les ensembles $(A \cap B_n)$ sont deux-à-deux disjoints et de plus $\mathbb{P}(A \cap B_n) = \mathbb{P}(A|B_n)\,\mathbb{P}(B_n)$. Le résultat découle du deuxième point de la définition de la probabilité (p. 15). ■

Proposition – Formule de Bayes.

Selon les mêmes hypothèses que ci-dessus et si $\mathbb{P}(A) > 0$, on a

$$\forall\, i \in \{1, \ldots, n\},\ \mathbb{P}(B_i|A) = \frac{\mathbb{P}(A|B_i)\,\mathbb{P}(B_i)}{\sum_{n\in\mathbb{N}^*} \mathbb{P}(A|B_n)\,\mathbb{P}(B_n)}.$$

Démonstration. Le dénominateur vaut $\mathbb{P}(A)$ d'après la Formule des probabilités totales (p. 18). La définition de la probabilité conditionnelle (p. 17) implique :

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A \cap B_i)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\mathbb{P}(A)}.$$

■

Remarque.

La formule de Bayes, simple conséquence des axiomes et de la définition de la probabilité conditionnelle, tient une place à part dans le calcul des probabilités en raison de son importance pratique considérable et des controverses auxquelles son application pratique a donné lieu : elle est à la base de toute une branche de la statistique appelée statistique bayésienne.

Exercice – Test (•) Un individu est tiré au hasard dans une population où l'on trouve une proportion 10^{-4} de séropositifs. On lui fait passer un test de détection de la séropositivité. Par ailleurs, des expérimentations antérieures ont permis de savoir que les probabilités d'avoir un résultat positif lors de l'application du test si l'individu est séropositif, ou s'il ne l'est pas, sont respectivement égales à 0,99 (c'est la sensibilité du test) et à 0,001 (0,999 = 1 - 0,001 est la spécificité du test). Sachant que le test donne un résultat positif, quelle est la probabilité pour que l'individu soit effectivement séropositif ?

3.4. Indépendance des événements

La notion d'indépendance est absolument fondamentale en probabilités et nous verrons par la suite toutes ses implications dans la modélisation de l'aléatoire.

Intuitivement, deux événements A et B sont indépendants si le fait de savoir que A est réalisé ne donne aucune information sur la réalisation de B et réciproquement.

Si B est un événement de probabilité strictement positive, A sera dit indépendant de B si

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \mathbb{P}(A)$$

On remarque que cette formule se symétrise et la notion d'indépendance se définit finalement comme suit.

Définition – Indépendance de deux événements.

Deux événements A et B sont *indépendants* si et seulement si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\,\mathbb{P}(B).$$

Remarque.

- La probabilité de voir A réalisé ne dépend pas de la réalisation de B, et réciproquement.
- Cette notion est liée au choix de la probabilité $\mathbb{P}$ et n'est pas une notion ensembliste. Cela n'a en particulier rien à voir avec le fait que A et B soient disjoints ou non.
- Si $\mathbb{P}(A) > 0$ et $\mathbb{P}(B) > 0$, alors

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\,\mathbb{P}(B) \Leftrightarrow \mathbb{P}(A) = \mathbb{P}(A|B) \Leftrightarrow \mathbb{P}(B) = \mathbb{P}(B|A).$$

Proposition.

Si les événements A et B sont indépendants, alors il en est de même des couples (A^c, B), (A, B^c) et (A^c, B^c).

Exercice – Démonstration (•)

Exercice – Auto-indépendant ? (•) À quelle condition un événement A est-il indépendant de lui-même ?

Exemple.

1. On lance 3 fois un dé. Si A_i est un événement qui ne dépend que du $i^{\text{ème}}$ lancer, alors A_1 , A_2 , A_3 sont indépendants.
2. On tire une carte au hasard dans un jeu de 52 cartes. Soit $A = \{\text{la carte est une dame}\}$ et $B = \{\text{la carte est un coeur}\}$. Il est facile de voir que $\mathbb{P}(A) = 4/52$ et $\mathbb{P}(B) = 13/52$ et $\mathbb{P}(A \cap B) = \mathbb{P}(\{\text{la carte est la dame de coeur}\}) = 1/52 = \mathbb{P}(A)\mathbb{P}(B)$. Ainsi, les événements A et B sont indépendants pour la probabilité uniforme $\mathbb{P}$.
3. On suppose maintenant que le jeu de cartes soit trafiqué. Soit $\widetilde{\mathbb{P}}$ la nouvelle probabilité correspondant au tirage de cartes. On suppose également que

$$\widetilde{\mathbb{P}}(\{\text{As de trèfle}\}) = \frac{1}{2}, \quad \widetilde{\mathbb{P}}(\{\text{autre carte}\}) = \frac{1}{2}\frac{1}{51} = \frac{1}{102},$$

alors

$$\widetilde{\mathbb{P}}(A \cap B) = \frac{1}{102} \neq \widetilde{\mathbb{P}}(A)\widetilde{\mathbb{P}}(B) = \frac{2}{51}\frac{13}{102}.$$

Les événements A et B ne sont pas indépendants sous la probabilité $\widetilde{\mathbb{P}}$.

Définition – Indépendance de n événements.

n événements $A_1, \ldots, A_n$ sont *mutuellement indépendants* ou simplement *indépendants* si et seulement si pour toute partie $I \subset \{1, \ldots, n\}$

$$\mathbb{P}(\cap_{i \in I} A_i) = \prod_{i \in I} \mathbb{P}(A_i).$$

Remarque.

Attention, l'indépendance des évènements deux à deux n'implique pas l'indépendance mutuelle des évènements.

3.5. Remarque : réflexion sur le concept de probabilité

La théorie mathématiques des probabilités ne dit pas quelle loi de probabilité choisir sur un espace $(\Omega, \mathcal{A})$ parmi l'infinité de lois possibles. Ce problème qui concerne ceux qui veulent appliquer le calcul des probabilités, renvoie à la nature "physique" du concept de probabilité qui formalise et quantifie le sentiment d'incertitude vis-à-vis d'un événement. Ce problème d'ordre conceptuel oppose deux écoles de pensée, la conception objectiviste et la conception subjectiviste.

Pour les tenants du premier point de vue, la probabilité d'un événement peut être déterminée de manière unique. Dans la vision dite classique, héritée des jeux de hasard, Ω est fini et on donne à chaque événement élémentaire la même probabilité. Le calcul des probabilités se résume alors à un problème de dénombrement et la probabilité d'un événement est le rapport du nombre de cas favorables sur le nombre de cas possibles. Dans le cas infini, la vision fréquentiste repose sur la loi des grands nombres : si on répète un grand nombre de fois l'expérience, la proportion de fois où un événement sera réalisé va converger vers la probabilité de cet événement. Dans ce cadre, il est impossible de donner une valeur et même un sens à un événement non répétable comme "pleuvra-t-il demain ?". En outre, la répétition à l'infini d'une même expérience étant physiquement irréalisable, la loi des grands nombres étant un résultat qui suppose défini le concept de probabilité, la vision fréquentiste est logiquement intenable.

Dans la conception subjectiviste, la probabilité objective d'un événement n'existe pas et n'est donc pas une grandeur mesurable analogue à la masse d'un corps, par exemple. C'est simplement une mesure d'incertitude qui reflète un degré de croyance pouvant varier avec les circonstances et l'observateur, donc subjective, la seule exigence étant qu'elle satisfasse aux axiomes du calcul des probabilités. Des méthodes ont alors été proposées pour passer d'un simple pré-ordre sur les événements, à une probabilité. Puisque la répétition n'est plus nécessaire, on peut probabiliser des événements non répétables et étendre ainsi le domaine d'application du calcul des probabilités, notamment pour orienter des prises de décisions. On notera que la formule de Bayes (p. 18) permet d'intégrer facilement de l'information a priori, dans la mesure où celle-ci est probabilisée.

On arrête ici ces quelques remarques sans prendre parti dans une querelle qui dure encore. L'un ou l'autre point de vue sera adopté selon les ouvrages rencontrés. Dans tous les cas, les outils mathématiques développés dans ce cours seront adaptés. On rappelle tout de même que la modélisation probabiliste a prouvé son efficacité dans de nombreuses applications mais que, comme tout modèle, ce n'est qu'une représentation simplificatrice de la réalité et que ses hypothèses doivent être mises à l'épreuve des faits. À ce titre, on citera Georges Matheron qui dans son essai sur la pratique des probabilités Estimer et Choisir (Matheron (1978)) écrit fort justement : "Il n'y a pas de probabilités en soi. Il n'y a que des modèles probabilistes".

4. Variables aléatoires

En théorie moderne des probabilités, on préfère prendre un point de vue fonctionnel plutôt qu'ensembliste, et utiliser les variables aléatoires plutôt que les événements. Une variable aléatoire est une grandeur qui dépend du résultat de l'expérience. Par exemple,

- le nombre de 6 obtenus dans un lancer de 3 dés,
- le nombre d'appels dans un central téléphonique pendant une heure,
- la distance du point d'atteinte d'une flèche au centre de la cible,
- la valeur maximale d'un prix d'actif sur un intervalle de temps donné,

sont des variables aléatoires.

Définition – Variable aléatoire.

Soient $(\Omega, \mathcal{A})$ et $(E, \mathcal{E})$ deux espaces probabilisables (mesurables). Une *variable aléatoire* X à valeurs dans E est une application mesurable de $(\Omega, \mathcal{A})$ dans $(E, \mathcal{E})$, c'est-à-dire telle que $\forall B \in \mathcal{E}$, $X^{-1}(B) \in \mathcal{A}$.

En pratique, l'ensemble E pourra être un ensemble fini ou dénombrable ou $\mathbb{R}$ ou $\mathbb{R}^d$ ou encore un espace plus sophistiqué tel que l'ensemble $C(\mathbb{R}_+, \mathbb{R}^d)$ des fonctions continues de $\mathbb{R}_+$ dans $\mathbb{R}^d$.

Remarque – Vocabulaire.

La terminologie, consacrée par l'usage, peut être trompeuse. Une variable aléatoire n'est pas une variable (au sens de l'analyse) mais une fonction. Cette terminologie est apparentée à la notion de variable en physique ou en sciences humaines où on désigne volontiers par "variable" la valeur prise par une fonction de l'état du système étudié.

L'intérêt principal de travailler avec des variables aléatoires est de pouvoir substituer à l'espace abstrait Ω des résultats de l'expérience l'espace E, mieux connu dans la pratique. Ainsi, grâce à une variable aléatoire X, nous pouvons transporter la structure abstraite du modèle probabiliste $(\Omega, \mathcal{A}, \mathbb{P})$ sur l'espace d'arrivée E, en posant pour $B \in \mathcal{E}$

$$\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B)) = \mathbb{P}(\{\omega, X(\omega) \in B\})$$

Cette formule définit une nouvelle probabilité, notée $\mathbb{P}_X$ et définie sur $(E, \mathcal{E})$, qui s'appelle la *loi de la variable* X. On dit aussi que $\mathbb{P}_X$ est la *mesure (de probabilité) image* de $\mathbb{P}$ par X.

Pour se convaincre que $\mathbb{P}_X$ définit bien une probabilité sur $(E, \mathcal{E})$, il suffit de remarquer que

$$X^{-1}(\varnothing) = \varnothing, X^{-1}(E) = \Omega, X^{-1}(B^c) = X^{-1}(B)^c$$
$$X^{-1}(\cap_i A_i) = \cap_i X^{-1}(A_i), X^{-1}(\cup_i A_i) = \cup_i X^{-1}(A_i)$$

Remarque – Notation.

Il est usuel de noter l'ensemble $X^{-1}(B) = \{\omega \in \Omega, X(\omega) \in B\}$ par $\{X \in B\}$, ce qui allège les écritures. On se rappelera néanmoins que cette notation désigne un sous-ensemble de Ω.

$\mathbb{P}_X$ sera plus facile à caractériser que $\mathbb{P}$ puisque E est un ensemble connu (on pourra en particulier utiliser ses propriétés topologiques) alors que Ω est un espace abstrait. Les variables que nous rencontrerons dans ce cours seront soit à valeurs dans un ensemble dénombrable, soit à valeurs dans $\mathbb{R}$ ou dans $\mathbb{R}^d$. Nous les appellerons respectivement des variables aléatoires discrètes, réelles ou des vecteurs aléatoires. Leurs lois seront alors des probabilités respectivement sur un ensemble dénombrable, sur $\mathbb{R}$ ou sur $\mathbb{R}^d$. Le cas discret est considéré connu.

4.1. Variables aléatoires réelles

Dans le cas où $E = \mathbb{R}$, on travaille généralement avec la *tribu des boréliens*, que l'on notera $\mathcal{B}(\mathbb{R})$, qui est très utile comme on le verra pour identifier les lois de probabilité. On rappelle ici quelques propriétés sur les tribus, déjà vues dans le cours d'intégration.

Définition – Tribu engendrée.

Si $C \subset \mathcal{P}(\Omega)$, on appelle tribu engendrée par C la plus petite tribu contenant C. Elle existe toujours, car d'une part $\mathcal{P}(\Omega)$ est une tribu contenant C, et d'autre part l'intersection d'une famille quelconque de tribus est une tribu. Ainsi, la tribu engendrée par C est l'intersection de toutes les tribus contenant C.

Exemple – Tribus engendrées.

- La tribu engendrée par un ensemble $A \subset \Omega$ est $\varnothing, A, A^c, \Omega$.
- si $(A_i)_{i\in I}$ est une partition finie ou dénombrable de Ω (i.e. les A_i sont deux-à-deux disjoints et leur réunion est Ω), la tribu engendrée par $\{A_i, i \in I\}$ est l'ensemble des réunions $B_J = \cup_{i\in J} A_i$, où J décrit la classe de toutes les parties de I.

Définition – Tribu borélienne sur $\mathbb{R}$.

Si $\Omega = \mathbb{R}$, on appelle tribu borélienne, que l'on note $\mathcal{B}(\mathbb{R})$, la tribu engendrée par la classe des ouverts de $\mathbb{R}$.

À titre d'exercice de maniement des tribus, on donne en détail la démonstration du résultat suivant :

Proposition – Définition alternative.

La tribu borélienne de $\mathbb{R}$ est la tribu engendrée par les intervalles de la forme $]-\infty, a]$ pour $a \in \mathbb{Q}$.

Démonstration. On rappelle que toute tribu est stable par passage au complémentaire, par réunion ou intersection dénombrable.

Soit C_1 la classe des intervalles ouverts de $\mathbb{R}$, C_2 la classe des intervalles $]-\infty, a]$ pour $a \in \mathbb{Q}$ et $\mathcal{B}(\mathbb{R})$ la tribu borélienne.

Tout ouvert A est réunion dénombrable d'intervalles ouverts, en effet, on a $A = \cup_{(q,n)\in B}]q-\frac{1}{n}, q-\frac{1}{n}[$, où B est l'ensemble (dénombrable) des couples (q,n) avec $q \in \mathbb{Q}$, $n \in \mathbb{N}$ et $]q-\frac{1}{n}, q-\frac{1}{n}[\in A$. La tribu engendrée par les intervalles ouverts est donc identique à la tribu borélienne par la stabilité par réunion dénombrable et le fait que $C_1 \subset \mathcal{B}(\mathbb{R})$.

Réciproquement, soit $]x, y[$ un intervalle ouvert de $\mathbb{R}$. Soit $(x_n)_n$ une suite de rationnels décroissant vers x et $(y_n)_n$ une suite de rationnels croissant strictement vers y. On a :

$$]x, y[= \bigcup_n (]-\infty, y_n] \bigcap]-\infty, x_n]^c).$$

Donc C_1 et par conséquent $\mathcal{B}(\mathbb{R})$ sont inclus dans la tribu engendrée par C_2. Finalement, comme tout fermé est dans $\mathcal{B}(\mathbb{R})$ par complémentarité, on a aussi $C_2 \subset \mathcal{B}(\mathbb{R})$, d'où le résultat. ■

On peut maintenant définir une variable aléatoire réelle :

Définition – Variable aléatoire réelle.

Soit l'espace d'état Ω muni de la tribu $\mathcal{A}$ des évènements. Une application X de Ω dans $\mathbb{R}$ est une *variable aléatoire réelle* si $X^{-1}(B) \in \mathcal{A}$ pour tout $B \in \mathcal{B}(\mathbb{R})$, autrement dit si X est une application mesurable de $(\Omega, \mathcal{A})$ dans $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Définition – Loi d'une variable aléatoire réelle.

La probabilité $\mathbb{P}_X$, définie sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ par $\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B))$ pour $B \in \mathcal{B}(\mathbb{R})$ est appelée *loi de la variable* X, ou *distribution* de X.

On peut voir $\mathbb{P}_X$ comme une transposition de $\mathbb{P}$ sur $\mathbb{R}$. On a alors le résultat très utile suivant :

Proposition – Composition.

Si $X_1, \ldots, X_n$ sont des variables aléatoires réelles et si g est une fonction mesurable de $\mathbb{R}^n$ dans $\mathbb{R}$ (munis de leur tribu borélienne), alors $Y = g(X_1, \ldots, X_n)$ est une variable aléatoire réelle.

4.1.1. Démonstration

On note $X = (X_1, \ldots, X_n)$. X est mesurable de $(\Omega, \mathcal{A})$ dans $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ puisque ce vecteur est constitué de composantes mesurables de $(\Omega, \mathcal{A})$ dans $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ et que $\mathcal{B}(\mathbb{R}^n) = \mathcal{B}(\mathbb{R}) \otimes \ldots \otimes \mathcal{B}(\mathbb{R})$. Soit $B \in \mathcal{B}(\mathbb{R})$, alors $Y^{-1}(B) = (g \circ X)^{-1}(B) = X^{-1}(g^{-1}(B))$. Puisque g et X sont mesurables, $g^{-1}(B) \in \mathcal{B}(\mathbb{R}^n)$ et $X^{-1}(g^{-1}(B)) \in \mathcal{A}$.

Comme application de ce résultat, on a les propriétés suivantes :

Proposition – Conséquences.

Soient X, Y et $(X_n)_{n\in\mathbb{N}^\star}$ des variables aléatoires réelles. On a

1. *$X+Y$, XY, $\frac{X}{Y}$ si $Y \neq 0$, sont des variables aléatoires.*
2. *$\sup_{1\leq p\leq n} X_p$, $\inf_{1\leq p\leq n} X_p$, sont des variables aléatoires.*

3. $\sup_{n\geq 1} X_n$, $\inf_{n\geq 1} X_n$, *sont des variables aléatoires.*

4. *Si* $X_n(\omega) \xrightarrow[n\to\infty]{} Z(\omega)$, $\forall\omega$, *alors la limite* Z *est une variable aléatoire.*

5. $Z = 1_A$ *est une variable aléatoire* $\Leftrightarrow A \in \mathcal{A}$.

4.2. Loi des variables aléatoires réelles

Nous avons vu précédemment la définition générale d'une probabilité $\mathbb{P}$ sur un espace quelconque Ω muni d'une tribu $\mathcal{A}$. Un problème fondamental est de construire et de caractériser ces probabilités. La résolution de ce problème lorsque Ω est fini ou dénombrable est supposée connue. Puisque les variables aléatoires réelles sont définies sur $\mathbb{R}$, nous allons étudier leur loi de probabilité $\mathbb{P}_X$ définie sur $\mathbb{R}$ muni de la tribu $\mathcal{B}(\mathbb{R})$.

Définition – Fonction de répartition.

Soit X une variable aléatoire réelle et $\mathbb{P}_X$ sa loi. La *fonction de répartition* de X est la fonction

$$F_X(x) = \mathbb{P}_X(]-\infty, x]) = \mathbb{P}(X \leq x),\ x \in \mathbb{R}.$$

Théorème – La fonction de répartition caractérise la probabilité.

La fonction de répartition F *caractérise la probabilité* $\mathbb{P}_X$ *sur* $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Démonstration. On veut montrer que la connaissance de F telle que définie ci-dessus (p. 24) détermine $\mathbb{P}_X$ de manière unique, c'est-à-dire que si il existe une autre probabilité $\mathbb{P}_Y$ telle que $G(x) = \mathbb{P}_Y(]-\infty, x])$ pour $x \in \mathbb{R}$ et si $F = G$, alors $\mathbb{P}_X = \mathbb{P}_Y$.

Soit $\mathcal{B}_0$ l'ensemble de toutes les réunions finies d'intervalles disjoints de la forme $]x, y]$ ou $-\infty \leq x < y \leq +\infty$. Cet ensemble contient $\mathbb{R}$, $\varnothing$ et est stable par passage au complémentaire et par réunion finie, c'est donc une algèbre. De manière évidente, il est aussi stable par intersection finie et est ainsi un π-système. Par ailleurs, on a déjà vu que $\sigma(\mathcal{B}_0)$ (la tribu engendrée par $\mathcal{B}_0$) est la tribu borélienne $\mathcal{B}(\mathbb{R})$.

D'après la définition de la fonction de répartition (p. 24), on a $\mathbb{P}_X(]x, y]) = F(y) - F(x)$ pour tous $x < y$. Par conséquent, si $B = \cup_{i=1}^n]x_i, y_i]$, avec $x_i < y_i < x_{i+1}$, on a

$$\mathbb{P}_X(B) = \sum_{i=1}^n \mathbb{P}_X(]x_i, y_i]) = \sum_{i=1}^n F(y_i) - F(x_i),$$

car les intervalles sont disjoints.

Si $\mathbb{P}_Y$ est une autre probabilité telle que $F(x) = \mathbb{P}_Y(]-\infty, x])$, alors ce qui précède montre que $\mathbb{P}_X = \mathbb{P}_Y$ sur $\mathcal{B}_0$ qui engendre $\mathcal{B}(\mathbb{R})$. $\mathbb{P}_X$ et $\mathbb{P}_Y$ étant des mesures finies, la proposition B.3.12 du cours de calcul intégral nous permet d'assurer que $\mathbb{P}_X = \mathbb{P}_Y$ pour tous les éléments de $\mathcal{B}(\mathbb{R})$, autrement dit que ces deux mesures de probabilités sont identiques sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. ■

Théorème – Caractérisation de la fonction de répartition.

Une fonction F est la fonction de répartition d'une unique probabilité $\mathbb{P}_X$ sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ si et seulement si elle vérifie les trois conditions suivantes :

1. *elle est croissante,*
2. *elle est continue à droite,*
3. $\lim_{x\to-\infty} F(x) = 0$, $\lim_{x\to+\infty} F(x) = 1$.

Démonstration. La première assertion est immédiate d'après la définition (p. 24). Pour la seconde, on remarque que si x_n décroît vers x, alors $]-\infty, x_n]$ décroît vers $]-\infty, x]$ et donc $F(x_n)$ décroît vers $F(x)$ par le théorème de la continuité monotone (p. 16). La troisième assertion se montre de manière analogue en remarquant que $]-\infty, x]$ décroît vers $\varnothing$ (resp. croît vers $\mathbb{R}$) lorsque x décroît vers $-\infty$ (resp. croît vers $+\infty$).

Pour la réciproque, on se reportera au chapitre 7 de Jacod and Protter (2003). ■

Remarque – Quelques propriétés.

Comme F est croissante, elle admet une limite à gauche en chaque point notée $F(x^-)$. En remarquant que $]-\infty, y[= \lim_{n\to+\infty}]-\infty, y_n[$ si y_n tend vers y par valeurs décroissantes, on obtient pour $x < y$:

- $\mathbb{P}_X(]x, y]) = \mathbb{P}(x < X \leq y) = F(y) - F(x)$
- $\mathbb{P}_X(]x, y[) = \mathbb{P}(x < X < y) = F(y-) - F(x)$
- $\mathbb{P}_X([x, y]) = \mathbb{P}(x \leq X \leq y) = F(y) - F(x^-)$
- $\mathbb{P}_X([x, y[) = \mathbb{P}(x \leq X < y) = F(y-) - F(x^-)$

En particulier, $\mathbb{P}_X(\{x\}) = F(x) - F(x^-)$ est le **saut** de la fonction F au point x. On a donc $\mathbb{P}_X(\{x\}) = 0$ pour tout x si et seulement si F est continue en tout point.

Remarque – Nécessité des tribus.

Le théorème ci-dessus (p. 24) explique pourquoi, d'un point de vue strictement mathématique, il est nécessaire d'introduire les tribus en probabilités, malgré la complexité que cela engendre.

Plus concrètement, considérons l'exemple suivant : soit $\Omega = [0, 1]$ et $\mathbb{P}$ telle que $\mathbb{P}(]a, b]) = b - a$ pour $0 \leq a \leq b \leq 1$ (il s'agit de la loi uniforme sur [0,1]). C'est une probabilité naturelle qui assigne à tout intervalle sa longueur comme probabilité. Supposons maintenant que l'on souhaite étendre de manière unique $\mathbb{P}$ aux $2^{[0,1]}$ éléments de $\mathcal{P}([0, 1])$ de manière à ce que $\mathbb{P}(\Omega) = 1$ et $\mathbb{P}\left(\cup_{n\in\mathbb{N}^\star} A_n\right) = \sum_{n\in\mathbb{N}^\star} \mathbb{P}(A_n)$ pour toute suite $(A_n)_{n\in\mathbb{N}^\star}$ tels que $\mathcal{A}_n \cap A_m = \varnothing$ pour $n \neq m$. On peut prouver qu'un tel $\mathbb{P}$ n'existe pas. $\mathcal{P}([0, 1])$ est trop "grand" pour définir un tel $\mathbb{P}$. Il contient en particulier des ensembles non mesurables.

Si l'on voulait travailler avec la tribu $\mathcal{A} = \mathcal{P}(\mathbb{R})$, il n'existerait que très peu de probabilités sur $\mathbb{R}$, à savoir les probabilités discrètes que l'on décrit rapidement ci-dessous.

Exemple – Probabilités discrètes.

1. Les masses de Dirac (ou **mesures** de Dirac).

   X est identiquement égale à $a \in \mathbb{R}$. Alors sa loi est la mesure de Dirac en a, la probabilité $\mathbb{P}_X$ sur $\mathbb{R}$ qui vérifie pour $A \in \mathcal{P}(\mathbb{R})$

   $$\mathbb{P}_X(A) = \begin{cases} 1 & \text{si } a \in A, \\ 0 & \text{sinon.} \end{cases}$$

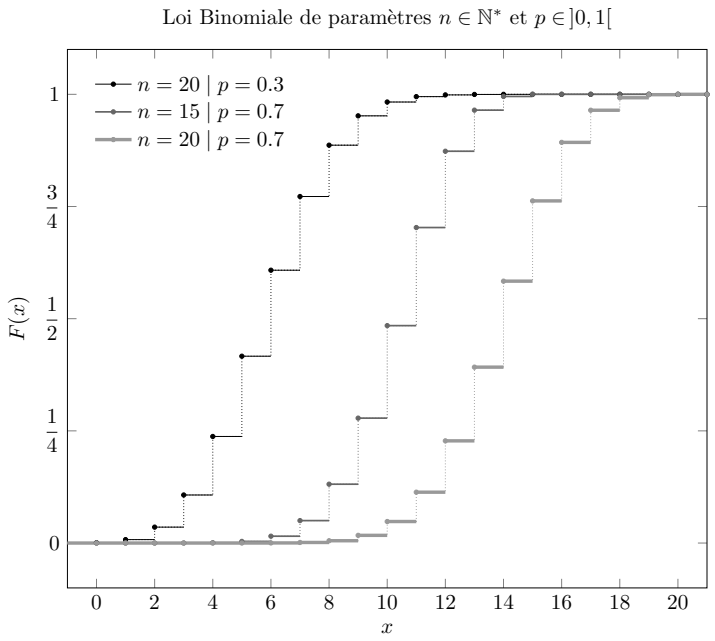
   Sa fonction de répartition est $F(x) = 1_{[a,+\infty[}(x)$.

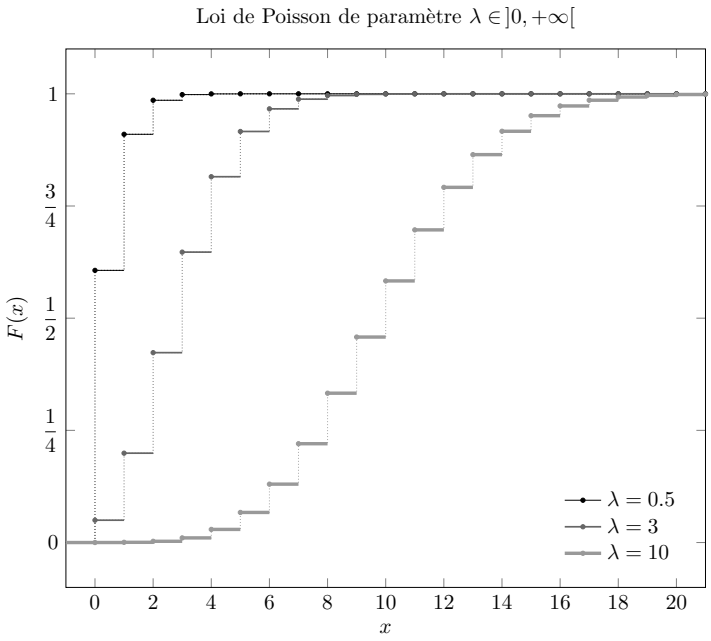
2. Les probabilités portées par $\mathbb{N}$.

   X est à valeurs dans $\mathbb{N}$. Comme $\mathbb{N}$ est une partie de $\mathbb{R}$, toute probabilité sur $\mathbb{N}$ peut être considérée comme une probabilité sur $\mathbb{R}$ qui ne "charge" que $\mathbb{N}$. Plus précisément, si Q est la loi de probabilité de X sur $\mathbb{N}$, on définit son "extension" $\mathbb{P}_X$ à $\mathbb{R}$ en posant $\mathbb{P}_X(A) = Q(A \cap \mathbb{N})$. Si $q_n = Q(\{n\})$ pour $n \in \mathbb{N}$, la fonction de répartition F de $\mathbb{P}_X$ est

   $$F(x) = \begin{cases} 0 & \text{si } x < 0, \\ \sum_{i=0}^{\lfloor x \rfloor} q_i & \text{sinon,} \end{cases}$$

   où $\lfloor \cdot \rfloor$ désigne la partie entière. A titre d'exemple, on représente ci-dessous les fonctions de répartitions de la loi binomiale et de la loi de Poisson.





3. Les probabilités discrètes.

   Plus généralement, si X prend ses valeurs dans une partie finie ou dénombrable E de $\mathbb{R}$, la loi $\mathbb{P}_X$ de X est caractérisée pour tout $i \in E$ par $q_i = \mathbb{P}_X(i) = \mathbb{P}(X = i)$. La fonction de répartition F de X est alors

   $$F(x) = \sum_{\substack{i \in E \\ i \leq x}} q_i,$$

   avec la convention qu'une somme "vide" vaut 0. On retrouve bien l'exemple 2 si $E = \mathbb{N}$. On voit que F est **purement discontinue** au sens où elle est complètement caractérisée par ses sauts $\triangle F(x) = F(x) - F(x^-)$:

   $$F(x) = \sum_{y \leq x} \triangle F(y).$$

Il existe bien d'autres probabilités, non discrètes, sur $\mathbb{R}$. Le paragraphe suivant est consacré à un exemple très important, celui des variables aléatoires dont la loi admet une densité.

4.3. Variables aléatoires réelles à densité

Définition – Densité de probabilité.

Une fonction réelle f sur $\mathbb{R}$ est une *densité de probabilité* (ou plus simplement une *densité*) si elle est positive, intégrable et vérifie

$$\int_{\mathbb{R}} f(x)\, dx = 1,$$

où dx désigne la mesure de Lebesgue sur $\mathbb{R}$.

Si f est une densité, la fonction

$$F(x) = \int_{-\infty}^{x} f(y)\, dy$$

est la fonction de répartition d'une probabilité sur $\mathbb{R}$.

Définition – Variable aléatoire réelle à densité.

Soit X une variable aléatoire. On dit que X a une *loi de densité* f (ou par abus de language "est de densité f"), si $\mathbb{P}_X$ admet la densité f et donc si pour tout réel x,

$$\mathbb{P}(X \leq x) = \int_{-\infty}^{x} f(y)dy.$$

Proposition – Fonction de répartition d'une variable aléatoire à densité.

Soit X de loi de densité f.

1. *Sa fonction de répartition F est continue, de sorte que*
$$\mathbb{P}(X = x) = 0, \quad \forall x \in \mathbb{R}.$$
2. *La fonction F est dérivable en tout point x où f est continue et*
$$F'(x) = f(x).$$
3. *A l'inverse, si la fonction de répartition F de X est dérivable, ou seulement continue partout et dérivable par morceaux, alors X admet la densité*
$$F'(x) = f(x).$$

Il existe bien sûr des variables aléatoires qui n'ont pas de densité : c'est le cas des variables discrètes données en exemple ci-dessus. Il existe des cas "mixtes" : soient d'une part f une fonction positive, intégrable et d'intégrale strictement positive et d'autre part une partie finie ou dénombrable E de $\mathbb{R}$ et des poids $p_i > 0$ indexés par $i \in E$, tels que :

$$\int_{\mathbb{R}} f(x)\,dx + \sum_{i \in E} p_i = 1.$$

Alors la fonction

$$F(x) = \int_{-\infty}^{x} f(x)\,dx + \sum_{\substack{i \in E \\ i \leq x}} p_i$$

est une fonction de répartition, et la probabilité associée $\mathbb{P}_X$ n'admet pas de densité et n'est pas non plus discrète.

La mesure de probabilité associée s'écrit $\mathbb{P}_X = f\lambda + \sum_{i \in E} p_i \delta_i$ où λ est la mesure de Lebesgue

Remarque.

1. La fonction de répartition est entièrement déterminée par la probabilité $\mathbb{P}$. Il n'en est pas de même de la densité lorsqu'elle existe : si en effet on a $F(x) = \int_{-\infty}^{x} f(y)\,dy$ et si on pose $g(x) = f(x)$ si $x \notin E$ et $g(x) = f(x) + 1$ (par exemple) si $x \in E$, où E est un

ensemble négligeable, alors g est encore une densité de $\mathbb{P}$. Autrement dit, la densité

2. Une interprétation intuitive de la densité f de $\mathbb{P}$: si dx est un petit accroissement de la variable x, on a (si du moins f est continue en x) :

$$f(x) \sim \frac{\mathbb{P}([x, x+dx])}{dx}.$$

Exercice – Durée de fonctionnement (•) On suppose que la durée de fonctionnement, en heures, d'un ordinateur avant sa première panne est une variable aléatoire positive de loi exponentielle de paramètre 1/100, de densité donnée par

$$f(x) = \begin{cases} \frac{1}{100} \exp\left(-\frac{x}{100}\right) & x \geq 0, \\ 0 & x < 0. \end{cases}$$

1. Calculer la probabilité que cette durée de fonctionnement X soit comprise entre 50 et 150 heures.
2. Calculer la probabilité que l'ordinateur fonctionne moins de 100 heures.
3. Calculer la probabilité que l'ordinateur fonctionne exactement 100 heures avant sa première panne.

Exercice – Précipitation (•) On souhaite modéliser la hauteur de précipitation (en mm) tombée sur Paris en une journée par une variable aléatoire X. On considère que cette hauteur suit une loi exponentielle de paramètre 1/10 lorsqu'il pleut et qu'il pleut en moyenne un jour sur deux.

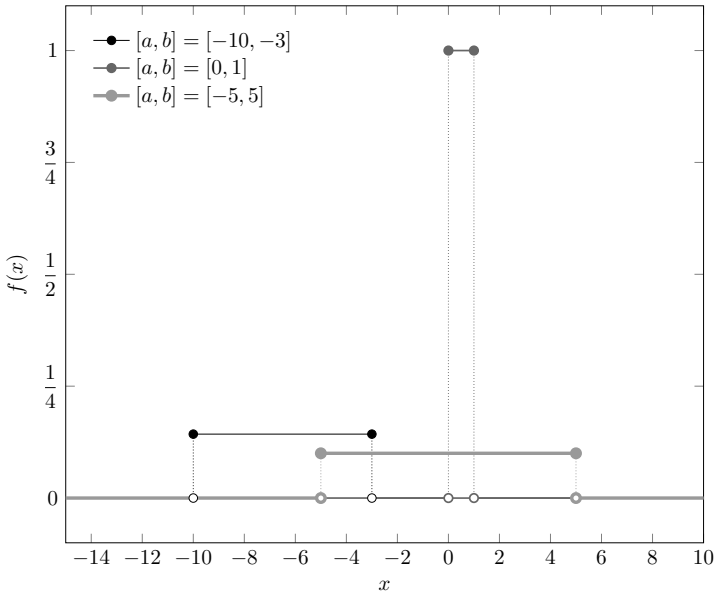
1. Donner la Fonction de répartition de X.
2. X admet-elle une densité ?

Exemple – Quelques lois à densités.

1. La *loi uniforme* sur $[a, b]$, avec $a, b \in \mathbb{R}$ tels que $a < b$, notée $\mathcal{U}_{[a,b]}$, est la probabilité $\mathbb{P}$ qui admet la densité

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } a \leq x \leq b, \\ 0 & \text{sinon.} \end{cases}$$

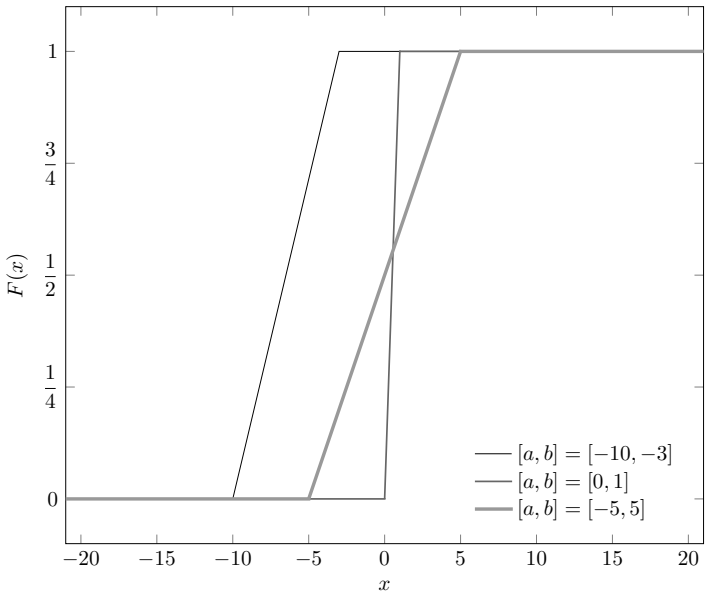
Loi Uniforme de paramètres $a, b \in \mathbb{R}$ $(a < b)$



En vertu de la remarque 1. ci-dessus, on aurait pu choisir $f(a) = f(b) = 0$. Au vu de l'interprétation 2. ci-dessus, le fait que f soit constante sur $[a, b]$ exprime que si on choisit un point selon la probabilité uniforme, on a "autant de chances" de tomber au voisinage de chaque point de l'intervalle $[a, b]$. Cela explique le nom "uniforme". On remarque aussi que $\mathbb{P}(\{x\}) = 0$ pour tout x (comme pour toutes les probabilités à densité). On a donc une probabilité nulle de tomber exactement en un point x fixé à l'avance. On vérifie aisément que sa fonction de répartition est

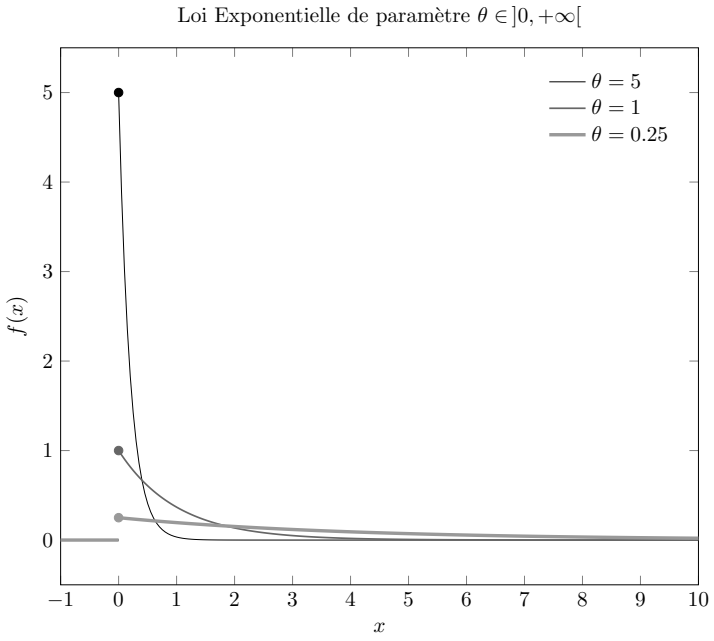
$$F(x) = \begin{cases} 0 & \text{si } x < a, \\ \frac{x-a}{b-a} & \text{si } a \leq x \leq b, \\ 1 & \text{si } x > b. \end{cases}$$

Loi Uniforme de paramètres $a, b \in \mathbb{R}$ $(a < b)$



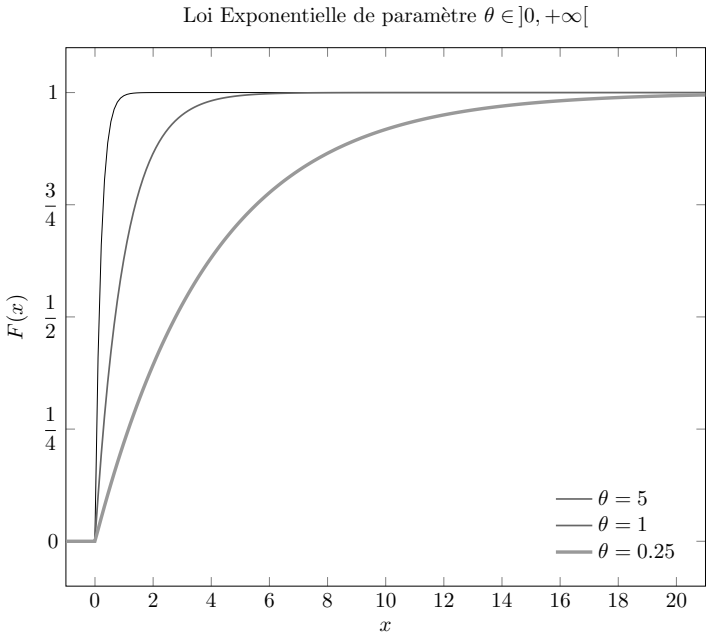
2. La *loi exponentielle* de paramètre θ, notée $\mathcal{E}_\theta$, est la loi de densité

$$f(x) = \begin{cases} 0 & \text{si } x < 0, \\ \theta e^{-\theta x} & \text{sinon.} \end{cases}$$



et de fonction de répartition

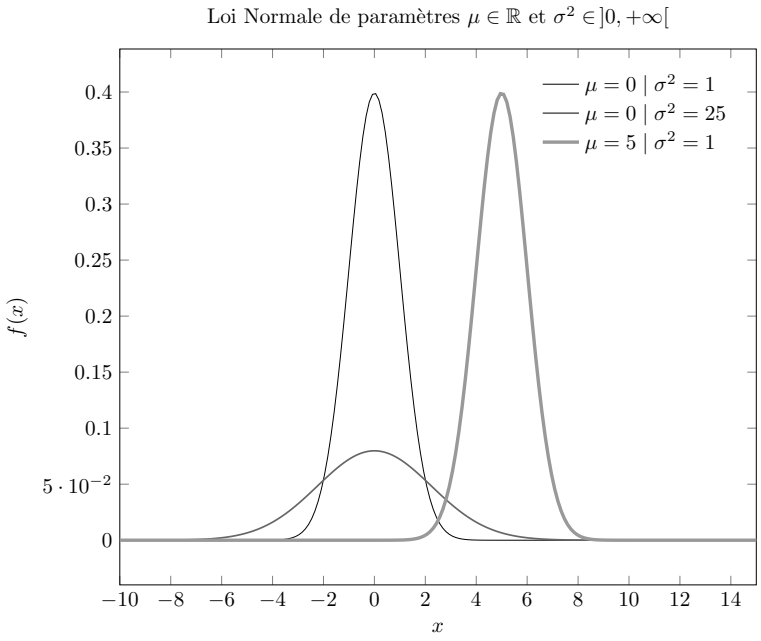
$$F(x) = \begin{cases} 0 & \text{si } x < 0, \\ 1 - e^{-\theta x} & \text{sinon.} \end{cases}$$



Dans la pratique, on utilise fréquemment la loi exponentielle pour modéliser une durée de vie ou le temps d'attente avant l'arrivée d'un événement spécifique. Par exemple la durée de vie d'une bactérie, d'un composant électronique, la durée d'une conversation téléphonique ou le temps qui nous sépare du prochain tremblement de terre peuvent être considérées comme des variables aléatoires de loi exponentielle.

3. La *loi normale* (ou de *Gauss* ou encore *gaussienne*) de paramètres μ et σ^2, notée $\mathcal{N}(\mu, \sigma^2)$, est la loi de densité

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$



Lorsque $\mu = 0$ et $\sigma^2 = 1$, on l'appelle la loi normale *centrée réduite* pour des raisons que nous expliciterons au prochain chapitre.

La distribution normale fut introduite par De Moivre en 1733. Celui-ci l'utilisa pour approximer une variable aléatoire binomiale quand le paramètre n de celle-ci était grand. Ce résultat fut ensuite progressivement généralisé par Laplace et d'autres confrères pour devenir le théorème connu sous le nom de théorème de la limite centrale, qui sera démontré au Chapitre 4. Ce théorème est l'un des plus importants de la théorie des probabilités et prouve que de très nombreux phénomènes aléatoires suivent approximativement une loi normale. On peut citer à titre d'exemple la taille d'un individu choisi au hasard, les composantes de la vitesse d'une molécule de gaz ou l'erreur de mesure d'une quantité physique.

Il est difficile de faire des calculs avec la loi normale car sa densité n'admet pas de primitive explicite. Aussi des tables numériques ont-elles été construites pour permettre aux utilisateurs d'obtenir très rapidement des valeurs numériques. Elles sont disponibles dans la plupart des logiciels et permettent entre autre de représenter sa fonction de répartition.

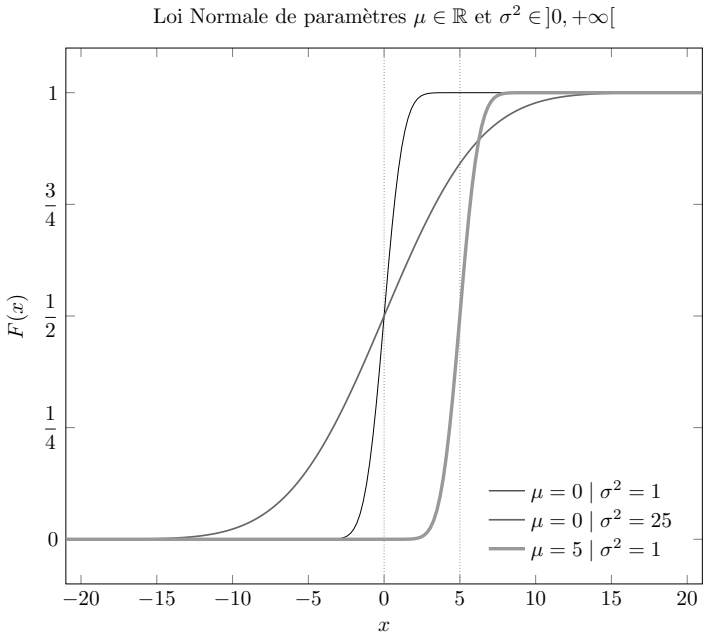


FIGURE 4.1. – fonction de répartition de la loi normale

Nous aurons l'occasion de voir par la suite un grand nombre d'autres exemples de probabilités à densité.

5. Exercices complémentaires

5.1. Indépendance et conditionnement

Question 1 Dans quelles circonstances particulières deux événements A et B tels que $A \cup B$ soit presque sûr sont-ils indépendants ?

Question 2 Soit A, B et C trois événements indépendants **2 à 2**, avec $\mathbb{P}(C) > 0$. Donner une condition nécessaire et suffisante sur A, B et C pour que A et B soient indépendants relativement à la probabilité conditionnelle $\mathbb{P}(\ |C)$, à la place de $\mathbb{P}$.

Question 3 Etablir que deux événements A et B sont indépendants ssi

$$\mathbb{P}(A \cap B)\mathbb{P}(A^c \cap B^c) = \mathbb{P}(A \cap B^c)\mathbb{P}(A^c \cap B)$$

5.2. Problème de Monty Hall

Dans un jeu télévisé, vous êtes confrontés au problème suivant : devant vous se trouvent 3 portes fermées. Derrière l'une d'entre elle se trouve une voiture, derrière chacune des deux autres, une chèvre. Vous désignez au hasard l'une d'entre elle. Le présentateur, qui sait où se trouve la voiture, ouvre alors une porte, qui n'est ni celle que vous avez choisie, ni celle qui cache la voiture. Il vous offre alors la possibilité de réviser votre choix. Que choisissez-vous ?

Calculer la probabilité de remporter la voiture selon les deux stratégies (changer ou non son choix de porte).

5.3. Mesure de Probabilité

Soit $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé et X une variable aléatoire réelle définie sur $(\Omega, \mathcal{A}, \mathbb{P})$ telle que $X \geq 0$ p.s. et $\mathbb{E}(X) = \int_\Omega X(\omega) d\mathbb{P}(\omega) = 1$. (on reviendra sur cette définition dans le chapitre suivant).

On définit $Q : \mathcal{A} \to \mathbb{R}$ par $Q(A) = \mathbb{E}(X\, 1_A) = \int_\Omega X(\omega) 1_A(\omega) d\mathbb{P}(\omega)$ pour $A \in \mathcal{A}$.

Question 1 Montrer que Q est une mesure de probabilité sur $(\Omega, \mathcal{A})$.

Question 2 Montrer que si $\mathbb{P}(A) = 0$, alors $Q(A) = 0$. Donner un exemple montrant que $Q(A) = 0$ n'implique pas en général que $\mathbb{P}(A) = 0$.

Question 3 En notant $\mathbb{E}_Q$, l'espérance par rapport à Q, montrer que $\mathbb{E}_Q(Y) = \int_\Omega Y(\omega) Q(d\omega) = \mathbb{E}_\mathbb{P}(XY)$ pour toute variable aléatoire réelle Y définie sur $(\Omega, \mathcal{A}, \mathbb{P})$ positive ou bornée.

Question 4 Supposons que $\mathbb{P}(X > 0) = 1$.

i) Montrer que $\frac{1}{X}$ est intégrable pour Q.

ii) Soit $R : \mathcal{A} \to \mathbb{R}$ telle que $\forall A \in \mathcal{A}\ R(A) = \mathbb{E}_Q(\frac{1}{X} 1_A)$. Montrer que R est exactement la probabilité $\mathbb{P}$.

iii) Montrer que $Q(A) = 0$ implique $\mathbb{P}(A) = 0$.

5.4. Queues de distributions

Soit une densité f sur $\mathbb{R}$ telle que la fonction $h : x \in \mathbb{R} \mapsto x\, f(x)$ est intégrable. Cette hypothèse sera appelée $(\mathcal{H})$. On note F la fonction de répartition correspondante. Nous allons montrer que [1]

$$\left| \begin{array}{rl} 1 - F(x) & \underset{x \to +\infty}{=} o\left(\frac{1}{x}\right), \quad (1) \\ F(x) & \underset{x \to -\infty}{=} o\left(\frac{1}{x}\right). \quad (2) \end{array} \right.$$

Etude en $+\infty$

1. Vérifier que pour tout $u > 0$,

$$\int_{-\infty}^{+\infty} h(x)\, dx \geq \int_{-\infty}^{u} h(x)\, dx + u\, (1 - F(u)).$$

2. En déduire (1).

Etude en $-\infty$

3. En vous inspirant du raisonnement précédent, montrer (2).

1. Soient $a \in [-\infty, +\infty]$ et f et g deux fonctions définies sur un même voisinage I de a. On dit que f est *négligeable* par rapport à g (ou que g est *prépondérante* par rapport à f) au voisinage de a et on note note $f(x) \underset{x \to a}{=} o(g(x))$ s'il existe une fonction ϵ définie sur I telle que $\epsilon(x) \xrightarrow[x \to a]{} 0$ et $f = \epsilon \times g$.

Interprétation

4. Proposez une interprétation de ce résultat.

Etude de la réciproque Considérons maintenant la fonction de répartition

$$F : x \in \mathbb{R} \mapsto \left| \begin{array}{ll} 1 - \dfrac{e}{x \ln(x)} & \text{si } x \geq e, \\ 0 & \text{si } x < e, \end{array} \right.$$

5. Vérifier que cette fonction possède bien une densité f et l'expliciter.
6. A-t-on les développements asymptotiques (1) et (2) ?
7. La fonction h correspondante est-elle absolument intégrable ?
8. Qu'en concluez-vous ?

Liens entre les développements asymptotiques Soient les fonctions de répartition

$$F : x \in \mathbb{R} \mapsto \left| \begin{array}{ll} 1 - \dfrac{1}{\ln(x)} & \text{si } x \geq e, \\ 0 & \text{sinon,} \end{array} \right.$$

et $G : x \in \mathbb{R} \mapsto 1 - F(-x)$.

9. Que peut-on dire sur les éventuels liens entre (1) et (2) à l'aide de ces deux fonctions ?

5.5. Densité et fonction de répartition d'une loi Normale

On considère la densité d'une loi Normale centrée réduite :

$$f : x \in \mathbb{R} \mapsto \frac{1}{\sqrt{2\,\pi}} \exp\left\{-\frac{x^2}{2}\right\},$$

où $f(-\infty) := \lim_{x \to -\infty} f(x)$ et $f(+\infty) := \lim_{x \to +\infty} f(x)$.

Propriétés générales

1. Faire l'étude de f (domaine, parité, limites aux bornes, dérivabilité, variations, convexité/-concavité).
2. Donner la définition de la fonction de répartition F associée à f. En donner une expression faisant apparaître la *fonction d'erreur* (qui est une fonction spéciale)

$$\text{erf} : x \in \mathbb{R} \mapsto \frac{2}{\sqrt{\pi}} \int_0^x e^{-u^2}\, du.$$

Encadrement de $1 - F(x)$ pour tout $x > 0$ Nous allons maintenant démontrer la propriété suivante : $\forall\, x > 0$

$$\frac{x}{1+x^2}\, f(x) \leq 1 - F(x) \leq \frac{f(x)}{x}.$$

3. En observant que $u \geq x > 0$ implique $\dfrac{u}{x} \geq 1$, montrer l'inégalité de droite.

4. En observant que $u \geq x > 0$ implique $u^{-2} \leq x^{-2}$, montrer que $\forall\, x > 0$,

$$\left(1 + \frac{1}{x^2}\right)(1 - F(x)) \geq \frac{f(x)}{x}.$$

   En déduire l'inégalité de gauche.

Equivalent de $1 - F(x)$ quand $x \to +\infty$.

5. Déduire de l'encadrement prédédent un équivalent de $1 - F(x)$ lorsque $x \to +\infty$.

Remarque – Ratio de Mills.

Pour $x \in \mathbb{R}$, le rapport $\dfrac{1 - F(x)}{f(x)}$ est appelé *ratio de Mills*. Il est beaucoup utilisé en statistique, en particulier pour l'analyse des modèles de régression en présence de biais de sélection.

6. Comparer ce résultat à celui de l'exercice sur les développements limités pour les fonctions de répartition. En particulier, $h : x \in [-\infty, +\infty] \mapsto x\, f(x)$ est-elle intégrable ?

Loi Normale générale. Considérons maintenant la densité plus générale

$$g(x) = \frac{1}{\sqrt{2\,\pi}\,\sigma}\, \exp\left\{-\frac{(x-\mu)^2}{2\,\sigma^2}\right\},$$

où $\mu \in \mathbb{R}$ et $\sigma^2 > 0$. On note G sa fonction de répartition associée.

7. En réécrivant g en fonction de f, déduire des questions précédentes un équivalent de $1 - G(x)$ lorsque $x \to +\infty$.

5.6. Loi de vie et de mort

La durée de vie d'un être vivant ou d'un matériel peut-être assimilée à une variable aléatoire strictement positive T. Dans ce cadre, on peut définir les notions suivantes :

- Loi de vie a priori : il s'agit de la loi du temps T caractérisée par fonction de répartition complémentaire
$$G(t) = \mathbb{P}(T > t)$$
- Loi de survie après $t_0 \geq 0$: il s'agit de la loi du temps $T - t_0$ qu'il lui reste à vivre, sachant qu'il était encore en vie à t_0, de fonction de répartition complémentaire
$$G_{t_0}(t) = \mathbb{P}(T > t + t_0 | T > t_0)$$

On dira que la loi de vie satisfait la propriété de non vieillissement (ou d'absence de mémoire) si la loi de survie et la loi de vie sont égales :

$$\forall t \geq 0 \text{ et } \forall t_0 \geq 0, G_{t_0}(t) = G(t)$$

Question 1 Exprimer la loi de survie à partir de la loi de vie a priori.

Question 2 Montrer qu'une variable aléatoire T satisfait la propriété de non-vieillissement si et seulement si elle est de loi exponentielle.

Question 3 On suppose que T admet une densité continue sur $\mathbb{R}_+^*$. Montrer que l'on peut définir le taux de mort à l'instant t par

$$D(t) = \lim_{\Delta t \to 0} \frac{1}{\Delta t} \mathbb{P}(t < T \leq t + \Delta t | T > t)$$

et exprimer G en fonction de D.

Quelles lois correspondent-elles à D constant ?

---

6. Références

Garnier, Josselin. 2018. *Aléatoire*. http://josselin-garnier.org/wp-content/uploads/2018/03/MAP311_2018.pdf.

Jacod, J., and P. Protter. 2003. *L'essentiel En Théorie Des Probabilités*. Cassini. https://hal.archives-ouvertes.fr/hal-00104956.

Jourdain, Benjamin. 2016. *Probabilités et Statistique*. Ellipses. http://cermics.enpc.fr/~jourdain/probastat/poly.pdf.

Matheron, Georges. 1978. *Estimer et choisir: essai sur la pratique des probabilités*. Fontainebleau, France: Ecole nationale supérieure des mines de Paris. http://cg.ensmp.fr/bibliotheque/public/MATHERON_Ouvrage_00208.pdf.

Tebaldi, Claudia, and Reto Knutti. 2007. "The Use of the Multi-Model Ensemble in Probabilistic Climate Projections." *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences* 365 (1857): 2053–75. https://doi.org/10.1098/rsta.2007.2076.

Deuxième partie

Probabilités II : Moments, vecteurs aléatoires, modélisation statistique

1. Objectifs d'apprentissage

Moments d'une variable aléatoire

- • connaître la définition de l'espérance d'une variable aléatoire
- • connaître l'interprétation de l'espérance
- • connaître les propriétés de base de l'espérance
- • connaître la définition de la variance d'une variable aléatoire
- • savoir que la variance est toujours positive
- • savoir ce que signifie variable centrée-réduite
- • connaître la définition de la covariance
- • savoir que la covariance est une forme bilinéaire
- • connaître et savoir manipuler l'inégalité de Cauchy-Schwarz
- •• connaître les conditions d'existence de l'espérance d'une fonction (mesurable) d'une variable aléatoire
- •• savoir exprimer la probabilité d'un événement de la forme $X \in A$ sous la forme d'une espérance
- •• connaître et savoir calculer les moments des lois usuelles

Vecteurs aléatoires

- • savoir que les composantes d'un vecteur aléatoire sont des variables aléatoires définies sur le même espace de probabilité
- • connaître la définition d'un vecteur aléatoire à densité
- •• connaître les conditions d'existence de l'espérance d'une fonction (mesurable) d'un vecteur aléatoire à densité
- •• savoir calculer les densités marginales d'un vecteur aléatoire à densité
- •• savoir qu'un couple de variables aléatoires à densité n'admet pas nécessairement de densité
- • connaître la définition de l'espérance d'un vecteur aléatoire à densité
- • connaître la définition de la matrice de covariance d'un vecteur aléatoire à densité
- • savoir que la matrice de covariance est semi-définie positive

Variables et vecteurs aléatoires indépendantes

- • connaître la définition de l'indépendance de deux vecteurs/variables aléatoires
- • savoir caractériser l'indépendance de deux vecteurs/variables aléatoires à densité
- •• savoir que si X et Y sont indépendantes, alors $g(X)$ et $h(Y)$ sont aussi indépendantes
- •• savoir que si X et Y sont indépendantes et si $g(X)$ et $h(Y)$ sont intégrables alors $\mathbb{E}(g(X)g(Y)) = \mathbb{E}(g(X))\mathbb{E}(g(Y))$
- • savoir que la covariance de deux variables indépendantes est nulle
- •• savoir que la réciproque est fausse et connaître un contre-exemple

Identification de densité

- •• savoir identifier la densité d'une fonction d'une variable aléatoire par la méthode de la fonction muette
- •• savoir identifier la densité d'une fonction d'un vecteur aléatoire par la méthode de la fonction muette

2. Moments d'une variable aléatoire

La loi de probabilité d'une variable aléatoire définie sur l'espace probabilisé $(\Omega, \mathcal{A}, \mathbb{P})$ va nous permettre de calculer aisément des grandeurs caractéristiques telles que sa valeur moyenne et sa variance (lorsqu'elles existent). Elles sont définies ci-dessous.

Définition – Espérance d'une variable aléatoire réelle.

La variable aléatoire $X : \Omega \to \mathbb{R}$ de loi $\mathbb{P}_X$ est dite *intégrable* si l'intégrale $\int_{\mathbb{R}} |x| d\mathbb{P}_X(x)$ est finie, autrement dit si x est $\mathbb{P}_X$-intégrable. On définit alors son *espérance* par

$$\mathbb{E}(X) = \int_{\mathbb{R}} x d\mathbb{P}_X(x) = \int_{\Omega} X(\omega) d\mathbb{P}(\omega)$$

Si la variable aléatoire X admet une densité f par rapport à la mesure de Lebesgue, elle sera *intégrable* si l'intégrale $\int_{\mathbb{R}} |x| f(x) dx$ est finie, autrement dit si le produit $xf(x)$ est intégrable par rapport à la mesure de Lebesgue. Son *espérance* vaut alors

$$\mathbb{E}(X) = \int_{\mathbb{R}} x f(x) dx$$

Remarque – Interprétation.

$\mathbb{E}(X)$ est un nombre réel qui donne une valeur moyenne résumant la variable aléatoire X.

L'espérance mathématique d'une variable aléatoire est un concept fondamental de la théorie des probabilités. La dénomination d'espérance pour cette quantité fait référence aux problèmes de jeux et d'espérance de gain. Cette terminologie imagée a été introduite par Pascal.

On note $\mathcal{L}^1$ l'ensemble de toutes les variables réelles X intégrables. Les propriétés suivantes découlent directement des propriétés de l'intégrale.

Proposition – Propriétés de base.

- $\mathcal{L}^1$ *est un espace vectoriel et* $\forall X, Y \in \mathcal{L}^1$, $\forall a, b \in \mathbb{R}$
$$\mathbb{E}(aX + bY) = a\mathbb{E}(X) + b\mathbb{E}(Y).$$
- $X \in \mathcal{L}^1 \Leftrightarrow |X| \in \mathcal{L}^1$, *et dans ce cas*
$$|\mathbb{E}(X)| \leq \mathbb{E}(|X|).$$
- *Si* $X \geq 0$ *et* $X \in \mathcal{L}^1$, *alors* $\mathbb{E}(X) \geq 0$.

- *Si $X, Y \in \mathcal{L}^1$ sont telles que $X \leq Y$, alors*

$$\mathbb{E}(X) \leq \mathbb{E}(Y).$$

- *L'espérance d'une variable presque-sûrement constante est égale à cette constante :*

$$Si\ \mathbb{P}(X(\omega) = a) = 1,\ alors\ \mathbb{E}(X) = a.$$

- *Si $\exists b \in \mathbb{R}_+$ tel que $|X| \leq b$, alors $X \in \mathcal{L}^1$ et $\mathbb{E}(X) \leq b$.*

Exercice – Démontrer ces propriétés (•)

Remarque – Rappel : cas discret.

Dans le cas d'une variable aléatoire discrète X à valeurs dans $\mathbb{N}^*$, son espérance est définie par la quantité $\mathbb{E}(X) = \sum_{i \in \mathbb{N}^*} i\mathbb{P}(X = i)$, pourvu que celle-ci soit finie. On voit immédiatement que les propriétés ci-dessus sont également vérifiées.

Outre l'espace $\mathcal{L}^1$, nous pouvons définir l'espace $\mathcal{L}^2$ des variables aléatoires réelles dont le carré X^2 est dans $\mathcal{L}^1$.

Définition – Variance.

La variable aléatoire $X : \Omega \to \mathbb{R}$ de loi $\mathbb{P}_X$ est dite *de carré intégrable* si $\mathbb{E}(X^2) = \int_{\mathbb{R}} x^2 \mathbb{P}_X(dx) = \int_\Omega X^2(\omega)\mathbb{P}(d\omega) < +\infty$. Sa *variance* est définie par

$$\mathbb{V}(X) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

Si la variable aléatoire X admet une densité f par rapport à la mesure de Lebesgue, elle sera *de carré intégrable* si $\mathbb{E}(X^2) = \int_{\mathbb{R}} x^2 f(x)dx$ est définie, autrement dit si le produit $x^2 f(x)$ est intégrable par rapport à la mesure de Lebesgue.

Proposition – Propriétés.

$\mathcal{L}^2$ est un sous-espace vectoriel de $\mathcal{L}^1$, et si $X \in \mathcal{L}^2$,

$$|\mathbb{E}(X)| \leq \mathbb{E}(|X|) \leq \sqrt{\mathbb{E}(X^2)}$$

Démonstration. Soient X et Y deux variables aléatoires réelles de $\mathcal{L}^2$ et $a \in \mathbb{R}$. Comme $(aX + Y)^2 \leq 2a^2X^2 + 2Y^2$, alors $aX + Y \in \mathcal{L}^2$. Ainsi, $\mathcal{L}^2$ est un espace vectoriel.

L'inclusion $\mathcal{L}^2 \subset \mathcal{L}^1$ découle de $|X| \leq 1 + X^2$ et de la proposition précédente (p. 40) (linéarité).

La première inégalité a déjà été vue ci-dessus (p. 40). Pour la seconde, nous pouvons nous limiter au cas où X est positive. Soit alors $a = \mathbb{E}(X)$ et $Y = X - a$. Par linéarité, on a

$$\mathbb{E}(Y^2) = \mathbb{E}(X^2) - 2a\mathbb{E}(X) + a^2 = \mathbb{E}(X^2) - a^2.$$

Et $\mathbb{E}(Y^2) \geq 0$ par le troisième point de la proposition ci-dessus (p. 40). Par conséquent,

$\mathbb{E}(X)^2 = a^2 \leq \mathbb{E}(X^2)$ ce qui est le résultat recherché. ■

Exercice – Approximation par une constante (•) Soit X une v.a. de carré intégrable. Montrer que $\mathbb{E}((X-a)^2)$ atteint son minimum lorsque $a = \mathbb{E}(X)$.

Remarque – La variance est positive.

En vertu de cette proposition (p. 41), $\mathbb{V}(X)$ est **positive** et sa racine carrée σ_X s'appelle l'*écart-type* de X. L'écart-type est une grandeur qui mesure la moyenne (en un certain sens) de l'écart des valeurs de X à sa moyenne, d'où son nom.

On a également

$$\mathbb{V}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

que l'on obtient en développant $(X - \mathbb{E}(X))^2$. Cette manipulation anodine est fort utile dans la pratique. On retiendra que "La variance est égale à la moyenne des carrés moins le carré de la moyenne". On désigne le terme $\mathbb{E}(X^2)$ par l'expression *moment d'ordre deux* tandis que la variance est parfois appelée *moment centré d'ordre deux*.

Remarque – Variable centrée réduite.

D'après ce qui précède, si X est une variable aléatoire de carré intégrable, d'espérance $\mathbb{E}(X)$ et d'écart-type $\sigma_X > 0$, alors la variable aléatoire

$$\frac{X - \mathbb{E}(X)}{\sigma_X}$$

est d'espérance nulle et de variance 1. On dira qu'une telle variable aléatoire est *centrée et réduite*.

On peut remarquer que si X et Y sont dans $\mathcal{L}^2$, la variable aléatoire XY est dans $\mathcal{L}^1$, puisque $|XY| \leq \frac{1}{2}(X^2 + Y^2)$. On peut ainsi définir la *covariance* de deux variables aléatoires :

Définition – Covariance.

Si X et Y sont dans $\mathcal{L}^2$, la variable aléatoire $(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))$ est intégrable. On appelle la *covariance* de X et Y l'espérance de cette variable aléatoire et on la note :

$$\mathrm{Cov}(X,Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))).$$

Le *coefficient de corrélation* des variables aléatoires X et Y est le nombre

$$\rho(X,Y) = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathbb{V}(X)}\sqrt{\mathbb{V}(Y)}}$$

qui est bien défini lorsque $\mathbb{V}(X) > 0$ et $\mathbb{V}(Y) > 0$.

Exercice – Calcul d'une covariance (•) Soit $U \sim \mathcal{U}_{[0,1]}$ et $V = 1 - U$. Calculer $\mathrm{Cov}(U, V)$ et $\rho(U, V)$.

Du fait de la linéarité de l'espérance, on a

$$\mathrm{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

et d'ailleurs, on voit que la formule de calcul de la variance donnée plus haut est un cas particulier de cette formulation car $\mathbb{V}(X) = \mathrm{Cov}(X, X)$. La linéarité de l'espérance nous donne encore pour $a, a', b, b' \in \mathbb{R}$

$$\mathbb{E}((aX + b)(a'Y + b')) = aa'\mathbb{E}(XY) + ab'\mathbb{E}(X) + a'b\mathbb{E}(Y) + bb'$$
$$\mathbb{E}(aX + b)\mathbb{E}(a'Y + b') = aa'\mathbb{E}(X)\mathbb{E}(Y) + ab'\mathbb{E}(X) + a'b\mathbb{E}(Y) + bb'$$

On en déduit que la covariance est une forme bilinéaire sur l'espace vectoriel des variables aléatoires de carré intégrable, et nous avons

$$\mathrm{Cov}(aX + b, a'Y + b') = aa'\mathrm{Cov}(X, Y)$$

En particulier, on a

$$\mathbb{V}(aX) = a^2\mathbb{V}(X)$$

On en déduit que les coefficients de corrélation de X et Y et de $aX + b$ et $a'Y + b'$ sont égaux lorsque $aa' > 0$.

Proposition – Inégalité de Cauchy-Schwarz.

Soit X et Y deux variables aléatoires de carré intégrable, alors on a l'inégalité de Cauchy-Schwarz *:*

$$|\mathbb{E}(XY)| \leq \mathbb{E}(|XY|) \leq \sqrt{\mathbb{E}(X^2)\mathbb{E}(Y^2)}$$

avec égalité si et seulement si X et Y sont presque-sûrement proportionnelles.

Démonstration. La première inégalité a été démontrée plus haut. Pour la seconde, on a $\forall x \in \mathbb{R}$ d'après la linéarité de l'espérance :

$$x^2\mathbb{E}(X^2) + 2x\mathbb{E}(XY) + \mathbb{E}(Y^2) = \mathbb{E}((xX + Y)^2) \geq 0.$$

Mais ceci n'est possible que si ce trinôme en x n'a au plus qu'une seul racine réelle ; son discriminant

$$4\left((\mathbb{E}(XY))^2 - \mathbb{E}(X^2)\mathbb{E}(Y^2)\right)$$

doit donc être négatif ou nul ce qui donne le résultat.

Le discriminant est nul si et seulement si le trinôme admet une racine double x_0 et dans ce cas, $Y(\omega) = -x_0X(\omega)$ pour presque tout ω. ■

Exercice – Coefficient de corrélation (•) Montrer que le coefficient de corrélation de X et Y vérifie

$$-1 \leq \rho(X, Y) \leq 1.$$

Enfin, il peut être intéressant de pouvoir calculer l'espérance d'une fonction mesurable d'une variable aléatoire réelle qui est une variable aléatoire en vertu de la proposition de composition.

Proposition – Espérance de $g(X)$.

Soit X une variable aléatoire réelle de loi $\mathbb{P}_X$, et g une fonction mesurable de $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ dans $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Alors $g(X)$ est $\mathbb{P}_X$ - intégrable si et seulement si l'intégrale

$$\int_{\mathbb{R}} |g(x)| d\mathbb{P}_X(x),$$

est finie et dans ce cas

$$\mathbb{E}(g(X)) = \int_{\mathbb{R}} g(x) d\mathbb{P}_X(x) = \int_{\Omega} g(X(\omega)) d\mathbb{P}(\omega)$$

Si $\mathbb{P}_X$ admet une densité f par rapport à la mesure de Lebesgue, alors $g(X)$ est $\mathbb{P}_X$ - intégrable si et seulement si le produit fg est intégrable par rapport à la mesure de Lebesgue. On a alors :

$$\mathbb{E}(g(X)) = \int_{\mathbb{R}} g(x) d\mathbb{P}_X(x) = \int_{\mathbb{R}} g(x) f(x) dx = \int_{\Omega} g(X(\omega)) d\mathbb{P}(\omega)$$

Démonstration. On rappelle que la loi de probabilité $\mathbb{P}_X$ est définie pour $B \in \mathcal{B}(\mathbb{R})$ par $\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B))$. Par conséquent

$$\mathbb{E}(1_B(X)) = \mathbb{P}(X^{-1}(B)) = \mathbb{P}_X(B) = \int_{\mathbb{R}} 1_B(X) d\mathbb{P}(x).$$

Ainsi, si g est une fonction étagée positive ($g \in \mathcal{E}^+$), on obtient le résultat voulu par linéarité.

Si g est positive, soit $(g_n)_{n \in \mathbb{N}^\star}$ une suite croissante de fonctions étagées positives convergeant simplement vers g. On a alors

$$\begin{aligned}
\mathbb{E}(g(x)) &= \mathbb{E}(\lim_{n\to\infty} g_n(X)) \\
&= \lim_{n\to\infty} \mathbb{E}(g_n(X)) \quad \text{par le théorème de convergence monotone} \\
&= \lim_{n\to\infty} \int_{\mathbb{R}} g_n(x) d\mathbb{P}_X(x) \\
&= \int_{\mathbb{R}} \lim_{n\to\infty} g_n(x) d\mathbb{P}_X(x) \quad \text{par le théorème de convergence monotone} \\
&= \int_{\mathbb{R}} g(x) d\mathbb{P}_X(x).
\end{aligned}$$

Enfin, si g n'est pas positive, on utilise la décomposition $g = g^+ - g^-$ et on déduit le résultat par soustraction. ■

Remarque – Cas particulier.

L'espérance et la variance sont des cas particuliers de ce résultat.

Proposition – Inégalité de Jensen.

Soit X une variable aléatoire réelle intégrable de loi $\mathbb{P}_X$, et soit $g : \mathbb{R} \to \mathbb{R}$ une fonction convexe telle que $g(X)$ soit $\mathbb{P}_X$ - intégrable. On a alors

$$g(\mathbb{E}(X)) \leq \mathbb{E}(g(X)).$$

Démonstration. Puisque g est convexe, pour tout $a \in \mathbb{R}$ il existe $\lambda_a \in \mathbb{R}$ tel que pour tout $x \in \mathbb{R}$ on a

$$g(x) \geq g(a) + \lambda_a (x - a).$$

C'est une conséquence directe de la caractérisation de la convexité par les inégalités des pentes. C'est vrai en particulier pour $x = X(\omega)$, $\omega \in \Omega$, et $a = \mathbb{E}(X)$: pour tout $\omega \in \Omega$,

$$g(X(\omega)) \geq g(\mathbb{E}(X)) + \lambda_{\mathbb{E}(X)} (X(\omega) - \mathbb{E}(X)).$$

En intégrant de chaque côté de l'inégalité, on obtient bien

$$\begin{aligned}\int_\Omega g(X(\omega))\, \mathbb{P}(d\omega) = \mathbb{E}(g(X)) &\geq g(\mathbb{E}(X)) + \lambda_{\mathbb{E}(X)} \left(\int_\Omega X(\omega)\, \mathbb{P}(d\omega) - \mathbb{E}(X) \right) \\ &= g(\mathbb{E}(X)) + \lambda_{\mathbb{E}(X)} (\mathbb{E}(X) - \mathbb{E}(X)) \\ &= g(\mathbb{E}(X)).\end{aligned}$$

■

2.1. Exemples de loi à densité

Nous donnons ici quelques exemples de densités de probabilité. Nous reprenons en particulier les trois exemples de densités donnés au premier cours :

2.1.1. *Loi uniforme*

sur $[a, b]$, où $a < b$ et on note $X \sim \mathcal{U}_{[a,b]}$ si X est de densité

$$f(x) = \frac{1}{b-a} 1_{[a,b]}(x).$$

Exercice – Moments d'une variable aléatoire de loi uniforme sur $[a, b]$ (•) Soit $X \sim \mathcal{U}_{[a,b]}$. Montrer que son espérance vaut

$$\mathbb{E}(X) = \int_a^b \frac{x}{b-a} dx = \frac{a+b}{2}$$

et que sa variance vaut

$$\mathbb{V}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 = \frac{(b-a)^2}{12}.$$

2.1.2. *Loi exponentielle*

de paramètre $\theta > 0$ et on note $X \sim \mathcal{E}(\theta)$ si X est de densité

$$f(x) = \theta e^{-\theta x} 1_{\{x>0\}}(x).$$

Exercice – Moments d'une v.a. exponentielle (•) Montrer que son espérance et sa variance valent

$$\mathbb{E}(X) = \frac{1}{\theta} \text{ et } \mathbb{V}(X) = \frac{1}{\theta^2}$$

2.1.3. *Loi gamma*

On rappelle tout d'abord que la fonction gamma est définie pour $\alpha \in]0, +\infty[$ par

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx.$$

En intégrant par partie, on obtient la relation $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$, et on a $\Gamma(1) = 1$. On en déduit que $\Gamma(n) = (n-1)!$.

Une variable aléatoire X suit une loi gamma de paramètre d'échelle θ et d'indice α et on note $X \sim \Gamma(\alpha, \theta)$, si sa loi admet la densité

$$f(x) = \frac{1}{\Gamma(\alpha)} \theta^\alpha x^{\alpha-1} e^{-\theta x}.$$

Exercice – Moments d'une v.a. de loi gamma (•) Soit $X \sim \Gamma(\alpha, \theta)$. Montrer que son espérance et sa variance valent :

$$\mathbb{E}(X) = \frac{\alpha}{\theta} \text{ et } \mathbb{V}(X) = \frac{\alpha}{\theta^2}.$$

On remarquera que $\Gamma(1, \theta)$ est la loi exponentielle de paramètre θ.

Lorsque α est entier, la loi gamma permet de modéliser le temps d'attente avant la n-ième occurence d'événements indépendants de loi exponentielle de paramètre θ.

2.1.4. *Loi normale*

de paramètres μ et σ^2 et on note $X \sim \mathcal{N}(\mu, \sigma^2)$ si X est de densité

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Son espérance et sa variance valent

$$\mathbb{E}(X) = \mu \text{ et } \mathbb{V}(X) = \sigma^2$$

Exercice – Moments d'une v.a. gaussienne (•) Après avoir vérifié que f est bien une densité, calculer l'espérance et la variance de $X \sim \mathcal{N}(\mu, \sigma^2)$

Remarque – Estimation statistique.

Dans les exemples ci-dessus, on peut remarquer que les densités sont paramétrées par des nombres réels qui sont liés directement aux valeurs de l'espérance et de la variance de la variable. C'est très utile en statistique où l'on cherchera à estimer la valeur de ces paramètres à partir des observations disponibles. Dans le cas de la loi normale, la moyenne et la variance (empiriques) des échantillons fourniront ainsi directement des estimateurs des paramètres.

Il existe des variables aléatoires qui n'ont pas d'espérance, comme le montre l'exercice suivant.

Exercice – *Loi de Cauchy* (••) Un gyrophare envoie un flash lumineux dans une direction aléatoire uniforme d'angle θ. On cherche la distribution de l'abscisse X du point d'impact du rayon lumineux sur un écran plan infini situé à distance 1 du gyrophare. Donner la densité de X. Calculer son espérance.

3. Rappels sur les intégrales multiples

Dans la suite, nous aurons besoin de quelques résultats à propos des intégrales multiples que nous reformulons ici dans le contexte des probabilités.

Théorème – Théorème de Fubini (pour les probabilités).

Soient $\mathbb{P}_X$ et $\mathbb{P}_Y$ deux probabilités définies respectivement sur $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ et $(\mathbb{R}^m, \mathcal{B}(\mathbb{R}^m))$.

1. *Soient $A \in \mathcal{B}(\mathbb{R}^n)$ et $B \in \mathcal{B}(\mathbb{R}^m)$, alors*

$$\mathbb{P}(A \times B) = \mathbb{P}_X(A)\mathbb{P}_Y(B)$$

   définit de manière unique une probabilité sur $(\mathbb{R}^{n+m}, \mathcal{B}(\mathbb{R}^{n+m}))$ (que l'on note aussi $\mathbb{P}_X \otimes \mathbb{P}_Y$).
2. *Soit f une fonction $\mathcal{B}(\mathbb{R}^{n+m})$-mesurable positive ou $\mathbb{P}_X \otimes \mathbb{P}_Y$-intégrable, alors la fonction $x \mapsto \int f(x,y)\mathbb{P}_Y(dy)$ est $\mathcal{B}(\mathbb{R}^n)$-mesurable, la fonction $y \mapsto \int f(x,y)\mathbb{P}_X(dx)$ est $\mathcal{B}(\mathbb{R}^m)$-mesurable et*

$$\int f d\mathbb{P}_X \otimes \mathbb{P}_Y = \int \left(\int f(x,y)\mathbb{P}_Y(dy) \right) \mathbb{P}_X(dx) = \int \left(\int f(x,y)\mathbb{P}_X(dx) \right) \mathbb{P}_Y(dy)$$

Exercice – Calcul de l'aire d'un triangle (•) Considérons le triangle

$$T = \{(x,y) \in \mathbb{R}^2 \mid x \geq 0,\ y \geq 0 \text{ et } x + y \leq 1\}.$$

En supposant l'intégrale ci-dessous bien définie, calculer :

$$a(T) = \int_{\mathbb{R}^2} 1_T(x,y)\, dxdy.$$

Exercice – Contre-exemple (••) Comparer les valeurs des intégrales multiples

$$\int_0^1 \left[\int_0^1 \frac{x^2 - y^2}{(x^2+y^2)^2}\, dx \right] dy \quad \text{et} \quad \int_0^1 \left[\int_0^1 \frac{x^2 - y^2}{(x^2+y^2)^2}\, dy \right] dx,$$

puis expliquer le résultat. Indication : on remarquera que

$$\frac{x^2 - y^2}{(x^2+y^2)^2} = \frac{\partial}{\partial x}\left(-\frac{x}{x^2+y^2} \right)$$

Pour pouvoir appliquer le théorème de Fubini, il faut savoir a priori que la fonction est intégrable et pas seulement que ses intégrales multiples sont bien définies (cf. "Contre-exemple" ci-dessus (p. 47)). Si la fonction est à valeurs positives toutefois, l'examen de ses intégrales multiples permet de s'assurer de l'intégrabilité ; c'est le théorème de Fubini-Tonelli vu dans le cours de calcul intégral.

Autrement dit, en pratique, on appliquera Fubini-Tonelli à la valeur absolue de la fonction pour vérifier que celle-ci est intégrable, puis Fubini, s'il est applicable, pour effectuer le calcul de l'intégrale.

Théorème – Changement de variables.

Soient D_1 et D_2 des ouverts de $\mathbb{R}^n$ et $h : D_1 \to D_2$ un C^1-difféomorphisme de D_1 sur D_2, c'est-à-dire une fonction continûment différentiable et bijective dont l'inverse $h^{-1} : D_2 \to D_1$ est également continûment différentiable. La matrice jacobienne associée à la différentielle de h étant notée J_h, la fonction $f : D_2 \to \mathbb{R}$ est intégrable si et seulement si la fonction $(f \circ h)|\det J_h| : D_1 \to \mathbb{R}$ est intégrable et dans ce cas,

$$\int_{D_2} f(y)\,dy = \int_{D_1} f(h(x))|\det J_h(x)|\,dx.$$

[figure manquante : changement-de-variables.svg.pdf]

FIGURE 3.1. – Changement de variables

Exercice – Homothétie (•) Soit $f : \mathbb{R}^n \to \mathbb{R}$ une fonction intégrable. Montrer que pour tout coefficient $\alpha > 0$, l'intégrale

$$\int_{\mathbb{R}^n} f(\alpha x)dx$$

est bien définie et la calculer en fonction de l'intégrale de f sur $\mathbb{R}^n$.

Exercice – Volume et translation (•) Montrer que si A est mesurable et de volume fini dans $\mathbb{R}^3$ l'image de A par une translation est également mesurable et de même volume.

Exercice – Coordonnées polaires (••) Soit

$$C = \{(x, y) \in \mathbb{R}^2 \mid y \neq 0 \text{ ou } x > 0\} \text{ et } P = \{(r, \theta) \in \mathbb{R}^2 \mid r > 0 \text{ et } -\pi < \theta < \pi\}.$$

On note h la fonction de P dans C définie par $h(r, \theta) = (r\cos\theta, r\sin\theta)$. Montrer que pour toute fonction $f : C \to \mathbb{R}$ intégrable, si l'on pose $g(r, \theta) = f(x, y)$ où $(x, y) = h(r, \theta)$, alors

$$\int_C f(x, y)\,d(x, y) = \int_P g(r, \theta)r\,d(r, \theta).$$

Exercice – Absence du déterminant jacobien (••) Supposons D_1, D_2, h et f conformes aux hypothèses du théorème de changement de variables (p. 48). On suppose de plus que $f \circ h$ est intégrable sur D_1. Exprimer l'intégrale

$$\int_{D_1} f(h(x))\,dx$$

comme une intégrale sur D_2.

4. Vecteurs aléatoires

Nous allons généraliser ici la notion de variable aléatoire en considérant qu'elle peut prendre ses valeurs dans $\mathbb{R}^n$. Les vecteurs aléatoires se rencontrent naturellement lorsqu'on s'intéresse à plusieurs quantités conjointement, par exemple dans le cas de la météo, la température, la pluviométrie et la vitesse et la direction du vent.

4.1. Définitions

Une variable aléatoire X à valeurs dans $\mathbb{R}^n$ (ou vecteur aléatoire) est simplement une collection de n variables réelles définies sur le même espace probabilisé $(\Omega, \mathcal{A}, \mathbb{P})$, qui sont les *composantes* de X. On écrit $X = (X_1, \dots, X_n)$.

De même qu'en dimension 1, la loi de X est caractérisée par la fonction de répartition multi-dimensionnelle $F : \mathbb{R}^n \to \mathbb{R}$ définie par

$$F(x_1, \dots, x_n) = \mathbb{P}_X(X_1 \leq x_1, \dots, X_n \leq x_n)$$

Cependant, caractériser les fonctions de répartition sur $\mathbb{R}^n$ est délicat, de sorte que cette notion est rarement utilisée. Nous allons plus particulièrement nous intéresser aux vecteurs aléatoires à densité. On gardera tout de même à l'esprit que les lois de probabilités définies sur $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ n'admettent pas toutes une densité !

Définition – Vecteur aléatoire à densité.

On dit que X admet la densité f si la fonction réelle f sur $\mathbb{R}^n$ est positive, intégrable et vérifie

$$\int_{\mathbb{R}^n} f(x)dx = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f(x_1, \dots, x_n)dx_1 \dots dx_n = 1$$

et si

$$\mathbb{P}_X(X_1 \leq x_1, \dots, X_n \leq x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f(x_1, \dots, x_n)dx_1 \dots dx_n.$$

De la même manière que dans le cas unidimensionnel (p. 44), on a :

Proposition – Fonction d'un vecteur aléatoire.

Soit X un vecteur aléatoire de densité f, et soit g une fonction de $\mathbb{R}^n$ dans $\mathbb{R}$, mesurable. On a alors $g(X) \in \mathcal{L}^1$ si et seulement si

$$\int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} |g(x_1, \dots, x_n)| f(x_1, \dots, x_n)dx_1 \dots dx_n,$$

est finie et dans ce cas, on a

$$\mathbb{E}(g(X)) = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} g(x_1, \dots, x_n) f(x_1, \dots, x_n)dx_1 \dots dx_n.$$

Pour revenir à la densité d'une composante d'un vecteur aléatoire, on intègre par rapport aux autres variables. On le présente ici dans le cas d'un couple $Z = (X, Y)$ de variables aléatoires. On généralise aisément à une dimension supérieure.

Proposition – Densités marginales.

Supposons que Z admette une densité f. Alors X et Y admettent les densités f_X et f_Y données par

$$f_X(x) = \int_{\mathbb{R}} f(x, y)dy, \quad f_Y(y) = \int_{\mathbb{R}} f(x, y)dx.$$

Les fonctions f_X et f_Y s'appellent les densités marginales *de f.*

Démonstration. Pour tout $x \in \mathbb{R}$, on a par définition

$$\mathbb{P}(X \leq x) = \mathbb{P}(Z \in]-\infty, x] \times \mathbb{R}) = \mathbb{E}(1_{]-\infty,x]\times\mathbb{R}}(Z)) = \int_{-\infty}^{x} du \left(\int_{\mathbb{R}} f(u,v)dv \right),$$

où l'on a utilisé le théorème de Fubini-Tonelli pour $1_{]-\infty,x]\times\mathbb{R}}(u,v)f(u,v)$ qui est bien positive. Donc si f_X est définie par $f_X(x) = \int_{\mathbb{R}} f(x,y)dy$, on obtient que $\mathbb{P}(X \leq x) = \int_{-\infty}^{x} f_X(u)du$, ce qui montre que f_X est la densité de X. Le raisonnement est analogue pour Y. ■

Remarque – Réciproque ?.

La réciproque de cette proposition est fausse en revanche : les variables aléatoires X et Y peuvent avoir des densités sans que le couple $Z = (X, Y)$ en ait une.

Supposons par exemple que $X = Y$. Si $\Delta = \{(x, x); x \in \mathbb{R}\}$ est la diagonale de $\mathbb{R}^2$, nous avons évidemment $\mathbb{P}_Z(\Delta) = 1$ mais si la proposition précédente (p. 49) était valide pour $\mathbb{P}_Z$, on aurait $\mathbb{P}_Z(\Delta) = \mathbb{E}(1_\Delta) = \int_{\mathbb{R}^2} 1_\Delta f_Z(z)dz = 0$ car Δ est de volume nul dans $\mathbb{R}^2$.

En particulier, il faut faire attention au fait que dans le cas général, la densité d'un couple de variables aléatoires n'est pas le produit des densités.

Exercice – Lancer de fléchette (••) On lance une fléchette sur une cible circulaire de rayon unité. Le joueur est suffisamment maladroit pour que le point M d'impact de la fléchette soit supposé uniformément distribué sur la cible (On décide de n'observer que les lancés qui atteignent la cible). Exprimer la densité du couple formé par les coordonnées cartésiennes (X, Y) de M puis leurs densités marginales.

4.2. Moments d'un vecteur aléatoire

Définition – Vecteur espérance et covariance.

Si les composantes X_i du vecteur aléatoire $X = (X_1, \ldots, X_n)$ sont intégrables, on peut définir le *vecteur espérance*

$$\mathbb{E}(X) = (\mathbb{E}(X_1), \ldots, \mathbb{E}(X_n))$$

Si les composantes X_i du vecteur aléatoire $X = (X_1, \ldots, X_n)$ sont de carré intégrable, la *matrice de covariance* de X est la matrice $C_X = (c_{i,j})_{1\leq i\leq n, 1\leq j\leq n}$ de taille $n \times n$ et dont les éléments valent

$$c_{i,j} = \mathrm{Cov}(X_i, X_j)$$

Proposition – Matrice de covariance.

La matrice de covariance est symétrique non-négative (ou encore semi-définie positive).

Démonstration. La symétrie est évidente. Non-négative signifie que pour tous réels $a_1, \dots, a_n$, on a $\sum_{i=1}^n \sum_{j=1}^n a_i a_j c_{i,j} \geq 0$. Un calcul simple montre que

$$\sum_{i=1}^{n} \sum_{j=1}^{n} a_i a_j c_{i,j} = \mathbb{V}(\sum_{i=1}^{n} a_i X_i) \geq 0.$$

■

Exemple – Vecteur Gaussien n-dimensionel.

Un exemple important de vecteurs aléatoires est celui des vecteurs gaussiens, que nous étudierons plus en détail au chapitre suivant. Soient $m \in \mathbb{R}^n$ et C une matrice symétrique définie positive (c'est-à-dire telle que pour tout $x \in \mathbb{R}^n$ non identiquement nul $x^t C x > 0$ où ^{t} désigne la transposée). Le vecteur $X \in \mathbb{R}^n$ est un vecteur aléatoire gaussien d'espérance m et de matrice de covariance C si sa densité s'écrit

$$f(x) = \frac{1}{(2\pi)^{n/2}\sqrt{\det(C)}} \exp(-\frac{1}{2}(x-m)^t C^{-1}(x-m))$$

On a alors $\mathbb{E}(X) = m$ et $C_X = C$.

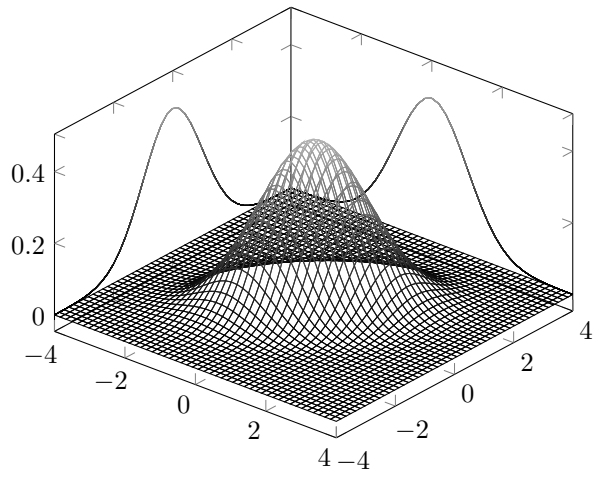


FIGURE 4.1. – Densité de probabilité de la loi normale bivariée centrée, réduite, de coefficient de corrélation 1/2

5. Variables aléatoires indépendantes

Lorsqu'on modélise plusieurs variables conjointement, une hypothèse importante est celle de l'indépendance. Ce caractère traduit l'absence de lien de causalité entre les variables. Par exemple, on fait naturellement l'hypothèse d'indépendance lorsque l'on considère une répétition d'une même expérience dans les mêmes conditions.

Dans ce paragraphe, on considère un couple (X, Y) de vecteurs aléatoires respectivement à valeurs dans $\mathbb{R}^m$ et $\mathbb{R}^n$. Les résultats s'étendent sans peine à une famille finie quelconque.

On peut se ramener aux évènements pour caractériser l'indépendance de deux vecteurs aléatoires. En effet, considérons le vecteur aléatoire $Z = (X, Y)$, A et B deux ensembles dans $\mathcal{B}(\mathbb{R}^m)$ et $\mathcal{B}(\mathbb{R}^n)$. On a vu que les évènements $X \in A$ et $Y \in B$ sont indépendants si et seulement si $\mathbb{P}_Z(X \in A, Y \in B) = \mathbb{P}(X^{-1}(A) \cap Y^{-1}(B)) = \mathbb{P}(X^{-1}(A))\mathbb{P}(Y^{-1}(B)) = \mathbb{P}_X(X \in A)\mathbb{P}_Y(Y \in B)$. Pour que deux vecteurs aléatoires soient indépendants, on va donc demander que ceci soit valable quels que soient A et B.

Définition – Vecteurs aléatoires indépendants.

Les vecteurs aléatoires X et Y sont *indépendants* si pour tous ensembles A et B des tribus correspondantes,

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B)$$

En termes de mesures de probabilité, cette égalité s'écrit

$$\mathbb{P}_{(X,Y)}(A \times B) = \mathbb{P}_X(A)\mathbb{P}_Y(B) = (\mathbb{P}_X \otimes \mathbb{P}_Y)(A \times B).$$

Autrement dit, X et Y sont indépendantes si et seulement si la mesure de probabilité du couple (X, Y) est la mesure produit $P_X \otimes P_Y$ dont l'existence et l'unicité sont garanties par le théorème de Fubini (p. 47).

Cette définition se traduit dans le cas à densité dans la proposition suivante que l'on énonce sans perte de généralité pour un couple de variables aléatoires.

Proposition – Caractérisation de l'indépendance – cas à densité.

Soient X et Y deux variables aléatoires réelles de densités f_X et f_Y. X et Y sont indépendantes si et seulement si le couple $Z = (X, Y)$ a pour densité (sur $\mathbb{R}^2$) :

$$f_Z(x, y) = f_X(x)f_Y(y).$$

Démonstration. S'il y a indépendance, la définition (p. 52) implique

$$P(X \leq x, Y \leq y) = P(X \leq x)\mathbb{P}(Y \leq y) = \int_{-\infty}^{x} f_X(u)du \int_{-\infty}^{y} f_Y(v)dv$$

ce qui montre que $\mathbb{P}_Z$ vérifie la définition d'un vecteur aléatoire à densité (p. 49) avec $f_Z = f_X f_Y$.

Inversement, si $f_Z = f_X f_Y$, on a pour tous A, B de $\mathcal{B}(\mathbb{R})$

$$\mathbb{P}(X \in A, Y \in B) = \int_A \int_B f_X(x)f_Y(y)dxdy = \mathbb{P}(X \in A)\mathbb{P}(Y \in B)$$

où on a utilisé le théorème de Fubini-Tonelli. ■

Exercice – Lancer de fléchette (suite) (•) Les coordonnées cartésiennes (X, Y) de M sont elles indépendantes ?

Considérons maintenant deux fonctions mesurables g et h définies sur $\mathbb{R}^m$ et $\mathbb{R}^n$.

Proposition – Fonctions de vecteurs aléatoires indépendants.

Avec les notations précédentes, si X et Y sont indépendantes de densités respectives f_X et f_Y, les variables aléatoires $g(X)$ et $h(Y)$ sont aussi indépendantes. Si de plus $g(X)$ et $h(Y)$ sont

intégrables, alors le produit $g(X)h(Y)$ est aussi intégrable, et on a

$$\mathbb{E}(g(X)h(Y)) = \mathbb{E}(g(X))\mathbb{E}(h(Y))$$

Démonstration. La première assertion est évidente par définition de l'indépendance. Par ailleurs, si $g(X)$ et $h(Y)$ sont intégrables, en notant $f_{(X,Y)}$ la densité du couple (X, Y), et en utilisant le théorème de Fubini, on a

$$\begin{aligned}
\mathbb{E}(g(X)h(Y)) &= \int_{\mathbb{R}^{m+n}} g(x)h(y)f_{(X,Y)}(x,y)dxdy \\
&= \int_{\mathbb{R}^m}\int_{\mathbb{R}^n} g(x)h(y)f_X(x)f_Y(y)dxdy \\
&= \left(\int_{\mathbb{R}^m} g(x)f_X(x)dx\right)\left(\int_{\mathbb{R}^n} h(y)f_Y(y)dy\right) \\
&= \mathbb{E}(g(X))\mathbb{E}(h(Y))
\end{aligned}$$

■

Remarque – Cas général.

Ce résultat est encore valable dans le cas général (sans densité). Il suffit de remplacer $f_{(X,Y)}(x,y)dxdy$ par $d\mathbb{P}_{X,Y}(x,y) = d\mathbb{P}_X(x)d\mathbb{P}_Y(y)$ dans la démonstration précédente.

On déduit de ce résultat et de la définition de la covariance (p. 42) que :

Corollaire – Covariance de variables aléatoires indépendantes.

Si les variables aléatoires réelles X et Y sont indépendantes et de carré intégrable, alors $Cov(X, Y) = 0$ et $\rho(X, Y) = 0$.

Exercice – Démonstration (•) Démontrer ce résultat.

5.0.1. Remarque

Attention, la réciproque est fausse. Par exemple, si $X \sim \mathcal{U}_{[-1,1]}$ et $Y = X^2$. X et Y ne sont clairement pas indépendantes mais on a

$$\mathrm{Cov}(X, Y) = \mathrm{Cov}(X, X^2) = \mathbb{E}(X^3) - \mathbb{E}(X)\mathbb{E}(X^2) = 0$$

6. Identification de densité

Un problème important est le suivant. Soit X une variable aléatoire réelle, admettant la densité f_X. Soit g une fonction mesurable, de sorte que $Y = g(X)$ est aussi une variable aléatoire. Est-ce que Y admet une densité, et si oui, comment la calculer ?

On peut déjà remarquer que cette densité n'existe pas toujours. Si par exemple $g(x) = a$ pour tout x, la loi de Y est la mesure de Dirac en a, qui n'a pas de densité par rapport à la mesure de

Lebesgue.

Pour résoudre ce problème, l'idée consiste à essayer de mettre $E(h(Y)) = E(h \circ g(X))$ sous la forme $\int h(y) f_Y(y) dy$ pour une fonction convenable f_Y, et une classe de fonctions h suffisamment grande. La fonction f_Y sera alors la densité cherchée.

La proposition qui assure que $g(X)$ est intégrable pour une variable aléatoire réelle X (p. 44) implique

$$\mathbb{E}(h(Y)) = \mathbb{E}(h \circ g(X)) = \int_{\mathbb{R}} h \circ g(x) f_X(x) dx$$

et on fait le changement de variable $y = g(x)$ dans cette intégrale. Cela nécessite que g soit dérivable et bijective "par morceaux", et il faut faire très attention aux domaines où g est croissante ou décroissante. Puisque la fonction h est arbitraire, on appelle couramment cette technique la *méthode de la fonction muette*. Cette approche résulte en fait de la proposition suivante :

Proposition – Méthode de la fonction muette.

Si il existe une fonction f positive telle que pour toute fonction mesurable h telle que $h(x)f(x)$ soit intégrable,

$$\mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) f(x) dx$$

alors la loi de X admet la densité f par rapport à la mesure de Lebesgue.

Démonstration. Supposons qu'un tel f existe. Soit $B \in \mathcal{B}(\mathbb{R})$, alors 1_B est mesurable. En particulier, si $B =]-\infty, x]$, $x \in \mathbb{R}$, on a

$$\mathbb{P}(X \leq x) = \mathbb{P}(X \in B) = \mathbb{P}_X(B) = \mathbb{E}(1_B(X)) = \int_{-\infty}^{x} f(y) dy$$

Par ailleurs, prenant $B = \mathbb{R}$, on a $1 = \mathbb{P}(X \in \mathbb{R}) = \int_{\mathbb{R}} f(y) dy$. Par conséquent, $\mathbb{P}_X$ admet la densité f. ■

Nous donnons ici quelques exemples d'application de cette méthode :

- Soit $Y = aX + b$, où a et b sont des constantes. Si $a = 0$, alors $Y = b$ et la loi de Y est la masse de Dirac en b (sans densité). Si $a \neq 0$, on fait le changement de variable $y = ax + b$, ce qui donne

  $$\mathbb{E}(h(Y)) = \int_{\mathbb{R}} h(ax+b) f_X(x) dx = \int_{\mathbb{R}} h(y) f_X(\frac{y-b}{a}) \frac{1}{|a|} dy$$

  Donc

  $$f_Y(y) = f_X(\frac{y-b}{a}) \frac{1}{|a|}$$

- Soit $Y = X^2$. La fonction g est décroissante sur $\mathbb{R}_-$ et croissante sur $\mathbb{R}_+$. Le changement de variable $y = x^2$ donne alors

  $$\begin{aligned}\mathbb{E}(h(Y)) &= \int_{-\infty}^{0} h(x^2) f_X(x) dx + \int_{0}^{+\infty} h(x^2) f_X(x) dx \\ &= \int_{0}^{+\infty} h(y) f_X(-\sqrt{y}) \frac{1}{2\sqrt{y}} dy + \int_{0}^{+\infty} h(y) f_X(\sqrt{y}) \frac{1}{2\sqrt{y}} dy\end{aligned}$$

et on en déduit

$$f_Y(y) = (f_X(-\sqrt{y}) + f_X(\sqrt{y}))\frac{1}{2\sqrt{y}}1_{]0,+\infty[}$$

Dans le cas des vecteurs aléatoires, l'idée est la même. Soit $X = (X_1, \ldots, X_n)$, un vecteur aléatoire de densité f_X sur $\mathbb{R}^n$, g une fonction de $\mathbb{R}^n$ dans $\mathbb{R}^m$ et $Y = g(X)$. Plusieurs cas sont à considérer :

1. $m > n$, le vecteur Y n'admet pas de densité.
2. $m = n$, on utilise comme dans le cas unidimensionel le changement de variable $y = g(x)$ dans

   $$\mathbb{E}(h(Y)) = \mathbb{E}(h \circ g(X)) = \int_{\mathbb{R}^n} h \circ g(x) f_X(x) dx$$

   Supposons d'abord que g soit une bijection continûment différentiable de A dans B, ouverts de $\mathbb{R}^n$. Sous l'hypothèse que $h \circ g(x) f_X(x)$ soit intégrable, le théorème de changement de variable nous assure :

   $$\int_A h \circ g(x) f_X(x) dx = \int_B h(y) f_X \circ g^{-1}(y) \frac{1}{|\det J_g(g^{-1}(y))|} dy,$$

   où J_g désigne la matrice de Jacobi associée à la différentielle de g. Dans le cas où $f_X(x) = 0$ en dehors de A, on obtient que Y admet la densité

   $$f_Y(y) = 1_B(y) f_X \circ g^{-1}(y) \frac{1}{|\det J_g(g^{-1}(y))|}.$$

   Lorsque g est simplement continûment différentiable, il existe souvent une partition finie $(A_i)_{1 \leq i \leq n}$ de l'ensemble $\{x; f(x) > 0\}$, telle que g soit bijective sur chaque A_i. On note alors $B_i = g(A_i)$ l'image de A_i par g. On découpe alors l'intégrale selon les A_i, on applique la formule précédente à chaque morceau et on somme pour obtenir :

   $$f_Y(y) = \sum_{i=1}^{n} 1_{B_i}(y) f_X \circ g^{-1}(y) \frac{1}{|\det J_g(g^{-1}(y))|},$$

   où g^{-1} est bien définie sur chaque B_i comme image réciproque de la restriction de g à A_i.
3. $m < n$, on commence par "compléter" Y, en essayant de construire une application g' de $\mathbb{R}^n$ dans $\mathbb{R}^n$ dont les m premières composantes coïncident avec les composantes de g et pour laquelle on peut appliquer l'une des deux formules précédentes. On obtient ainsi la densité f'_Y de $Y' = g'(X)$ puis on obtient la densité de Y en calculant sa loi marginale :

   $$f_Y(y_1, \ldots, y_m) = \int_{\mathbb{R}^{n-m}} f_{Y'}(y_1, \ldots, y_m, y_{m+1}, \ldots y_n) dy_{m+1} \ldots dy_n.$$

Exemple – Coordonnées polaires.

Soit $X = (U, V)$ un vecteur aléatoire de $\mathbb{R}^2$, et $Y = (R, \Theta)$ ses coordonnées polaires. La transformation g est un difféomorphisme de $A = \mathbb{R}^2 \setminus \{0\}$ dans $B =]0, +\infty[\times]0, 2\pi]$, et son inverse g^{-1} s'écrit : $u = r\cos\theta$, $v = r\sin\theta$. Le Jacobien de g^{-1} au point (r, θ) vaut r, donc le point 2. ci-dessus entraîne que

$$f_Y(r, \theta) = r f_X(r\cos\theta, r\sin\theta) 1_B(r, \theta)$$

Par exemple, si U et V sont indépendantes et de loi $\mathcal{N}(0, 1)$, on a $f_X(u, v) = \frac{1}{2\pi} \exp\left(-\frac{u^2+v^2}{2}\right)$

et donc

$$f_Y(r,\theta) = \frac{1}{2\pi} r \exp\left(-\frac{r^2}{2}\right) 1_{]0,+\infty[}(r) 1_{]0,2\pi]}(\theta).$$

En particulier, on remarque que R et Θ sont indépendantes de densités respectives $r\exp\left(-\frac{r^2}{2}\right)1_{]0,+\infty[}(r)$ et $1_{]0,2\pi]}(\theta)$.

Exercice – Lancer de fléchette (fin) (•) Donner la densité du couple (R,Θ) des coordonnées polaires de M. Sont-elles indépendantes ?

Exemple – Somme de deux variables aléatoires indépendantes.

Soient U et V indépendantes et admettant les densités f_U et f_V, on cherche la densité de la somme $Z = U + V$. On commence par compléter Z en le couple $T = (U, Z)$ (par exemple), correspondant à la bijection $g(u,v) = (u, u+v)$ sur $\mathbb{R}^2$ dont le jacobien est 1 et d'inverse $g^{-1}(x,y) = (x, x-y)$. Appliquant le point 3. ci-dessus, on obtient :

$$f_Z(z) = \int_{\mathbb{R}} f_U(u) f_V(z-u) du = \int_{\mathbb{R}} f_U(z-v) f_V(v) dv.$$

La fonction f_Z est appelée *le produit de convolution* des des fonctions f_U et f_V.

Exercice – Loi bêta (•••) Soit $X = (U,V)$ un vecteur aléatoire de $\mathbb{R}^2$, avec U et V indépendantes de lois $\Gamma(\alpha,\theta)$ et $\Gamma(\beta,\theta)$. Identifier la densité de $Y = \frac{U}{U+V}$, puis de $Z = U + V$.

7. Modélisation statistique

On a vu un certain nombre d'exemples de lois de probabilité à densité. Celles-ci font intervenir des paramètres qui permettent d'ajuster la forme de la densité aux données observées. Par exemple, la loi normale fait intervenir deux paramètres : l'espérance et la variance. Dans cette section, nous formalisons l'approche statistique qui consiste à choisir une loi de probabilité pour modéliser un phénomène aléatoire, puis à estimer les paramètres de cette loi à partir d'observations.

La première hypothèse que nous faisons est que le phénomène étudié peut être modélisé par une variable aléatoire X de densité f inconnue. La première étape de la modélisation consiste à choisir une famille de densités $(f_\theta)_{\theta\in\Theta}$, où Θ est un ensemble de paramètres. Par exemple, pour la loi normale, on peut choisir $\Theta = \mathbb{R}\times\mathbb{R}_+^*$ et $f_{(m,\sigma)}$ la densité de la loi $\mathcal{N}(m,\sigma^2)$.

La seconde étape consiste à estimer le paramètre θ de manière à ce que la densité f_θ soit la plus proche possible de la densité f inconnue. On a donc besoin d'une notion de proximité entre deux densités. Plusieurs choix sont possibles, mais le plus courant est celui de la divergence de Kullback-Leibler.

Définition – Divergence de Kullback-Leibler.

Soient f et g deux densités de probabilité sur $\mathbb{R}$, telles que $g(x) > 0$ pour tout x tel que

$f(x) > 0$. La *divergence de Kullback-Leibler* de g par rapport à f est définie par

$$D_{KL}(f||g) = \int f(x) \log\left(\frac{f(x)}{g(x)}\right) dx.$$

Remarque.

La divergence de Kullback-Leibler n'est pas une distance au sens mathématique du terme. En effet, elle n'est pas symétrique et ne satisfait pas l'inégalité triangulaire. En revanche, on a toujours $D_{KL}(f||g) \geq 0$, avec égalité si et seulement si $f = g$ presque partout.

Proposition – Positivité de la divergence de Kullback-Leibler.

Soient f et g deux densités de probabilité sur $\mathbb{R}$, telles que $g(x) > 0$ pour tout x tel que $f(x) > 0$. Alors

$$D_{KL}(f||g) \geq 0,$$

avec égalité si et seulement si $f = g$ presque partout.

Démonstration. La fonction log est strictement concave, donc $-\log$ est strictement convexe. On peut donc appliquer l'inégalité de Jensen (p. 44) :

$$\begin{aligned} D_{KL}(f||g) &= \int_{\mathbb{R}} f(x) \log\left(\frac{f(x)}{g(x)}\right) dx = -\int_{\mathbb{R}} f(x) \left(-\log\left(\frac{g(x)}{f(x)}\right)\right) dx \\ &= -\mathbb{E}\left(-\log\left(\frac{g(X)}{f(X)}\right)\right) \geq -\left(-\log\left(\mathbb{E}\left(\frac{g(X)}{f(X)}\right)\right)\right) = -\log(1) = 0. \end{aligned}$$

On a égalité si et seulement si $\frac{g(x)}{f(x)}$ est presque sûrement constant, ce qui revient à dire que $f = g$ presque partout. ■

Exercice – Divergence de Kullback-Leibler entre deux gaussiennes Soient f et g les densités de deux lois normales $\mathcal{N}(m_1, \sigma_1^2)$ et $\mathcal{N}(m_2, \sigma_2^2)$. Montrer que $D_{KL}(f||g) = \log\left(\frac{\sigma_2}{\sigma_1}\right) + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}$.

Revenons à notre problème d'estimation de paramètres. Soit X une variable aléatoire de densité inconnue f. On choisit une famille de densités $(f_\theta)_{\theta \in \Theta}$, et on cherche à minimiser la divergence de Kullback-Leibler entre f et f_θ :

$$\hat{\theta} = \arg\min_{\theta \in \Theta} D_{KL}(f||f_\theta).$$

On peut réécrire la divergence de Kullback-Leibler sous la forme suivante :

$$\begin{aligned} D_{KL}(f||f_\theta) &= \int f(x) \log\left(\frac{f(x)}{f_\theta(x)}\right) dx \\ &= \int f(x) \log(f(x)) dx - \int f(x) \log(f_\theta(x)) dx \\ &= -H(f) - \mathbb{E}_f(\log f_\theta(X)), \end{aligned}$$

où $H(f) = -\int f(x) \log f(x) dx$ est l'**entropie** de la densité f. Celle-ci s'interprète comme Ce terme ne dépend pas de θ, donc minimiser $D_{KL}(f||f_\theta)$ revient à maximiser $\mathbb{E}_f(\log f_\theta(X))$. En

statistique, $f_\theta(X)$ est appelée la *vraisemblance* de l'observation X pour le paramètre θ, et $\log f_\theta(X)$ la *log-vraisemblance*. L'estimateur $\hat{\theta}$ est ainsi appelé *estimateur du maximum de vraisemblance*.

En pratique, on dispose d'un échantillon $X_1, \ldots, X_n$ de variables aléatoires indépendantes et identiquement distribuées selon la loi de densité f. Le choix de la forme paramétrique est généralement guidé par des considérations théoriques, portant sur la physique du phénomène étudié, ou empiriques, en regardant par exemple l'histogramme des données. On peut ensuite estimer $\mathbb{E}_f(\log f_\theta(X))$ par la moyenne empirique

$$\frac{1}{n}\sum_{i=1}^{n} \log f_\theta(X_i),$$

et l'estimateur du maximum de vraisemblance s'écrit

$$\hat{\theta}_n = \arg\max_{\theta\in\Theta} \frac{1}{n}\sum_{i=1}^{n} \log f_\theta(X_i).$$

Cela revient à remplacer f par la mesure empirique de l'échantillon $\tilde{p} = \frac{1}{n}\sum_{i=1}^{n} \delta_{X_i}$ dans la définition de la divergence de Kullback-Leibler.

8. Exercices complémentaires

8.1. Durée de vie

La durée de vie, exprimée en années, d'un circuit électronique est une variable aléatoire T dont la fonction de répartition F est définie par :

$$F(t) = (1 - e^{-t^2/2})1_{t\geq 0}$$

Question 1 Donner la densité de probabilité f de T . Calculer $\mathbb{E}(T)$.

Question 2 Sachant que le circuit a déjà fonctionné durant 1 an, quelle est la probabilité qu'il continue à fonctionner encore durant au moins 2 ans ? La loi est-elle sans mémoire ?

Un équipement électronique E est composé de 10 circuits identiques et indépendants. Au circuit $i(1 \leq i \leq 10)$ est associée la variable aléatoire X_i , avec $X_i = 1$ si la durée de vie du circuit i est inférieure à un an et $X_i = 0$ sinon.

Question 3 Quelle est la loi du nombre N de circuits de E dont la durée de vie est inférieure à 1 an ?

Question 4 L'équipement E est dit en série si la défaillance de l'un de ses circuits entraîne sa défaillance. Quelle est alors la probabilité qu'il soit défaillant avant 1 an ?

Question 5 L'équipement E est dit en parallèle si sa défaillance ne peut se produire que si tous ses circuits sont défaillants. Quelle est alors la probabilité qu'il soit défaillant avant 1 an ?

8.2. Crues centennales de la Seine

On suppose que la hauteur d'eau maximale au cours de l'année n est décrite par une variable aléatoire X_n de densité $f(x)$ et de fonction de répartition $F(x)$, identique pour toutes les X_n, que l'on suppose également indépendantes.

Question 1 Calculer la fonction de répartition du maximum sur n années $Y = \max(X_1, \ldots, X_n)$.

Question 2 En déduire la densité de Y.

Question 3 Expliciter la densité de Y lorsque les X_i sont de loi uniforme sur $[0, 1]$.

Question 4 Selon mêmes hypothèses, calculer la hauteur minimale des quais pour que la probabilité de voir la Seine déborder sur une période de n années soit inférieure à $1/1000$.

Question 5 Toujours selon les mêmes hypothèses, calculer la médiane de Y. La comparer avec celle des X_i. Commenter.

8.3. Indépendance et vecteurs gaussiens

Soit $Z := (X, Y)$ un vecteur gaussien (i.e. qui suit une loi Normale bi-variée) d'espérance m et de matrice de covariance définie positive C. Notons f_Z sa densité.

Question 1 Rappeler la forme de f_Z et en donner une expression non matricielle faisant apparaître le coefficient de corrélation noté ρ.

Question 2 Expliciter les lois marginales de X et de Y.

Question 3 Montrer que X et Y sont indépendantes ssi $\mathrm{Cov}\,(X, Y) = 0$.

8.4. Symétrie de la gaussienne

Soit X une variable aléatoire réelle de loi Normale centrée réduite, dont la densité est notée f et la fonction de répartition F. Pour tout $c > 0$ on pose

$$X_c := \left| \begin{array}{ll} X & \text{si } |X| > c, \\ -X & \text{si } |X| \leq c. \end{array} \right.$$

Question 1 Déterminer la loi de X_c.

Question 2 Calculer la covariance de X et de X_c et montrer qu'il existe une valeur c_0 de c qui l'annule.

Question 3 Les deux variables X et X_{c_0} sont-elles indépendantes ?

Question 4 Le vecteur aléatoire (X, X_{c_0}) est-il gaussien ?

8.5. Loi du χ^2

On considère une variable aléatoire X gaussienne centrée réduite. On note f sa densité et F sa fonction de répartition.

A 1 degré de liberté

1. Calculer la densité de la variable aléatoire $Y := X^2$. En donner une expression faisant apparaître la fonction gamma (on rappelle que $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$).

On dit que Y suit une *loi du χ^2 à 1 degré de liberté*, et on note $Y \sim \chi^2$.

A n degrés de liberté Soient maintenant $n \in \mathbb{N}^*$ et $X_1, \ldots, X_n$ des copies indépendantes de X. Pour tout $i \in \{1, \ldots, n\}$ on pose $Y_i := X_i^2$.

2. Montrer que la variable aléatoire $Y := \sum_{i=1}^n Y_i$ admet pour densité

$$f_Y : x \in \mathbb{R} \mapsto \left| \begin{array}{ll} \dfrac{x^{\frac{n}{2}-1}}{2^{\frac{n}{2}}\,\Gamma\left(\frac{n}{2}\right)} \exp\left\{-\dfrac{x}{2}\right\} & \text{si } x > 0, \\ 0 & \text{si } x \leq 0. \end{array} \right.$$

   On pourra procéder par récurrence sur n.

On dit que Y suit une *loi du χ^2 à n degrés de liberté* et on note $Y \sim \chi^2_n$.

8.6. Combinaisons linéaires de variables Gaussiennes indépendantes

Soit X une variable aléatoire de loi Normale centrée réduite, dont on note f la densité et F la fonction de répartition.

Préliminaires

1. Rappeler la loi de la variable aléatoire $s\,X + m$, où $s, m \in \mathbb{R}$.

Combinaisons linéaires Soient maintenant $n \in \mathbb{N}^*$ variables aléatoires $X_1, \ldots, X_n$ indépendantes et de même loi que X (on dit que ce sont des *copies indépendantes* de X). Pour tout vecteur $a = (a_1, \ldots, a_n) \in (\mathbb{R}^*)^n$ on pose $S_n^a := \sum_{i=1}^n a_i\,X_i$.

2. Montrer que pour S_n^a suit une loi Normale d'espérance nulle et de variance $\sum_{i=1}^n a_i^2$ (on pourra raisonner par récurrence sur n).

3. Soient $a, b \in (\mathbb{R}^*)^n$. Sous quelle condition a-t-on $\mathrm{Cov}\left(S_n^a, S_n^b\right) = 0$?

8.7. Loi de Maxwell

On désire déterminer la distribution des vitesses des molécules d'un gaz monoatomique parfait à l'équilibre (loi de Maxwell (1859)).

On représente la vitesse d'une molécule d'un gaz monoatomique parfait à l'équilibre dans un repère orthonormal par un vecteur aléatoire $V = (V_1, V_2, V_3)$. Le choix du repère étant arbitraire, il est naturel de supposer que la loi de V est invariante par rotation (autour de l'origine) et que les composantes de V sont indépendantes.

8.7.1. Partie 1

Soit (X, Y, Z) un vecteur aléatoire à valeurs dans $\mathbb{R}^3$ de densité $f_{(X,Y,Z)}$. Ce vecteur aléatoire est supposé invariant par rotation : il existe une fonction $\phi : [0, +\infty[\to]0, +\infty[$ (strictement positive) telle que

$$f_{(X,Y,Z)}(x, y, z) = \phi(x^2 + y^2 + z^2) \text{ pour tout } (x, y, z) \in \mathbb{R}^3.$$

Question 1 On suppose de plus les variables aléatoires X, Y et Z indépendantes. Montrer qu'il existe une fonction $f : \mathbb{R} \to [0, +\infty[$ qui soit une densité telle que

$$f_{(X,Y,Z)}(x, y, z) = f(x)f(y)f(z) \text{ pour tout } (x, y, z) \in \mathbb{R}^3.$$

Montrer finalement que $f(x) > 0$ pour tout $x \in \mathbb{R}$.

Question 2 On suppose de plus que les densités marginales de X, Y et Z ainsi que la fonction ϕ sont continûment différentiables (c'est-à-dire de classe C^1). Montrer que la densité de chacune des composantes s'écrit sous la forme $f(x) = ae^{cx^2/2}$, avec a et c deux constantes réelles.

Question 3 En déduire que le vecteur (X, Y, Z) suit une loi gaussienne d'espérance l'origine dont on précisera la matrice de covariance en fonction de la constante $\sigma = 1/\sqrt{|c|}$.

8.7.2. Partie 2

On suppose que le vecteur aléatoire $(X, Y, Z) = V$ vérifie les hypothèses des questions précédentes.

Question 4 Calculer l'énergie cinétique moyenne d'un atome du gaz, c'est-à-dire l'espérance

$$E_c := \mathbb{E}\left(\frac{1}{2}m\|V\|^2\right)$$

où m est la masse d'un atome du gaz. L'énergie cinétique moyenne d'un atome du gaz de masse m étant égale à $\frac{3}{2}kT$ où k est la constante de Boltzmann et T la température du gaz, en déduire la valeur de σ^2 en fonction de k, T et m.

Question 5 On rappelle que si X et Y sont deux variables aléatoires indépendantes de loi respective $\Gamma(a, \lambda)$ et $\Gamma(b, \lambda)$, alors la loi de $X + Y$ est la loi $\Gamma(a + b, \lambda)$. On rappelle également que la densité g de la loi $\Gamma(a, \lambda)$ vérifie

$$g(x) = \frac{1}{\Gamma(a)}\lambda^a x^{a-1}e^{-\lambda x}1_{]0,+\infty[}(x) \text{ pour tout } x \in \mathbb{R},$$

où Γ est la fonction définie par

$$\Gamma(a) = \int_0^{+\infty} x^{a-1}e^{-x}dx \text{ pour } a \in]0, +\infty[\,.$$

On remarquera que $\Gamma(1/2) = \sqrt{\pi}$ et que $\Gamma(x + 1) = x\Gamma(x)$.

Calculer la loi de V_1^2. En déduire la loi de $\|V\|^2$ puis la densité de $\|V\| = \sqrt{V_1^2 + V_2^2 + V_3^2}$. La probabilité associée est appelée loi de Maxwell.

Troisième partie

Probabilités III : Conditionnement

1. Objectifs d'apprentissage

Cette section s'efforce d'expliciter et de hiérarchiser les acquis d'apprentissages associés au chapitre. Ces objectifs sont organisés en paliers :
(○) Prérequis (•) Fondamental (••) Standard (•••) Avancé (••••) Expert
Sauf mention particulière, la connaissance des démonstrations du document n'est pas exigible [1]

Lois conditionnelles

- •• connaître le théorème de Fubini conditionnel
- •• connaître les formules de balayage conditionnel
- •• savoir appliquer ces résultats pour différents types de loi de probabilité (à densité ou non)
- • connaître le critère d'indépendance qui résulte du théorème de Fubini conditionnel

Espérance conditionnelle

- • connaître les deux points de la définition de l'espérance conditionnelle
- • connaître les deux points de la définition de l'espérance conditionnelle d'une fonction de variables aléatoires
- • connaître et savoir utiliser la formule de l'espérance totale
- •• savoir calculer la densité conditionnelle d'un certain nombre de composantes sachant les autres dans un vecteur gaussien à densité

Cas $\mathcal{L}^2$

- •• savoir que la régression linéaire est la meilleure approximation linéaire (au sens des moindres carrés) d'une variable aléatoire par une autre
- ••• savoir retrouver ce résultat
- ••• connaître l'interprétation géométrique de l'espérance conditionnelle dans le cas $\mathcal{L}^2$
- • connaître et savoir utiliser la formule de la variance totale

2. Lois conditionnelles

2.1. Introduction

On s'est consacré jusqu'à présent à l'étude de variables aléatoires indépendantes. En pratique cependant, on rencontre souvent des variables dépendant les unes des autres. Dans le cas de la météo, les variables température, vitesse du vent et pression en fournissent un exemple. Dans les approches bayésiennes, on résume l'information disponible sur l'état du système étudié par la **loi a priori** et on met à jour notre connaissance du système en incorporant de l'information supplémentaire (par exemple des observations). On cherche alors à caractériser la **loi a posteriori** de l'état du système, qui est la loi de l'état sachant l'information supplémentaire. On va

1. l'étude des démonstrations du cours peut toutefois contribuer à votre apprentissage, au même titre que la résolution d'exercices.

ainsi s'attacher dans ce chapitre à décrire les **lois conditionnelles** qui vont permettre de résumer l'information apportée par une variable (ou un vecteur) sur une autre et s'intéresser en particulier à l'**espérance conditionnelle** qui indiquera le comportement moyen d'une variable conditionnellement à une autre. Ce dernier cas pose le cadre probabiliste d'un des problèmes fondamentaux en apprentissage statistique : l'apprentissage supervisé, où on dispose d'un ensemble de réalisations d'une variable dont on cherche à prédire le comportement à partir d'un ensemble de variables dites explicatives (ou prédicteurs).

2.2. Lois conditionnelles dans un couple

Soient deux variables aléatoire X et Y définies sur le même espace probabilisé $(\Omega, \mathcal{A}, \mathbb{P})$. Dans le cas où X et Y sont indépendantes, on a vu que pour tous boréliens B_1 et B_2 de $\mathcal{B}(\mathbb{R})$, on a

$$\mathbb{P}(X \in B_1, Y \in B_2) = \mathbb{P}(X \in B_1)\mathbb{P}(Y \in B_2) = \mathbb{P}_X(B_1)\mathbb{P}_Y(B_2) = \int_{B_1} \mathbb{P}_Y(B_2) d\mathbb{P}_X(x),$$

où on a utilisé le théorème de Fubini.

Du fait de l'indépendance, on a aussi $\mathbb{P}_Y(B_2) = \mathbb{P}(Y \in B_2) = \mathbb{P}(Y \in B_2 | X \in B_1) = \mathbb{P}_Y(B_2 | X \in B_1)$ ce qui exprime que pour tout borélien B_1, la loi conditionnelle de Y sachant $X \in B_1$ est identique à la loi de Y.

Lorsque X et Y en sont pas indépendantes, on va chercher à établir une égalité de la forme

$$\mathbb{P}(X \in B_1, Y \in B_2) = \mathbb{P}_X(B_1)\mathbb{P}_Y(B_2 | X \in B_1) = \int_{B_1} \mathbb{P}_{Y|X=x}(B_2) d\mathbb{P}_X(x)$$

et s'intéresser à caractériser la *loi conditionnelle de Y sachant $X = x$*, que l'on notera donc $\mathbb{P}_{Y|X=x}$.

De même, pour toute application $g : \mathbb{R}^2 \to \mathbb{R}$ mesurable telle que $g(X, Y)$ admette une espérance (relativement à la loi du couple $\mathbb{P}_{X,Y}$), on voudrait écrire :

$$\mathbb{E}(g(X, Y)) = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(x, y) d\mathbb{P}_{Y|X=x}(y) \right) d\mathbb{P}_X(x)$$

Pour bien fixer les idées, on va décrire spécifiquement les cas où X est discrète puis où le couple (X, Y) admet une densité avant d'aborder le cas général.

2.3. Cas où X est discrète

Dans ce paragraphe, on suppose que la variable aléatoire réelle X est discrète, c'est-à-dire que l'ensemble $X(\Omega) \subset \mathbb{R}$ des valeurs x_k prises par X est au plus dénombrable.

On peut imposer que $\forall x \in X(\Omega)$ on ait $\mathbb{P}(X = x) > 0$, quitte à modifier X sur un ensemble de probabilité nulle. On va ainsi pouvoir utiliser la définition de la probabilité conditionnelle pour des événements de la forme $\{X = x\}$. Ceci permet d'écrire pour tous boréliens B_1 et B_2 de $\mathbb{R}$:

$$\begin{aligned}
\mathbb{P}(X \in B_1, Y \in B_2) &= \sum_{x \in X(\Omega) \cap B_1} \mathbb{P}(X = x, Y \in B_2) \\
&= \sum_{x \in X(\Omega) \cap B_1} \mathbb{P}(X = x)\mathbb{P}(Y \in B_2 | X = x) \\
&= \int_{B_1} \mathbb{P}(Y \in B_2 | X = x) d\mathbb{P}_X(x)
\end{aligned}$$

puisque $\mathbb{P}_X = \sum_{x \in X(\Omega)} \mathbb{P}(X = x)\delta_x$. On obtient ainsi l'écriture souhaitée en posant

$$\mathbb{P}_{Y|X=x}(B_2) = \mathbb{P}(Y \in B_2 | X = x), \ \ \forall x \in X(\Omega), \forall B_2 \in \mathcal{B}(\mathbb{R}).$$

Remarque – Image de la probabilité conditionnelle.

$\mathbb{P}_{Y|X=x}$ ainsi définie est simplement la probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ image par Y de la probabilité conditionnelle $\mathbb{P}(\cdot|X=x)$ définie sur $(\Omega, \mathcal{A})$, autrement dit, la **loi de Y relative à** $\mathbb{P}(\cdot|X=x)$ et non à $\mathbb{P}$.

La formule ci-dessus s'écrit $\mathbb{P}_{X,Y}(B_1 \times B_2) = \int_{B_1} \mathbb{P}(Y \in B_2|X=x)d\mathbb{P}_X(x)$, où $\mathbb{P}_{X,Y}$ est la loi du couple. Elle se généralise à tout borélien B de $\mathbb{R}^2$ de la manière suivante :

$$\begin{aligned}\mathbb{P}_{X,Y}(B) = \mathbb{P}((X,Y) \in B) &= \sum_{x \in X(\Omega)} \mathbb{P}(X=x, (x,Y) \in B) \\ &= \sum_{x \in X(\Omega)} \mathbb{P}(X=x)\mathbb{P}((x,Y) \in B|X=x) \\ &= \sum_{x \in X(\Omega)} \mathbb{P}(X=x)\mathbb{P}_{Y|X=x}(B_x),\end{aligned}$$

où $B_x = \{y \in \mathbb{R}, (x,y) \in B\}$. Ainsi, pour tout B borélien de $\mathbb{R}^2$,

$$\mathbb{E}(1_B(X,Y)) = \int_{\mathbb{R}^2} 1_B(x,y)d\mathbb{P}_{X,Y}(xy) = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} 1_B(x,y)d\mathbb{P}_{Y|X=x}(y) \right) d\mathbb{P}_X(x)$$

Par linéarité de l'espérance, on peut ainsi exprimer l'espérance d'une fonction étagée. Pour avoir le résultat pour une fonction mesurable positive, on exprime celle-ci comme limite simple d'une suite croissante de fonctions étagées, et on applique le théorème de convergence monotone. Enfin, on applique cette construction à g_+ et g_- pour une fonction g de signe quelconque $\mathbb{P}_{X,Y}$-intégrable. En d'autres termes, on reprend le procédé de construction de l'intégrale de Lebesgue. On obtient ainsi la formule souhaitée :

$$\mathbb{E}(g(X,Y)) = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(x,y)d\mathbb{P}_{Y|X=x}(y) \right) d\mathbb{P}_X(x).$$

Exemple – Pour fixer les idées (1).

Soit $X \geq 0$ une variable aléatoire à valeurs dans $\mathbb{N}$ et Y une variable aléatoire réelle positive telle que la loi du couple $\mathbb{P}_{X,Y}$ vérifie pour tout $n \in \mathbb{N}$ et tout borélien B_2 de $\mathbb{R}$:

$$\mathbb{P}_{X,Y}(\{n\} \times B_2) = (1-\alpha)\alpha^n \int_{B_2 \cap \mathbb{R}_+^*} e^{-t}\frac{t^n}{n!}dt, \;\; 0 < \alpha < 1$$

$\mathbb{P}_{X,Y}$ est bien une probabilité sur $\mathbb{R}^2$ puisque par convergence monotone :

$$\begin{aligned}\mathbb{P}_{X,Y}(\mathbb{R}^2) &= \mathbb{P}_{X,Y}(\mathbb{N} \times \mathbb{R}) \\ &= \sum_{n \in \mathbb{N}} \mathbb{P}_{X,Y}(\{n\} \times \mathbb{R}) \\ &= \sum_{n \in \mathbb{N}} (1-\alpha)\alpha^n \int_{\mathbb{R}_+^*} e^{-t}\frac{t^n}{n!}dt \\ &= (1-\alpha)\int_{\mathbb{R}_+^*} e^{-t} \sum_{n \in \mathbb{N}} \frac{(\alpha t)^n}{n!}dt \\ &= (1-\alpha)\int_{\mathbb{R}_+^*} e^{-(1-\alpha)t}dt = 1\end{aligned}$$

où on aura reconnu la loi exponentielle de paramètre $(1-\alpha)$. $\forall n \in \mathbb{N}$,

$$\int_{\mathbb{R}_+^*} e^{-t}\frac{t^n}{n!}dt = \int_{\mathbb{R}_+^*} e^{-t}\frac{t^{(n-1)}}{(n-1)!}dt = \ldots = \int_{\mathbb{R}_+^*} e^{-t}dt = 1$$

par intégrations par parties itérées. La loi marginale de X s'écrit donc :

$$\forall n \in \mathbb{N}, \mathbb{P}(X=n) = \mathbb{P}_{X,Y}(\{n\} \times \mathbb{R}_+^*) = (1-\alpha)\alpha^n,$$

loi géométrique de paramètre $(1-\alpha)$. On en déduit la loi conditionnelle de Y sachant $X=n$:

$$\mathbb{P}_{Y|X=n}(B_2) = \mathbb{P}(Y \in B_2 | X=n) = \frac{\mathbb{P}_{X,Y}(\{n\} \times B_2)}{\mathbb{P}(X=n)} = \int_{B_2 \cap \mathbb{R}_+^*} e^{-t}\frac{t^n}{n!}dt$$

et $\mathbb{P}_{Y|X=n}$ est la donc la loi gamma de paramètre $(n+1,1)$.

2.4. Densités conditionnelles

On suppose maintenant que le couple (X,Y) admet une densité $f_{X,Y}$ (par rapport à la mesure de Lebesgue). On note $f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x,y)dy$ (respectivement $f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x,y)dx$) la loi marginale de X (resp. de Y). On s'intéresse à caractériser la densité de la variable Y connaissant la valeur prise par la variable X, c'est la *densité conditionnelle* de Y sachant $\{X=x\}$:

Proposition – Densité conditionnelle.

La formule suivante définit une densité sur $\mathbb{R}$, pour tout $x \in \mathbb{R}$ tel que $f_X(x) > 0$.

$$f_{Y|X=x}(y) = \frac{f_{X,Y}(x,y)}{f_X(x)}.$$

Cette fonction s'appelle la densité conditionnelle de Y sachant $\{X=x\}$. *La probabilité conditionnelle de Y sachant $\{X=x\}$ s'écrit ainsi $\mathbb{P}_{Y|X=x} = f_{Y|X=x}\lambda$, où λ représente la mesure de Lebesgue.*

Démonstration. La preuve est immédiate puisque $f_{Y|X=x}$ est une fonction positive d'intégrale 1. ■

Exercice – Dans un triangle (1) (•) Soient X et Y de densité jointe $f_{X,Y}(x,y) = \frac{1}{x}1_T(x,y)$ où T est le triangle $T = \{0 < y < x < 1\}$.

1. Calculer la densité marginale de X
2. Calculer la densité conditionnelle de Y sachant $X=x$.

L'interprétation de cette définition est la suivante : la fonction $f_{Y|X=x}$ est la densité de la "loi conditionnelle de Y sachant que $X=x$". Bien sûr, nous avons $\mathbb{P}(X=x)=0$ puisque X admet une densité, donc la phrase ci-dessus n'a pas réellement de sens, mais elle se justifie heuristiquement ainsi : dx et dy étant de "petits" accroissements des variables x et y et lorsque

f et f_X sont continues et strictement positives respectivement en (x, y) et x :

$$\begin{aligned} f_X(x)dx &\approx \mathbb{P}(X \in [x, x+dx]) \\ f_{X,Y}(x,y)dxdy &\approx \mathbb{P}(X \in [x, x+dx], Y \in [y, y+dy]) \end{aligned}$$

Par suite

$$\begin{aligned} f_{Y|X=x}(y)dy &\approx \frac{\mathbb{P}(X \in [x, x+dx], Y \in [y, y+dy])}{\mathbb{P}(X \in [x, x+dx])} \\ &\approx \mathbb{P}(Y \in [y, y+dy] | X \in [x, x+dx]) \end{aligned}$$

On a alors le résultat suivant qui résout le problème posé en introduction :

Proposition.

Pour toute fonction $g : \mathbb{R}^2 \to \mathbb{R}$ telle que $g(X, Y)$ admette une espérance, on a :

$$\mathbb{E}(g(X,Y)) = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(x,y) f_{Y|X=x}(y)dy \right) f_X(x)dx,$$

dont on déduit, en prenant $g = 1_{B_1 \times B_2}$, que :

$$\mathbb{P}(X \in B_1, Y \in B_2) = \int_{B_1} \left(\int_{B_2} f_{Y|X=x}(y)dy \right) f_X(x)dx.$$

Démonstration. On a

$$\begin{aligned} \mathbb{E}(g(X,Y)) &= \int_{\mathbb{R}^2} g(x,y) f_{X,Y}(x,y)dydx \\ &= \int_{\mathbb{R}^2} g(x,y) f_{Y|X=x}(y) f_X(x)dydx \\ &= \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(x,y) f_{Y|X=x}(y)dy \right) f_X(x)dx, \end{aligned}$$

les calculs étant licites par application du théorème de Fubini et du fait que l'application $x \mapsto \int_{\mathbb{R}} g(x,y) f_{Y|X=x}(y)dy$ est définie pour $f_X(x) > 0$, soit presque partout relativement à la mesure $\mathbb{P}_X = f_X \lambda$. ■

2.5. Cas général

On peut établir le résultat suivant, qui complète le théorème de Fubini et le résultat d'existence et d'unicité des mesures produits, et que l'on admettra.

Théorème – Fubini conditionnel.

Soit un couple (X, Y) de variables aléatoires réelles de loi jointe $\mathbb{P}_{X,Y}$, il existe une famille $\left(\mathbb{P}_{Y|X=x}\right)_{x \in \mathbb{R}}$ de probabilités sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, unique à une égalité $\mathbb{P}_X$-presque partout près[1]*,*

qui vérifie pour tous B_1, B_2 boréliens de $\mathbb{R}$:

$$\mathbb{P}_{X,Y}(B_1 \times B_2) = \int_{B_1} \left(\int_{B_2} d\mathbb{P}_{Y|X=x}(y) \right) d\mathbb{P}_X(x).$$

Ces probabilités sont appelées lois conditionnelles *de Y sachant $X = x$. On a de plus pour toute application $g : \mathbb{R}^2 \to \mathbb{R}$ telle que $g(X, Y)$ admette une espérance :*

$$\mathbb{E}(g(X,Y)) = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(x,y) d\mathbb{P}_{Y|X=x}(y) \right) d\mathbb{P}_X(x).$$

Remarque – A noter.

- Ce résultat peut être interprété comme un **théorème de Fubini conditionnel**, dans le sens où il permet une intégration séquentielle, mais ici la mesure de probabilité du couple (X, Y) s'exprime comme un produit de mesures dont l'un des termes dépend de la variable d'intégration de l'autre. En particulier, si on change l'ordre d'intégration, on change les mesures qui interviennent.
- Fréquemment, dans les applications, la famille des lois conditionnelles est une donnée du modèle considéré, et leur existence ne pose donc pas de problème !
- On retrouve les cas vus précédemment en notant que pour tout borélien B_1 de $\mathbb{R}$ on a $\mathbb{P}_X(B_1) = \int_{B_1} d\mathbb{P}_X(x) = \sum_{x \in B_1} \mathbb{P}(X = x)$ lorsque X est discrète, et que pour tous boréliens B_1 et B_2 de $\mathbb{R}$ on a $\mathbb{P}_X(B_1) = \int_{B_1} f_X(x)dx$ et $\mathbb{P}_{X,Y}(B_1 \times B_2) = \int_{B_1 \times B_2} f_{X,Y}(x,y)dxdy$.
- Dans tout ce qui précède, les rôles de X et Y peuvent évidemment être inversés.

2.6. Conséquences

Le théorème précédent (p. 67) a deux conséquences majeures. Il fournit d'une part un moyen efficace d'identifier la loi marginale de Y connaissant la loi marginale de X et la loi de Y sachant $X = x$. En effet, en notant que pour tout borélien B de $\mathbb{R}$, $\mathbb{P}_Y(B) = \mathbb{P}_{X,Y}(\mathbb{R} \times B)$ et en appliquant ce théorème, on a la proposition suivante :

Proposition – Formule de balayage conditionnel.

- *La loi marginale $\mathbb{P}_Y$ de Y s'exprime comme la moyenne des lois conditionnelles $\mathbb{P}_{Y|X=x}$ pondérée par la loi de X. Pour tout B borélien de $\mathbb{R}$*

$$\mathbb{P}_Y(B) = \int_{\mathbb{R}} \left(\int_B d\mathbb{P}_{Y|X=x}(y) \right) d\mathbb{P}_X(x) = \int_{\mathbb{R}} \mathbb{P}_{Y|X=x}(B) d\mathbb{P}_X(x)$$

- *Dans le cas où X est discrète (à valeurs dans I dénombrable), on retrouve une expression de la formule des probabilités totales et composées :*

$$\mathbb{P}_Y(B) = \mathbb{P}(Y \in B) = \sum_{x \in I} \mathbb{P}(Y \in B | X = x) \mathbb{P}(X = x)$$

- *Dans le cas où le couple (X, Y) admet une densité, puisqu'on a $f_{X,Y}(x, y) =$*

1. c'est-à-dire qu'on peut définir ces probabilités de la manière qu'on souhaite pour les boréliens B tels que $\mathbb{P}_X(B) = 0$.

$f_{Y|X=x}(y)f_X(x)$, on obtient l'expression suivante pour la densité marginale :

$$f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x,y)dx = \int_{\mathbb{R}} f_{Y|X=x}(y)f_X(x)dx.$$

On a en particulier la formule de Bayes pour les densités *: pour tout x tel que $f_X(x) > 0$ et tout y tel que $f_Y(y) > 0$:*

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x,y)}{f_Y(y)} = \frac{f_{Y|X=x}(y)f_X(x)}{f_Y(y)}.$$

Exemple – Pour fixer les idées (2).

Poursuivons l'exemple vu plus haut (p. 65). On rappelle qu'on a déjà identifié la loi marginale de X ainsi que la loi conditionnelle de Y sachant $X = n$ pour $n \in \mathbb{N}$ que l'on rappelle ici :

$$\mathbb{P}(X = n) = (1-\alpha)\alpha^n,\ n \in \mathbb{N} \text{ et } \forall B \in \mathcal{B}(\mathbb{R}),\ \mathbb{P}_{Y|X=n}(B) = \int_{B\cap\mathbb{R}_+^*} e^{-t}\frac{t^n}{n!}dt$$

On peut en déduire la loi marginale de Y en utilisant la formule de balayage conditionnel (p. 68) et le théorème de convergence monotone :

$$\begin{aligned}\mathbb{P}_Y(B) &= \sum_{n\in\mathbb{N}}(1-\alpha)\alpha^n \int_{B\cap\mathbb{R}_+^*} e^{-t}\frac{t^n}{n!}dt \\ &= (1-\alpha)\int_{B\cap\mathbb{R}_+^*} e^{-t}\sum_{n\in\mathbb{N}}\frac{(\alpha t)^n}{n!}dt \\ &= \int_B 1_{\mathbb{R}_+}(t)(1-\alpha)e^{-(1-\alpha)t}dt,\end{aligned}$$

de sorte que Y suit une loi exponentielle de paramètre $(1-\alpha)$.

En inversant les rôles, on va pouvoir identifier la loi de X sachant $Y \in B$ en notant que

$$\begin{aligned}\mathbb{P}_{X,Y}(\{n\}\times B) &= \mathbb{P}_X(\{n\})\mathbb{P}_{Y|X=n}(B) \\ &= \int_B \frac{(\alpha t)^n}{n!}e^{-\alpha t}d\mathbb{P}_Y(t) \\ &= \int_B \mathbb{P}_{X|Y=t}(\{n\})d\mathbb{P}_Y(t)\end{aligned}$$

où l'on reconnaît que $\mathbb{P}_{X=n|Y=t}(\{n\}) = \frac{(\alpha t)^n}{n!}e^{-\alpha t}$, c'est-à-dire que X sachant $Y = t$ suit une loi de Poisson de paramètre αt pour $\mathbb{P}_Y$-presque tout t.

En utilisant, le théorème de Fubini conditionnel (p. 67), on obtient également une nouvelle caractérisation de l'indépendance de deux variables aléatoires faisant intervenir les lois conditionnelles.

Proposition – Critère d'indépendance.

1. *X et Y sont indépendantes si et seulement si, pour $\mathbb{P}_X$-presque tout x, $\mathbb{P}_{Y|X=x}$ ne*

dépend pas de x et dans ce cas, on a $\mathbb{P}_{Y|X=x} = \mathbb{P}_Y$, c'est-à-dire que la loi conditionnelle est identique à la loi marginale.

2. *Dans le cas où (X, Y) admet une densité, X et Y sont indépendantes si et seulement si la densité conditionnelle de Y sachant $\{X = x\}$ ne dépend pas de x.*

Démonstration.

1. Si X et Y sont indépendantes, pour tous B_1, B_2 boréliens de $\mathbb{R}$, $\mathbb{P}_{X,Y}(B_1 \times B_2) = \mathbb{P}_X(B_1)\mathbb{P}_Y(B_2) = \int_{B_1} \mathbb{P}_Y(B_2) d\mathbb{P}_X(x) = \int_{B_2} \mathbb{P}_X(B_1) d\mathbb{P}_Y(y)$. Le résultat d'unicité du théorème de Fubini conditionnel (p. 67) (à une égalité $\mathbb{P}_X$-presque sûre près), nous indique alors que $\mathbb{P}_{Y|X=x}(B_2) = \mathbb{P}_Y(B_2)$.

   Inversement, si $\mathbb{P}_{Y|X=x} = \mathbb{P}_Y$, alors $\mathbb{P}_{X,Y}(B_1 \times B_2) = \int_{B_1} \mathbb{P}_{Y|X=x}(B_2) d\mathbb{P}_X(x) = \int_{B_1} \mathbb{P}_Y(B_2) d\mathbb{P}_X(x) = \mathbb{P}_X(B_1)\mathbb{P}_Y(B_2)$.

2. Si X et Y sont indépendantes, $f_{X,Y}(x, y) = f_X(x) f_Y(y)$, d'où $f_{Y|X=x}(y) = f_Y(y)$.

   Inversement, si $f_{Y|X=x}(y) = f_Y(y)$ alors $f_{X,Y}(x, y) = f_{Y|X=x}(y) f_X(x) = f_Y(y) f_X(x)$ et X et Y sont indépendantes.

■

3. Espérance conditionnelle

Puisque $\mathbb{P}_{Y|X=x}$ est la loi d'une variable aléatoire, on peut définir l'espérance qui lui est associée et introduire la notion d'espérance conditionnelle dans le cas où Y est intégrable.

Définition – Espérance conditionnelle.

Soit $Y \in \mathcal{L}^1$.

1. L'*espérance conditionnelle de Y sachant $\{X = x\}$* est définie par

$$\mathbb{E}(Y|X = x) = \int_{\mathbb{R}} y d\mathbb{P}_{Y|X=x}(y).$$

2. L'*espérance conditionnelle de Y sachant X* est la **variable aléatoire** définie par :

$$\mathbb{E}(Y|X) = \psi(X), \text{ avec } \psi(x) = \mathbb{E}(Y|X = x).$$

Exercice – Dans un triangle (2) (•) Soient X et Y de densité jointe $f_{X,Y}(x, y) = \frac{1}{x} 1_T(x, y)$ où T est le triangle $T = \{0 < y < x < 1\}$. Calculer l'espérance conditionnelle de Y sachant X.

Remarque – Conséquences.

1. $\psi(x)$ n'est définie que pour $x \notin N$, avec $\mathbb{P}(X \in N) = 0$. Par conséquent, la définition (p. 70) définit bien l'espérance conditionnelle $\psi(X) = \mathbb{E}(Y|X)$ $\mathbb{P}_X$-presque partout, autrement dit avec probabilité 1, ou encore presque sûrement.
2. $\mathbb{E}(\mathbb{E}(|Y||X)) = \mathbb{E}(|Y|)$ comme conséquence directe du théorème de Fubini conditionnel

(p. 67). L'espérance conditionnelle de Y sachant X est bien définie dès que Y est intégrable.

3. Lorsque (X, Y) admet une densité, l'espérance conditionnelle de Y sachant $\{X = x\}$ s'écrit
$$\mathbb{E}(Y|X = x) = \int_{\mathbb{R}} y f_{Y|X=x}(y)dy.$$

Exercice – Auto-conditionnement (•) Montrer que $\mathbb{E}(Y|Y) = Y$.

On peut étendre cette définition aux variables de la forme $g(X, Y)$.

Définition – Espérance conditionelle d'une fonction de variables aléatoires.

Soit (X, Y) un couple de variables aléatoires réelles et g une fonction mesurable positive ou $\mathbb{P}_{X,Y}$-intégrable sur $\mathbb{R}^2$.

1. L'*espérance conditionnelle de* $g(X, Y)$ *sachant* $\{X = x\}$ est définie par
$$\mathbb{E}(g(X, Y)|X = x) = \int_{\mathbb{R}} g(x, y)d\mathbb{P}_{Y|X=x}(y).$$
2. L'*espérance conditionnelle de* $g(X, Y)$ *sachant* X est la **variable aléatoire** définie par :
$$\mathbb{E}(g(X, Y)|X) = \psi(X), \text{ avec } \psi(x) = \mathbb{E}(g(X, Y)|X = x).$$

Théorème – Espérance totale.

Si Y *est intégrable, alors* $\psi(X) = \mathbb{E}(Y|X)$ *est intégrable, et*
$$\mathbb{E}(\psi(X)) = E(Y).$$

Démonstration. C'est une conséquence directe du théorème de Fubini conditionnel (p. 67). ■

Ce résultat permet de calculer $\mathbb{E}(Y)$ en conditionnant par une variable auxiliaire X :
$$\mathbb{E}(Y) = \int_{\mathbb{R}} \mathbb{E}(Y|X = x)d\mathbb{P}_X(x)$$

Il généralise la formule des probabilités totales, qui correspond ici à $Y = 1_A$, et $B_x = \{X = x\}$ où les B_x forment cette fois une partition non dénombrable de $\mathbb{R}$. On l'écrit souvent sous la forme
$$\mathbb{E}\left(\mathbb{E}(Y|X)\right) = \mathbb{E}(Y)$$
et on l'appelle la *formule de l'espérance totale.*

L'espérance conditionnelle étant définie comme l'espérance selon la loi conditionnelle, elle hérite des propriétés usuelles de l'espérance :

1. si Y et Z sont intégrables, $\mathbb{E}(aY + bZ|X) = a\mathbb{E}(Y|X) + b\mathbb{E}(Z|X)$,
2. $\mathbb{E}(Y|X) \geq 0$ si $Y \geq 0$,
3. $\mathbb{E}(1|X) = 1$.

De plus, si g est mesurable positive ou $\mathbb{P}_X$-intégrable,

$$\mathbb{E}(Yg(X)|X) = g(X)\mathbb{E}(Y|X)$$

est une généralisation de l'égalité 1. ci-dessus, au cas où $a = g(X)$, qui doit être considéré "comme une constante" dans le calcul de l'espérance conditionnelle sachant X (X est fixée comme une donnée connue a priori). En effet, on a alors $\mathbb{E}(g(x)Y|X = x) = g(x)\psi(x)$. Enfin, on déduit directement du théorème de Fubini conditionnel (p. 67) la proposition suivante.

Proposition – Transfert conditionnel.

Soient un couple (X, Y) de variables aléatoires réelles de loi jointe $\mathbb{P}_{X,Y}$ et g une fonction mesurable positive ou $\mathbb{P}_{X,Y}$-intégrable sur $\mathbb{R}^2$. On a pour $\mathbb{P}_X$-presque tout x dans $\mathbb{R}$

$$\mathbb{E}(g(X,Y)|X = x) = \mathbb{E}(g(x,Y)|X = x) = \int_{\mathbb{R}} g(x,y)d\mathbb{P}_{Y|X=x}(y)$$

Si de plus X et Y sont indépendantes, on a :

$$\mathbb{E}(g(X,Y)|X = x) = \mathbb{E}(g(x,Y)|X = x) = \int_{\mathbb{R}} g(x,y)d\mathbb{P}_Y(y).$$

Autrement dit, lorsqu'on conditionne par l'événement $\{X = x\}$, cela revient à fixer la valeur de la variable aléatoire X à la constante x.

Exercice – Espérance conditionnelle d'un produit de variables (•) Calculer $\mathbb{E}(XY|X = x)$ puis $\mathbb{E}(XY|X)$.

3.1. Exemple : vecteurs Gaussiens à densité

Dans ce qui précède, on a décrit les lois et les espérances conditionnelles dans le cas d'un couple de variables aléatoires à valeurs dans $\mathbb{R}^2$. Ces résultats sont aussi valables pour des couples de vecteurs, dont on décrit ici un cas particulier.

Dans le cas des vecteurs gaussiens à densité, c'est-à-dire dont la matrice de covariance est définie positive et donc inversible, le calcul des lois conditionnelles de certaines composantes par rapport aux autres est particulièrement aisé. On va voir en particulier que les lois conditionnelles ont le bon goût d'être elles-mêmes gaussiennes, ce qui explique (en partie) le succès de ces modèles dans les applications.

On considère un vecteur gaussien $X = (X_1, \ldots, X_n)$ à valeurs dans $\mathbb{R}^n$ d'espérance m et de matrice de covariance C définie positive. On a vu au chapitre 2 que la densité du vecteur X s'écrit pour $x \in \mathbb{R}^d$:

$$f_X(x) = \frac{1}{(2\pi)^{n/2}\sqrt{\det(C)}} \exp\left(-\frac{1}{2}(x-m)^t C^{-1}(x-m)\right)$$

Soit $1 \leq k < n$ un entier. On souhaite exprimer $f_{Y|Z=z}$, la densité conditionnelle de $Y = (X_1, \ldots, X_k)$ sachant $Z = (X_{k+1}, \ldots, X_n) = (x_k, \ldots, x_n) = z$ (si $k + 1 = n$, ce vecteur se réduit à une seul valeur). On a vu que

$$f_X = f_{Y|Z=z} f_Z,$$

où f_Z est la densité marginale de Z. On cherche donc à décomposer f_X de la sorte. On note

$m = (m_Y, m_Z)$ et on remarque que C peut se décomposer en blocs :

$$C = \begin{pmatrix} C_Y & C_{Y,Z} \\ C_{Z,Y} & C_Z \end{pmatrix}$$

où $C_Y = \mathrm{Cov}(Y,Y)$, $C_Z = \mathrm{Cov}(Z,Z)$ et $C_{Y,Z} = \mathrm{Cov}(Y,Z)$. Le *complément de Schur*[1] du bloc C_Y est la matrice

$$CS_Y = C_Y - C_{Y,Z}C_Z^{-1}C_{Z,Y}$$

et permet d'exprimer l'inverse de C comme :

$$C^{-1} = \begin{pmatrix} CS_Y^{-1} & -CS_Y^{-1}C_{Y,Z}C_Z^{-1} \\ -C_Z^{-1}C_{Z,Y}CS_Y^{-1} & C_Z^{-1} + C_Z^{-1}C_{Z,Y}CS_Y^{-1}C_{Y,Z}C_Z^{-1} \end{pmatrix}$$

On peut alors réarranger les termes de la forme quadratique dans f_X et on obtient :

$$\begin{aligned}(x-m)^t C^{-1}(x-m) = &\Big(y - (m_Y + C_{Y,Z}C_Z^{-1}(z-m_Z))\Big)^t CS_Y^{-1} \\ &. \Big(y - (m_Y + C_{Y,Z}C_Z^{-1}(z-m_Z))\Big) \\ &+ (z-m_Z)^t C_Z^{-1}(z-m_Z)\end{aligned}$$

Pour la constante, on peut remarquer que :

$$\det(C) = \det(CS_Y)\det(C_Z).$$

On en déduit ainsi que

$$f_{Y|Z=z}(y) = \frac{1}{(2\pi)^{k/2}\sqrt{\det(CS_Y)}} \exp\left(-\frac{1}{2}\left(y-\psi(z)\right)^t CS_Y^{-1}\left(y-\psi(z)\right)\right)$$

C'est-à-dire que la variable aléatoire $Y|Z=z$ est gaussienne d'espérance $m_{Y|Z=z} = \psi(z) = m_Y + C_{Y,Z}C_Z^{-1}(z-m_Z)$ et de matrice de covariance $CS_Y = C_Y - C_{Y,Z}C_Z^{-1}C_{Z,Y}$. Autrement dit, l'espérance conditionnelle de Y sachant Z est la variable aléatoire $\mathbb{E}(Y|Z) = \psi(Z) = (m_Y + C_{Y,Z}C_Z^{-1}(Z-m_Z))$. On notera que la covariance conditionnelle donnée par CS_Y ne dépend pas de la valeur prise par Z.

4. Régression et espérance conditionnelle des variables de carré intégrable

La régression est un ensemble de méthodes (d'apprentissage) statistiques très utilisées pour analyser la relation d'une variable par rapport à une ou plusieurs autres. Ces méthodes visent notamment à décrire les liens de dépendance entre variables mais aussi à prédire au mieux la valeur d'une quantité non observée en fonction d'une ou plusieurs autres variables.

Pour fixer les idées, supposons que l'on s'intéresse au lien entre une variable d'intérêt Y et une variable explicative X dans le but de prédire la valeur de Y étant donnée l'observation de X. Le but est alors de proposer une certaine fonction $f : \mathbb{R} \to \mathbb{R}$ qui permette d'approximer Y par $f(X)$. Une telle fonction f est appelée un *prédicteur* de Y en fonction de X.

On va montrer dans cette section que, dans le cadre des variables de carré intégrable, une solution naturelle à ce problème est précisément donnée par l'espérance conditionnelle de Y sachant X. Nous nous appuierons pour ce faire sur une interprétation géométrique de l'espérance conditionnelle en tant que projection orthogonale dans un espace de Hilbert. Cette approche justifie en particulier l'usage des méthodes de moindres carrés dans les problèmes de régression.

1. voir par exemple l'excellent matrix cookbook.

4.1. Rappels sur les espaces de Hilbert et application en probabilités

Soit $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé. On rappelle que par définition, une variable aléatoire Y sur cet espace est une fonction $\mathcal{A}$-mesurable $Y : \Omega \to \mathbb{R}$. On considère alors l'espace fonctionnel $L^2(\Omega)$ introduit dans le cours de calcul intégral. Pour rappel, cet espace contient l'ensemble des fonctions $\mathcal{A}$-mesurables (i.e. des variables aléatoires) Y telles que $|Y|^2$ soit intégrable c'est-à-dire telles que

$$\|Y\|_2 = \left(\int_\Omega |Y(\omega)|^2 d\mathbb{P}(\omega) \right)^{1/2} = \mathbb{E}(Y^2)^{1/2} < \infty.$$

En particulier, contrairement à l'espace $\mathcal{L}^2$ introduit au chapitre précédent, dans l'espace $L^2(\Omega)$ les fonctions égales $\mathbb{P}$-presque partout sont confondues. C'est-à-dire que deux fonctions X et Y égales $\mathbb{P}$-presque partout correspondent à un même élément de $L^2(\Omega)$ appelé classe d'équivalence. Ainsi, pour $X, Y \in L^2(\Omega)$, l'égalité $X = Y$ signifiera donc que X et Y sont dans la même classe d'équivalence, autrement dit que les variables X et Y sont égales presque sûrement.

On a vu dans le cours de calcul intégral que l'espace $L^2(\Omega)$, muni de la norme $\|\cdot\|_2$, était un espace de Banach, c'est-à-dire un espace vectoriel normé et complet pour cette norme. On va maintenant introduire un produit scalaire sur cet espace, dont la norme associée sera précisément la norme $\|\cdot\|_2$, et montrer que $L^2(\Omega)$ est ainsi un espace de Hilbert.

On considère à cet effet l'application bilinéaire $\langle \cdot | \cdot \rangle$ définie par

$$\langle X|Y \rangle = \int_\Omega X(\omega)Y(\omega) d\mathbb{P}(\omega) = \mathbb{E}(XY), \quad X, Y \in L^2(\Omega).$$

L'application $\langle \cdot | \cdot \rangle$ est bien définie puisque, d'après l'inégalité de Cauchy-Schwartz, on a pour tous $X, Y \in L^2(\Omega)$:

$$\langle X|Y \rangle^2 = \mathbb{E}(XY)^2 \leq \mathbb{E}(X^2)\mathbb{E}(Y^2) = \|X\|_2^2 \|Y\|_2^2 < \infty.$$

De plus, l'application $\langle \cdot | \cdot \rangle$ définit un produit scalaire sur $L^2(\Omega)$ car elle vérifie les propriétés suivantes pour tous $X, Y \in L^2(\Omega)$:

- Symétrique: $\langle X|Y \rangle = \mathbb{E}(XY) = \mathbb{E}(YX) = \langle X|Y \rangle$,
- Positive: $\langle X|X \rangle = \mathbb{E}(X^2) \geq 0$,
- Définie: $\langle X|X \rangle = 0 \Leftrightarrow \mathbb{E}(X^2) = 0 \Leftrightarrow X = 0$.

On remarque enfin que la norme associée au produit scalaire $\langle \cdot | \cdot \rangle$ est bien la norme $\|\cdot\|_2$ introduite précédemment (car pour tout $X \in L^2(\Omega)$, $\langle X|X \rangle^{1/2} = \mathbb{E}(X^2)^{1/2} = \|X\|_2$). On en déduit que l'espace $L^2(\Omega)$ muni du produit scalaire $\langle \cdot | \cdot \rangle$ est un espace de Hilbert.

L'intérêt de travailler avec un espace de Hilbert est qu'il est possible d'y définir de manière univoque la notion de projection orthogonale. En effet, la projection orthogonale d'un élément $Y \in L^2(\Omega)$ sur un sous-espace convexe, fermé et non-vide $K \subset L^2(\Omega)$ est définie comme l'unique élément $P_K(Y) \in K$ qui minimise la distance $\|Y - P_K(Y)\|_2$, autrement dit l'erreur des moindres carrés $\mathbb{E}((Y - P_K(Y))^2)$ entre Y et les éléments de K. On retrouve en particulier l'objectif de prédiction décrit en introduction, ce qui permet de conclure que la projection orthogonale $P_K(Y)$ est le prédicteur optimal de Y au sens des moindres carrés parmi les éléments de K. On en déduit la propriété suivante qui permet de caractériser ce prédicteur optimal d'après les propriétés de la projection orthogonale vues dans le cours de calcul intégral.

Proposition – Prédicteur optimal sur un convexe fermé.

Soit $Y \in L^2(\Omega)$ et soit $K \subset L^2(\Omega)$ convexe, fermé et non-vide. Le prédicteur optimal, au

sens des moindres carrés, de Y sur K est la projection orthogonale de Y sur K. Il est donc caractérisé comme étant l'unique élément de K vérifiant la propriété

$$\langle Y - P_K(Y) | U - P_K(Y) \rangle \leq 0 \quad \forall\, U \in K.$$

Si de plus K est un sous-espace vectoriel, cette caractérisation prend une forme plus simple, à savoir:

$$\langle Y - P_K(Y) | U \rangle = 0 \quad \forall\, U \in K.$$

Pour revenir à notre problème initial de prédiction optimale de Y par une fonction de X, il s'agit donc de choisir le sous-espace K de projection de manière à ce qu'il ne contienne que des éléments s'exprimant comme des fonctions de X, et d'identifier parmi les éléments de K celui qui satisfait la propriété ci-dessus (p. 74).

4.2. Cas particulier: la régression linéaire

Reprenons les variables $X, Y \in L^2(\Omega)$ introduites en début de section, et le problème initial de prédiction de Y à partir de X. Dans cette sous-section, nous nous restreignons à des prédicteurs affines, c'est-à-dire que nous souhaitons trouver la meilleure approximation, au sens des moindres carrés, de Y par une fonction affine de X de la forme $f(X) = aX + b$. Un tel prédicteur est appelé *régression linéaire de Y par X*.

Tout prédicteur affine $f(X) = aX + b$ peut être vu comme une combinaison linéaire de deux variables aléatoires de $L^2(\Omega)$: X, et la variable aléatoire 1 égale à 1 presque sûrement. Par conséquent, $f(X) \in K$ où K désigne le sous-espace vectoriel de $L^2(\Omega)$ engendré par $X \in L^2(\Omega)$ et $1 \in L^2(\Omega)$. Ainsi, trouver un prédicteur affine optimal de Y revient à trouver un prédicteur optimal de Y dans le sous-espace vectoriel K.

K étant un sous-espace vectoriel fermé de $L^2(\Omega)$ (car de dimension finie), la propriété de caractérisation (p. 74) du prédicteur optimal permet de conclure que le prédicteur affine optimal de Y par X est la projection orthogonale $P_K(Y)$ de Y sur K. En particulier, puisque tout élément de K est une combinaison linéaire de X et 1, on peut écrire que $P_K(Y) = a^*X + b^*1$, où les coefficients a^*, b^* vérifient:

$$\langle Y - (a^*X + b^*1) | aX + b1 \rangle = 0 \quad \forall a, b \in \mathbb{R},$$

Cette égalité devant être vérifiée pour tous $a, b \in \mathbb{R}$, elle implique, par bilinéarité du produit scalaire, que les coefficients a^* et b^* soient solutions du système:

$$\begin{cases} \langle Y | X \rangle - a^* \langle X | X \rangle - b^* \langle 1 | X \rangle = 0 \\ \langle Y | 1 \rangle - a^* \langle X | 1 \rangle - b^* \langle 1 | 1 \rangle = 0 \end{cases}$$

Par définition du produit scalaire $\langle \cdot | \cdot \rangle$, ce système se réécrit sous la forme:

$$\begin{cases} \mathbb{E}(XY) = a^* \mathbb{E}(X^2) + b^* \mathbb{E}(X) \\ \mathbb{E}(Y) = a^* \mathbb{E}(X) + b^* \end{cases}$$

et a pour solution

$$\begin{aligned} a^* &= \frac{\mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)}{\mathbb{E}(X^2) - \mathbb{E}(X)^2} = \frac{\mathrm{Cov}(X, Y)}{\mathbb{V}(X)} = \rho(X, Y) \frac{\sigma_Y}{\sigma_X} \\ b^* &= \mathbb{E}(Y) - a^*\ \mathbb{E}(X) \end{aligned}$$

En conclusion, le meilleur prédicteur affine, au sens des moindres carrés, de Y par X est la fonction $f^*(X)$ définie par

$$f^*(X) = P_K(Y) = a^*X + b^* = \mathbb{E}(Y) + \rho(X,Y)\frac{\sigma_Y}{\sigma_X}(X - \mathbb{E}(X)),$$

et l'erreur quadratique moyenne associée à ce prédicteur vaut:

$$\begin{aligned}\mathbb{E}\left((Y - f^*(X))^2\right) &= \sigma_Y^2 + \rho^2(X,Y)\sigma_Y^2 - 2\rho^2(X,Y)\sigma_Y^2 \\ &= \sigma_Y^2(1 - \rho^2(X,Y)).\end{aligned}$$

On voit ainsi que cette erreur est proche de 0 lorsque $|\rho(X,Y)| \approx 1$ tandis qu'elle est proche de $\mathbb{V}(Y) = \sigma_Y^2$ lorsque $\rho(X,Y) \approx 0$. On notera au passage qu'on obtient que la meilleure approximation de Y par une constante (ce qui revient à prendre $X = 0$) est son espérance.

Exercice – Une deuxième approche (•) Montrer que les coefficients a^* et b^* sont les uniques minimiseurs de l'erreur $\ell(a,b) = \mathbb{E}((Y - (aX + b))^2)$, pour $a, b \in \mathbb{R}$.

Remarque – Limites de la régression linéaire.

L'hypothèse d'une relation linéaire est très forte et pas nécessairement toujours adaptée pour expliquer des relations de dépendances entre variables. Soit en effet une variable aléatoire réelle X de $\mathcal{L}^3$ (i.e. X^3 est $\mathbb{P}_X$ intégrable) symétrique, c'est-à-dire telle que X et $-X$ sont de même loi. On a alors $\mathbb{E}(X) = -\mathbb{E}(X) = 0$. Les variables X et X^2 ne sont clairement pas indépendantes. Pour autant, on a $\mathrm{Cov}(X, X^2) = \mathbb{E}(X^3) = -\mathbb{E}(X^3) = 0$ et le coefficient de régression a^* est nul.

4.3. Cas général

Dans le paragraphe précédent, on s'est intéressé à approximer une variable aléatoire $Y \in L^2(\Omega)$ par une fonction affine d'une autre variable $X \in L^2(\Omega)$. On va montrer ici que si on généralise la recherche du prédicteur optimal à l'ensemble des fonctions f telles que $f(X)$ est de carré intégrable, la solution est donnée par l'espérance conditionnelle $\psi(X) = \mathbb{E}(Y|X)$.

En effet, considérons le sous-espace $L^2_X(\Omega) \subset L^2(\Omega)$ constitué des (classes d'équivalence) des variables aléatoires de la forme $f(X)$, avec $f : \mathbb{R} \to \mathbb{R}$ borélienne et telle que $f(X) \in L^2(\Omega)$. On remarque que $L^2_X(\Omega)$ est sous-espace vectoriel de $L^2(\Omega)$. On admettra par ailleurs que $L^2_X(\Omega)$ est fermé. Par conséquent, le prédicteur optimal de Y dans $L^2_X(\Omega)$ est donné par la projection orthogonale de Y sur $K = L^2_X(\Omega)$, et on peut une nouvelle fois appliquer la propriété de caractérisation (p. 74) associée pour l'identifier.

On note par ailleurs que l'espérance conditionnelle $\psi(X) = \mathbb{E}(Y|X) \in L^2_X(\Omega)$ et que pour tout $f(X) \in L^2_X(\Omega)$,

$$\begin{aligned}\langle Y - \psi(X)|f(X)\rangle = \mathbb{E}\big((Y - \psi(X))f(X)\big) &= \mathbb{E}\big(Yf(X)\big) - \mathbb{E}\big(\mathbb{E}(Y|X)f(X)\big) \\ &= \mathbb{E}\big(Yf(X)\big) - \mathbb{E}\big(\mathbb{E}(Yf(X)|X)\big) \\ &= \mathbb{E}\big(Yf(X)\big) - \mathbb{E}\big(Yf(X)\big) = 0\end{aligned}$$

où la seconde égalité se déduit du fait que $f(X)$ est $\mathbb{P}$-intégrable, et la troisième découle du théorème de l'espérance totale. Ainsi l'espérance conditionnelle vérifie la propriété de caractérisation (p. 74) et par unicité de la projection orthogonale, on en déduit que $P_{L^2_X(\Omega)}(Y) = \psi(X)$.

En conclusion, l'espérance conditionnelle $\mathbb{E}(Y|X)$ est le meilleur prédicteur de Y au sens des moindres carrés parmi les fonctions de X. On notera qu'en pratique, dans les problèmes

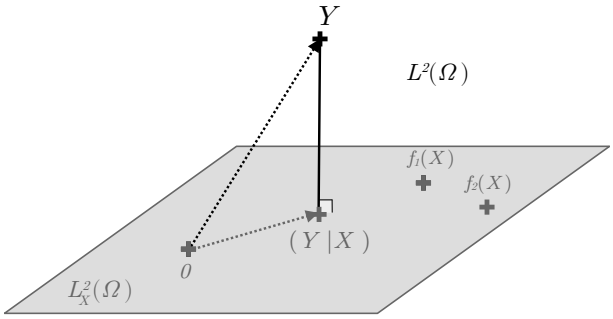


FIGURE 4.1. – Illustration géométrique de l'espérance conditionnelle comme projection orthogonale sur un sous-espace de $L^2(\Omega)$

de régression, on se restreint souvent à des classes de fonctions paramétrées (par exemple les fonctions affines vues précédemment, ou les réseaux de neurones dans l'apprentissage profond) car on ne dispose que rarement de l'expression explicite de l'espérance conditionnelle.

Il est ensuite immédiat que le "résidu" $Y - \mathbb{E}(Y|X)$ est non corrélé avec X du fait de l'orthogonalité. On en déduit ainsi la *formule de la variance totale* :

$$\begin{aligned}
\mathbb{V}(Y) = \|Y - \mathbb{E}(Y)\|^2 &= \|Y - \mathbb{E}(Y|X) + \mathbb{E}(Y|X) - \mathbb{E}(Y)\|^2 \\
&= \|Y - \mathbb{E}(Y|X)\|^2 + \|\mathbb{E}(Y|X) - \mathbb{E}(Y)\|^2 \\
&= \mathbb{E}((Y - \mathbb{E}(Y|X))^2) + \mathbb{E}((\mathbb{E}(Y|X) - \mathbb{E}(Y))^2) \\
&= \mathbb{E}(\mathbb{E}((Y - \mathbb{E}(Y|X))^2|X)) + \mathbb{V}(\mathbb{E}(Y|X)) \\
&= \mathbb{E}(\mathbb{V}(Y|X)) + \mathbb{V}(\mathbb{E}(Y|X)).
\end{aligned}$$

où on a utilisé la formule de l'espérance totale et introduit la variable aléatoire variance conditionnelle $\mathbb{V}(Y|X) = \mathbb{E}((Y - \mathbb{E}(Y|X))^2|X)$ comme cas particulier de la définition vue plus haut (p. 71). Cette décomposition est illustrée dans la figure ci-après (p. 77).

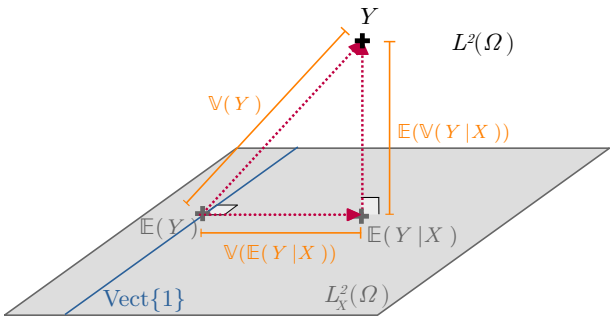


FIGURE 4.2. – Illustration géométrique de la formule de la variance totale. L'espace Vect$\{1\}$ désigne le sous-espace de $L^2(\Omega)$ composé des variables aléatoires p.s. constantes.

Exercice – Variance totale (•) Démontrer ce résultat sans utiliser la notion d'orthogonalité.

5. Exercices

5.1. Couple de variables

Soient X et Y deux v.a. réelles. On suppose que la densité conditionnelle de X sachant $Y = y$ est la densité $1_{\mathbb{R}_+}(x)y^2xe^{-xy}$ et que la loi de Y est de densité $\frac{1}{y^2}1_{[1,+\infty[}(y)$. On pose $T = XY$.

Question 1 Trouver la loi du couple (T, Y). Qu'en déduit-on ?

Question 2 Trouver la loi conditionnelle de Y sachant $X = x$.

Question 3 Calculer $E(Y|X)$.

5.2. Mélanges de lois

Adapté du cours de probabilités de S. Bonnabel et M. Schmidt (MINES ParisTech).

Pour modéliser un phénomène multimodal, on utilise souvent des mélanges de gaussiennes. C'est le cas notamment en classification non-supervisée, où on fait l'hypothèse que chacune des classes suit une loi gaussienne. Soient $n \in \mathbb{N}^*$ et K une variable aléatoire prenant les valeurs $1, \dots, n$ avec les probabilités non nulles $p_1, \dots, p_n$ telles que $\sum_{i=1}^n p_i = 1$. Soient $X_1, \dots, X_n$ des variables aléatoires gaussiennes mutuellement indépendantes, d'espérances respectives $m_1, \dots, m_n \in \mathbb{R}$ et de variances respectives $\sigma_1^2, \dots, \sigma_n^2 \in \mathbb{R}_+^*$, toutes indépendantes de K. On appelle mélange de gaussiennes la loi de la variable aléatoire $X = X_K$. Pour tout $i \in \{1, \dots, n\}$, on notera f_i la densité de la variable aléatoire X_i.

Question 1 Soit $i \in \{1, \dots, n\}$. Quelle est la densité $f_{X|K=i}$ de X conditionnellement à l'événement $\{K = i\}$?

Question 2 Calculer la densité de probabilité de la variable X.

Question 3 Calculer $\mathbb{E}(X)$. Montrer que $\mathbb{V}(X) = \sum_{i=1}^n p_i\sigma_i^2 + \bar{\sigma}^2$, où ce dernier terme peut être interprété comme la dispersion des espérances.

Question 4 Comment approximeriez-vous le mélange par une unique gaussienne ? Faire un schéma dans le cas $m = 2$.

5.3. Lois conjuguées

Soit un vecteur aléatoire (X, Y) de loi jointe $\mathbb{P}_{X,Y}$. Expliciter la loi conditionnelle de Y sachant $\{X = x\}$ dans les situations suivantes, en prenant soin d'expliciter pour quelles valeurs de x ces dernières ont du sens.

Question 1 Y suit une loi Exponentielle de paramètre $\lambda \in \mathbb{R}_+^*$ et pour tout $y \in \mathbb{R}_+^*$, la variable aléatoire X sachant $\{Y = y\}$ suit une loi Exponentielle de paramètre y.

Question 2 Y suit une loi Gamma de paramètres $\alpha, \theta \in \mathbb{R}_+^*$ et pour tout $y \in \mathbb{R}_+^*$, la variable aléatoire X sachant $\{Y = y\}$ suit une loi de Poisson de paramètre y.

5.4. Randomisation

Extrait du cours de probabilités de S. Bonnabel et M. Schmidt (MINES ParisTech).

Des clients arrivent à la boutique SNCF du boulevard Saint-Michel à des instants aléatoires. On note T_0 l'heure d'ouverture puis $T_1, T_2, \dots$ les temps successifs d'arrivée des clients jusqu'à l'heure de fermeture. Les études statistiques montrent qu'on peut, dans une tranche horaire donnée, supposer que les temps d'attente $X_1 = T_1 - T_0, X_2 = T_2 - T_1, \dots$ peuvent être modélisés par des variables aléatoires indépendantes et de même loi qu'une variable aléatoire positive X. Par ailleurs, une loterie interne décide que chaque jour dans la tranche horaire considérée, le $N^{\text{ème}}$ client sera l'heureux gagnant d'un trajet gratuit Paris-La Ciotat, où N est une variable aléatoire bornée dont la loi dépend du processus de loterie (e.g. tous les clients entre le premier et le $30^{\text{ème}}$ ont une chance $1/30$ d'être tirés au sort, en supposant qu'on est sûr d'avoir au moins 30 clients dans la tranche horaire).

On se demande alors : quel est le temps d'attente moyen avant d'obtenir un gagnant ?

5.5. Etats cachés — indépendance conditionnelle

Soucieux de l'évolution du potager de l'école, des élèves à la main verte s'intéressent à l'évolution de la température dans le jardin côté Luxembourg. Ils récupèrent pour cela un thermomètre dans un laboratoire, l'installent près du potager, et en relèvent les mesures à intervalles de temps réguliers. Les résultats les surprennent rapidement : les températures affichées ne correspondent pas à celles prévues par météo-France. Leur thermomètre est sans doute déréglé.

On se propose de les aider à comprendre le phénomène dont ils sont témoins à l'aide d'un modèle probabiliste particulier, nommé *modèle de Markov caché*. Précisément, on considère la suite des vraies températures que l'on aurait souhaité relever comme une suite de v.a.r. non indépendantes $(X_n)_{n\in\mathbb{N}^*}$, dite *d'états cachés* (on ne les observe pas directement). Les erreurs commises par le thermomètre sont quant à elles modélisées par une suite de v.a.r. $(\epsilon_n)_{n\in\mathbb{N}^*}$, toutes indépendantes et de même loi admettant une densité f_ϵ. Elles sont supposées indépendantes de la suite $(X_n)_{n\in\mathbb{N}^*}$ (l'erreur du thermomètre lui est propre et ne dépend pas de la température réelle). A chaque instant $n \in \mathbb{N}^*$, on suppose que la mesure du thermomètre est la variable aléatoire

$$Y_n = X_n + \epsilon_n,$$

et que le vecteur aléatoire $(X_1, \dots, X_n)$ possède une densité jointe notée $f_{1:n}$.

Question 1 Montrer que pour tout $n \in \mathbb{N}^*$ et tout $x \in \mathbb{R}$, la loi de Y_n sachant $\{X_n = x\}$ admet une densité, que l'on explicitera.

Question 2 Montrer que les $n \in \mathbb{N}^*$ relevés de température $Y_1, \dots, Y_n$ sont indépendants **conditionnellement** aux états cachés $X_1, \dots, X_n$.

5.6. Covariance totale

Soient X, Y et Z trois variables aléatoires réelles de carré intégrable. La covariance conditionnelle de X et Y sachant Z est définie comme la variable aléatoire

$$\mathrm{Cov}(X, Y \mid Z) = \mathbb{E}\Big(\big(X - \mathbb{E}(X \mid Z)\big)\big(Y - \mathbb{E}(Y \mid Z)\big) \;\Big|\; Z\Big).$$

Etablir la formule de la covariance totale :

$$\mathrm{Cov}(X, Y) = \mathbb{E}\big(\mathrm{Cov}(X, Y \mid Z)\big) + \mathrm{Cov}\big(\mathbb{E}(X \mid Z), \mathbb{E}(Y \mid Z)\big).$$

5.7. Débruitage (formule de Tweedie)

Les photographies sont souvent entâchées d'un bruit qui dégrade leur qualité, notamment lorsque la lumière est faible. Pour améliorer le rendu, des algorithmes de débruitage sont mis en oeuvre. Dans cet exercice, on se propose de donner un éclairage probabiliste sur ce problème.

On considère que l'image d'intérêt X est un vecteur aléatoire de $\mathbb{R}^d$ de densité f_X (quitte à réarranger les pixels et les canaux RGB) et que le bruit Z est de densité f_Z, gaussienne, centrée, de covariance Σ. L'image bruitée peut donc être représentée par $Y = X + Z$.

Question 1 Exprimer la densité f_Y de Y en fonction de f_X et f_Z.

Question 2 Calculer le gradient de $\log f_Y$, que l'on appelle aussi le score de la loi de Y.

Question 3 En déduire une expression de $\mathbb{E}(X|Y)$ ne faisant pas intervenir la densité f_X.

Cette propriété est particulièrement intéressante en pratique puisque pour ce type de problèmes, on ne dispose généralement que d'obervations bruitées qui vont nous permettre d'approximer les quantités nécessaires pour effectuer ce calcul selon une approche statistique. Elle est par ailleurs au coeur des algorithmes modernes de génération d'image.

5.8. Non-réponse

Inspiré du cours de probabilité de M. Christine (ENSAE ParisTech).

Un questionnaire est diffusé aux $n \in \mathbb{N}^*$ étudiants de l'école pour savoir combien de temps ils ont consacré à l'étude des probabilités ce semestre. On note Y_i le temps de travail de l'étudiant $i \in \{1, \dots, n\}$ et X_i la variable valant 1 s'il a répondu au questionnaire et 0 sinon. On suppose que les $(X_1, Y_1), \dots, (X_n, Y_n)$ sont des vecteurs aléatoires indépendants de même distribution qu'un vecteur générique (X, Y) tel que

- X est une variable de Bernoulli de paramètre $p \in]0, 1[$ indiquant la probabilité de réponse,
- Y est positive, de carré intégrable, d'espérance $m \in \mathbb{R}_+$ et de variance $\sigma^2 \in \mathbb{R}_+^*$. Le coefficient de corrélation entre X et Y est enfin noté $\rho \in [-1, 1]$.

Question 1 En reprenant la définition de l'espérance conditionnelle $\mathbb{E}(Y \mid X)$ comme meilleure approximation au sens des moindres carrés de Y par une fonction de X, montrer qu'elle coïncide ici avec l'approximation affine de Y par X puis l'écrire en fonction de m, ρ, σ et p.

Question 2 On pose $m_0 := \mathbb{E}(Y \mid X = 0)$ et $m_1 = \mathbb{E}(Y \mid X = 1)$. Calculer m_0 et m_1 en fonction de m, ρ, σ et p.

Question 3 On pose $\sigma_0^2 := \mathbb{V}(Y \mid X = 0)$ et $\sigma_1^2 := \mathbb{V}(Y \mid X = 1)$. Vérifier l'égalité

$$\sigma^2 = \frac{(1-p)\,\sigma_0^2 + p\,\sigma_1^2}{1-\rho^2}.$$

Question 4 Que dire des résultats obtenus aux questions 2 et 3 lorsque :

- X et Y sont non corrélées,
- X et Y sont indépendantes ?

---

6. Références

Quatrième partie

Probabilités IV : Convergences

1. Objectifs d'apprentissage

Cette section s'efforce d'expliciter et de hiérarchiser les acquis d'apprentissages associés au chapitre. Ces objectifs sont organisés en paliers :
(○) Prérequis (•) Fondamental (••) Standard (•••) Avancé (••••) Expert
Sauf mention particulière, la connaissance des démonstrations du document n'est pas exigible [1]

Préambule

- • connaître la définition des espaces $\mathcal{L}^p$
- •• connaître la propriété d'inclusion dans les espaces $\mathcal{L}^p$
- • connaître l'inégalité de Markov
- • connaître l'inégalité de Bienaymé-Chebyshev

Suites de v.a. indépendantes

- •••• connaître le théorème d'existence et d'unicité de la mesure produit sur les espaces produit de dimension infinie
- •• connaître la définition d'une suite de variables aléatoires indépendantes
- •• connaître et savoir utiliser le lemme de Borel-Cantelli

Convergence et loi des grands nombres

- •• connaître les différents modes de convergence des suites de v.a.
- ••• savoir caractériser le(s) mode(s) de convergence d'une suite de v.a.
- •• connaître les liens d'implication entre les différents modes de convergence
- •• connaître la propriété de continuité
- • connaître la loi faible des grands nombre
- • connaître la loi forte des grands nombre (sous les hypothèses minimales)

Convergence en loi et théorème central limite

- • connaître la définition de la convergence en loi
- • savoir que la convergence en probabilité implique la convergence en loi
- •• savoir que la convergence simple des fonctions de répartition équivaut à la convergence en loi
- • connaître et savoir utiliser le théorème central limite

2. Préambule

Dans ce chapitre, on va s'intéresser à l'étude des suites de variables aléatoires. On introduira notamment différents modes de convergence. En particulier, on établira la *loi des grands nombres* qui montre rigoureusement que, quand le nombre de répétitions de l'expérience tend vers l'infini,

1. l'étude des démonstrations du cours peut toutefois contribuer à votre apprentissage, au même titre que la résolution d'exercices.

la fréquence de réalisation d'un événement converge vers la probabilité de réalisation de cet événement. Ce résultat justifie également la démarche employée en statistique où l'on cherche par exemple à estimer une espérance par une moyenne empirique : cette moyenne empirique va ainsi converger vers la quantité ciblée. Enfin, on présentera le théorème central limite qui nous indiquera la vitesse à laquelle cette convergence a lieu ainsi qu'un moyen de contrôler l'erreur commise en remplaçant une espérance par sa contrepartie empirique.

Notons d'abord qu'on peut étendre les définitions des espaces $\mathcal{L}^1$ et $\mathcal{L}^2$ pour un $p \in \mathbb{N}^*$ quelconque.

Définition – Espace $\mathcal{L}^p$.

Soit X une variable aléatoire. On note $X \in \mathcal{L}^p$, ou $\mathcal{L}^p(\Omega, \mathcal{A}, \mathbb{P})$, si et seulement si $\mathbb{E}(|X|^p) = \int_{\mathbb{R}} |x|^p \mathbb{P}_X(dx) = \int_\Omega |X|^p(\omega)\mathbb{P}(d\omega) < +\infty$.

Si $X \in \mathcal{L}^p$, on dit qu'elle admet un moment d'ordre p. Du fait que $\mathbb{P}$ est une mesure finie, on a la stabilité par inclusion suivante :

Proposition – Inclusion.

Soit $p \in \mathbb{N}^*$, on a l'inclusion :

$$\mathcal{L}^{p+1}(\Omega, \mathcal{A}, \mathbb{P}) \subset \mathcal{L}^p(\Omega, \mathcal{A}, \mathbb{P})$$

Démonstration. Supposons $X \in \mathcal{L}^{p+1}(\Omega, \mathcal{A}, \mathbb{P})$. On a

$$|X|^p \leq \max(1, |X|^{p+1}) = 1_{|X|<1} + 1_{|X|\geq 1}|X|^{p+1}.$$

Le terme de droite est intégrable, en effet :

$$\mathbb{E}\left(1_{|X|<1} + 1_{|X|\geq 1}|X|^{p+1}\right) \leq \int_\Omega \mathbb{P}(d\omega) + \int_\Omega |X(\omega)|^{p+1}\mathbb{P}(d\omega) = 1 + \mathbb{E}(|X|^{p+1}).$$

donc $|X|^p$ est intégrable. ■

On donne ici dans le cas général les inégalités de Markov et de Bienaymé-Chebyshev, déjà vues en CPGE.

Théorème – Inégalité de Markov.

Soient $p \in \mathbb{N}^*$ et $a \in \mathbb{R}_+^*$. Soit $X \in \mathcal{L}^p(\Omega, \mathcal{A}, \mathbb{P})$, on a

$$\mathbb{P}(|X| \geq a) \leq \frac{\mathbb{E}(|X|^p)}{a^p}$$

Démonstration. On a

$$|X|^p \geq a^p 1_{[a,+\infty[}(|X|)$$

et en prenant l'espérance, on obtient ainsi

$$\mathbb{E}(|X|^p) \geq a^p \mathbb{E}(1_{[a,+\infty[}(|X|)) = a^p \mathbb{P}(|X| \geq a).$$

■

Corollaire – Inégalité de Bienaymé-Chebyshev.

Soit $X \in \mathcal{L}^2$, on a

$$\mathbb{P}(|X - \mathbb{E}(X)| \geq a) \leq \frac{\mathbb{V}(X)}{a^2}$$

Exercice – Démonstration (•)

Remarque – Interprétation.

L'inégalité de Bienaymé-Chebyshev est très utile en pratique. Elle permet de mesurer la probabilité des grands écarts entre X et sa moyenne. Par exemple, avec $a = 10\sigma$, il en résulte qu'il est improbable qu'une variable aléatoire X dévie de son espérance $\mathbb{E}(X)$ de plus de 10 fois son écart-type (la probabilité est inférieure à 0.01). Cette inégalité, tout à fait générale, n'est cependant pas très précise, et surestime très souvent en pratique le membre de gauche. On préférera, quand c'est possible, calculer directement ces probabilités à partir de la loi de X.

3. Suites de variables indépendantes

Au début du chapitre II, nous avons vu comment construire des couples (et même des n-uplets en itérant) de variables aléatoires réelles indépendantes en considérant l'espace produit, munis des tribus produit et des (mesures de) probabilités produit. Il est malheureusement beaucoup plus délicat, mais indispensable pour les applications (en particulier la loi des grands nombres), de construire une **suite infinie de variables indépendantes** de lois données.

Plus précisément, pour chaque entier n on se donne une v.a.r. X_n définie sur un espace de probabilité $(\Omega_n, \mathcal{A}_n, \mathbb{P}_n)$, à valeurs dans $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ et de loi $\mathbb{P}_{X_n}$ (pour construire chaque X_n, on peut procéder comme ci-dessus). Ensuite, on pose

$$\Omega = \prod_{n=1}^{\infty} \Omega_n \text{ (produit cartésien dénombrable)},$$
$$\mathcal{A} = \bigotimes_{n=1}^{\infty} \mathcal{A}_n,$$

où $\bigotimes_{n=1}^{\infty} \mathcal{A}_n$ désigne la plus petite tribu de Ω à laquelle appartienne tous les ensembles de la forme

$$A_1 \times A_2 \times \ldots \times A_k \times \Omega_{k+1} \times \Omega_{k+2} \times \ldots, \quad A_i \in \mathcal{A}_i, \quad k \in \mathbb{N}^*$$

On a alors le théorème suivant, que l'on admettra, qui constitue un résultat non trivial de la théorie de la mesure et qui généralise le théorème de Fubini.

Théorème – Mesure produit sur un espace de dimension infinie.

Avec les notations ci-dessus, il existe une unique probabilité $\mathbb{P}$ sur $(\Omega, \mathcal{A})$, telle que

$$\mathbb{P}(A_1 \times \ldots \times A_k \times \Omega_{k+1} \times \ldots) = \prod_{i=1}^{k} \mathbb{P}_i(A_i)$$

pour tous $k \in \mathbb{N}^*$ et $A_i \in \mathcal{A}_i$, $i \in \{1, \ldots, k\}$.

Nous sommes maintenant en mesure de définir une suite de variables aléatoires toutes définies sur le même espace de probabilité $(\Omega, \mathcal{A}, \mathbb{P})$.

Définition – Suites de variables aléatoires indépendantes.

La suite $(X_n)_{n\in\mathbb{N}^*}$ de variables aléatoires est dite *indépendante* si pour tout $n \in \mathbb{N}^*$, la famille finie $X_1, \ldots, X_n$ est indépendante.

Il est facile de vérifier que l'indépendance est préservée par certaines transformations.

Proposition – Conséquences.

L'indépendance de la suite $(X_n)_{n\in\mathbb{N}^*}$ entraîne celle de

1. *toute sous-suite $(X_{i_k})_{k\in\mathbb{N}^*}$,*
2. *toute suite de vecteurs issus de X_n,*
3. *toute suite de la forme $(f_n(X_n))_{n\in\mathbb{N}^*}$, où les fonctions f_n sont des fonctions mesurables.*

Exemple – Développement dyadique.

Nous considérons l'ensemble $\Omega = [0, 1[$ muni de la tribu borélienne restreinte à cet ensemble, et de la mesure de Lebesgue. A chaque réel ω, nous associons son développement dyadique (unique si l'on impose que les ω_i ne soient pas tous égaux à 1 à partir d'un certain rang) :

$$\omega = \sum_{i\in\mathbb{N}^*} \frac{\omega_i}{2^i}, \ \ \omega_i \in \{0, 1\}.$$

L'application $X_i : \Omega \to \{0, 1\}$, qui à ω associe $X_i(\omega) = \omega_i$ est une variable aléatoire sur Ω. En effet, pour $x_i \in \{0, 1\}$, $1 \leq i \leq n$,

$$\{X_i = x_i\} = \bigcup_{x_1,\ldots,x_{i-1}\in\{0,1\}} \left[\sum_{j=1}^{i} \frac{x_j}{2^j}, \sum_{j=1}^{i} \frac{x_j}{2^j} + \frac{1}{2^i}\right[,$$

qui est bien un élément de la tribu borélienne de $\Omega = [0, 1[$, et

$$\mathbb{P}(\{X_i = x_i\}) = \frac{1}{2^i} \sum_{x_1,\ldots,x_{i-1}\in\{0,1\}} 1 = \frac{1}{2}.$$

Montrons l'indépendance des variables aléatoires $(X_i)_{1\leq i\leq n}$. Nous avons

$$\bigcap_{1\leq i\leq n} \{X_i = x_i\} = \left[\sum_{i=1}^{n} \frac{x_i}{2^i}, \sum_{i=1}^{n} \frac{x_i}{2^i} + \frac{1}{2^n}\right[$$

si bien que

$$\mathbb{P}\left(\bigcap_{1\leq i\leq n}\{X_i = x_i\}\right) = \frac{1}{2^n} = \prod_{1\leq i\leq n}\mathbb{P}(\{X_i = x_i\}).$$

Cela démontre que les variables aléatoires X_i sont indépendantes et de loi de Bernoulli de paramètre $\frac{1}{2}$. Ainsi, nous venons de construire sur Ω une suite de variables aléatoires telle que toute sous-suite finie est constituée de variables aléatoires indépendantes. C'est donc une suite de variables aléatoires indépendantes de loi de Bernoulli de paramètre $\frac{1}{2}$.

On note enfin le résultat très utile suivant portant sur les suites d'événements indépendants.

Lemme – Borel-Cantelli.

Soit $(A_n)_{n\in\mathbb{N}^*}$ une suite d'événements sur l'espace probabilisé $(\Omega, \mathcal{A}, \mathbb{P})$.

1. *Si $\sum_{n=1}^{\infty}\mathbb{P}(A_n) < \infty$, alors $\mathbb{P}(\limsup_{n\to\infty} A_n) = \mathbb{P}\left(\bigcap_{n\geq 1}\bigcup_{k\geq n} A_k\right) = 0$.*
2. *Si $\sum_{n=1}^{\infty}\mathbb{P}(A_n) = \infty$ et si les événements A_n sont mutuellement indépendants, alors on a $\mathbb{P}(\limsup_{n\to\infty} A_n) = 1$.*

Démonstration. Exercice. ■

Exercice – Pile ou face infini (•) On considère un jeu de pile ou face infini où on a une probabilité $p, 0 < p < 1$, d'obtenir face. Montrer que l'événement $A = \{\omega :$ il n'y a qu'un nombre fini de faces$\}$ est de probabilité nulle. (Considérer les événements $A_n = \{$on a face au n-ième tirage$\}$, puis montrer que $\sum_{n=1}^{\infty}\mathbb{P}(A_n) = \infty$).

4. Convergences et loi des grands nombres

4.1. Convergences des variables aléatoires

Dans ce paragraphe, on va décrire les notions de convergence de variables (on y inclut les vecteurs) aléatoires. On verra que plusieurs notions sont possibles, non équivalentes, ce qui enrichit mais complique aussi la description des comportements asymptotiques.

En calcul intégral, on a beaucoup étudié le cas de suites de fonctions convergeant simplement. Une variable aléatoire étant une fonction, on a donc la même notion qui revient à écrire qu'une suite $(X_n)_{n\in\mathbb{N}^*}$ de variables aléatoires converge simplement vers X si $\lim_{n\to\infty} X_n(\omega) = X(\omega)$ pour tout $\omega \in \Omega$. Cette définition naturelle est malheureusement à peu près inutile en probabilités, comme l'illustre l'exemple suivant.

Exemple – Pile ou face infini (bis).

Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de v.a. réelles qui sont indépendantes et de même loi (on notera *i.i.d* pour *indépendantes et identiquement distribuées*), avec $\mathbb{P}(X_n = 1) = p$ et $\mathbb{P}(X_n = 0) = 1 - p$. Ce sont donc des v.a. de loi de Bernoulli de paramètre p qui modélisent par exemple les résultats d'un jeu de pile ou face. Lorsque n est grand, on s'attend à ce que la proportion

de faces ($X_n = 1$) soit à peu près égale à p (c'est l'essence de la conception objectiviste des probabilités). Mathématiquement, on voudrait que

$$\lim_{n\to\infty} \frac{X_1(\omega) + \ldots + X_n(\omega)}{n} = p \text{ pour tout } \omega \in \Omega.$$

C'est en fait complètement faux. En effet, si on considère par exemple la suite $\omega_0 = p, p, p, \ldots$ qui ne contient que des piles, on obtient

$$\lim_{n\to\infty} \frac{X_1(\omega_0) + \ldots + X_n(\omega_0)}{n} = 0$$

et plus généralement, on a $\lim_{n\to\infty} \frac{1}{n}\sum_{i=1}^{n} X_i(\omega) = 0$ pour tout ω dans l'ensemble $A = \{\omega : \text{ il n'y a qu'un nombre fini de faces}\}$. On peut même trouver des ω pour lesquels la fréquence converge vers n'importe quel nombre fixé dans $[0, 1]$! Bien entendu, l'événement A est invraisemblable et on peut montrer qu'il vérifie $\mathbb{P}(A) = 0$[1]. On verra cependant que la **loi des grands nombres** assure :

$$\mathbb{P}\left(\left\{\omega;\ \lim_{n\to\infty} \frac{1}{n}\sum_{i=1}^{n} X_i(\omega) = p\right\}\right) = 1.$$

Ce type de convergence, pour lequel on n'a pas convergence pour tout ω, mais seulement pour presque tout ω (autrement dit $\mathbb{P}$-presque partout) est typiquement ce qui arrive pour des variables aléatoires.

On considère une suite $(X_n)_{n\in\mathbb{N}^*}$ de variables aléatoires, définies sur un même espace de probabilité $(\Omega, \mathcal{A}, \mathbb{P})$, et à valeurs dans $\mathbb{R}^d$. On considère également sur le même espace un vecteur "limite" X. On notera $|\cdot|$ la valeur absolue dans $\mathbb{R}$ ou la norme euclidienne dans $\mathbb{R}^d$.

Définition – Modes de convergences.

1. La suite $(X_n)_{n\in\mathbb{N}^*}$ *converge presque sûrement* vers X, ce qui s'écrit $X_n \to X$ p.s., s'il existe un ensemble $N \in \mathcal{A}$ de probabilité nulle tel que
$$X_n(\omega) \xrightarrow[n\to\infty]{} X(\omega), \quad \forall \omega \notin N.$$

2. La suite $(X_n)_{n\in\mathbb{N}^*}$ *converge en probabilité* vers X, ce qui s'écrit $X_n \xrightarrow{\mathbb{P}} X$, si $\forall \varepsilon > 0$ on a
$$\mathbb{P}(|X_n - X| \geq \varepsilon) \xrightarrow[n\to\infty]{} 0.$$

3. La suite $(X_n)_{n\in\mathbb{N}^*}$ *converge en moyenne* (ou dans $\mathcal{L}^1$) vers X, ce qui s'écrit $X_n \xrightarrow{\mathcal{L}^1} X$, si X_n et X sont dans $\mathcal{L}^1$ et si
$$\mathbb{E}(|X_n - X|) \xrightarrow[n\to\infty]{} 0.$$

1. cf. exercice plus haut (p. 87)

Remarque – Convergence $\mathcal{L}^p$.

La définition de la convergence dans $\mathcal{L}^1$ se généralise aux ordres supérieurs, pour $p \in \mathbb{N}^*$, on parle de convergence dans $\mathcal{L}^p$ (en moyenne quadratique si $p = 2$) ce qui s'écrit $X_n \xrightarrow{\mathcal{L}^p} X$, si X_n et X sont dans $\mathcal{L}^p$ et si

$$\mathbb{E}(|X_n - X|^p) \xrightarrow[n\to\infty]{} 0.$$

Ces modes de convergences ne sont pas équivalents comme le montrent les exemples suivants.

Exercice – En proba et en moyenne (•) Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de variables aléatoires de Bernoulli à valeurs dans $\{0, 1\}$ telles que

$$\mathbb{P}(X_n = 1) = \frac{1}{n}; \quad \mathbb{P}(X_n = 0) = 1 - \frac{1}{n}.$$

Montrer que la suite $(X_n)_{n\in\mathbb{N}^*}$ converge en probabilité et en moyenne vers 0.

Exercice – En proba mais pas en moyenne (•) Soit maintenant une suite $(Y_n)_{n\in\mathbb{N}^*}$ de variables aléatoires de Bernoulli à valeurs dans $\{0, n^2\}$ telles que

$$\mathbb{P}(Y_n = n^2) = \frac{1}{n}; \quad \mathbb{P}(Y_n = 0) = 1 - \frac{1}{n}.$$

Montrer que la suite $(Y_n)_{n\in\mathbb{N}^*}$ converge en probabilité vers 0 mais pas en moyenne.

Exercice – Presque sûre (•) Soit U une variable aléatoire uniforme sur $[0, 1]$. Posons $Z_n = 1_{\{U\leq\frac{1}{n}\}}$. Alors

$$\mathbb{P}(Z_n = 1) = \frac{1}{n}; \quad \mathbb{P}(Z_n = 0) = 1 - \frac{1}{n}$$

Montrer que la suite $(Z_n)_{n\in\mathbb{N}^*}$ converge presque sûrement vers 0.

Il existe cependant des liens entre ces différents modes de convergences que l'on explore ci-dessous.

Proposition – p.s. / $\mathcal{L}^1$ ⇒ en proba.

La convergence presque sûre et la convergence en moyenne entraînent la convergence en probabilité.

Démonstration. Soient $n \in \mathbb{N}^*$, $\varepsilon > 0$ et $A_{n,\varepsilon} = \{|X_n - X| > \varepsilon\}$.

- Supposons que $X_n \to X$ p.s. et soit N l'ensemble de probabilité nulle en dehors duquel on a $X_n(\omega) \to X(\omega)$. Si $\omega \notin N$, on a $\omega \notin A_{n,\varepsilon}$ pour tout $n \geq n_0$, où n_0 dépend de ω et de ε, ce qui implique que les variables aléatoires $Y_{n,\varepsilon} = 1_{N^c\cap A_{n,\varepsilon}}$ tendent simplement vers 0 lorsque $n \to \infty$. Comme on a aussi $0 \leq Y_{n,\varepsilon} \leq 1$ le théorème de convergence dominée implique que $\mathbb{E}(Y_{n,\varepsilon}) \xrightarrow[n\to\infty]{} 0$. Par suite,

$$\mathbb{P}(A_{n,\varepsilon}) \leq \mathbb{P}(N^c \cap A_{n,\varepsilon}) + \mathbb{P}(N) = \mathbb{P}(N^c \cap A_{n,\varepsilon}) = \mathbb{E}(Y_{n,\varepsilon}) \xrightarrow[n\to\infty]{} 0.$$

- Supposons que $X_n \xrightarrow{\mathcal{L}^1} X$. Pour $\varepsilon > 0$, on a $1_{A_{n,\varepsilon}} \leq \frac{1}{\varepsilon}|X_n - X|$, donc

$$\mathbb{P}(A_{n,\varepsilon}) \leq \frac{1}{\varepsilon}\mathbb{E}(|X_n - X|) \xrightarrow[n\to\infty]{} 0.$$

■

La convergence en probabilité n'entraîne pas la convergence en moyenne, comme nous l'avons vu dans l'exemple précédent (p. 89), ne serait-ce que parce qu'elle n'implique pas l'appartenance de X_n et X à $\mathcal{L}^1$. Si les X_n ne sont "pas trop grands", il y a cependant équivalence entre les deux modes de convergence. En voici un exemple.

Proposition – Cas borné.

S'il existe une constante a telle que $|X_n| \leq a$ presque sûrement, il y a équivalence entre $X_n \xrightarrow{\mathbb{P}} X$ et $X_n \xrightarrow{\mathcal{L}^1} X$.

Démonstration. Etant donnée la proposition précédente (p. 89), dont on reprend les notations, il suffit de montrer que la convergence en probabilité implique la convergence en moyenne lorsque $|X_n| \leq a$.

Comme $|X_n| \leq a$ p.s., on a $\{|X| > a + \varepsilon\} \subset A_{n,\varepsilon}$, et donc $\mathbb{P}(|X| > a + \varepsilon) \leq \mathbb{P}(A_{n,\varepsilon})$. En faisant $n \to \infty$, on en déduit que $\mathbb{P}(|X| > a + \varepsilon) = 0$. Ceci est vrai pour tout ε et donc

$$\mathbb{P}(|X| > a) = 0.$$

Comme $|X_n| \leq a$, on a aussi

$$|X_n - X| \leq \varepsilon + (X_n + X)1_{A_{n,\varepsilon}} \leq \varepsilon + 2a1_{A_{n,\varepsilon}}$$

sur l'ensemble $\{|X| \leq a\}$ qui est de probabilité 1. On a ainsi

$$\mathbb{E}(|X_n - X|) \leq \varepsilon + 2a\mathbb{P}(A_{n,\varepsilon})$$

On en déduit que $\limsup_{n\to\infty} \mathbb{E}(|X_n - X|) \leq \varepsilon$, et comme ε est arbitrairement proche de 0, on a le résultat souhaité. ■

Les rapports entre convergence presque-sûre et convergence en probabilité sont plus subtils. La première de ces deux convergences est plus forte que la seconde d'après la proposition plus haut (p. 89), mais "à peine plus", comme le montre le résultat suivant.

Proposition – Existence d'une sous-suite convergente.

Si $X_n \xrightarrow{\mathbb{P}} X$, il existe une sous-suite (n_k) telle que $X_{n_k} \to X$ p.s. quand $k \to \infty$.

Démonstration. On remarque d'abord que l'on peut réécrire la définition de la convergence en probabilité de la manière suivante : $\forall \varepsilon > 0$ et $\delta > 0$, il existe $N = N(\delta, \varepsilon)$ tel que

$$n \geq N \Rightarrow \mathbb{P}(|X_n - X| > \varepsilon) < \delta.$$

Comme la suite $(X_n)_{n\in\mathbb{N}^*}$ converge en probabilité vers X, on peut définir une sous-suite de la manière suivante : posons $n_1 = 1$, et soit

$$n_j = \inf \left\{ n > n_{j-1}; \mathbb{P}\left(|X_m - X| > \frac{1}{2^j} \right) < \frac{1}{3^j}, \text{ pour } m \geq n \right\}.$$

On a alors

$$\sum_j \mathbb{P}\left(|X_{n_j} - X| > \frac{1}{2^j}\right) < \sum_j \frac{1}{3^j} < \infty$$

et en appliquant le lemme de Borel-Cantelli (p. 87) aux ensembles

$$A_j = \left\{|X_{n_j} - X| > \frac{1}{2^j}\right\},$$

on obtient que la suite $(X_{n_j})_{j\in\mathbb{N}^*}$ converge presque-sûrement. ■

Exercice – Intervalles de longueur aléatoire (1) (•) Soient $\Omega = \mathbb{R}$ muni de sa tribu borélienne et $\mathbb{P}$ la probabilité uniforme sur [0, 1]. Soit $X_n = 1_{A_n}$, où A_n est un intervalle de [0, 1] de longueur $\frac{1}{n}$.

Montrer que la suite des X_n converge en moyenne et en proba.

Exercice – Intervalles de longueur aléatoire (2) (•••) Montrer que la suite des X_n ne converge pas presque sûrement. Extraire une sous-suite qui converge presque sûrement.

Proposition – Continuité.

Soit f une fonction continue de $\mathbb{R}^d$ dans $\mathbb{R}$.

1. *Si $X_n \to X$ presque-sûrement, alors $f(X_n) \to f(X)$ presque-sûrement.*
2. *Si $X_n \xrightarrow{\mathbb{P}} X$, alors $f(X_n) \xrightarrow{\mathbb{P}} f(X)$.*

Démonstration.

1. Soit N l'ensemble de probabilité nulle en dehors duquel on a $X_n(\omega) \xrightarrow[n\to\infty]{} X(\omega)$. Si $\omega \notin N$, il vient
$$\lim_{n\to\infty} f(X_n(\omega)) = f(\lim_{n\to\infty} X_n(\omega)) = f(X(\omega))$$
par continuité de f, d'où le résultat.

2. On remarque d'abord que si $K > 0$ et $\varepsilon > 0$,
$$\{|f(X_n) - f(X)| \geq \varepsilon\} \subset \{|X| > K\} \cup \{|X| \leq K, |f(X_n) - f(X)| \geq \varepsilon\}.$$
La fonction f est uniformément continue sur $\{x : |x| \leq K\}$, donc il existe $\eta > 0$ tel que $|x - y| < \eta$ et $|x| \leq 2K$ et $|y| \leq 2K$ impliquent $|f(x) - f(y)| < \varepsilon$. On a donc
$$\{|f(X_n) - f(X)| \geq \varepsilon\} \subset \{|X| > K\} \cup \{|X_n - X| \geq \eta\}$$
d'où
$$\mathbb{P}(|f(X_n) - f(X)| \geq \varepsilon) \leq \mathbb{P}(|X| > K) + \mathbb{P}(|X_n - X| \geq \eta).$$
Par hypothèse, il vient
$$\lim_{n\to\infty} \mathbb{P}(|f(X_n) - f(X)| \geq \varepsilon) \leq \mathbb{P}(|X| > K).$$
Enfin, $\lim_{K\to+\infty} \mathbb{P}(|X| > K) = 0$ (par convergence dominée) et donc la limite ci-dessus est nulle. On a ainsi le résultat.

■

4.2. La loi des grands nombres

On présente maintenant l'un des résultats essentiels de la théorie des probabilités. Ce résultat montre rigoureusement que, quand le nombre de répétitions de l'expérience tend vers l'infini, la fréquence de réalisation d'un événement converge p.s. vers la probabilité de réalisation de cet événement. Ce résultat, appelé **Loi des grands nombres**, a d'autres portées fondamentales. Il est en particulier à l'origine de méthodes de calcul numérique appelées Méthodes de Monte-Carlo, qui sont extrêmement puissantes et robustes. Elles sont par exemple très utilisées en Physique, en Mathématiques Financières ou encore dans les problèmes de quantification d'incertitudes. Une introduction à ces méthodes sera donnée au chapitre V.

Dans ce paragraphe, on considère une suite $(X_n)_{n\in\mathbb{N}^*}$ de variables aléatoires **indépendantes et de même loi** (ou indépendantes et identiquement distribuées, i.i.d. en abrégé). On considère la "moyenne" des n premières variables aléatoires :

$$M_n = \frac{X_1 + \ldots + X_n}{n},$$

et notre objectif est de montrer que M_n converge vers l'espérance des X_n lorsque celle-ci existe (comme les X_n ont même loi, cette espérance est la même pour tout n).

Nous allons démontrer dans un premier temps la loi des grands nombres pour des variables aléatoires de carré intégrable.

Théorème – Loi des grands nombres cas $\mathcal{L}^2$.

Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de variables aléatoires indépendantes, de même loi et de ***carré intégrable****, et $m = \mathbb{E}(X_n)$ leur espérance. Alors la suite $(M_n)_{n\in\mathbb{N}^*}$ définie par*

$$M_n = \frac{X_1 + \ldots + X_n}{n}$$

converge vers m, ***presque sûrement et en moyenne****, quand n tend vers l'infini. Elle converge donc aussi en probabilité. On a même convergence en* moyenne quadratique*, à savoir que :*

$$\mathbb{E}((M_n - m)^2) \xrightarrow[n\to\infty]{} 0.$$

Exercice – Loi faible des grands nombres (•) Le résultat sur la convergence en probabilité est appelé *loi faible des grands nombres*. Démontrer ce résultat.

Le résultat est peu informatif et permet d'obtenir certains contrôles d'erreurs. Le résultat prouvant la convergence presque-sûre est appelé *loi forte des grands nombres*. Sa preuve est plus délicate et utilise le lemme de Borel-Cantelli (p. 87).

4.2.1. Démonstration

Notons σ^2 la variance des variables X_n, bien définie puisqu'on les a supposées de carré intégrable. En vertu de la linéarité de l'espérance, on a

$$\mathbb{E}(M_n) = m, \quad \mathbb{E}((M_n - m)^2) = \mathbb{V}(M_n) = \frac{\sigma^2}{n},$$

d'où la convergence en moyenne quadratique.

Comme $\mathbb{E}(Y)^2 \leq \mathbb{E}(Y^2)$, on en déduit que $\mathbb{E}(|M_n - m|) \to 0$, donc on a aussi la convergence en moyenne.

La preuve de la convergence presque-sûre est plus délicate.

Quitte à remplacer X_n par $X_n - m$ (et donc M_n par $M_n - m$), nous pouvons supposer que $m = 0$.

Montrons tout d'abord que la sous-suite $(M_{n^2})_{n\in\mathbb{N}^*}$ converge presque-sûrement vers 0.

La convergence dans $\mathcal{L}^1$ impliquant la convergence en probabilité, on sait qu'on peut extraire de $(M_n)_n$ une sous-suite convergeant p.s. vers 0. Cependant, cela ne suffit pas puisqu'on veut que la suite $(M_n)_n$ elle-même converge p.s. Pour le montrer, on construit d'abord une sous suite-particulière qui converge p.s. puis on traite les termes qui se trouvent entre deux éléments successifs de la sous-suite.

D'après l'inégalité de Bienaymé-Chebyshev (p. 85) et ce qui précède, on a pour $q \in \mathbb{N}^*$

$$\mathbb{P}\left(|M_{n^2}| \geq \frac{1}{q}\right) \leq \frac{\sigma^2 q^2}{n^2}$$

Donc si $A_{n,q} = \{|M_{n^2}| \geq \frac{1}{q}\}$, nous obtenons que $\sum_{n\geq 1} \mathbb{P}(A_{n,q}) < \infty$. Posons ensuite $B_{n,q} = \cup_{m\geq n} A_{m,q}$ et $C_q = \cap_{n\geq 1} B_{n,q} = \limsup_n A_{n,q}$. En appliquant le lemme de Borel-Cantelli (p. 87), on obtient que $\mathbb{P}(C_q) = 0$. En conséquence, si on pose $N = \cup_{q\in\mathbb{N}^*} C_q$, on obtient $\mathbb{P}(N) \leq \sum_{q\in\mathbb{N}^*} \mathbb{P}(C_q) = 0$.

Si $\omega \notin N$, alors $\omega \in \cap_{q\in\mathbb{N}^*} (C_q)^c$. Ainsi, $\omega \notin C_q$ pour tout $q \geq 1$, et donc $\omega \notin B_{n,q}$ pour n assez grand (car $B_{n,q}$ est décroissant en n). Cela signifie que pour tout $\omega \notin N$, pour tout $q \geq 1$, il existe un n assez grand tel que $M_{k^2} \leq \frac{1}{q}$ dès que $k \geq n$. Autrement dit, $M_{n^2} \to 0$ si $\omega \notin N$, avec $\mathbb{P}(N) = 0$, d'où

$$M_{n^2} \xrightarrow[n\to\infty]{} 0 \text{ p.s.}$$

Montrons maintenant que la suite $(M_n)_{n\in\mathbb{N}^*}$ tend presque-sûrement vers 0.

Pour tout entier n, notons $p(n)$, l'entier tel que $p(n)^2 \leq n \leq (p(n)+1)^2$. Alors,

$$M_n - \frac{p(n)^2}{n} M_{p(n)^2} = \frac{1}{n} \sum_{p=p(n)^2+1}^{n} X_p,$$

et puisque les variables aléatoires de la somme sont indépendantes, il vient

$$\begin{aligned}
\mathbb{E}\left(\left(M_n - \frac{p(n)^2}{n} M_{p(n)^2}\right)^2\right) &= \frac{n - p(n)^2}{n^2}\sigma^2 \\
&\leq \frac{2p(n)+1}{n^2}\sigma^2 \\
&\leq \frac{2\sqrt{n}+1}{n^2}\sigma^2 \leq \frac{3}{n^{3/2}}\sigma^2
\end{aligned}$$

où on a utilisé le fait que $p(n) \leq \sqrt{n}$.

En appliquant de nouveau l'inégalité de Bienaymé-Chebyshev (p. 85), on obtient

$$\mathbb{P}\left(\left|M_n - \frac{p(n)^2}{n} M_{p(n)^2}\right| > a\right) \leq \frac{2\sqrt{n}+1}{n^2}\frac{\sigma^2}{a^2}$$

Comme la série $\sum_n \frac{2\sqrt{n}+1}{n^2}$ converge, le même raisonnement que pour M_{n^2} décrit ci-dessus, montre que

$$M_n - \frac{p(n)^2}{n} M_{p(n)^2} \to 0 \text{ p.s.}$$

Par ailleurs, on a déjà montré que $M_{p(n)^2} \to 0$ p.s. et $\frac{p(n)^2}{n} \to 1$. On en déduit que $M_n \to 0$ p.s.

Plus généralement, le théorème suivant donne les hypothèses minimales assurant la validité de la loi des grands nombres, à savoir que les X_n sont dans $\mathcal{L}_1$ (on se référera par exemple à ce document en ligne ou à Jacod and Protter (2003) pour la démonstration).

Théorème – Loi des grands nombres cas $\mathcal{L}^1$.

Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de variables aléatoires indépendantes, de même loi et ***intégrables****, et $m = \mathbb{E}(X_n)$ leur espérance. Alors la suite $(M_n)_{n\in\mathbb{N}^*}$ définie par*

$$M_n = \frac{X_1 + \ldots + X_n}{n}$$

converge vers m, ***presque sûrement et en moyenne****, quand n tend vers l'infini.*

Exercice – Exponentielle (•) Soit $(X_i)_{i\in\mathbb{N}^*}$ une suite de variables aléatoires i.i.d. d'espérance m et $Y_i = e^{X_i}$. Montrer que :

$$\left(\prod_{i=1}^{n} Y_i\right)^{1/n}$$

converge presque sûrement vers une constante à déterminer.

Exercice – Variance (•) Soit $(X_i)_{i\in\mathbb{N}^*}$ une suite de variables aléatoires i.i.d. d'espérance m et de variance σ^2. Montrer que :

$$\lim_{n\to\infty} \frac{1}{n}\sum_{i=1}^{n}(X_i - m)^2 \to \sigma^2 \text{ p.s.}$$

5. Convergence en loi et théorème central limite

Nous allons introduire maintenant une nouvelle notion de convergence de suites de variables aléatoires. La convergence en loi définie dans ce paragraphe va concerner les lois des variables aléatoires. Elle signifiera que les lois sont asymptotiquement "proches", sans que les variables aléatoires elles-mêmes le soient nécessairement.

5.1. Convergence en loi

On considère des vecteurs aléatoires X_n et X, tous à valeurs dans le même espace $\mathbb{R}^d$, mais pouvant éventuellement être définis sur des espaces de probabilité différents.

Définition – Convergence en loi.

On dit que la suite $(X_n)_{n\in\mathbb{N}^*}$ *converge en loi* vers X et on écrit $X_n \xrightarrow{\mathcal{L}} X$, si pour toute fonction réelle f **continue bornée** sur $\mathbb{R}^d$,

$$\mathbb{E}(f(X_n)) \xrightarrow[n\to\infty]{} \mathbb{E}(f(X)).$$

Exemple – Cas fini.

Un cas très simple est celui où toutes les variables aléatoires X_n prennent un nombre fini de valeurs $\{x_i, 1 \leq i \leq N\}$. Alors, la suite $(X_n)_{n\in\mathbb{N}^*}$ converge en loi vers X si et seulement si

$$\lim_{n\to+\infty} \mathbb{P}(X_n = x_i) = \mathbb{P}(X = x_i), \ \ \forall 1 \leq i \leq N$$

Il suffit d'écrire pour f continue bornée

$$\mathbb{E}(f(X_n)) = \sum_{i=1}^{N} f(x_i)P(X_n = x_i)$$

Dans l'exemple ci-dessus, N est fini et fixé. Mais nous avons un résultat analogue (en faisant tendre N vers l'infini) si les variables aléatoires ont un nombre dénombrable de valeurs. En particulier, le cas de la convergence de la loi binomiale vers la loi de Poisson a été traité en CPGE.

Remarque – Univers de définition.

Dans la définition (p. 94), les v.a. X_n et X peuvent être définies sur des univers distincts puisque seules leurs lois sont en cause. Il arrive même qu'une suite X_n converge vers une limite X qui ne peut pas exister sur les espaces sur lesquels sont définies les X_n, parce que ceux-ci sont trop "petits" : par exemple, si X_n est une variable binomiale à n modalités, convenablement normalisée, et la limite X est gaussienne (on pourra justifier ceci par le théorème central limite (p. 98)); l'espace naturel sur lequel est définie X_n contient $n+1$ points, et sur un tel espace toutes les v.a. sont discrètes. La convergence en loi permet donc une sorte de convergence pour des v.a. pour lesquelles toute autre forme de convergence serait impossible.

Exercice – Suite gaussienne (•) Soit $(X_n)_{n\in\mathbb{N}^*}$ et X des variables aléatoires de lois respectives $\mathcal{N}(0, \sigma_n^2)$ et $\mathcal{N}(0, \sigma^2)$. On suppose que la suite de réels positifs $(\sigma_n)_{n\in\mathbb{N}^*}$ converge vers $\sigma > 0$ quand n tend vers l'infini. Montrer que la suite $(X_n)_{n\in\mathbb{N}^*}$ converge en loi vers X.

La convergence en loi est plus faible que la convergence en probabilité et donc aussi que les convergences presque-sûre et en moyenne.

Proposition – En proba ⇒ en loi.

Soient $(X_n)_{n\in\mathbb{N}*}$ et X des v.a., toutes définies sur le même espace de probabilité $(\Omega, \mathcal{A}, \mathbb{P})$. Si $X_n \xrightarrow{\mathbb{P}} X$, alors $X_n \xrightarrow{\mathcal{L}} X$.

Démonstration. Soit f une fonction réelle continue bornée. D'après la proposition de continuité (p. 91), on a $f(X_n) \xrightarrow{\mathbb{P}} f(X)$ et donc $f(X_n)$ converge aussi en moyenne vers $f(X)$ par la proposition — cas borné (p. 90). Comme $|\mathbb{E}(Y)| \leq \mathbb{E}(|Y|)$ pour toute variable aléatoire réelle Y, on en déduit $\mathbb{E}(f(X_n)) \to \mathbb{E}(f(X))$. ■

On peut finalement résumer les liens d'implications entre les différents modes de convergence à l'aide de la figure ci-desous.

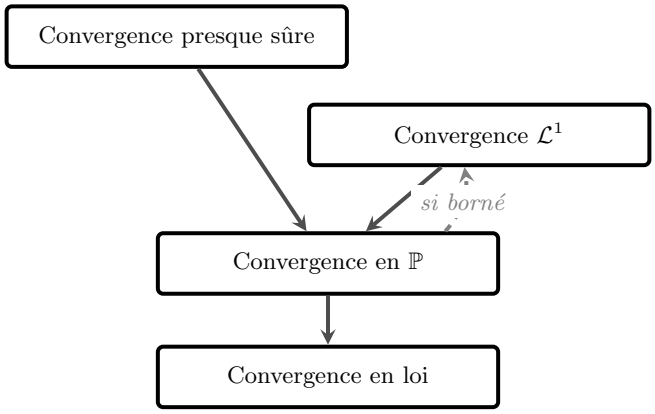


FIGURE 5.1. – Relations entre modes de convergence

Un moyen efficace de caractériser la convergence en loi des variables aléatoires réelles passe par l'étude de la suite des fonctions de répartition.

Proposition – Convergence en loi et fonction de répartition.

Soient $(X_n)_{n\in\mathbb{N}^*}$ et X des variables aléatoires réelles de fonctions de répartition respectives F_n et F. Pour que $X_n \xrightarrow{\mathcal{L}} X$, il faut et il suffit que $F_n(x) \xrightarrow[n\to\infty]{} F(x)$ pour tout x en lequel F est continue.

Notons que puisque la fonction F est continue à droite et croissante, l'ensemble des points où F est continue est l'ensemble $D = \{x : F(x-) = F(x)\}$, et son complémentaire est au plus dénombrable. Ainsi, D est dense[1] *dans $\mathbb{R}$.*

Démonstration.

1. Supposons d'abord que $X_n \xrightarrow{\mathcal{L}} X$. Soit $a \in \mathbb{R}$ tel que $F(a-) = F(a)$. Pour tout $p \in \mathbb{N}^*$ et tout $b \in \mathbb{R}$, il existe une fonction $f_{p,b}$ continue bornée sur $\mathbb{R}$ telle que
$$1_{]-\infty,b]} \leq f_{p,b} \leq 1_{]-\infty,b+\frac{1}{p}]}.$$
Alors, par définition, $\mathbb{E}(f_{p,b}(X_n)) \to \mathbb{E}(f_{p,b}(X))$ quand n tend vers l'infini. L'inégalité ci-dessus implique que $F_n(a) = \mathbb{P}(X_n \leq a) \leq \mathbb{E}(f_{p,a}(X_n))$ et $\mathbb{E}(f_{p,a}(X)) \leq F(a + 1/p)$; donc $\limsup_n F_n(a) \leq F(a + 1/p)$ pour tout p et donc on a aussi $\limsup_n F_n(a) \leq F(a)$. On a également que $F_n(a) \geq \mathbb{E}(f_{p,a-1/p}(X_n))$ et $\mathbb{E}(f_{p,a-1/p}(X)) \geq F(a - 1/p)$; donc $\liminf_n F_n(a) \geq F(a - 1/p)$ pour tout p et donc aussi $\liminf_n F_n(a) \geq F(a)$, puique $F(a-) = F(a)$. Ces deux résultats impliquent que $F_n(a) \xrightarrow[n\to\infty]{} F(a)$.
2. Inversement, supposons $F_n(x) \xrightarrow[n\to\infty]{} F(x)$ pour tout $x \in T$, où T est une partie dense de $\mathbb{R}$. Soit f une fonction continue bornée sur $\mathbb{R}$ et $\varepsilon > 0$. Soient $a, b \in T$ avec $F(a) \leq \varepsilon$ et $F(b) \geq 1 - \varepsilon$. Il existe n_0 tel que
$$n \geq n_0 \Rightarrow \mathbb{P}(X_n \notin]a, b]) = 1 - F_n(b) + F_n(a) \leq 3\varepsilon.$$

1. Soient Ω un espace topologique et A une partie de Ω. On dit que A est *dense* dans Ω si l'une des propriétés équivalentes est satisfaite : tout ouvert non vide de Ω contient des éléments de A ; l'adhérence de A est égale à Ω ; tout point de Ω est adhérent à A ; le complémentaire de A est d'intérieur vide.

La fonction f est uniformément continue sur $[a,b]$, donc il existe un nombre fini de points $a_0 = a < a_1 < \ldots < a_k = b$ appartenant tous à T, et tels que $|f(x) - f(a_i)| \leq \varepsilon$ si $a_{i-1} \leq x \leq a_i$. Donc

$$g(x) = \sum_{i=1}^{k} f(a_i) 1_{]a_{i-1},a_i]}(x)$$

vérifie $|f - g| \leq \varepsilon$ sur $]a,b]$. Si $M = \sup_x |f(x)|$, il vient alors

$$|\mathbb{E}(f(X_n)) - \mathbb{E}(g(X_n))| \leq M\mathbb{P}(X_n \notin [a,b]) + \varepsilon,$$

de même pour X. Enfin, $\mathbb{E}(g(X_n)) = \sum_{i=1}^{k} f(a_i)(F_n(a_i) - F_n(a_{i-1})$, et de même pour X par définition de g. Comme $(F_n(a_i))_{n\in\mathbb{N}^*}$ converge vers $F(a_i)$ pour tout i, on en déduit l'existence de n_1 tel que

$$n \geq n_1 \Rightarrow |\mathbb{E}(g(X_n)) - \mathbb{E}(g(X))| \leq \varepsilon.$$

Finalement, on a

$$n \geq \sup(n_0, n_1) \Rightarrow |\mathbb{E}(f(X_n)) - \mathbb{E}(f(X))| \leq 3\varepsilon + 5M\varepsilon.$$

Vu l'arbitraire sur ε, on en déduit que $\mathbb{E}(f(X_n))$ converge vers $\mathbb{E}(f(X))$, d'où le résultat.

■

Corollaire – Cas où X admet une densité.

Si la suite $(X_n)_{n\in\mathbb{N}^*}$ de variables aléatoires réelles converge en loi vers X, et si la loi de X admet une densité, alors pour tous $a < b$,

$$\mathbb{P}(X_n \in]a,b]) \xrightarrow[n\to\infty]{} \mathbb{P}(X \in]a,b]).$$

Démonstration. La fonction de répartition de X est alors continue en tout point. (Mais pas nécessairement celle des variables aléatoires X_n.) ■

5.2. Théorème central limite

Ce théorème est aussi connu sous le nom de théorème de la limite centrale. Plus simplement, il apparaît souvent sous l'abréviation TCL.

On considère une suite de variables aléatoire $(X_n)_{n\in\mathbb{N}^*}$ indépendantes, de même loi et de carré intégrable. On note m et σ^2 l'espérance et la variance commune aux variables X_n, et

$$S_n = X_1 + \ldots + X_n$$

ainsi $(S_n = nM_n)$. On a vu que la loi des grands nombres assure que M_n converge vers m presque-sûrement et en moyenne. On va s'intéresser à la vitesse à laquelle cette convergence a lieu.

Pour évaluer cette vitesse, c'est-à-dire trouver un équivalent de $\frac{S_n}{n} - m$, on est amené à étudier la limite éventuelle de la suite $n^\alpha(\frac{S_n}{n} - m)$ pour différentes valeurs de α : si α est "petit" cette suite va encore tendre vers 0, et elle va "exploser" si α est "grand". On peut espérer que pour une (et alors nécessairement une seule) valeur de α, cette suite converge vers une limite qui n'est ni infinie ni nulle.

Il se trouve que la réponse à cette question a un aspect "négatif" : la suite $n^\alpha(\frac{S_n}{n} - m)$ ne converge au sens presque-sûr, ou même en probabilité, pour aucune valeur de α. Elle a aussi un aspect "positif" : cette suite converge, au sens de la convergence en loi, pour la même valeur $\alpha = 1/2$ quelle que soit la loi des X_n, et toujours vers une loi normale.

Ce résultat, qui peut sembler miraculeux, a été énoncé par Laplace (1749-1827) et démontré beaucoup plus tard par Lyapounov (1901). Il montre le caractère universel de la loi normale en probabilités (d'où son nom).

Théorème – central limite (TCL).

Si les X_n sont des variables aléatoires réelles, indépendantes et de même loi, de carré intégrable, d'espérance m et de variance $\sigma^2 > 0$, alors les variables

$$\frac{S_n - nm}{\sigma\sqrt{n}}$$

convergent en loi vers une variable aléatoire de loi $\mathcal{N}(0,1)$.

En d'autres termes, $\sqrt{n}(M_n - m)$ converge vers une variable normale de loi $\mathcal{N}(0,\sigma^2)$.

Démonstration. Soit ϕ la fonction caractéristique de $X_n - m$, et $Y_n = \frac{S_n - nm}{\sigma\sqrt{n}}$. Comme les X_n sont indépendantes, la proposition — somme (p. 104) entraîne que la fonction caractéristique de Y_n est

$$\begin{aligned}
\phi_{Y_n}(u) &= \phi_{\frac{1}{\sigma\sqrt{n}}\sum_{j=1}^n (X_j - m)}(u) \\
&= \phi_{\sum_{j=1}^n (X_j - m)}\left(\frac{u}{\sigma\sqrt{n}}\right) \\
&= \prod_{j=1}^n \phi\left(\frac{u}{\sigma\sqrt{n}}\right) \\
&= \phi\left(\frac{u}{\sigma\sqrt{n}}\right)^n
\end{aligned}$$

Comme $\mathbb{E}(X_n - m) = 0$ et $\mathbb{E}((X_n - m)^2) = \sigma^2$, la proposition — fonction caractéristique et moments (p. 104) entraîne que

$$\phi'(0) = 0 \text{ et } \phi''(0) = -\sigma^2$$

Si on fait le développement de Taylor à l'ordre 2 au voisinage de zéro, on obtient

$$\phi(u) = 1 - \frac{u^2\sigma^2}{2} + u^2 h(|u|),$$

où $h(u) \to 0$ quand $u \to 0$. On a ainsi

$$\begin{aligned}
\phi_{Y_n}(u) &= \phi\left(\frac{u}{\sigma\sqrt{n}}\right)^n \\
&= e^{n\log\phi\left(\frac{u}{\sigma\sqrt{n}}\right)} \\
&= e^{n\log(1 - \frac{u^2}{2n} + \frac{u^2}{n\sigma^2}h(\frac{u}{\sigma\sqrt{n}}))}
\end{aligned}$$

où log désigne la valeur principale du logarithme complexe[2] (elle vaut 0 au point 1 et est continue dans le cercle complexe de centre 1 et de rayon 1/2 et admet le même développement limité au voisinage de $z = 1$ que le logarithme réel). Comme $\phi(0) = 1$ et que ϕ est continue en 0, on a que pour u fixé et n assez grand,

$$\left|\phi\left(\frac{u}{\sigma\sqrt{n}}\right) - 1\right| \leq 1/2.$$

En faisant $n \to \infty$, on obtient

$$\lim_{n\to\infty} \phi_n(u) = \exp -\frac{u^2}{2}$$

Le théorème de Lévy (p. 106) implique alors que Y_n converge en loi vers Z de fonction caractéristique $\phi_Z(u) = e^{-u^2/2}$ où l'on reconnaît la fonction caractéristique de la loi $\mathcal{N}(0,1)$.■

Remarque – Conséquence.

On peut déduire de ce résultat que $n^\alpha(\frac{S_n}{n} - m)$ converge vers 0 (resp. $+\infty$) en probabilité lorsque $\alpha < 1/2$ (resp. $\alpha > 1/2$).

5.2.1. Exemple : convergence des lois binomiales

Supposons que S_n suive une loi binomiale $\mathcal{B}(p,n)$. Cela revient à dire que S_n a la même loi qu'une somme $X_1 + \ldots + X_n$ de n variables aléatoires X_i indépendantes de loi $\mathcal{B}(p,1)$, i.e. $\mathbb{P}(X_i = 1) = p$ et $\mathbb{P}(X_i = 0) = 1 - p$. On a alors $m = p$ et $\sigma^2 = p(1-p)$.

On veut calculer $\mathbb{P}(S_n \leq x)$ pour x fixé et n grand.

Si p est petit de sorte que $\theta = np$ ne soit pas trop grand (en pratique, $\theta \leq 5$ convient), on peut utiliser l'approximation par une loi de Poisson, vue en CPGE. Si p est très proche de 1, de sorte que $\theta = n(1-p)$ soit comme ci-dessus, alors $n - S_n$ suit à son tour une loi proche de la loi de Poisson de paramètre θ.

Dans les autres cas, on utilise la loi des grands nombres et le théorème central limite :

$$\frac{S_n}{n} \xrightarrow{\mathbb{P}} p,$$
$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{\mathcal{L}} Y \sim \mathcal{N}(0,1)$$

Si on désigne par Φ la fonction de répartition de la loi $\mathcal{N}(0,1)$, il vient

$$\mathbb{P}(S_n \leq x) \approx \Phi\left(\frac{x - np}{\sqrt{np(1-p)}}\right)$$

Imaginons que l'on lance 1000 fois une pièce (non truquée). On cherche la probabilité d'obtenir plus de 545 fois le côté Face. Le calcul exact utilisant les lois binomiales est extrêmement lourd. Le résultat ci-dessus nous donne une très bonne approximation. On a

$$\mathbb{P}(S_{1000} > 545) = \mathbb{P}\left(\frac{S_{1000} - 500}{\sqrt{250}} > \frac{45}{\sqrt{250}}\right) \approx \int_{\frac{45}{\sqrt{250}}}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx.$$

Cette dernière intégrale se calcule numériquement (on trouve encore des abaques où les valeurs de Φ sont tabulées) et on obtient

$$\mathbb{P}(S_{1000} > 545) \approx 1 - \Phi(2,84) \approx 0,0023.$$

2. voir par exemple https://fr.wikipedia.org/wiki/Logarithme_complexe

Exercice – Surbooking (•) 400 places dans un avion, 420 billets vendus, 8% de taux de non-présentation : quelle probabilité de surbooking ? On utilisera une approximation judicieuse.

Le théorème (p. 98) admet une version multidimensionnelle, de preuve similaire. On considère des vecteurs aléatoires X_n à valeurs dans $\mathbb{R}^d$, indépendants et de même loi, dont les composantes sont de carré intégrable. On a un vecteur espérance $m = E(X_n)$, et une matrice de covariance $C = (c_{ij})_{i,j=1,\dots,d}$ avec $c_i j = \mathrm{Cov}(X_i, X_j)$. On peut alors énoncer le TCL multi-dimensionnel.

Théorème – central limite multi-dimensionnel.

Les vecteurs aléatoires $\frac{S_n - nm}{\sqrt{n}}$ *convergent en loi vers un vecteur aléatoire gaussien centré (i.e. d'espérance nulle), de matrice* C*.*

Remarque – Vitesse de convergence.

Il est important de noter ici que la vitesse de convergence ne dépend pas de la dimension des vecteurs X_n.

6. Annexe

6.1. Fonctions caractéristiques

Dans ce paragraphe, nous introduisons un outil important en calcul des probabilités : il s'agit de ce que l'on appelle *la fonction caractéristique* d'une variable aléatoire, et qui dans d'autres branches des mathématiques s'appelle aussi *la transformée de Fourier*. Elle nous sera notamment nécessaire, via le théorème de Lévy, pour démontrer le théorème central limite. L'essentiel de cette section peut être considéré hors programme, dans le sens où, bien que très utile en pratique, sa connaissance ne sera pas évaluée à l'examen.

On notera $< x, y >$ le produit scalaire de deux vecteurs de $\mathbb{R}^n$. Si $u \in \mathbb{R}^n$, la fonction (complexe) $x \mapsto e^{i<u,x>}$ est continue, de module 1. Donc si X est un vecteur aléatoire à valeurs dans $\mathbb{R}^n$, nous pouvons considérer $e^{i<u,X>}$ comme une variable aléatoire à valeurs complexes. Ses parties réelle $Y = \cos(< u, X >)$ et imaginaire $Z = \sin(< u, X >)$ sont des variables aléatoires réelles. Ces variables aléatoires réelles sont de plus bornées par 1, donc elles admettent une espérance. Il est alors naturel d'écrire que l'espérance de $e^{i<u,x>}$ est

$$\mathbb{E}(e^{i<u,X>}) = \mathbb{E}(Y) + i\mathbb{E}(Z) = \mathbb{E}(\cos < u, X >) + i\mathbb{E}(\sin < u, X >)$$

Définition – Fonction caractéristique.

Si X est un vecteur aléatoire à valeurs dans $\mathbb{R}^n$, sa *fonction caractéristique* est la fonction ϕ_X de $\mathbb{R}^n$ dans $\mathbb{C}$ définie par

$$\phi_X(u) = \mathbb{E}(e^{i<u,X>}) = \int_{\mathbb{R}^n} e^{i<u,x>} \mathbb{P}_X(dx).$$

Remarque – Interprétation.

La fonction caractéristique ne dépend en fait **que de la loi $\mathbb{P}_X$ de** X : c'est la "transformée de Fourier" de la loi $\mathbb{P}_X$.

Nous verrons que cette fonction porte bien son nom, au sens où elle caractérise la loi $\mathbb{P}_X$. C'est une notion qui, de ce point de vue, généralise la fonction génératrice $G_X(s) = \mathbb{E}(s^X)$, $s \in [0,1]$, vue en CPGE dans le cas discret. Elle vérifie

$$\phi_X(u) = G_X(e^{iu}) = \mathbb{E}(e^{iuX})$$

pour une variable X à valeurs dans $\mathbb{N}$.

Proposition – Propriétés de la fonction caractéristique.

ϕ_X est de module inférieur à 1, continue, avec

$$\phi(0) = 1; \;\; \phi_X(-u) = \overline{\phi_X(u)}.$$

Démonstration. $|z|$ désigne le module d'un nombre complexe z.

Comme $\mathbb{E}(Y)^2 \leq \mathbb{E}(Y^2)$ pour toute variable réelle Y, on a :

$$|\phi_X(u)|^2 = \mathbb{E}(\cos < u, X >)^2 + \mathbb{E}(\sin < u, X >)^2 \leq \mathbb{E}(\cos^2 < u, X > + \sin^2 < u, X >) = 1.$$

Pour montrer la continuité, considérons une suite $u_p \xrightarrow[p\to\infty]{} u$. Il y a convergence simple de $e^{i<u_p,X>}$ vers $e^{i<u,X>}$. Comme ces variables aléatoires sont de module inférieur à 1, le théorème de convergence dominée assure que $\phi_X(u_p) \xrightarrow[p\to\infty]{} \phi_X(u)$. ϕ_X est donc continue. ■

Proposition – Transformation linéaire.

Si X est un vecteur aléatoire à valeurs dans $\mathbb{R}^n$, si $a \in \mathbb{R}^m$ et A est une matrice réelle de taille $m \times n$, alors

$$\phi_{a+AX}(u) = e^{i<u,a>}\phi_X(A^t u), \forall u \in \mathbb{R}^m$$

Démonstration. Nous avons $e^{i<u,a+AX>} = e^{i<u,a>}e^{i<A^t u,X>}$. En effet, $< u, AX >=< A^t u, X >$. On prend ensuite les espérances pour obtenir le résultat. ■

Exemple.

1. X suit une loi binomiale $\mathcal{B}(n,p)$: $\phi_X(u) = (pe^{iu} + 1 - p)^n$.
2. X suit une loi de Poisson $\mathcal{P}(\theta)$: $\phi_X(u) = e^{\theta(e^{iu}-1)}$.
3. X suit une loi uniforme $\mathcal{U}_{[a,b]}$:$\phi_X(u) = \frac{e^{iua}-e^{iub}}{iu(b-a)}$.
4. X suit une loi exponentielle $\mathcal{E}(\lambda)$, $\lambda > 0$: $\phi_X(u) = \frac{\lambda}{\lambda - iu}$.
5. X suit une loi normale $\mathcal{N}(0,1)$: $\phi_X(u) = e^{-u^2/2}$. (calcul ci-dessous)
6. X suit une loi normale $\mathcal{N}(\mu,\sigma^2)$: $\phi_X(u) = e^{iu\mu - u^2\sigma^2/2}$. (application directe de la

proposition ci-dessus (p. 101))

6.1.1. Fonction caractéristique d'une variable gaussienne

Soit $X \sim \mathcal{N}(0,1)$. On a

$$\begin{aligned}\phi_X(u) = \mathbb{E}(e^{iuX}) &= \int_{\mathbb{R}} e^{iux}\frac{1}{\sqrt{2\pi}}e^{-x^2/2}dx \\ &= \int_{\mathbb{R}} \frac{\cos(ux)}{\sqrt{2\pi}}e^{-x^2/2}dx + \int_{\mathbb{R}} \frac{i\sin(ux)}{\sqrt{2\pi}}e^{-x^2/2}dx\end{aligned}$$

Comme $x \mapsto \frac{\sin(ux)}{\sqrt{2\pi}}e^{-x^2/2}$ est impaire et intégrable, son intégrale est nulle, d'où

$$\phi_X(u) = \int_{\mathbb{R}} \frac{\cos(ux)}{\sqrt{2\pi}}e^{-x^2/2}dx.$$

D'après la proposition — fonction caractéristique et moments (p. 104), on peut dériver les deux membres par rapport à u, et on obtient

$$\phi'_X(u) = \frac{1}{\sqrt{2\pi}}\int_{\mathbb{R}} -x\sin(ux)e^{-x^2/2}dx$$

puis par intégration par parties

$$\phi'_X(u) = -\frac{1}{\sqrt{2\pi}}\int_{\mathbb{R}} u\cos(ux)e^{-x^2/2}dx = -u\phi_X(u).$$

Ainsi, ϕ_X satisfait à l'équation différentielle $\phi'_X(u) = -u\phi_X(u)$, dont la solution générale est

$$\phi_X(u) = Ce^{-u^2/2}.$$

Comme $\phi_X(0) = 1$, on en déduit finalement que

$$\phi_X(u) = e^{-u^2/2}.$$

L'intérêt majeur de la fonction caractéristique réside dans le fait qu'elle caractérise la loi de la variable aléatoire (d'où son nom).

Théorème – Caractérisation.

La fonction caractéristique ϕ_X caractérise la loi du vecteur aléatoire X. Ainsi, si deux vecteurs aléatoires X et Y ont même fonction caractéristique, ils ont même loi.

Démonstration. Soient les fonctions suivantes avec $\sigma > 0$:

$$f_\sigma(x) = \frac{1}{(2\pi\sigma^2)^{n/2}}\exp\left(-\frac{|x|^2}{2\sigma^2}\right) \text{ et } \widehat{f_\sigma}(u) = \exp\left(-\frac{|u|^2\sigma^2}{2}\right).$$

On note que f_σ est la densité d'un vecteur gaussien Z de dimension n, centré et de matrice de covariance $\sigma^2 I_n$, autrement dit dont les composantes sont indépendantes, centrées, de variances σ^2.

On a

$$\begin{aligned}\mathbb{E}(e^{i<u,Z>}) = \int f_\sigma(x)e^{i<u,x>}dx &= \int_{\mathbb{R}^n} \prod_{j=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x_j^2}{2\sigma^2} + iu_jx_j\right) dx_1 \dots dx_n \\ &= \prod_{j=1}^n \int_{\mathbb{R}} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{t^2}{2\sigma^2} + iu_jt\right) dt \\ &= \prod_{j=1}^n e^{-u_j^2\sigma^2/2} \\ &= \widehat{f}_\sigma(u)\end{aligned}$$

d'après l'exemple 5 ci-dessus et en utilisant le théorème de Fubini. On remarque ainsi que

$$f_\sigma(u-v) = \frac{1}{(2\pi\sigma^2)^{n/2}} \widehat{f}_\sigma\left(\frac{u-v}{\sigma^2}\right) = \frac{1}{(2\pi\sigma^2)^{n/2}} \int f_\sigma(x)e^{i<u-v,x>/\sigma^2}dx.$$

Supposons que X et Y admettent la même fonction caractéristique $\phi_X = \phi_Y$. En utilisant le théorème de Fubini, on a

$$\begin{aligned}\mathbb{E}_X(f_\sigma(X-v)) &= \int f_\sigma(u-v)\mathbb{P}_X(du) \\ &= \int_{\mathbb{R}^n} \frac{1}{(2\pi\sigma^2)^{n/2}} \left(\int_{\mathbb{R}^n} f_\sigma(x)e^{i<u-v,x>/\sigma^2}dx\right) \mathbb{P}_X(du) \\ &= \int_{\mathbb{R}^n} f_\sigma(x) \frac{1}{(2\pi\sigma^2)^{n/2}} \left(\int_{\mathbb{R}^n} e^{i<u,x/\sigma^2>}\mathbb{P}_X(du)\right) e^{-i<v,x>/\sigma^2}dx \\ &= \int_{\mathbb{R}^n} f_\sigma(x) \frac{1}{(2\pi\sigma^2)^{n/2}} \phi_X\left(\frac{x}{\sigma^2}\right) e^{-i<v,x>/\sigma^2}dx,\end{aligned}$$

et la même égalité reste vraie pour $\mathbb{P}_Y$. On en déduit que

$$\mathbb{E}(g(X)) = \int g(u)\mathbb{P}_X(du) = \int g(u)\mathbb{P}_Y(du) = \mathbb{E}(g(X'))$$

pour toute fonction g de l'espace vectoriel de fonction engendrées par $u \mapsto f_\sigma(u-v)$.

D'après le théorème de Stone-Weiertrass[1], cet espace est dense dans l'ensemble C_0 des fonctions continues sur $\mathbb{R}^n$ et ayant une limite nulle à l'infini, pour la topologie de la convergence uniforme (la norme est le sup sur $\mathbb{R}^n$).

Par suite, $\mathbb{E}(g(X)) = \mathbb{E}(g(X'))$ pour toute fonction $g \in C_0$. Comme l'indicatrice de tout ouvert est limite croissante de fonctions de C_0, on en déduit que $\mathbb{P}_X(A) = \mathbb{E}(1_A(X))$ est égal à $\mathbb{P}_{X'}(A) = \mathbb{E}(1_A(X'))$ pour tout ouvert A, ce qui implique $P_X = P_{X'}$. ■

La fonction caractéristique offre également un moyen commode de caractériser l'indépendance.

Corollaire.

Soit $X = (X_1, \dots, X_n)$ un vecteur aléatoire à valeurs dans $\mathbb{R}^n$. Ses composantes X_i sont

1. voir par exemple Simmons (2003) p.160.

indépendantes si et seulement si pour tous $u_1, \ldots, u_n \in \mathbb{R}$,

$$\phi_X(u_1, \ldots, u_n) = \prod_{j=1}^{n} \phi_{X_j}(u_j)$$

où ϕ_X désigne la fonction caractéristique du vecteur aléatoire X, et ϕ_{X_j} celle de la composante X_j pour chaque j.

Démonstration. On a $< u, X >= \sum_{j=1}^{n} u_j X_j$. Si les X_i sont indépendantes, et comme $e^{i<u,x>} = \prod_j e^{iu_j x_j}$, nous obtenons directement le résultat en utilisant la proposition (valable dans le cas général) qui montre que l'espérance du produit de fonctions de variables aléatoires indépendantes est égal au produit des espérances.

Supposons inversement qu'on ait $\phi_X(u_1, \ldots, u_n) = \prod_{j=1}^{n} \phi_{X_j}(u_j)$. On peut alors construire des variables aléatoires X'_j indépendantes, telles que X'_j et X_j aient même loi pour tout j et donc telles que $\phi_{X'_j} = \phi_{X_j}$. Si $X' = (X'_1, \ldots, X'_n)$, on a donc $\phi_{X'} = \phi_X$. Donc X et X' ont même loi, ce qui entraîne que pour tous boréliens A_j, on ait

$$\mathbb{P}(\bigcap_j \{X_j \in A_j\}) = \mathbb{P}(\bigcap_j \{X'_j \in A_j\}) = \prod_j \mathbb{P}(\{X'_j \in A_j\}) = \prod_j \mathbb{P}(\{X_j \in A_j\})$$

d'où l'indépendance. ■

Proposition – Somme.

Si X et Y sont deux vecteurs aléatoires indépendants à valeurs dans $\mathbb{R}^n$, la fonction caractéristique de la somme $X + Y$ est donnée par

$$\phi_{X+Y} = \phi_X \phi_Y$$

Démonstration. Comme $e^{i<u,X+Y>} = e^{i<u,X>} e^{i<u,Y>}$, il suffit d'appliquer la proposition déjà utilisée dans la preuve du corollaire ci-dessus. ■

6.1.2. Exemples :

Soient X et Y deux variables aléatoires réelles indépendantes et $Z = X + Y$:

1. Si X suit la loi normale $\mathcal{N}(m, \sigma^2)$ et Y suit $\mathcal{N}(m', \sigma'^2)$, alors Z suit une loi $\mathcal{N}(m + m', \sigma^2 + \sigma'^2)$, d'après l'exemple ci-dessus (p. 101) point 6. et la proposition ci-dessus (p. 104).
2. Si X et Y suivent des lois de Poisson de paramètres θ et θ', alors Z suit une loi de Poisson de paramètre $\theta + \theta'$, d'après l'exemple ci-dessus (p. 101) point 2. et la proposition ci-dessus (p. 104).
3. Si X suit une loi binomiale $\mathcal{B}(n, p)$ et Y la loi biomiale $\mathcal{B}(m, p)$, alors Z suit une loi binomiale $\mathcal{B}(n + m, p)$, d'après l'exemple ci-dessus (p. 101) point 1. et la proposition ci-dessus (p. 104).

Proposition – Fonction caractéristique et moments.

Soit X un vecteur aléatoire de $\mathbb{R}^n$. Si la variable $|X|^m$ (où $|\cdot|$ désigne la norme euclidienne)

est intégrable pour un entier m, la fonction ϕ_X est m fois continûment différentiable sur $\mathbb{R}^n$ et pour tout choix des indices $i_1, \ldots, i_m$,

$$\frac{\partial^m}{\partial u_{i_1} \ldots \partial u_{i_m}} \phi_X(u) = i^m \mathbb{E}(e^{i<u,X>} X_{i_1} \ldots X_{i_m}),$$

où les X_j sont les composantes de X.

Démonstration. Le résultat se démontre par application itérée du théorème de dérivation sous le signe somme. ■

Remarque.

En prenant $u = 0$ dans la proposition — somme (p. 104), la formule permet de calculer $\mathbb{E}(X_{i_1} \ldots X_{i_m})$ en fonction des dérivées à l'origine de ϕ_X, autrement dit de calculer tous les moments du vecteur X, s'ils existent. Par exemple, si X est à valeurs réelles et est intégrable (respectivement de carré intégrable), on a

$$\mathbb{E}(X) = i\phi'_X(0), \quad (\text{resp. } \mathbb{E}(X^2) = \phi"_X(0))$$

On donne ici la définition générale d'un vecteur gaussien, qui nous sera utile pour la démonstration du théorème central limite.

Définition – Vecteur Gaussien (cas général).

Un vecteur aléatoire $X = (X_1, \ldots, X_n)$ à valeurs dans $\mathbb{R}^n$ est dit gaussien si toute combinaison linéaire de ses composantes, soit $\sum_{j=1}^n a_j X_j$ où $a_j \in \mathbb{R}$, suit une loi normale uni-dimensionnelle (éventuellement dégénérée, par exemple si on prend $a_j = 0$ pour tout j).

Théorème – Cas gaussien.

X est un vecteur gaussien si et seulement si sa fonction caractéristique s'écrit

$$\phi_X(u) = e^{i<u,m> - \frac{1}{2}<u,Cu>}$$

où $m = \mathbb{E}(X) \in \mathbb{R}^n$ et C est la matrice de covariance de X qui est donc semi-définie positive.

Démonstration.

1. Supposons $\phi_X(u) = e^{i<u,m> - \frac{1}{2}<u,Cu>}$. Pour toute combinaison linéaire $Y = \sum_j a_j X_j =< a, X >$, et pour tout $v \in \mathbb{R}$, on a

$$\phi_Y(v) = \phi_X(va) = e^{iv<a,m> - \frac{v^2}{2}<a,Ca>}$$

   donc Y suit la loi $\mathcal{N}(< a, m >, < a, Ca >)$.
2. Inversement, soit C la matrice de covariance de X et m son vecteur moyenne. Si $Y =<$

$a, X >= \sum_{j=1}^{n} a_j X_j$ avec $a \in \mathbb{R}^n$, un calcul simple montre

$$\mathbb{E}(Y) =< a, m >, \mathbb{V}(Y) =< a, Ca >$$

Par hypothèse, Y suit une loi normale donc vu le point 6. de l'exemple plus haut (p. 101), sa fonction caractéristique est

$$\phi_Y(v) = e^{iv<a,m>-\frac{v^2}{2}<a,Ca>}$$

Mais $\phi_Y(1) = \phi_{<a,X>}(1) = \mathbb{E}(e^{i<a,X>}) = \phi_X(a)$, d'où le résultat.

■

Le théorème suivant caractérise la convergence en loi à l'aide des fonctions caractéristiques. C'est un critère extrêmement utile dans la pratique.

Théorème – de Lévy.

Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de vecteurs aléatoires à valeurs dans $\mathbb{R}^d$.

1. *Si la suite $(X_n)_{n\in\mathbb{N}^*}$ converge en loi vers X, alors ϕ_{X_n} converge simplement vers ϕ_X.*
2. *Si les ϕ_{X_n} convergent simplement vers une fonction (complexe) ϕ sur $\mathbb{R}^d$ et si cette fonction est **continue** en 0, alors c'est la fonction caractéristique d'une variable aléatoire X et $X_n \xrightarrow{\mathcal{L}} X$.*

Démonstration.

1. On remarque que $\phi_{X_n}(u) = \mathbb{E}(g_u(X_n))$ et $\phi_X(u) = \mathbb{E}(g_u(X))$ où g_u est la fonction continue bornée $g_u(x) = e^{i<u,x>}$. On applique alors la définition (p. 94).
2. Se reporter à Jacod and Protter (2003).

■

7. Exercices

7.1. Inégalités de concentration

Question 1 Soit $(X_n)_n$ une suite de variables aléatoires indépendantes et identiquement distribuées d'espérance $\mathbb{E}(X_i) = m$ et de variance $\mathbb{V}(X_i) = \sigma^2 \leq 1$. Montrer que pour tout $\delta \in]0, 1[$, avec probabilité au moins $1 - \delta$ on a

$$\left| \frac{1}{n} \sum_{i=1}^{n} X_i - m \right| \leq \sqrt{\frac{1}{\delta n}}$$

On peut trouver des bornes à décroissance beaucoup plus rapide dans des cas particuliers.

Question 2 On suppose désormais que les X_i sont de loi $\mathcal{N}(m, \sigma^2)$.

i) On pose pour $u \in \mathbb{R}$: $M(u) = \mathbb{E}(e^{u(X_1-m)})$. Calculer $M(u)$.

ii) On pose $S_n = X_1 + \ldots + X_n$. Montrer que $\forall a \in \mathbb{R}, \forall u \in \mathbb{R}_+$,

$$\mathbb{P}(S_n - nm > a) \leq e^{-ua}(M(u))^n,$$

et que $\forall a \in \mathbb{R}, \forall u \in \mathbb{R}_-$,

$$\mathbb{P}(S_n - nm < -a) \leq e^{ua}(M(u))^n.$$

iii) Soit $Y_n = \frac{S_n}{n}$. Montrer que $\forall \varepsilon > 0$,

$$\mathbb{P}(|Y_n - m| > \varepsilon) \leq 2\exp\left(\frac{-n\varepsilon^2}{2\sigma^2}\right).$$

Cette inégalité est appelée inégalité de Chernov.

On peut dériver ce type d'inégalités pour différentes lois de probabilité. On voit qu'ici la concentration auprès de la moyenne se fait à vitesse exponentielle. On a le même type de résultats pour la loi de Bernoulli par exemple ce qui est très utile en apprentissage statistique dans les problèmes de classification.

Question 3

iv) On suppose que $m = 1$ et que $\sigma^2 = 10$. Quelle taille d'échantillon doit-on choisir pour obtenir

$$\mathbb{P}(|Y_n - m| < \varepsilon) \geq \alpha,$$

avec $\alpha = 0,95$ et $\varepsilon = 0,05$,

- en utilisant l'inégalité de Bienaymé-Chebyshev ?
- en utilisant l'inégalité de Chernov ?

7.2. Lemme de Borel-Cantelli

Soit A_n une suite d'événements sur l'espace probabilisé $(\Omega, \mathcal{A}, \mathbb{P})$.

Question 1 On suppose que $\sum_{i=1}^n \mathbb{P}(A_n) < \infty$. Montrer que $\mathbb{P}(\limsup_{n\to\infty} A_n) = \mathbb{P}\left(\bigcap_{n\geq 1}\bigcup_{k\geq n} A_k\right) = 0$.

Question 2 On suppose maintenant que les événements A_n sont mutuellement indépendants. Montrer que si $\sum_{i=1}^n \mathbb{P}(A_n) = \infty$, alors on a $\mathbb{P}(\limsup_{n\to\infty} A_n) = 1$.

Question 3 Donner un exemple où $\sum_{i=1}^n \mathbb{P}(A_n) = \infty$ et $\mathbb{P}(\limsup_{n\to\infty} A_n) < 1$ quand les A_n ne sont pas indépendants.

7.3. Convergence vers une constante

Soient $(X_n)_{n\in\mathbb{N}^*}$ une suite de variables aléatoires réelles, X une autre variable aléatoire réelle et $a \in \mathbb{R}$.

Convergence $\mathcal{L}^2$ On suppose que X et chaque X_n, $n \in \mathbb{N}^*$, sont de carré intégrable.

1. Montrer l'implication

$$X_n \xrightarrow[n\to+\infty]{\mathcal{L}^2} X \Rightarrow \left| \begin{array}{l} \mathbb{E}(X_n) \xrightarrow[n\to+\infty]{} \mathbb{E}(X), \\ \mathbb{V}(X_n) \xrightarrow[n\to+\infty]{} \mathbb{V}(X). \end{array} \right.$$

2. Vérifier l'équivalence

$$X_n \xrightarrow[n\to+\infty]{\mathcal{L}^2} a \Leftrightarrow \left| \begin{array}{l} \mathbb{E}(X_n) \xrightarrow[n\to+\infty]{} a, \\ \mathbb{V}(X_n) \xrightarrow[n\to+\infty]{} 0. \end{array} \right.$$

Convergences en loi et probabilité Montrer que si X_n converge en loi vers a quand $n \to +\infty$, alors elle converge aussi en probabilité vers a.

7.4. Fonction de répartition empirique

Soient X une variable aléatoire réelle de fonction de répartition F et $(X_n)_{n\in\mathbb{N}^*}$ une suite de variables aléatoires indépendantes, de même loi que X. Pour tout $n \in \mathbb{N}^*$ on définit la fonction de répartition empirique comme suit :

$$F_n : x \in \mathbb{R} \mapsto \frac{1}{n} \sum_{i=1}^{n} 1_{]-\infty,x]}(X_i).$$

Son nom est issu de la modélisation probabiliste en statistique. Lorsque l'on souhaite étudier une variable physique dont on n'est pas à même de prédire parfaitement les valeurs (e.g. la hauteur d'eau de la Seine à la station d'Austerlitz), le statisticien va la considérer comme une variable aléatoire X. Pour en retrouver les propriétés, il va observer un certain nombre $n \in \mathbb{N}^*$ de réalisations de cette variable (en réalisant des mesures sur le terrain), qu'il va à nouveau considérer comme des variables aléatoires $X_1, \ldots, X_n$ de même loi que X. Lorsque cette hypothèse est raisonnable, il va supposer que ces dernières sont même indépendantes. Nous allons voir dans cet exercice que pour tout $x \in \mathbb{R}$, $F_n(x)$, calculée à partir des données de terrain (d'où le nom attribué à F_n), approche bien la quantité théorique $F(x) = \mathbb{P}(X \leq x)$.

On considère $x \in \mathbb{R}$ fixé.

Préliminaire Quelle est la loi de la variable aléatoire $1_{]-\infty,x]}(X)$? Expliciter son espérance et sa variance.

Biais Soit $n \in \mathbb{N}^*$. Calculer l'espérance de $F_n(x)$. On dit que $F_n(x)$ est un *estimateur sans biais* de $F(x)$.

Erreur quadratique moyenne Montrer que $F_n(x) \xrightarrow{\mathcal{L}^2} F(x)$ quand $n \to +\infty$.

Consistance Montrer que $F_n(x) \to F(x)$ p.s. quand $n \to +\infty$. On dit que $F_n(x)$ est un *estimateur fortement consistant* de $F(x)$.

7.5. Théorème de Weierstrass sur $[0, 1]$

Le théorème de Weierstrass est un résultat classique d'analyse dont l'énoncé est le suivant : soient I un segment de $\mathbb{R}$ et $f : I \to \mathbb{R}$ une fonction continue. Alors il existe une suite $(P_n)_{n\in\mathbb{N}^*}$ de polynômes $\mathbb{R} \to \mathbb{R}$ convergeant uniformément vers f sur I.

Dans cet exercice, nous allons voir une démonstration constructive de ce théorème dans le cas particulier où $I = [0, 1]$.

Preuve du théorème. Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de variable aléatoires indépendantes, suivant toutes la même loi de Bernoulli de paramètre $x \in]0, 1[$. Pour tout $n \in \mathbb{N}^*$ on pose $M_n := \frac{1}{n}\sum_{i=1}^{n} X_i$. On considère une fonction $f : [0, 1] \to \mathbb{R}$ continue.

1. Soit $n \in \mathbb{N}^*$. Vérifier que $\mathbb{E}\left(f(M_n)\right)$ peut s'écrire sous forme de polynôme.
2. Montrer que $\mathbb{E}\left(f(M_n)\right) \xrightarrow[n\to+\infty]{} f(x)$.
3. En déduire qu'il existe une suite de polynômes $[0, 1] \to \mathbb{R}$ qui convergent simplement vers f.
4. Montrer que la suite de polynômes exhibée à la question précédente converge même uniformément vers f.

7.6. Théorème de Slutsky

Question 1 Soient $(X_n)_n$ et X des variables aléatoires. Montrer que $X_n \xrightarrow{\mathcal{L}} X$ si et seulement si $\mathbb{E}(f(X_n)) \xrightarrow[n\to\infty]{} \mathbb{E}(f(X))$ pour toute fonction f lipschitzienne bornée.

Question 2 Soient $(X_n)_n$ et $(Y_n)_n$ deux suites de variables aléatoires définies sur le même espace de probabilité. On suppose que $(X_n)_n$ converge en loi vers X et que $(X_n - Y_n)_n$ converge vers 0 en probabilité. Montrer que $(Y_n)_n$ converge en loi vers X.

Question 3 Montrer ce résultat à l'aide du théorème de Lévy (p. 106).

---

8. Références

Jacod, J., and P. Protter. 2003. *L'essentiel En Théorie Des Probabilités*. Cassini. `https://hal.archives-ouvertes.fr/hal-00104956`.

Simmons, George F. 2003. *Introduction to Topology and Modern Analysis*. Reprint edition. Malabar, Fla: Krieger Publishing Company.

Cinquième partie

Probabilités V : Simulation

1. Objectifs d'apprentissage

Cette section s'efforce d'expliciter et de hiérarchiser les acquis d'apprentissages associés au chapitre. Ces objectifs sont organisés en paliers :

(○) Prérequis (•) Fondamental (••) Standard (•••) Avancé (••••) Expert

Sauf mention particulière, la connaissance des démonstrations du document n'est pas exigible [1]

Intégrale de Monte Carlo

- • connaître le principe de l'intégration par la méthode Monte Carlo
- • savoir que cette approche se justifie par la loi des grands nombres
- • savoir que l'approximation fournie par le TCL offre un contrôle de l'erreur

Génération de nombres pseudo-aléatoires

- • connaître le principe de la génération de nombres pseudo-aléatoires par la méthode des congruences

Méthodes de simulation de v.a.

- • connaître et savoir implémenter en python la méthode d'inversion
- • connaître et savoir implémenter en python la méthode de rejet
- • connaître la méthode de Box-Muller
- • connaître et savoir implémenter la simulation de vecteurs gaussien par la méthode de Cholesky

Echantillonnage d'importance

- • connaître la définition de la méthode d'échantillonnage d'importance
- • savoir qu'un bon choix de densité instrumentale permet de minimiser la variance d'estimation

2. Intégrale de Monte-Carlo

Les méthodes de Monte-Carlo ont été développées initialement par des physiciens dans les années 1950 (notamment par les travaux de Metropolis, Ulam, Hastings, Rosenbluth) pour calculer des intégrales (déterministes) à partir de méthodes probabilistes numériquement assez économiques. Le nom a été donné en référence au célèbre casino du fait du caractère aléatoire de ces méthodes.

Les méthodes de simulation sont basées sur la production de nombres aléatoires, distribués selon une certaine loi de probabilité. Dans de nombreuses applications, pour une certaine fonction h, on souhaite calculer, pour une variable aléatoire X de loi $\mathbb{P}_X$

$$\mathcal{I} = \mathbb{E}\left(h(X)\right) = \int h(x)\, \mathbb{P}_X(dx).$$

1. l'étude des démonstrations du cours peut toutefois contribuer à votre apprentissage, au même titre que la résolution d'exercices.

En général, même si on sait évaluer h en tout point, on ne peut pas calculer formellement l'intégrale $\mathcal{I}$. Le calcul d'intégrale par la méthode Monte-Carlo consiste dans sa version la plus simple à générer un *échantillon* $(X_1, \ldots, X_n) \sim_{i.i.d.} \mathbb{P}_X$, et à estimer $\mathcal{I}$ par la moyenne empirique

$$M_n(h) = \frac{1}{n} \sum_{i=1}^{n} h(X_i),$$

où i.i.d signifie indépendant et identiquement distribué. En effet, d'après la loi forte des grands nombres, si $h(x)$ est $\mathbb{P}_X$-intégrable, on a l'assurance que quand $n \to +\infty$,

$$M_n(h) \to \int h(x)\mathbb{P}_X(dx) \text{ p.s.}$$

Si de plus $h(X)^2$ est intégrable, la vitesse de convergence de $M_n(h)$ peut être évaluée, puisque la variance

$$\mathbb{V}(M_n(h)) = \frac{1}{n} \int (h(x) - \mathcal{I})^2 \, \mathbb{P}_X(dx)$$

peut également être estimée à partir de l'échantillon $(X_1, \ldots, X_n)$ par la quantité

$$\sigma_n^2 = \frac{1}{n} \sum_{i=1}^{n} (h(X_i) - M_n(h))^2 .$$

Le théorème central limite assure alors que pour n grand,

$$\frac{M_n(h) - \mathcal{I}}{\sigma_n}$$

suit approximativement une loi $\mathcal{N}(0,1)$ [1]. Cette propriété conduit à la construction de tests de convergence et de bornes de confiance asymptotiques pour $M_n(h)$. Par exemple, on aura

$$\mathbb{P}\left(\mathcal{I} \in [M_n(h) - 1.96\sigma_n, M_n(h) + 1.96\sigma_n]\right) \approx 0.95,$$

où $1.96 \approx \Phi^{-1}(0,975)$ avec Φ la fonction de répartition de la loi normale centrée réduite.

En outre, cette propriété indique que la vitesse de convergence de $M_n(h)$ est de l'ordre de $\sqrt{n}$, et ce indépendamment de la dimension du problème. Cela explique la supériorité de cette méthode par rapport aux méthodes d'intégration numérique déterministes dont les vitesses de convergence décroissent rapidement (exponentiellement) avec la dimension du problème.

Exercice – Calcul numérique d'une probabilité (••) Calculer une estimation de la probabilité de l'événement $\sin(X) > 1/2$ pour X de loi $\mathcal{N}(0,1)$.

Indication : si x est un vecteur, `y=(np.sin(x)>1/2)` désigne le vecteur de booléens dont les coordonnées valent `True` ou `False` selon que les coordonnées correspondantes de `np.sin(x)` soient ou non $> 1/2$. Par ailleurs, les vecteurs de booléens se convertissent naturellement en vecteurs de 0 et de 1 si on leur applique une fonction dont les arguments sont des nombres (ex : `np.mean`).

3. Génération de nombres pseudo-aléatoires

Les ordinateurs sont des machines déterministes. Il peut sembler paradoxal de leur demander de générer des nombres aléatoires [1]. En réalité, les algorithmes de génération de nombres aléatoires

1. ce résultat sera démontré dans le cours de science des données au second semestre.

1. Von Neumann (1951) résume ce problème très clairement : "Any one who considers arithmetical methods of reproducing random digits is, of course, in a state of sin. As has been pointed out several times, there is no such thing as a random number — there are only methods of producing random numbers, and a strict arithmetic procedure of course is not such a method."

vont produire des séquences de nombres déterministes qui vont avoir l'aspect de l'aléatoire. On s'intéresse ici à la génération de nombres uniformes sur $]0,1[$ (on exclut les bornes par commodité), puisque, comme on le verra dans la suite, il s'agit de l'ingrédient de base de toutes les méthodes de simulation stochastique.

Définition – Générateur de nombres uniformes pseudo-aléatoires.

Un *générateur de nombres uniformes pseudo-aléatoires* est un algorithme qui étant donné une valeur initiale u_0 et une transformation T produit une séquence $u_i = T^i(u_0)$, $i \in \mathbb{N}^*$, de valeurs dans $]0,1[$.

Pour tout $n \in \mathbb{N}^*$, les valeurs $(u_1, \ldots, u_n)$ reproduisent le comportement d'une suite de variables aléatoires $(V_1, \ldots, V_n)$ i.i.d de loi uniforme sur $]0,1[$, lorsqu'on les compare au travers d'un ensemble de tests statistiques[2], vérifiant par exemple que la corrélation entre deux nombres successifs est suffisamment faible.

Exemple – la méthode des congruences.

Cet algorithme, dû à Lehmer (1951), est l'un des premiers à avoir été proposé et implémenté. Il repose sur 2 paramètres :

- le multiplicateur $a \in \mathbb{N}^*$,
- le modulo $m \in \mathbb{N}^*$.

Etant donné un entier k_0 tel que $1 \leq k_0 \leq m-1$, la séquence de nombres est générée par la transformation suivante : pour tout $n \in \mathbb{N}^*$ on définit l'entier $k_{n+1} = a\, k_n \bmod m$ puis on pose

$$u_{n+1} = \frac{k_{n+1}}{m}, \quad u_0 = \frac{k_0}{m}.$$

On peut remarquer que l'algorithme va produire une séquence de valeurs qui sera périodique, c'est-à-dire qu'après un certain nombre d'itérations, la suite se répétera, et qu'il pourra fournir au plus $m-1$ valeurs différentes. Ce trait est commun à tous les générateurs de nombre aléatoires et est lié aux limitations matérielles des ordinateurs (on ne peut représenter qu'un nombre fini de nombres). Le choix des valeurs de a et m est par conséquent crucial. Il existe des critères qui permettent de s'assurer du bon comportement de cette suite :

- m est un nombre premier (le plus grand possible),
- $p = (m-1)/2$ est un nombre premier,
- $a^p = -1 \bmod m$.

Ce critère assure une période pleine et donc que tous les nombres $(1/m, \ldots, (m-1)/m)$ seront générés. Cependant, les nombres générés ne sont pas indépendants, pas même non corrélés. On peut montrer que la corrélation entre 2 nombres successifs vaut approximativement $1/a$. Il convient donc de choisir a suffisamment grand pour que celle-ci devienne négligeable. Par exemple, en prenant $a = 1000$ et $m = 2001179$, on obtient une période de 2001178 et une corrélation de l'ordre de 10^{-3}.

Ce générateur de nombres uniformes pseudo-aléatoires, bien que rudimentaire, a ouvert la voie à des générateurs plus sophistiqués, toujours basés sur des opérations arithmétiques. Le

2. Par exemple, la suite de tests Die Hard, due à Marsaglia.

plus couramment utilisé à ce jour est l'algorithme de Mersenne-Twister. Il s'agit du générateur par défaut de la plupart des logiciels tels que Python, R, MATLAB, Julia, MS Excel,... Il passe notamment avec succès toute la batterie de tests Die Hard. En particulier, sa période vaut $2^{19937} - 1$.

Pour certains usages, cet algorithme n'est cependant pas recommandé du fait de sa prédictibilité. C'est notamment un défaut rédhibitoire pour les applications en cryptographie. Il existe des variantes mieux adaptées à ce cas de figure. On notera enfin qu'il existe des générateurs de nombres aléatoires basés sur des phénomènes physiques comme un bruit électrique ou des phénomènes quantiques et donc parfaitement imprévisibles.

4. Méthodes de simulation de variables aléatoires réelles

On a vu au chapitre II du cours de Probabilités que l'on pouvait transformer des variables aléatoires réelles suivant certaines lois pour en obtenir de nouvelles. Par exemple, si $X_1, \ldots, X_n$ sont $n \in \mathbb{N}^*$ variables gaussiennes centrées réduites indépendantes, alors $X_1^2 + \ldots, X_n^2$ suit une loi du χ^2 à n degrés de liberté. Dans le même esprit, on va voir ici comment simuler des v.a.r. de lois diverses à partir de la simulation de variables uniformes sur $]0,1[$. On introduit une notation qui sera utile dans la suite : pour spécifier que deux v.a.r. X et Y ont même loi, on écrira $X \overset{\mathcal{L}}{=} Y$.

4.1. Méthode d'inversion

L'objectif de ce paragraphe est de définir quand et comment il est possible de simuler une variable aléatoire réelle X de fonction de répartition (f.d.r.) F_X en transformant la simulation d'une variable aléatoire U de loi uniforme sur $]0,1[$. En d'autres termes, on cherche à déterminer les conditions sous lesquelles il est possible d'identifier une fonction borélienne $\psi :]0,1[\to \mathbb{R}$ telle que $X \overset{\mathcal{L}}{=} \psi(U)$.

Commençons par un cadre simple, où F_X est **bijective** d'un intervalle non vide de $\mathbb{R}$ sur $]0,1[$.

Proposition – Cas où F_X est bijective.

Soient X une variable aléatoire réelle de fonction de répartition F_X et U une variable uniforme sur $]0,1[$. S'il existe un intervalle non vide $]a,b[\subset \mathbb{R}$ tel que $F_X :]a,b[\to]0,1[$ est bijective, de bijection réciproque $F_X^{-1} :]0,1[\to]a,b[$, alors $F_X^{-1}(U) \overset{\mathcal{L}}{=} X$ et $F_X(X) \overset{\mathcal{L}}{=} U$.

Démonstration. Le premier résultat est immédiat : pour tout $x \in \mathbb{R}$, par croissance de F_X et donc de F_X^{-1}, on a

$$\mathbb{P}\left(F_X^{-1}(U) \leq x\right) = \mathbb{P}\left(U \leq F_X(x)\right) = F_X(x).$$

Concernant le second, notons G la fonction de répartition de la variable aléatoire $F_X(X)$. La croissance de F_X garantit que $\mathbb{P}\left(F_X(X) \in]0,1[\right) = 1$. Ainsi, pour tout $x \in \mathbb{R}$ on a bien

$$G(x) = \begin{cases} 1 & \text{si } x \geq 1, \\ \mathbb{P}\left(F_X(X) \leq x\right) = \mathbb{P}\left(X \leq F_X^{-1}(x)\right) = x & \text{si } 0 < x < 1, \\ 0 & \text{sinon.} \end{cases}$$

■

Exercice – Exemples d'application 1 (•) Donner un algorithme de simulation d'une v.a.r. X suivant une loi

- uniforme sur un intervalle $I \subset \mathbb{R}$,
- Exponentielle de paramètre $\lambda \in \mathbb{R}_+^*$,
- de Cauchy, de densité $x \in \mathbb{R} \mapsto \left(\pi\left(1+x^2\right)\right)^{-1}$,
- de Laplace de paramètres $\mu \in \mathbb{R}$ et $s \in \mathbb{R}_+^*$, de densité $x \in \mathbb{R} \mapsto \frac{1}{2s} \exp\left\{-\frac{|x-\mu|}{s}\right\}$,
- Logistique de paramètres $\mu \in \mathbb{R}$ et $s \in \mathbb{R}_+^*$, de fonction de répartition $x \in \mathbb{R} \mapsto \left(1+\exp\left\{-\frac{x-\mu}{s}\right\}\right)^{-1}$?

Dans cette situation idéale, $\psi = F_X^{-1}$ est une solution à notre problème. Que se passe-t-il en revanche si F_X n'est pas bijective ?

Exercice – Pile ou face (•) Proposer une méthode pour simuler un tir à pile ou face à partir de la simulation d'une variable uniforme sur $]0,1[$.

On a déjà vu au chapitre II que les fonctions de répartition de v.a.r. possèdent un nombre au plus dénombrable de points de discontinuité. Sur chaque intervalle où elles sont continues, on peut alors considérer qu'elles sont bijectives, quitte à réduire les zones de palier à un point. Cela permet de généraliser la notion de bijection réciproque pour ces fonctions.

Définition – Réciproque généralisée.

Soit F une fonction de répartition. On définit sa *réciproque généralisée* (aussi appelée *inverse généralisée* ou *pseudo-inverse*) comme la fonction

$$F^- : u \in]0,1[\mapsto \inf\{x \in \mathbb{R} : F(x) \geq u\} \in \mathbb{R}.$$

Remarque – Conséquences.

- Cette fonction est bien définie sur tout $]0,1[$, car quel que soit u dans cet intervalle, l'ensemble $\{x \in \mathbb{R} : F(x) \geq u\}$ est non vide et minoré. S'il était vide ou non minoré pour un certain $u_0 \in]0,1[$, pour tout $x \in \mathbb{R}$ on aurait dans le premier cas $F(x) < u_0 < 0$ et dans le second $F(x) \geq u_0 > 1$. L'une comme l'autre de ces inégalités est impossible pour une fonction de répartition.
- La réciproque généralisée de la f.d.r. F_X d'une v.a.r. X est aussi appelée *fonction quantile*. On pourra notamment remarquer que $F_X^-\left(\frac{1}{2}\right)$ est la médiane de X.
- Lorsque F réalise une bijection d'un intervalle non vide $I \subset \mathbb{R}$ sur $]0,1[$, sa réciproque généralisée coïncide avec sa bijection réciproque.

On a alors le résultat suivant, qui indique que $\psi = F_X^-$ est une solution universelle à notre problème. La preuve détaillée est donnée en Annexe.

Théorème – Méthode d'inversion.

Soient U une variable uniforme sur $]0,1[$ ainsi que X une variable aléatoire réelle de fonction de répartition F_X et de réciproque généralisée F_X^-. Alors $F_X^-(U) \overset{\mathcal{L}}{=} X$.

Exercice – Exemples d'application 2 (•) Donner un algorithme de simulation d'une v.a.r. X suivant une loi

- Binomiale de paramètres $n \in \mathbb{N}^*$ et $p \in]0,1[$,
- Uniforme sur l'union de deux segments non vides et disjoints $[a,b], [c,d] \subset \mathbb{R}$, de densité $x \in \mathbb{R} \mapsto (b-a+d-c)^{-1} 1_{[a,b]\cup[c,d]}(x)$?

4.1.1. Limitations

La méthode d'inversion peut sembler universelle pour simuler une v.a.r. X à partir de $U \sim \mathcal{U}_{]0,1[}$. Cependant, elle nécessite en pratique de disposer d'une expression analytique de F_X pour en déduire sa réciproque généralisée. Ce n'est typiquement pas le cas de nombreuses lois usuelles comme la loi Normale. On va donc déterminer d'autres procédures pour simuler des variables suivant de telles lois.

4.2. Méthode de rejet

La méthode de rejet est une alternative populaire à la méthode d'inversion, lorsque cette dernière ne peut être utilisée directement et que **la loi cible possède une densité**. On la doit à Von Neumann (1951). Pour en comprendre le fondement, il faut d'abord introduire une généralisation naturelle de la loi uniforme dans $\mathbb{R}$ à $\mathbb{R}^d$ ($d \in \mathbb{N}^*$). On notera λ la mesure de Lebesgue sur $\mathbb{R}^d$.

Définition – Loi uniforme sur un borélien.

La loi uniforme sur un borélien $A \subset \mathbb{R}^d$ de volume $\lambda(A) > 0$ est une loi de probabilité admettant pour densité

$$f : x \in \mathbb{R}^d \mapsto \frac{1_A(x)}{\lambda(A)}.$$

Exercice – Loi uniforme sur un pavé (•) Comment simuler un vecteur aléatoire $(U_1, \ldots, U_d)$ de loi uniforme sur un pavé non vide $[a_1, b_1] \times \cdots \times [a_d, b_d] \subset \mathbb{R}^d$?

Une propriété fondamentale de cette loi est qu'elle reste stable par conditionnement, dans le sens suivant.

Proposition – Stabilité par conditionnement.

Soit U un vecteur aléatoire de loi uniforme sur un borélien $A \subset \mathbb{R}^d$ de volume $\lambda(A) > 0$. Alors pour tout borélien $B \subset A$ de volume $\lambda(B) > 0$, la loi conditionnelle $\mathbb{P}_{U|U\in B}$ de U sachant que $U \in B$ est uniforme sur B.

Exercice – Démonstration (•)

Exercice – Simulation (•) Déduire de la proposition précédente (p. 116) une méthode pour simuler un vecteur aléatoire de loi uniforme sur un borélien $B \subset \mathbb{R}^d$ **borné** et de volume $\lambda(B) > 0$.

Il est aussi possible de simuler un vecteur aléatoire de loi uniforme sur certains boréliens non vides et non bornés, comme l'établit la proposition ci-dessous.

Proposition – Loi uniforme sur le sous-graphe d'une densité.

Soient une densité $f : \mathbb{R} \to \mathbb{R}$, une v.a.r. X et une variable U uniforme sur $]0,1[$, indépendante de X. On note $A_f := \{(x,y) \in \mathbb{R} \times \mathbb{R}_+ : f(x) \geq y\}$ le domaine limité par le graphe de f et l'axe des abscisses (souvent appelé sous-graphe de f). Si X est de densité f, alors le couple $(X, Uf(X))$ suit une loi uniforme sur A_f.

Démonstration. Commençons par remarquer que $\lambda(A_f) = 1$. Quel que soit $(z,v) \in \mathbb{R}^2$, par indépendance de X et U et par Fubini on a

$$\begin{aligned}
\mathbb{P}\left(X \leq z, Uf(X) \leq v\right) &= \int_{\mathbb{R}} \int_{\mathbb{R}} 1_{]-\infty,z]}(x)\, 1_{]-\infty,v]}(uf(x))\, 1_{]0,1[}(u)\, f(x)\, du\, dx \\
&= \int_{-\infty}^{z} \left(\int_{\mathbb{R}} 1_{]-\infty,v] \cap]0,f(x)[}(uf(x))\, f(x)\, du \right) dx \\
&= \int_{-\infty}^{z} \int_{-\infty}^{v} 1_{]0,f(x)[}(u)\, du\, dx \\
&= \int_{-\infty}^{z} \int_{-\infty}^{v} 1_{A_f}(x,u)\, du\, dx.
\end{aligned}$$

Ainsi, $(X, Uf(X))$ admet pour densité 1_{A_f}, qui correspond bien à celle d'une loi uniforme sur A_f. ■

Pour simuler un vecteur uniforme (X,Y) sur un ensemble A_f tel que défini à la proposition précédente, il suffit donc de simuler une v.a.r. X de densité f, puis une variable U uniforme sur $]0,1[$, et de poser $Y = f(X)U$.

En combinant les résultats précédents, on obtient la méthode de rejet, illustrée sur la figure ci-dessous, où $A_Y := \{(x,y) \in \mathbb{R} \times \mathbb{R}_+ : y \leq f_Y(x)\}$.

4.2.1. Méthode de rejet

On souhaite simuler une variable aléatoire réelle X de densité f_X. Supposons que l'on sait simuler une variable U uniforme sur $]0,1[$, ainsi qu'une v.a.r. Y (par exemple avec la méthode d'inversion) de densité f_Y telle qu'il existe un réel $a > 0$ pour lequel on a $\forall x \in \mathbb{R} : f_X(x) \leq a\, f_Y(x)$. Il suffit alors de suivre l'algorithme suivant :

1. simuler Y et U,
2. si $aUf_Y(Y) > f_X(Y)$, recommencer à l'étape 1.
3. poser $X = Y$.

4.2.2. Limitations

La méthode de rejet a l'avantage de permettre de simuler des variables aléatoires à densité dont la fonction de répartition n'a pas de forme analytique, rendant la méthode d'inversion inapplicable. Néanmoins, pour pouvoir l'appliquer il faut connaître une densité auxiliaire qui, multipliée par un réel positif, majore la densité cible, et que l'on sait simuler. Le taux de rejet, c'est-à-dire la probabilité de l'événement $\{aUf_Y(Y) > f_X(Y)\}$, peut parfois être élevé, notamment lorsque la dimension de X est grande, ce qui limite l'efficacité de la méthode.

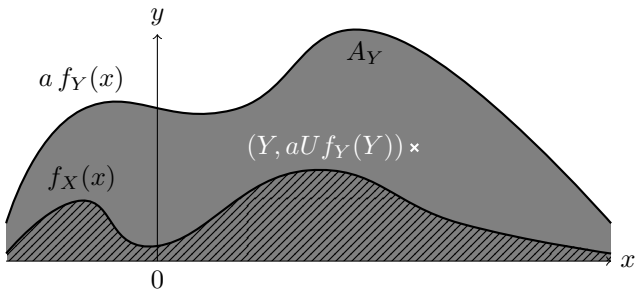


FIGURE 4.1. – Méthode de rejet

Exercice – Taux de rejet (••) Calculer le taux de rejet de la méthode proposée ci-dessus.

4.3. Simulation de variables aléatoires gaussiennes : Box-Muller

On a vu que la méthode d'inversion est inappropriée pour simuler une variable gaussienne, puisqu'elle requiert l'expression analytique de la fonction de répartition cible. Il existe des méthodes basées sur une intégration numérique de la densité gaussienne puis une inversion de cette approximation de la f.d.r. mais elle ne sont pas optimales en temps de calcul. La méthode de rejet est quant à elle sous-optimale, dans le sens où toutes les variables uniformes générées ne sont pas directement utilisées (une partie, potentiellement grande, est rejetée). La loi normale étant fondamentale en probabilité, il est plus que souhaitable de pouvoir en trouver une méthode de simulation exacte et efficace.

George E. P. Box et Mervin E. Muller ont proposé en 1958 une telle méthode (G.E.P. Box and M.E. Muller (1958)). Elle exploite la propriété d'invariance par rotation de la densité d'un couple de variables gaussiennes indépendantes centrées réduites.

Proposition.

Soient U et V deux variables indépendantes, de loi uniforme sur $]0,1[$. Alors les variables aléatoires $X = \sqrt{-2\ln(U)}\cos(2\pi V)$ et $Y = \sqrt{-2\ln(U)}\sin(2\pi V)$ sont indépendantes et suivent toutes deux une loi normale centrée réduite.

Démonstration. On considère $(\widetilde{X}, \widetilde{Y})$ un vecteur aléatoire dont les deux composantes sont indépendantes, de loi normale centrée réduite. On note ses coordonnées polaires aléatoires $\widetilde{R}$ et $\widetilde{\Theta}$. On a vu dans le cours de Probabilités II que dans ce cas, $\widetilde{R}$ et $\widetilde{\Theta}$ sont indépendantes, la première de densité $f_{\widetilde{R}} : r \in \mathbb{R} \mapsto r\, e^{-\frac{r^2}{2}} 1_{\mathbb{R}_+^*}(r)$ et la seconde de loi uniforme sur $]0, 2\pi]$.

X et Y sont les coordonnées cartésiennes obtenues à partir d'un rayon et d'un angle : en posant $R = \sqrt{-2\ln(U)}$ et $\Theta = 2\pi V$ on obtient $X = R\cos(\Theta)$ et $Y = R\sin(\Theta)$. Par indépendance de U et V, R et Θ sont indépendantes. Pour que le vecteur (X, Y) ait la même distribution que $(\widetilde{X}, \widetilde{Y}) = \left(\widetilde{R}\cos(\widetilde{\Theta}), \widetilde{R}\sin(\widetilde{\Theta})\right)$, il suffit de montrer que $R \overset{\mathcal{L}}{=} \widetilde{R}$ et $\Theta \overset{\mathcal{L}}{=} \widetilde{\Theta}$.

- Commençons par étudier la loi de R, de fonction de répartition F_R. On remarque que la fonction $u \in]0,1[\mapsto \sqrt{-2\ln(u)} \in \mathbb{R}_+^*$ est bijective, strictement décroissante. Ainsi, pour tout $r \in \mathbb{R}_-$ on a $\mathbb{P}(R \leq r) = 0$ et pour tout $r \in \mathbb{R}_+^*$ on a

$$\mathbb{P}(R \leq r) = \mathbb{P}\left(\sqrt{-2\ln(U)} \leq r\right) = \mathbb{P}\left(U \geq e^{-\frac{r^2}{2}}\right) = 1 - e^{-\frac{r^2}{2}}.$$

qui correspond à la fonction de répartition associée à la densité $f_{\widetilde{R}}$.

$$\int_{-\infty}^{r} f_{\widetilde{R}}(x)\,dx = \begin{cases} \displaystyle\int_0^r x\,e^{-\frac{x^2}{2}}\,dx = \left[-e^{-\frac{x^2}{2}}\right]_0^r = 1 - e^{-\frac{r^2}{2}} & \text{si } r > 0, \\ 0 & \text{sinon.} \end{cases}$$

- En ce qui concerne la loi de Θ, de fonction de répartition F_Θ, puisque la fonction $v \in]0,1[\mapsto 2\pi v \in]0,2\pi[$ est bijective strictement croissante, on a que pour tout $\theta \in \mathbb{R}$

$$F_\Theta(\theta) = \begin{cases} 1 & \text{si } \theta \geq 2\pi, \\ \mathbb{P}\left(V \leq \frac{\theta}{2\pi}\right) = \dfrac{\theta}{2\pi} & \text{si } \theta \in]0,2\pi[, \\ 0 & \text{si } \theta \leq 0, \end{cases}$$

qui est bien la fonction de répartition d'une loi uniforme sur $]0,2\pi[$.

■

Cette méthode permet de simuler directement deux variables gaussiennes centrées réduites indépendantes à partir de deux variables uniformes indépendantes. Pour simuler une variable gaussienne d'espérance $m \in \mathbb{R}$ et de variance $\sigma^2 \in \mathbb{R}_+^*$ quelconques, on se rappelera que si X suit une loi normale centrée réduite, alors $\sigma X + m$ suit une loi normale d'espérance m et de variance σ^2.

5. Simulation d'un vecteur gaussien à densité

On souhaite simuler un vecteur gaussien $X = (X_1, \ldots, X_d)$ à valeurs dans $\mathbb{R}^d$ d'espérance m et de matrice de covariance C définie positive (et donc inversible) données.

Puisque la matrice C est définie positive, elle admet une racine carrée, c'est-à-dire qu'il existe une matrice N telle que $C = N\,N^t$. En effet, on peut par exemple décomposer C de la manière suivante :

$$C = V\,D\,V^t,$$

où V est une matrice orthogonale et D est la matrice diagonale dont les termes diagonaux sont les valeurs propres (toutes strictement positives) de C. Il suffit alors de prendre $N = V\,D^{1/2}$, où $D^{1/2}$ est la matrice diagonale dont les termes diagonaux sont les racines carrées des valeurs propres.

En pratique, il est coûteux numériquement d'effectuer le calcul des valeurs propres et des vecteurs propres de C. On va plutôt calculer sa *décomposition* ou *factorisation de Cholesky* qui permet d'écrire

$$C = L\,L^t$$

avec L une matrice triangulaire inférieure. [1]

Soit maintenant un autre vecteur gaussien $Y = (Y_1, \ldots, Y_d)$ à valeurs dans $\mathbb{R}^d$ et de matrice de covariance identité, notée I_d. Autrement dit, les Y_i sont des variables aléatoires gaussiennes centrées, réduites et indépendantes.

1. Cette décomposition est très utile dans la résolution de systèmes linéaires de la forme $A\,x = b$, où b est connu, x inconnu et A est définie positive. Cela revient à résoudre $L\,L^t\,x = b$. On pose alors $y = L^t\,x$ et on résout d'abord $Ly = b$, ce qui est très rapide puisque L est triangulaire inférieure (on commence par $y_1 = b_1/L_{11}$, puis $y_2 = (b_2 - L_{21}y_1)/L_{22}$, etc. en descendant). On résout ensuite $L^t\,x = y$, ce qui est aussi très rapide pour la même raison (on commence par $x_n = y_n/L_{nn}$ puis on remonte).

Alors, le vecteur $Z = m + LY$ est gaussien, d'espérance m et de matrice de covariance C. En effet, Z est gaussien comme combinaison linéaire de variables aléatoires gaussiennes, $\mathbb{E}(Z) = \mathbb{E}(m + LY) = m$ et $\mathbb{V}(Z) = \mathbb{E}((LY)^2) = LI_dL^t = C$.

6. Echantillonnage d'importance

On introduit dans cette section la méthode d'échantillonnage d'importance (importance sampling en anglais), que l'on appelle aussi, de manière plus intuitive, échantillonnage préférentiel, pour les lois à densité. Pour ce faire, nous allons commencer par un exemple qui montre qu'il peut être plus efficace de simuler des valeurs selon une loi différente de celle d'intérêt, autrement dit de modifier la représentation de l'intégrale $\mathcal{I}$ sous la forme d'une espérance calculée selon une autre densité.

Exemple – Loi de Cauchy conditionnelle.

Supposons que l'on s'intéresse à calculer la probabilité p qu'une variable X de loi de Cauchy standard soit plus grande que 2 (on peut le calculer directement et $p = 0.15$)

$$p = \int_2^{+\infty} \frac{1}{\pi(1+x^2)} dx.$$

Si on estime p directement à partir d'un échantillon $(X_1, \ldots, X_n)$ simulé selon la loi de Cauchy standard, soit

$$\widehat{p}_1 = \frac{1}{n} \sum_{i=1}^{n} 1_{X_i > 2},$$

la *variance de l'estimateur* $\mathbb{V}(\widehat{p}_1) = p(1-p)/n = 0.127/n$, puisque $\widehat{p}_1$ suit une loi binomiale de paramètre (n, p). On peut réduire cette variance (et donc améliorer la qualité de l'estimateur) en tirant parti de la symétrie de la densité de la loi de Cauchy, en formant un second estimateur

$$\widehat{p}_2 = \frac{1}{n} \sum_{i=1}^{n} 1_{|X_i| > 2},$$

dont la variance vaut $\mathbb{V}(\widehat{p}_2) = p(1-p/2)/2n = 0.052/n$. La relative inefficacité de ces méthodes est due au fait que la majeure partie des valeurs simulées seront en dehors de la zone d'intérêt $]2, +\infty[$. En passant par le complémentaire, on peut réécrire p comme

$$p = \frac{1}{2} - \int_0^2 \frac{1}{\pi(1+x^2)} dx,$$

dont le second terme peut être vu comme l'espérance de $h(U) = \frac{2}{\pi(1+U^2)}$ avec $U \sim \mathcal{U}_{[0,2]}$. Tirant un échantillon $(U_1, \ldots, U_n)$ i.i.d. de loi uniforme sur $[0, 2]$, on obtient un troisième estimateur :

$$\widehat{p}_3 = \frac{1}{2} - \frac{1}{n} \sum_{i=1}^{n} \frac{2}{\pi(1+U_i^2)},$$

dont la variance vaut $\mathbb{V}(\widehat{p}_3) = (\mathbb{E}(h(X)^2) - \mathbb{E}(h(U))^2)/n = 0.0285/n$ (par intégration par parties). Enfin, on peut encore réécrire (voir Ripley (1987))

$$p = \int_0^{1/2} \frac{y^{-2}}{\pi(1+y^{-2})} dy,$$

qui peut être vue comme $\mathbb{E}\left(\frac{V^{-2}}{2\pi(1+V^{-2})}\right)$ avec $V \sim \mathcal{U}_{]0,1/2[}$. L'estimateur formé à partir de cette représentation et d'un échantillon $(V_1, \ldots, V_n)$ i.i.d. de loi uniforme sur $[0, 1/2]$ a une variance de $0.95\,10^{-4}/n$. Il est donc bien plus efficace que $\widehat{p}_1$ puisqu'il nécessite environ $\sqrt{10^3} \approx 32$ fois moins de simulations pour atteindre la même précision.

On a ainsi vu sur ce cas particulier que l'estimation d'une intégrale de la forme

$$\mathcal{I} = \mathbb{E}\left(h(X)\right) = \int_{\mathbb{R}^d} h(x) f(x) dx,$$

peut s'écrire de différentes manières, en faisant varier h et f. Par conséquent, un estimateur "optimal" devrait tenir compte de l'ensemble de ces possibilités. C'est justement l'idée développée dans la méthode d'échantillonnage d'importance dont le principe est décrit dans la définition suivante.

Définition – Echantillonnage d'importance.

La méthode d'*échantillonnage d'importance* est une évaluation de $\mathcal{I}$ basée sur la simulation d'un échantillon $X_1, \ldots, X_n$ de loi de densité g et approximant :

$$\mathbb{E}_f\left(h(X)\right) \approx \frac{1}{n} \sum_{i=1}^{n} \frac{f(X_i)}{g(X_i)} h(X_i),$$

où la notation $\mathbb{E}_f$ signifie que l'espérance est calculée avec $X \sim f$. On appelle souvent les ratios $\frac{f(X_i)}{g(X_i)}$ les *poids d'importance* que l'on note w_i.

Cette méthode est basée sur la représentation suivante de $\mathcal{I}$:

$$\mathbb{E}_f\left[h(X)\right] = \int h(x) \frac{f(x)}{g(x)} g(x)\, dx$$

que l'on appelle l'*identité fondamentale de l'échantillonnage d'importance* et l'estimateur converge du fait de la loi forte des grands nombres.

Cette identité indique qu'une intégrale du type $\mathcal{I}$ n'est pas intrinsèquement associée à une loi donnée. L'intérêt de l'échantillonnage d'importance repose sur le fait qu'il n'y a aucune restriction sur le choix de la densité g, dite *instrumentale*, que l'on peut donc choisir parmi les densités des lois que l'on sait simuler aisément. Il y a bien évidemment des choix qui sont meilleurs que d'autres. Remarquons tout d'abord que bien que l'estimateur proposé dans la définition ci-dessus (p. 121) converge presque sûrement, sa variance est finie si

$$\mathbb{E}_g\left(h^2(X) \frac{f^2(X)}{g^2(X)}\right) = \mathbb{E}_f\left(h^2(X) \frac{f(X)}{g(X)}\right) = \int h^2(x) \frac{f^2(x)}{g(x)}\, dx < \infty.$$

On préconise alors l'usage de densités instrumentales g dont la queue de distribution est plus épaisse que celle de f pour éviter que cette variance puisse être infinie (on notera que cela dépend aussi de la fonction h à intégrer). En pratique, on utilise généralement l'estimateur suivant, de variance finie et qui donne des résultats plus stables numériquement que celui de la définition :

$$\frac{\sum_{i=1}^{n} w_i h(X_i)}{\sum_{i=1}^{n} w_i}$$

où on a remplacé n par la somme des poids d'importance. Puisque $\frac{1}{n}\sum_{i=1^n} w_i = \frac{1}{n}\sum_{i=1}^{n} \frac{f(x_i)}{g(x_i)}$ tend vers 1 quand $n \to \infty$, cet estimateur converge presque sûrement vers $\mathbb{E}_f\left(h(X)\right)$ par la loi forte des grands nombres (voir C. P. Robert and G. Casella (2004)).

Parmi les densités g qui fournissent des estimateurs de variance finie, il est possible d'exhiber la densité optimale (au sens de la variance de l'estimateur associé) pour une fonction h et une densité f données.

Théorème – Densité optimale.

Le choix de g qui minimise la variance de l'estimateur donné dans la définition ci-dessus (p. 121) est

$$g^*(x) = \frac{|h(x)|f(x)}{\int |h(x)|f(x)dx}.$$

Démonstration. Notons d'abord que

$$\mathbb{V}_g\left(\frac{h(X)f(X)}{g(X)}\right) = \mathbb{E}_g\left(h^2(X)\frac{f^2(X)}{g^2(X)}\right) - \mathbb{E}_g\left(h(X)\frac{f(X)}{g(X)}\right)^2$$

et le second terme ne dépend pas de g. On minimise donc le premier terme. D'après l'inégalité de Jensen, on a

$$\mathbb{E}_g\left(h^2(X)\frac{f^2(X)}{g^2(X)}\right) \geq \mathbb{E}_g\left(|h(X)|\frac{f(X)}{g(X)}\right)^2 = \left(\int |h(x)|f(x)dx\right)^2,$$

qui nous donne une borne inférieure indépendante du choix de g. Elle est atteinte en prenant $g = g^*$. ■

Ce résultat formel n'a que peu d'intérêt pratique : le choix optimal de g fait intervenir $\int |h(x)|f(x)dx$, qui est à une valeur absolue près la quantité que l'on souhaite estimer ! Il suggère néanmoins de considérer des densités g telles que $|h|f/g$ est quasi constante et de variance finie. On se reportera au chapitre 3 de C. P. Robert and G. Casella (2004) pour des exemples où un bon choix de g permet des améliorations considérables par rapport à des estimateurs de Monte-Carlo plus naïfs.

7. Exercices

7.1. Loi uniforme dans un domaine

Ecrire un algorithme pour simuler un point uniforme dans les trois domaines représentés ci-dessous.

[figure manquante : ex1-eps-converted-to.pdf]

[figure manquante : ex2-eps-converted-to.pdf]

[figure manquante : ex3-eps-converted-to.pdf]

7.2. Simulation selon la loi géométrique

Cette loi correspond à la loi du nombre d'essais avant d'obtenir un évènement de probabilité p

$$X \sim \mathcal{G}(p) \quad \mathbb{P}(X = n) = p(1-p)^{n-1} \quad n = 1, 2, \ldots$$

Question 1 Calculer l'espérance et la variance de X

Question 2 Générer un échantillon de taille 1000 pour $p = 0.6$, en utilisant une approche génétique. Calculer la moyenne et la variance. Comparer avec les valeurs théoriques.

Question 3 Montrer que si $X \sim \mathcal{E}(\lambda)$, alors $\lceil X \rceil \sim \mathcal{G}(p)$. On précisera la valeur de λ.

Question 4 Donner, implémenter et tester un algorithme pour simuler $\mathcal{G}(p)$ directement

7.3. Simulation de la loi gaussienne par la méthode de rejet

X est une variable aléatoire de loi gaussienne d'espérance $m = 0$ et de variance $\sigma^2 = 1$, $\mathcal{N}(0, 1)$. Sa densité est

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}x^2\right), \ x \in \mathbb{R}$$

Question 1 Montrer que $f(x) \leq C \exp(-|x|)$ où $C = \sqrt{\frac{e}{2\pi}}$

Question 2 On considère $g(x) = \frac{1}{2} \exp(-|x|), \ x \in \mathbb{R}$. Montrer que g est une densité de probabilité.

Question 3 Proposer un algorithme pour simuler selon g.

Question 4 Implémenter l'algorithme de rejet pour simuler selon f.

7.4. Simulation selon la loi de Wigner

La loi de Wigner (ou du demi-cercle) est la loi de support $[-2, 2]$ et de densité $f(x) = \frac{1}{2\pi}\sqrt{4 - x^2}$. Simuler un grand nombre de variables aléatoires de loi de Wigner, représenter l'histogramme associé et le comparer à la densité.

7.5. Loi des grands nombres et théorème central limite

Question 1 Afin d'illustrer la Loi des Grands Nombres, visualiser la suite $S_n = \frac{X_1 + \ldots + X_n}{n}$ pour $(X_i)_{i \in \mathbb{N}^*}$ une suite de variables aléatoires indépendantes de loi uniforme sur [-1, 1].

Indication : pour $x = [x_1, \ldots, x_n]$ vecteur, `np.cumsum(x)` est le vecteur $[x_1, x_1 + x_2, x_1 + x_2 + x_3, \ldots, x_1 + \ldots + x_n]$ des sommes cumulées des coordonnées de x.

Question 2 Faire de même avec des variables aléatoires Y_i de loi de Cauchy (c'est-à-dire de densité $\frac{1}{\pi(1+x^2)}$). La suite $\frac{Y_1 + \ldots + Y_n}{n}$ semble-t-elle converger ? Pourquoi ?

Question 3 Calculer la moyenne μ et l'écart-type σ des X_i et vérifier, afin d'illustrer le Théorème Central Limite, que $\sqrt{n}(S_n - \mu)/\sigma$ converge en loi, lorsque $n \to \infty$, vers une variable de loi $\mathcal{N}(0, 1)$: on se fixera une grande valeur de n, on simulera un grand nombre de fois $\sqrt{n}(S_n - \mu)/\sigma$, on en tracera l'histogramme et on le comparera à la densité $(2\pi)^-1/2e^{-x^2}$ la loi $\mathcal{N}(0, 1)$.

7.6. Simulation d'un mélange de gaussiennes

On souhaite simuler selon la loi de mélange introduite dans l'exercice Mélange de loi du chapitre 3.

Question 1 Soit K une v.a.r. de loi :

$$\mathbb{P}(K = x) = \begin{cases} 1/2 & \text{si } x = 1 \\ 1/4 & \text{si } x = 2 \\ 1/4 & \text{si } x = 3 \\ 0 & \text{sinon} \end{cases}$$

Implémenter la méthode d'inversion pour simuler K

Question 2 Soit X_1, X_2 et X_3 des variables aléatoires de lois respectives $\mathcal{N}(0,1)$, $\mathcal{N}(5,1/2)$ et $\mathcal{N}(8,4)$. Implémenter un algorithme de simulation de X_K. Comparer l'histogramme obtenu pour un échantillon de taille 1000 avec la densité de X_K.

7.7. Echantillonnage d'importance

On cherche à évaluer l'espérance d'une variable aléatoire X gaussienne centrée réduite (de densité f_X et de f.d.r. F_X) sachant qu'elle dépasse la valeur 3.

Question 1 Exprimer la densité conditionnelle de $X|X > 3$.

Question 2 Calculer la quantité souhaitée à partir d'un échantillon de taille 1000 généré selon F_X. Quelle est la valeur du taux de rejet ?

Question 3 Implémenter l'algorithme d'échantillonnage d'importance en prenant comme loi instrumentale la loi gaussienne d'espérance 3 et de variance 1. Quelle est la proportion de poids nuls ?

---

8. Annexe

8.1. Preuve de la méthode d'inversion

Pour pouvoir démontrer le théorème de la méthode d'inversion (p. 115), il faut d'abord établir un certain nombre de propriétés de la réciproque généralisée d'une fonction de répartition. Elle peuvent être visualisées sur la figure ci-dessous.

Proposition.

Soit F une fonction de répartition. Alors sa réciproque généralisée F^- satisfait les propriétés suivantes.

1. *F^- est croissante.*
2. *$\forall\, x \in \mathbb{R}$: $F^- \circ F(x) \leq x$.*
3. *$\forall\, u \in]0,1[$: $F \circ F^-(u) \geq u$ avec égalité si $u \in F(\mathbb{R})$.*

4. $\forall (u,x) \in]0,1[\times \mathbb{R}$ *:* $\{F(x) \geq u\} \Leftrightarrow \{x \geq F^-(u)\}$ *et* $\{F(x) < u\} \Rightarrow \{x \leq F^-(u)\}$.

Démonstration. Pour tout $u \in]0,1[$ on note $F^{-1}([u,1]) := \{x \in \mathbb{R} : F(x) \geq u\}$ l'image réciproque de $[u,1]$ par F.

1. Soit $(u,v) \in]0,1[^2$. Si $u < v$ alors $F^{-1}([v,1]) \subset F^{-1}([u,1])$ d'où $F^-(u) = \inf F^{-1}([u,1]) \leq \inf F^{-1}([v,1]) = F^-(v)$. La fonction F^- est donc bien croissante.
2. Soit $x \in \mathbb{R}$, alors $F^- \circ F(x) = \inf\{z \in \mathbb{R} : F(z) \geq F(x)\} = \inf F^{-1}([F(x),1])$. Comme F est croissante sur $\mathbb{R}$ on a $[x,+\infty[\subseteq F^{-1}([F(x),1])$ donc $F^- \circ F(x) = \inf F^{-1}([F(x),1]) \leq \inf[x,+\infty[= x$.
3. Soit $u \in]0,1[$.

- Puisque $F^{-1}([u,1])$ est nécessairement non vide, il existe une suite décroissante $(x_n)_{n\in\mathbb{N}} \subseteq F^{-1}([u,1])$ convergeant vers $\inf F^{-1}([u,1]) = F^-(u)$. La croissance de F implique que la suite $\left(F(x_n)\right)_{n\in\mathbb{N}}$ est elle aussi décroissante, minorée par u car $(x_n)_{n\in\mathbb{N}} \subseteq F^{-1}([u,1])$ donc convergente. Sa limite est de même supérieure ou égale à u. Comme F est continue à droite, cette dernière n'est autre que

$$\lim_{n\to+\infty} F(x_n) = F\left(\lim_{n\to+\infty} x_n\right) = F \circ F^-(u).$$

  Nous avons donc bien $F \circ F^-(u) \geq u$.
- Supposons maintenant que $u \in F(\mathbb{R})$. Alors $F^{-1}(\{u\}) := \{x \in \mathbb{R} : F(x) = u\} \neq \varnothing$. Il existe donc une suite décroissante $(x_n)_{n\in\mathbb{N}} \subseteq F^{-1}(\{u\})$ convergeant vers $\inf F^{-1}(\{u\}) = F^-(u)$ par croissance de F. Comme F est continue à droite en tout point de $\mathbb{R}$ et $F(x_n) = u$ pour tout $n \in \mathbb{N}$, on a bien

$$u = \lim_{n\to+\infty} F(x_n) = F\left(\lim_{n\to+\infty} x_n\right) = F \circ F^-(u).$$

4. Soit $(u,x) \in]0,1[\times \mathbb{R}$.

- **Equivalence.** Supposons $F(x) \geq u$. On a $F^- \circ F(x) \geq F^-(u)$ par croissance de F^- (propriété 1.) et $F^- \circ F(x) \leq x$ d'après la propriété 2. Réciproquement, supposons que $x \geq F^-(u)$. Alors par croissance de F on a $F(x) \geq F \circ F^-(u)$ puis $F \circ F^-(u) \geq u$ d'après la propriété 3.
- **Implication.** Supposons $F(x) < u$. Tout $z \in F^{-1}([u,1])$ vérifie $F(z) \geq u > F(x)$. Comme F est croissante sur $\mathbb{R}$ on a donc $z \geq x$, ce qui implique $x \leq \inf F^{-1}([u,1]) = F^-(y)$.

■

Nous pouvons maintenant établir la preuve du théorème de la méthode d'inversion (p. 115).

Démonstration. Soient $x \in \mathbb{R}$ et $(\Omega, \mathcal{A}, \mathbb{P})$ l'espace probabilisé sur lequel sont définies U et X. D'après la propriété 4 ci-dessus, on a $\left\{\omega \in \Omega : F_X^-(U(\omega)) \leq x\right\} = \{\omega \in \Omega : U(\omega) \leq F(x)\}$, d'où

$$\mathbb{P}\left(F_X^-(U) \leq x\right) = \mathbb{P}\left(U \leq F_X(x)\right) = F_X(x).$$

■

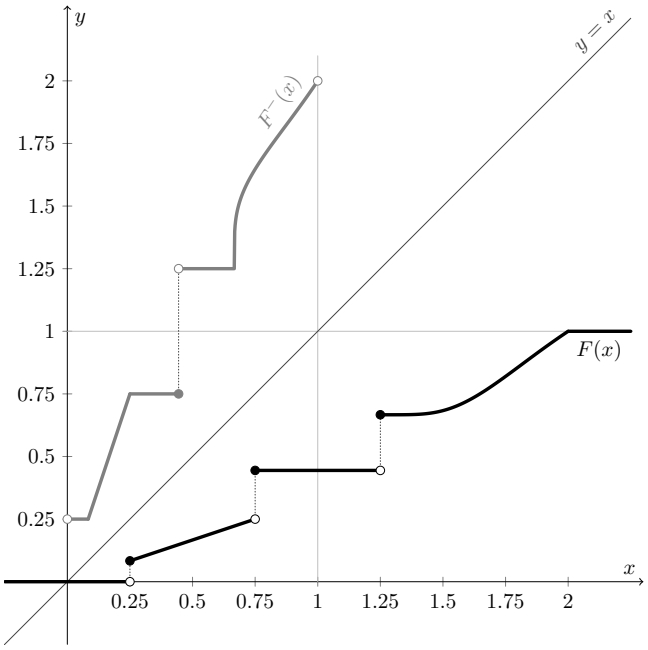


FIGURE 8.1. – Réciproque généralisée d'une fonction de répartition

9. Références

C. P. Robert, and G. Casella. 2004. *Monte-Carlo Statistical Methods*. 2nd edition, Berlin: Springer.

G.E.P. Box, and M.E. Muller. 1958. "A Note on the Generation of Random Normal Deviates." *Ann. Math. Stat.* 29: 610–11.

Lehmer, Derrick H. 1951. "Mathematical Methods in Large-Scale Computing Units." *Annu. Comput. Lab. Harvard Univ.* 26: 141–46.

Ripley, Brian D. 1987. *Stochastic Simulation*. New York: Wiley.

Von Neumann, John. 1951. "Various Techniques Used in Connection with Random Digits." *U.S. Nat. Bur. Stand. Math. Ser.* 12: 36–38.